BÁO CÁO KẾT THÚC HỌC PHẦN

Khám phá chủ đề và tìm kiếm tài liệu nghiên cứu về pin sodium-ion

LDA, BERTopic, BGE, BatteryBERT

và hệ thống tìm kiếm kết hợp

Trường / Khoa: .....

Học phần: .....

Sinh viên / Nhóm: .....

Mã sinh viên / Lớp: .....

Giảng viên: .....

Sodium-ion Research Explorer

Bản tổng hợp kết quả đến ngày 26 tháng 10 năm 2026

Tóm tắt

Báo cáo trình bày việc xây dựng hệ thống khám phá chủ đề và tìm kiếm trên 13.702 tài liệu, gồm 5.933 bằng sáng chế (Patent) và 7.769 công bố khoa học (Publication). Nguồn dữ liệu là Title–Abstract sẵn có. Nhánh chủ đề sử dụng LDA, BERTopic với BGE hoặc BatteryBERT và các catalog KMeans 10 cụm. Nhánh truy hồi so sánh TF-IDF, tìm kiếm ngữ nghĩa và tìm kiếm kết hợp; cấu hình hiện hành hợp nhất TF-IDF với BatteryBERT full-document bằng Reciprocal Rank Fusion (RRF).

Phần thực nghiệm mô tả tiền xử lý, chia dữ liệu, cấu hình huấn luyện, hàm mất mát, kiểm chứng độ bao phủ, lựa chọn checkpoint, đánh giá topic và đánh giá search. Huấn luyện continuation BatteryBERT cập nhật block cuối trên 10.921 tài liệu, bao phủ 26.147 chunks và 3.420.215 token Abstract duy nhất. Trên cùng giao thức Title–document proxy, validation Group MRR@10 tăng từ 0,906174 lên 0,933093; test từ 0,887839 lên 0,924704. Đây là proxy có Title context, không phải accuracy của tìm kiếm thực tế.

Đánh giá search ngày 26/10 sử dụng 703 cặp query–document có nhãn AI Silver 0–2 trên 20 truy vấn và sáu phương pháp. Full-document hybrid đạt P@10 = 0,5400, nDCG@10 = 0,7693 và MRR@10 = 0,7767, cao nhất về trung bình trong lần chấm này. Các chênh lệch với những phương pháp gần nhất còn bất định; chưa có nhãn chuyên gia độc lập. Báo cáo đưa đầy đủ 10 topic và 10 từ khóa của bảy catalog, hình huấn luyện, kết quả phân cụm, hình search, phân tích lỗi và phụ lục hình kết quả theo từng giai đoạn.

Bản bổ sung ngày 30/10 triển khai Search Radar Pilot, fusion TF-IDF–BGE–BatteryBERT, query understanding và các ablation chunk/evidence riêng. Candidate Recall@100 trong pool tăng từ 0,9253 lên 1,0000 trên 19 query có grade 2. Trên giao 14/20 query có đủ nhãn AI cho A0 và A3, P@10 tăng từ 0,5429 lên 0,6071; đây là chẩn đoán lịch sử có thể thiên lệch độ phủ. Chưa có nhãn development/held-out độc lập nên chưa chọn A7 hoặc đổi Search mặc định.

Mục lục

Tóm tắt **i**

Ký hiệu và chữ viết tắt **xii**

1 Giới thiệu bài toán **1**

1.1 Bối cảnh và động cơ 1

1.2 Phát biểu bài toán và đầu ra 1

1.3 Mục tiêu và câu hỏi nghiên cứu 1

1.4 Phạm vi dữ liệu và hạn chế ban đầu 2

2 Cơ sở lý thuyết các mô hình và công thức **3**

2.1 Biểu diễn và tiền xử lý văn bản 3

2.2 Latent Dirichlet Allocation 3

2.3 BERT, BGE và BERTopic 4

2.4 KMeans và hiệu chỉnh hướng nguồn 6

2.5 Từ khóa source-corrected 6

2.6 Phương pháp đánh giá 7

3 Dữ liệu, pipeline và triển khai **8**

3.1 Luồng xử lý tổng thể 8

3.2 Các góc nhìn văn bản 8

3.3 Chia dữ liệu và chống rò rỉ 9

3.4 Các mô hình và phiên bản thực sự được dùng 9

3.5 Cấu trúc mã và tái lập 9

4 Huấn luyện mô hình và kết quả train **12**

4.1 Huấn luyện LDA và BERTopic 12

4.2 BGE và BatteryBERT trước continuation 13

4.3 Continuation full-document 15

4.4 Gradient caching và quy trình tối ưu 15

4.5 Kết quả huấn luyện và đối chứng cùng protocol 16

4.6 Clustering sau encoder và các thử nghiệm không đạt 18

5 Thiết kế và vận hành search engine 20

5.1 Mục tiêu thiết kế và hợp đồng đầu vào 20
5.2 Lập chỉ mục offline 20
5.3 Lọc trước truy hồi 21
5.4 Sinh ứng viên và hợp nhất thứ hạng 22
5.5 Các bước thực thi một truy vấn 22
5.6 So sánh sáu phương pháp search 23
5.7 Reranker: cách hoạt động và lý do không triển khai 23
5.8 Các hệ tìm kiếm lịch sử 24
5.9 Ví dụ output thực tế và hình kết quả 24
5.10 Độ trễ, bộ nhớ và giới hạn vận hành 27
5.11 Phân tích tình huống lỗi và hướng sửa có kiểm chứng 27

6 Giao thức đánh giá và so sánh kết quả 29

6.1 Tách ba lớp đánh giá 29
6.2 Các chỉ số topic 29
6.3 Protocol relevance703 Silver Labels 31
6.4 Công thức P@10, MRR@10 và nDCG@10 31
6.5 Kết quả trung bình của sáu phương pháp 32
6.6 Chi tiết từng truy vấn và ví dụ tính từ output 34
6.7 Bất định, độ nhạy và kiểm chứng số học 35
6.8 Tổng hợp lỗi và giới hạn kết luận 36

7 Mười topic của từng mô hình và phân tích 37

7.1 Cách đọc catalog 37
7.2 BatteryBERT full-document · trained 38
7.3 BatteryBERT fine-tuned · optimized 42
7.4 BatteryBERT KMeans (pretrained) 46
7.5 LDA 50
7.6 BERTopic–BGE 54
7.7 BERTopic–BatteryBERT (pretrained) 58

7.8 BatteryBERT full-document · stable topics 62
7.9 Nhận xét đối chiếu giữa các mô hình 66

8 Thực nghiệm nâng cấp Search và Search Radar Pilot 67
8.1 Phạm vi cập nhật ngày 30/10/2026 67
8.2 Truy hồi ba nhánh và phân tích truy vấn 67
8.3 Độ phủ ứng viên và phần chưa có nhãn 68
8.4 Kết quả A0–A3 trên tập giao lịch sử 68
8.5 Chunk retrieval và chi phí vận hành 71
8.6 Pilot độc lập, kiểm thử và quyết định gate 71

9 Kết luận và hướng phát triển 73
9.1 Những kết quả đã đạt được 73
9.2 Kết quả bổ sung Search Radar Pilot ngày 30/10 73
9.3 Hạn chế 74
9.4 Hướng phát triển 74

Tài liệu tham khảo 75

A Toàn bộ hình kết quả bổ sung theo giai đoạn 77

B Danh sách truy vấn đánh giá và nguồn bằng chứng 110
B.1 Nguồn và cách tái lập báo cáo 111

Danh sách hình vẽ

1.1 Thành phần dữ liệu ở giai đoạn chuẩn bị; đọc cùng bảng corpus đã sàng lọc. 2

3.1 Pipeline từ dữ liệu đến topic và search; topic và xếp hạng là hai nhánh riêng. 8

3.2 Kết quả làm sạch và sàng lọc dữ liệu. 10

3.3 Phân bố độ dài văn bản; số từ khác số WordPiece tokens. 11

4.1 Lưới lựa chọn số topic LDA Stage2; kết quả lịch sử K20. 12

4.2 Loss BatteryBERT128 từ training_history.csv; accumulation không mở rộng tập negatives. 13

4.3 Đường huấn luyện encoder BGE ở Stage3 lịch sử; không phải continuation BatteryBERT. 14

4.4 Đối chứng biểu diễn trước/sau fine-tuning Stage3 lịch sử. 14

4.5 Loss và validation của continuation BatteryBERT full-document; nguồn log train thật. 17

4.6 Đối chứng cùng full-document pooling trước/sau continuation; proxy có Title context. 17

4.7 Ảnh hưởng số khởi tạo KMeans; embeddings được giữ nguyên. 18

4.8 Ảnh hưởng sửa công thức khi so keyword trên cùng canonical reference. 19

4.9 Các recipe lọc keyword bị loại do đánh đổi coherence và coverage. . . 19

5.1 Chi tiết luồng search full-document hybrid theo mã nguồn hiện hành. . 20

5.2 Reranker tăng dev nhưng giảm gate; không được kích hoạt. 24

5.3 Hình Top 10 dựng lại từ output đã lưu của Q01; không phải ảnh chụp phiên giao diện mới. 26

6.1 Phân bố10 topic của sáu catalog lịch sử; chưa bao gồm stable topics mới nhất. 30

6.2 So sánh các catalog theo protocol lịch sử; không xếp hạng chung với canonical reference mới. 30

6.3 P@10, nDCG@10 và MRR@10 trên 703 Silver Labels, cùng20 queries và sáu methods. 32

6.4 Điểm từng query; P@10 và nDCG cần được đọc cùng nhau. 33
6.5 Độ nhạy với ngưỡng relevance; nhãn 1 và nhãn 2 trả lời mục tiêu khác nhau. 33

7.1 Phân bố đầy đủ 10 topic: BatteryBERT full-document · trained 39
7.2 Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT full-document · trained 40
7.3 Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT full-document · trained 41
7.4 Phân bố đầy đủ 10 topic: BatteryBERT fine-tuned · optimized 43
7.5 Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT fine-tuned · optimized 44
7.6 Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT fine-tuned · optimized 45
7.7 Phân bố đầy đủ 10 topic: BatteryBERT KMeans (pretrained) 47
7.8 Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT KMeans (pretrained) 48
7.9 Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT KMeans (pretrained) 49
7.10 Phân bố đầy đủ 10 topic: LDA 51
7.11 Đủ10 từ khóa và trọng số cho topic 0–4: LDA 52
7.12 Đủ10 từ khóa và trọng số cho topic 5–9: LDA 53
7.13 Phân bố đầy đủ 10 topic: BERTopic–BGE 55
7.14 Đủ10 từ khóa và trọng số cho topic 0–4: BERTopic–BGE 56
7.15 Đủ10 từ khóa và trọng số cho topic 5–9: BERTopic–BGE 57
7.16 Phân bố đầy đủ 10 topic: BERTopic–BatteryBERT (pretrained) 59
7.17 Đủ10 từ khóa và trọng số cho topic 0–4: BERTopic–BatteryBERT (pretrained) 60
7.18 Đủ10 từ khóa và trọng số cho topic 5–9: BERTopic–BatteryBERT (pretrained) 61
7.19 Phân bố đầy đủ 10 topic: BatteryBERT full-document · stable topics . . 63
7.20 Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT full-document · stable topics 64

7.21 Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT full-document · stable topics 65

8.1 Radar mới trên giao 14/20 query đủ nhãn của A0 và A3. Thang 100 lần giá trị gốc; tập giao có thể thiên lệch. 69

8.2 P@10, nDCG@10 và MRR@10 trên cùng 14 query lịch sử đủ nhãn, không phải held-out. 69

8.3 Độ phủ ứng viên trong pool AI Silver và số query có Top 10 được chấm đủ. Q08 bị loại khỏi mẫu số candidate recall. 70

8.4 Độ trễ thực nghiệm CPU; đọc phạm vi đo kèm bảng và protocol, không so đơn vị latency với trục chất lượng. 70

A.1 Độ tập trung topic trước/sau optimization BatteryBERT ngày 23/10. . . 78

A.2 Kết quả10 topic tại phiên topic audit ngày 22/10. 78

A.3 Các cấu hình clustering được so tại phiên topic audit ngày 22/10. 79

A.4 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 01. Cả7 trang được giữ đủ. 79

A.5 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 02. Cả7 trang được giữ đủ. 80

A.6 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 03. Cả7 trang được giữ đủ. 80

A.7 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 04. Cả7 trang được giữ đủ. 81

A.8 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 05. Cả7 trang được giữ đủ. 81

A.9 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 06. Cả7 trang được giữ đủ. 82

A.10 BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 07. Cả7 trang được giữ đủ. 82

A.11 Phân bố84 topic BERTopic chunked lịch sử, trước bước gộp K10. . . . 83

A.12 UMAP2D BERTopic chunked lịch sử; clustering dùng không gian khác. 83

A.13 Mức thiếu trường dữ liệu trong giai đoạn chuẩn bị. 84

A.14 Phân bố tài liệu theo năm và nguồn khi chuẩn bị dữ liệu. 84

A.15 Phân bố độ dài Title và Abstract ban đầu. 85

A.16 Kết quả heuristic sàng lọc phạm vi sodium-ion. 85

A.17 Xu hướng tài liệu theo năm của corpus đã chuẩn hóa. 86
A.18 Các term phổ biến trong corpus. 86
A.19 Các n-gram phổ biến; cần đọc cùng quy tắc ranh giới token. 87
A.20 Author keywords xuất hiện trong dữ liệu có sẵn. 87
A.21 Xu hướng các term miền theo năm. 88
A.22 Phân bố topic LDA Stage2 K20 lịch sử. 88
A.23 Topic LDA theo nguồn Patent/Publication, Stage2 lịch sử. 89
A.24 Topic LDA theo năm, Stage2 lịch sử. 89
A.25 Xu hướng các topic LDA lớn, Stage2 lịch sử. 90
A.26 Từ khóa các topic LDA, Stage2 K20 lịch sử. 90
A.27 Phân bố BERTopic Stage3 lịch sử, trước catalog K10. 91
A.28 Từ khóa BERTopic Stage3 lịch sử. 91
A.29 Độ tương tự giữa các topic BERTopic Stage3 lịch sử. 92
A.30 UMAP2D BERTopic Stage3; chỉ là trực quan hóa. 92
A.31 Đối chiếu topic LDA/BERTopic theo protocol Stage3 lịch sử. 93
A.32 Các thành phần độ trễ SE1/SE2/SE3, Stage4 Top 5 lịch sử. 93
A.33 Phân bố độ trễ SE1/SE2/SE3, Stage4 Top 5 lịch sử. 94
A.34 Thành phần nguồn trong kết quả, Stage4 Top 5 lịch sử. 94
A.35 Thay đổi thứ hạng do topic bonus SE2 lịch sử. 95
A.36 Độ giao Top 5 giữa các search engine Stage4 lịch sử. 95
A.37 Ảnh dashboard BERTopic đã lưu ở Stage5 lịch sử. 96
A.38 Ảnh giao diện so sánh mô hình đã lưu ở Stage5 lịch sử. 96
A.39 Ảnh giao diện đánh giá ở Stage5 lịch sử; không phải kết quả703 Silver Labels. 97
A.40 Ảnh giao diện và kết quả search đã lưu ở Stage5 lịch sử. 97
A.41 Form search đã lưu ở Stage5 lịch sử. 98
A.42 Ảnh dashboard LDA đã lưu ở Stage5 lịch sử. 98
A.43 Kết quả kiểm tra search sau khởi động lại ở Stage5 lịch sử. 99
A.44 Form search sau khởi động lại ở Stage5 lịch sử. 99
A.45 Ảnh giao diện các tài liệu đại diện topic, Stage5 lịch sử. 100
A.46 Đủ10 topic BERTopic–BatteryBERT pretrained, ảnh output gốc. 100
A.47 Đủ10 topic BERTopic–BGE, ảnh output gốc. 101

A.48 Đủ10 topic LDA K10, ảnh output gốc. 101
A.49 So sánh ba catalog K10, ảnh output gốc. 102
A.50 Quy mô dữ liệu và split trong báo cáo pipeline25/10. 102
A.51 Lựa chọn K của LDA Stage2, hình tổng hợp25/10. 103
A.52 Đường train BatteryBERT full-document, hình tổng hợp25/10. 103
A.53 Phân bố nguồn của catalog full-document24/10 trước stable revision. . 104
A.54 Từ khóa catalog full-document24/10 trước stable revision. 104
A.55 Đánh đổi giữa các chỉ số topic, hình tổng hợp25/10. 105
A.56 Độ trễ search theo benchmark đã lưu, hình tổng hợp25/10. 105
A.57 Các ứng viên topic validation, hình tổng hợp25/10. 106
A.58 Ảnh giao diện và kết quả search đã lưu ở Stage5 lịch sử. 106
A.59 Đủ10 topic KMeans BatteryBERT pretrained, ảnh output gốc. 107
A.60 Một số topic stable với Top 10 keywords, ảnh revision gốc. 107
A.61 Pilot20 cặp AI lịch sử; đã được mở rộng thành 703 nhãn ở phần chính. 108
A.62 Phân bố nguồn của catalog stable topics mới nhất. 108
A.63 Điểm trên phần AI consensus đủ pool Top 5 lịch sử; không dùng thay Silver703. 109
A.64 Coverage AI consensus Top 5 lịch sử, trước bộ Silver703. 109

Danh sách bảng

1.1 Quy mô dữ liệu đầu vào và corpus chính. 2

3.1 Chia dữ liệu cho encoder và các bước fit train. 9
3.2 Vai trò của từng thành phần trong hệ thống. 10

4.1 Kết quả continuation trên cùng full-document proxy. 16

5.1 Sáu phương pháp trong đánh giá 703 Silver Labels. 23
5.2 Top 10 thực tế của full-document hybrid cho Q01 và nhãn Silver ghép sau retrieval. 25
5.3 Độ trễ requests đã lưu, đơn vị giây;19 warm requests/method, khác phiên chạy. 27

6.1 Đối chứng K10 cùng protocol lịch sử; nhánh fine-tuned BERTopic chưa hoàn thành không có điểm. 29
6.2 So sánh search trên 703 nhãn AI Silver; chưa xác minh bởi con người. . 32
6.3 Full-document hybrid theo từng truy vấn; cùng pool Silver. 34
6.4 Tính DCG từ output Q01, full-document hybrid. 35
6.5 Các lỗi search cần ưu tiên sau phân tích nhãn. 36

7.1 Đủ10 topic và 10 keywords/topic: BatteryBERT full-document · trained 38
7.2 Đủ10 topic và 10 keywords/topic: BatteryBERT fine-tuned · optimized 42
7.3 Đủ10 topic và 10 keywords/topic: BatteryBERT KMeans (pretrained) . 46
7.4 Đủ10 topic và 10 keywords/topic: LDA 50
7.5 Đủ10 topic và 10 keywords/topic: BERTopic–BGE 54
7.6 Đủ10 topic và 10 keywords/topic: BERTopic–BatteryBERT (pretrained) 58
7.7 Đủ10 topic và 10 keywords/topic: BatteryBERT full-document · stable topics 62

8.1 Các cấu hình pilot, không thay Search mặc định. 67
8.2 Ablation trên giao query đủ nhãn với A0, K=100. Các dòng có mẫu số khác nhau; không xếp hạng giữa các dòng. 68

8.3 Độ trễ và RSS trong benchmark CPU, K=100. Phạm vi đo được ghi trong nội dung. 71

B.1 Toàn bộ20 query tiếng Anh đã khóa trước chấm. 110

B.2 Các nguồn bằng chứng chính. 111

Ký hiệu và chữ viết tắt

N, V, K	Số tài liệu, số mục từ và số topic/cụm.
θ_d, ϕ_k	Phân bố topic của tài liệu; phân bố từ của topic LDA.
e_q, e_d	Vector truy vấn và tài liệu chuẩn hóa L2, 768 chiều.
BoW / TF-IDF	Bag-of-Words / Term Frequency–Inverse Document Frequency.
RRF / CE	Reciprocal Rank Fusion / cross-encoder.
qrels / pool	Nhãn relevance / hợp ứng viên từ nhiều phương pháp.
ARI / NPMI	Adjusted Rand Index / Normalized Pointwise Mutual Information.
MRR / nDCG	Mean Reciprocal Rank / normalized Discounted Cumulative Gain.

Chương 1

Giới thiệu bài toán

1.1 Bối cảnh và động cơ

Tập tài liệu nghiên cứu về pin sodium-ion chứa nhiều hướng nghiên cứu như hard carbon, oxide lớp P2/O3, Prussian blue, phosphate NASICON, điện ly và cấu trúc cell. Một người đọc cần vừa nắm được các nhóm nội dung, vừa tìm tài liệu trả lời câu hỏi cụ thể. Công bố khoa học thường mô tả cơ chế và hiệu năng, trong khi bằng sáng chế thường nhấn mạnh thành phần, quy trình và thiết bị. Khác biệt văn phong có thể chi phối phân cụm nếu hệ thống chỉ học nguồn tài liệu thay vì nội dung.

Tìm kiếm từ khóa có thể bỏ sót diễn đạt tương đương; tìm kiếm vector có thể trả đúng họ vật liệu nhưng sai vai trò điện cực hoặc thiếu điều kiện thí nghiệm. Vì vậy hệ thống sử dụng hai nhiệm vụ bổ trợ: mô hình chủ đề để khám phá corpus và truy hồi để xếp hạng theo truy vấn. Topic gần nhau không tự suy ra tài liệu đáp ứng nhu cầu cụ thể.

1.2 Phát biểu bài toán và đầu ra

Cho corpus $\mathcal{D} = \{d_1, \ldots, d_N\}$, mỗi tài liệu chứa ID, Title, Abstract, nguồn, năm và identifier. Bài toán chủ đề tìm cấu trúc $t(d)$ hoặc phân bố θ_d, đồng thời xuất từ khóa, kích thước nhóm, nguồn và đại diện. Bài toán tìm kiếm nhận truy vấn q cùng bộ lọc F và trả:

$$R_{10}(q, F) = \mathrm{Top}_{10}\{s(q, d) : d \in \mathcal{D},\ F(d) = 1\}. \tag{1.1}$$

Kết quả cần có thứ hạng, tiêu đề, nguồn, năm, đoạn trích và ý nghĩa điểm. Điểm cosine, RRF và relevance grade là ba đại lượng khác nhau. Hệ thống phải giữ đúng ID giữa ma trận embedding, index và metadata để kết quả có thể truy vết.

1.3 Mục tiêu và câu hỏi nghiên cứu

Ba câu hỏi chính là: (1) các mô hình tạo topic có diễn giải được và ổn định không; (2) đọc đủ Abstract và continuation training ảnh hưởng thế nào đến biểu diễn; (3) hệ thống kết hợp có đưa tài liệu đáp ứng truy vấn lên đầu không. Mỗi câu hỏi có bộ đo riêng: coherence/stability, paired retrieval proxy và relevance Top 10. Không dùng loss thấp để kết luận search tốt, cũng không dùng coherence cao để kết luận mọi thành viên đúng khoa học.

Đầu ra của học phần gồm pipeline xử lý dữ liệu; các mô hình và checkpoint đã thực

thi; catalog topic; search engine có lọc; benchmark so sánh; báo cáo LaTeX có công thức, bảng, hình và nhận xét. Đóng góp là một hệ thống ứng dụng và thực nghiệm có truy vết, chưa phải đề xuất thuật toán nền tảng mới.

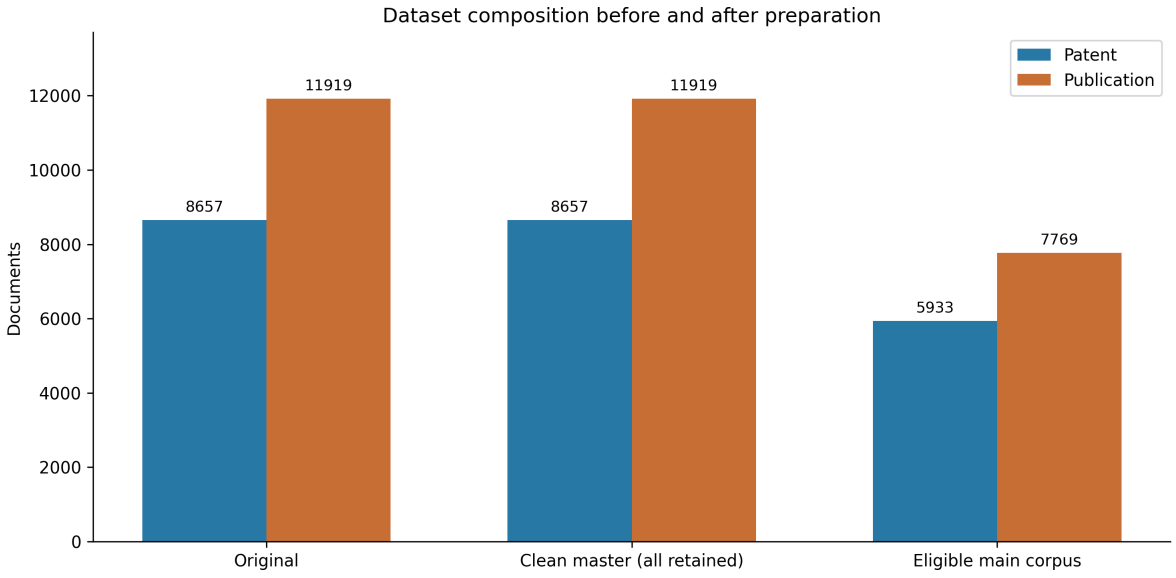
1.4 Phạm vi dữ liệu và hạn chế ban đầu

Dữ liệu đầu vào gồm hai tệp Excel với 20.576 bản ghi. Sau làm sạch và sàng lọc còn 13.702 tài liệu trong corpus chính. Corpus giữ các tài liệu có phạm vi natri rộng, phần cứng và một số nghiên cứu đa hệ pin. Nhãn CORE/RELATED là heuristic sàng lọc, không phải nhãn chuyên gia. Các trường thiếu và vai trò anode/cathode không nhất quán cần được giữ dấu vết thay vì tự sửa sau khi nhìn điểm.

Bảng 1.1: Quy mô dữ liệu đầu vào và corpus chính.

Nguồn	Đầu vào	Corpus chính
Patent	8.657	5.933
Publication	11.919	7.769
Tổng	20.576	13.702

Nguồn: data/processed/main_corpus.parquet;docs/BAO_CAO_PIPELINE_SODIUM_ION_20261025.md.



Hình 1.1: Thành phần dữ liệu ở giai đoạn chuẩn bị; đọc cùng bảng corpus đã sàng lọc. *Nguồn:* outputs/figures/data_preparation/figure_01_dataset_composition.png.

Chương 2

Cơ sở lý thuyết các mô hình và công thức

2.1 Biểu diễn và tiền xử lý văn bản

Một tài liệu được biểu diễn theo nhiều góc nhìn phù hợp với mô hình, thay vì ép mọi phương pháp dùng cùng một chuỗi đã loại bỏ cấu trúc. Văn bản chuẩn hóa giữ Title/Abstract để truy vết; token chủ đề được lemmatize, xử lý stopwords và ghép các cụm miền như hard_carbon. nhánh search lịch sử v2 xây dựng lexical view riêng và có kênh giữ case cho chuỗi giống công thức. Các phép này đều có giới hạn heuristic; không có bộ suy luận tương đương công thức hóa học.

Bag-of-Words mã hóa tài liệu d thành vector đếm:

$$x_{dt} = \sum_{n=1}^{L_d} \mathbf{1}[w_{dn} = t], \qquad x_d \in \mathbb{N}^V. \tag{2.1}$$

Ở đây L_d là số token, t là một mục từ vựng và V là kích thước từ vựng. Biểu diễn này bảo toàn tần suất nhưng bỏ thứ tự. Cụm từ ghép giảm một phần mất mát quan hệ cục bộ, không khôi phục được cấu trúc câu.

WordPiece chia văn bản thành các đơn vị con từ theo từ vựng checkpoint BERT. Một công thức hoặc từ kỹ thuật có thể thành nhiều WordPiece, nên số từ không đồng nhất với số token. Chuẩn hóa Unicode và tokenizer có thể làm hai cách viết khác nhau nhận cùng ID; thí nghiệm case trong artifacts chỉ minh họa giới hạn đầu vào, chưa chứng minh mọi trường hợp gây lỗi retrieval. Giới hạn 128 và 256 trong dự án là giới hạn cấu hình thực nghiệm, không phải khẳng định kiến trúc BGE chỉ hỗ trợ từng đó token.

2.2 Latent Dirichlet Allocation

LDA giả định mỗi tài liệu là hỗn hợp chủ đề và mỗi chủ đề là một phân bố trên từ vựng [1]. Với K chủ đề, đặt $\theta_d \in \Delta^{K-1}$ và $\phi_k \in \Delta^{V-1}$, trong đó Δ là simplex xác suất. Dạng Bayesian thông dụng viết:

$$\theta_d \sim \text{Dirichlet}(\alpha), \qquad \phi_k \sim \text{Dirichlet}(\eta), \tag{2.2}$$

$$z_{dn} \sim \text{Categorical}(\theta_d), \qquad w_{dn} \sim \text{Categorical}(\phi_{z_{dn}}). \tag{2.3}$$

z_{dn} là chủ đề ẩn của token thứ n; α, η là tham số prior, không phải relevance labels. Trong code Gensim, α được đặt asymmetric và η symmetric. Xác suất một từ trong tài

liệu là:

$$P(w = t \mid d) = \sum_{k=1}^{K} \theta_{dk}\phi_{kt}. \tag{2.4}$$

Do đó một bài về điện giải và giao diện có thể có khối lượng ở nhiều chủ đề thay vì chỉ một nhãn. Gán topic trội bằng $\arg\max_k \theta_{dk}$ phục vụ thống kê, nhưng làm mất thông tin hỗn hợp.

Hậu nghiệm chính xác khó tính. Suy luận biến phân dùng một họ phân bố q để tối ưu cận dưới:

$$\mathcal{L}(q) = \mathbb{E}_q[\log p(w, z, \theta, \phi)] - \mathbb{E}_q[\log q(z, \theta, \phi)]. \tag{2.5}$$

Các biến ẩn được xấp xỉ qua cập nhật lặp; implementation dùng gensim.models.LdaModel, không triển khai Gibbs sampling riêng. Cấu hình K được khảo sát trước, rồi lựa chọn bằng coherence và các tiêu chí bổ sung. Trong SE1 lịch sử, vector θ_q của query được so với θ_d bằng cosine; search hiện hành không dùng phép này. LDA dễ diễn giải theo từ nhưng yếu ở phủ định, trật tự và công thức hiếm.

2.3 BERT, BGE và BERTopic

2.3.1 Biểu diễn ngữ cảnh và fine-tuning đối chứng

BERT dùng các lớp Transformer để tạo biểu diễn ngữ cảnh hai chiều [2]. Với ma trận đầu vào X, một attention head sử dụng $Q = XW_Q$, $K = XW_K$, $V = XW_V$:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V. \tag{2.6}$$

d_k là kích thước key; softmax theo các vị trí cho phép mỗi token tổng hợp thông tin từ các token khác. Công thức mô tả một head, không phải toàn bộ mô hình; encoder còn multi-head, residual, normalization và feed-forward.

BGE-base-en-v1.5 là checkpoint embedding được dự án tải và pin provenance, không phải BERT huấn luyện từ đầu [3]. Với $h_{\text{CLS}}(x) \in \mathbb{R}^{768}$:

$$e(x) = \frac{h_{\text{CLS}}(x)}{\|h_{\text{CLS}}(x)\|_2}, \qquad s(q, d) = e(q)^\top e(d). \tag{2.7}$$

Do hai vector có norm bằng 1, dot product bằng cosine và nằm trong $[-1, 1]$, sai số số học ngoại trừ. Điểm không phải xác suất relevance. Query được thêm instruction của BGE; document không thêm instruction query.

2.3.2 BatteryBERT và lựa chọn pooling

BatteryBERT là encoder BERT tiếp tục pretraining trên tài liệu pin bằng MLM; checkpoint cased phân biệt chữ hoa/chữ thường [4]. Dự án không pretrain lại từ đầu. Khác BGE dùng CLS, BatteryBERT sử dụng trung bình hidden states của các token được mask cho phép rồi chuẩn hóa L2:

$$h(x) = \frac{\sum_{i=1}^{L} m_i H_i}{\sum_{i=1}^{L} m_i}, \qquad e(x) = h(x)/\|h(x)\|_2. \tag{2.8}$$

m_i chỉ chọn token nội dung theo từng phiên bản. Bản pretrained lịch sử dùng attention-mask mean; bản continuation full-document loại Title/SEP khỏi pooling nội dung Abstract. Title vẫn làm ngữ cảnh attention. Việc checkpoint chuyên miền dùng MLM không đồng nghĩa cosine mặc nhiên là relevance tốt; cần contrastive adaptation và đối chứng.

2.3.3 Giảm chiều, phân cụm và từ khóa

BERTopic dùng embeddings để tìm cụm, rồi c-TF-IDF để mô tả cụm [5]. UMAP tạo đồ thị lân cận và tìm biểu diễn chiều thấp giữ quan hệ kết nối [6]. Dạng cross-entropy giữa fuzzy memberships p_{ij} ở không gian gốc và q_{ij} ở chiều thấp có phần phụ thuộc nghiệm:

$$L_{\text{UMAP}} = -\sum_{i<j} \left[p_{ij} \log q_{ij} + (1 - p_{ij}) \log(1 - q_{ij}) \right]. \tag{2.9}$$

Công thức bỏ các hạng chỉ phụ thuộc p; implementation tối ưu bằng lấy mẫu và không tính tổng đầy đủ một cách ngây thơ. Trong dự án, cosine dùng xây lân cận từ embeddings; output 5 chiều dùng clustering. UMAP 2D minh họa được tính riêng, không dùng làm bằng chứng chất lượng cụm.

HDBSCAN khảo sát cấu trúc mật độ theo nhiều mức [7]. Mutual-reachability distance có dạng:

$$d_{\text{mr}}(a, b) = \max\{core_k(a), core_k(b), d(a, b)\}. \tag{2.10}$$

$core_k(a)$ phản ánh khoảng cách lân cận để đạt mật độ tại a; d là Euclidean ở không gian UMAP. Cây phân cấp mật độ được cô đọng, rồi EOM chọn các cụm bền vững. Tham số 30 là kích thước cụm tối thiểu, không phải số chủ đề; min_samples=10 điều chỉnh tính bảo thủ mật độ. Nhãn -1 là noise. Membership strength không phải phân bố xác suất chủ đề như θ_d của LDA.

Gộp các tài liệu mỗi cụm thành một class document; đặt n_{ct} là tần suất từ t trong cụm c, $L_c = \sum_t n_{ct}$, $f_t = \sum_c n_{ct}$ và A là độ dài class trung bình (implementation chuyển

sang số nguyên). Với reduce_frequent_words=True, trọng số là:

$$w_{ct} = \sqrt{\frac{n_{ct}}{L_c}} \log\left(1 + \frac{A}{f_t}\right). \tag{2.11}$$

Đây là biến thể căn bậc hai của TF sau L1 normalization theo implementation c-TF-IDF [8]. Nó giảm ưu thế tương đối của từ rất thường gặp. Từ khóa giải thích cụm đã hình thành, không quyết định lại embeddings; từ khóa có thể phản ánh lỗi kế thừa từ token Stage 1.

2.4 KMeans và hiệu chỉnh hướng nguồn

KMeans nhận các vector train đã biến đổi, tối thiểu hóa tổng bình phương khoảng cách:

$$\min_{\mu_1,\ldots,\mu_K,z} \sum_{d\in\mathcal{D}_{train}} \|\widetilde{e}_d - \mu_{z_d}\|_2^2, \qquad K = 10. \tag{2.12}$$

Sau fit, validation/test được predict bằng centroid đã học. KMeans không có reject/outlier. n_init là số khởi tạo để chọn nghiệm objective tốt nhất trong một lần fit, khác số epoch train encoder.

Source projection dùng hướng $u = \text{norm}_2(\overline{e}_P - \overline{e}_U)$ từ trung bình Patent/Publication trên train. Sau centering theo train, một dạng biểu diễn là:

$$\widetilde{e}_d = \text{norm}_2\left[(I - uu^\top)(e_d - \overline{e}_{train})\right]. \tag{2.13}$$

Mục đích là giảm một hướng phân biệt nguồn, nhưng có thể loại cả tín hiệu nội dung thật. Vì vậy so cả coherence, nguồn, độ tập trung cụm và stability; không mặc định source independence hoàn toàn là tốt nhất.

2.5 Từ khóa source-corrected

Nhánh KMeans dùng vocabulary unigram/bigram fit train, min_df5, max_df0,6, tối đa40.000 features. Điểm từ khóa tỷ lệ với TF tương đối, IDF và exclusivity lũy thừa0,25:

$$w_{kt} = \frac{n_{kt}}{\sum_v n_{kv}} \log\left(1 + \frac{N_{train}}{\max(df_t, 1)}\right) \left(\frac{df_{kt} + 1}{df_t + K}\right)^{0,25}. \tag{2.14}$$

Ở đây n_{kt} là tổng tần suất, df_{kt} là số tài liệu train của topic chứa từ và df_t là document frequency trên toàn train. Recipe giữ frequency power1 và phrase boost1; từ phải có ít nhất5 tài liệu train trong topic hỗ trợ. Đây là weighting khác c-TF-IDF BERTopic; điểm không phải xác suất đúng khoa học. Audit lưu bằng chứng support và ngữ cảnh, đặc biệt với công thức và bigram cần liền kề trong stream.

2.6 Phương pháp đánh giá

2.6.1 Topic coherence, diversity, outliers và stability

U_Mass đo đồng xuất hiện của các từ Top-n trên văn bản tham chiếu:

$$C_{UMass} = \frac{1}{|\mathcal{P}|} \sum_{(i,j)\in\mathcal{P}} \log \frac{D(w_i, w_j) + \epsilon}{D(w_j)}. \tag{2.15}$$

$D(w)$ là số tài liệu chứa từ, $\mathcal{P}$ gồm các cặp theo thứ tự keywords. Gensim có quy ước smoothing và aggregation cụ thể; báo cáo lấy số xuất từ thư viện thay vì tái gán thang điểm. Điểm thường âm, lớn hơn là tốt hơn theo tiêu chí này, không phải phần trăm và không có ngưỡng đạt phổ quát.

C_v kết hợp sliding-window co-occurrence, NPMI và indirect cosine confirmation [9]. Hạt nhân NPMI là:

$$NPMI(w_i, w_j) = \frac{\log \frac{P(w_i,w_j)}{P(w_i)P(w_j)}}{-\log P(w_i, w_j)}. \tag{2.16}$$

P được ước lượng trên cửa sổ Boolean; NPMI lý tưởng thuộc $[-1, 1]$, với smoothing xử lý zero. Để làm rõ C_v không phải trung bình NPMI đơn thuần, đặt vector ngữ cảnh $v(S)_j = \sum_{w_i\in S} NPMI(w_i, w_j)$ với exponent $\gamma = 1$ của cấu hình chuẩn. Confirmation giữa singleton $\{w_i\}$ và tập keywords W là:

$$\widetilde{m}(\{w_i\}, W) = \frac{v(\{w_i\})^\top v(W)}{\|v(\{w_i\})\|_2 \|v(W)\|_2}; \quad C_v = \text{mean}\, \widetilde{m}. \tag{2.17}$$

Gensim tổng hợp segmentation/topics với window 110 và Top 10. Điểm cosine ở công thức (2.17) không phải xác suất; reference và smoothing phải giữ cố định khi so sánh.

Topic diversity và outlier rate được định nghĩa:

$$D = \frac{|\bigcup_{k=1}^{K} Top_n(k)|}{Kn}, \qquad O = \frac{\sum_d \mathbf{1}[t(d) = -1]}{N}. \tag{2.18}$$

Cả hai thuộc $[0, 1]$. Diversity cao biểu thị ít trùng keywords, chưa chứng minh topic đúng; outlier rate không phải tỷ lệ tài liệu không liên quan. LDA không có cơ chế reject nên outlier 0 là tính chất mô hình, không phải ưu thế tự động.

Stability LDA ghép Top 10 sets giữa hai seed bằng Hungarian:

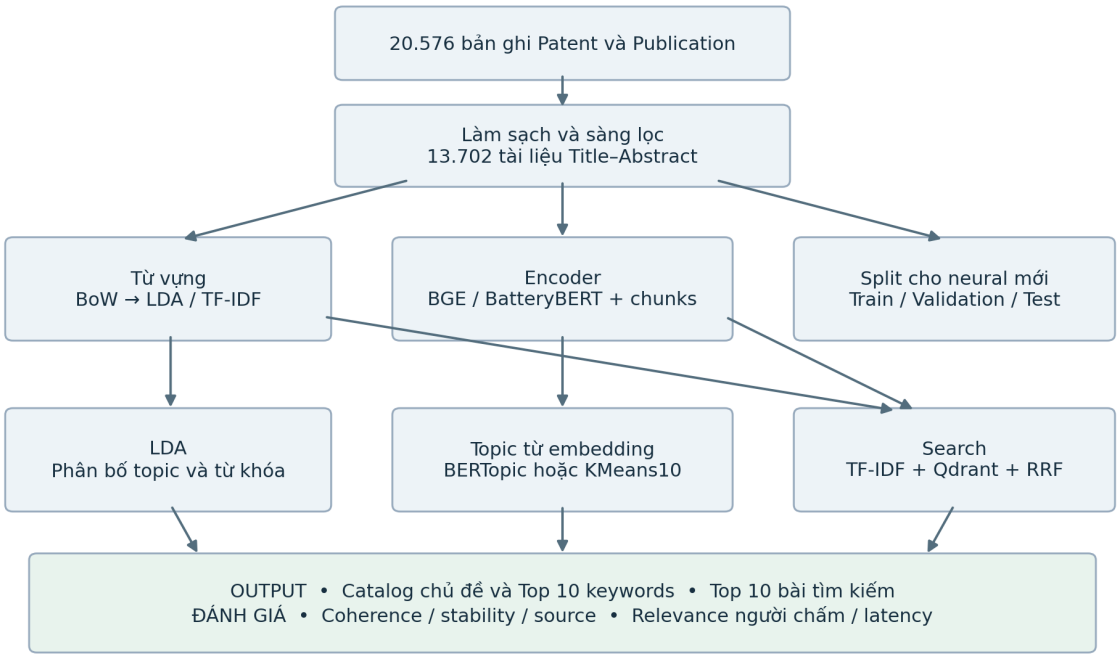
$$S(a, b) = \max_{\pi} \frac{1}{K} \sum_{k=1}^{K} \frac{|T_k^{(a)} \cap T_{\pi(k)}^{(b)}|}{|T_k^{(a)} \cup T_{\pi(k)}^{(b)}|}. \tag{2.19}$$

π là hoán vị tối ưu. Stability LDA và BERTopic dùng protocol khác nhau; ARI/NMI giữa hai phiên bản biểu diễn không thay stability nhiều seed.

Chương 3

Dữ liệu, pipeline và triển khai

3.1 Luồng xử lý tổng thể



Hình 3.1: Pipeline từ dữ liệu đến topic và search; topic và xếp hạng là hai nhánh riêng. *Nguồn:* outputs/report_pipeline_20261025/figures/01_pipeline.png.

Từ Excel, pipeline đọc và chuẩn hóa schema, loại bản ghi không sử dụng được, phát hiện trùng, chuẩn hóa văn bản, xác định phạm vi và tạo corpus có ID ổn định. Nhánh topic tạo BoW hoặc embedding; nhánh search xây TF-IDF và index vector. Dữ liệu và checkpoints hợp lệ được giữ nguyên khi tiếp tục phiên nghiên cứu. Nhánh topic và search có quyết định triển khai riêng.

3.2 Các góc nhìn văn bản

Văn bản gốc Title–Abstract được giữ để hiển thị và kiểm chứng. Token chủ đề có xử lý từ dừng, lemma và cụm miền. Lexical retrieval sử dụng tokenizer bảo toàn các mẫu công thức; neural encoder dùng WordPiece của checkpoint tương ứng. Không dùng một chuỗi đã loại stopwords làm đầu vào chung cho mọi mô hình vì có thể mất quan hệ và cú pháp.

Parser scientific stream v2 giữ ranh giới Title/Abstract, dấu câu và raw span. Ví dụ Na3V2(PO4)(3) được chuẩn hóa có điều kiện thành Na3V2(PO4)3, trong khi TiO2(101) không bị nối thành TiO2101. Các mẫu chưa hỗ trợ được giữ nguyên. Có 27.404 trường được xử lý qua 54 shard; 41.002 span giống công thức, 2.340 phép chuẩn hóa thận trọng và 15.702 span chưa hỗ trợ. Đây là kiểm chứng cú pháp, không phải bộ xác minh hợp chất hóa học.

3.3 Chia dữ liệu và chống rò rỉ

Bảng 3.1: Chia dữ liệu cho encoder và các bước fit train.

Tập	Tài liệu	Vai trò
Train	10.921	Gradient optimizer; fit vocabulary, geometry và KMeans.
Validation	1.361	Chọn learning rate, checkpoint và cấu hình phát triển.
Test	1.368	Đo sau lựa chọn; đây là test lịch sử.
Title only	52	Chỉ inference; không dùng optimizer.

Nguồn: data/stage3/split_assignments.parquet.

Các cặp có quan hệ nhóm được theo dõi bằng split_group_id. Trong contrastive batch, các cặp cùng nhóm hoặc có Title Jaccard từ 0,8 được mask để giảm false negative. Không đưa validation/test vào optimizer. Tuy nhiên, việc đã dùng split này trong nhiều vòng nghiên cứu giới hạn cách gọi nó là đánh giá độc lập; cần tập ngoài mới để đo khái quát.

3.4 Các mô hình và phiên bản thực sự được dùng

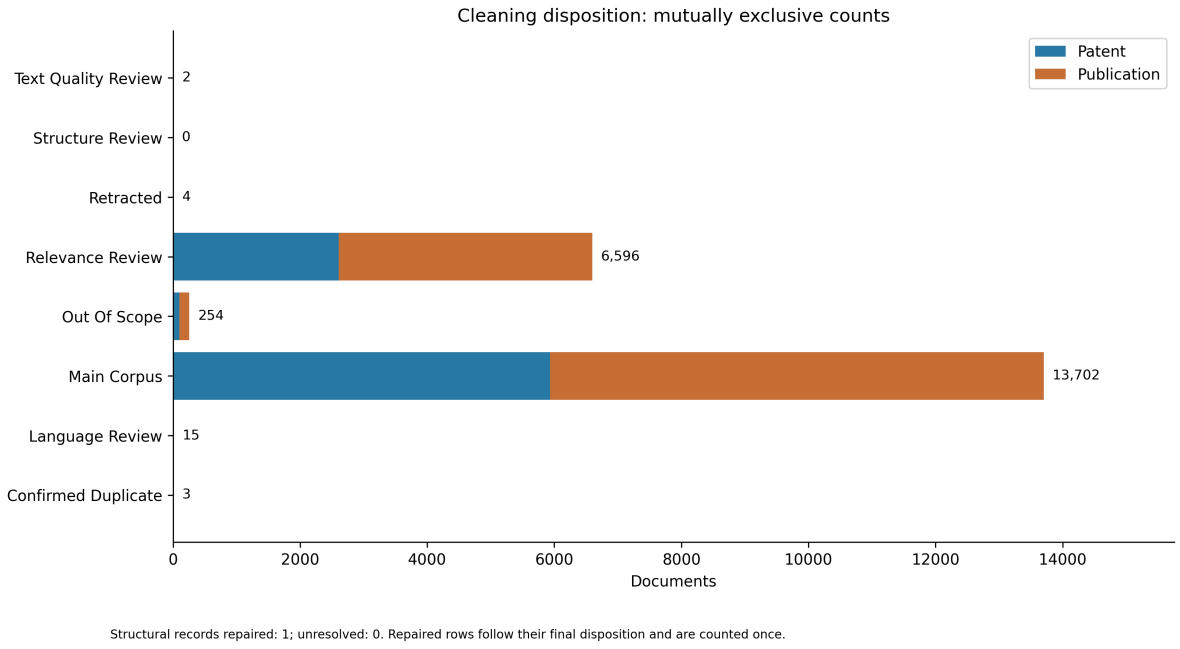
3.5 Cấu trúc mã và tái lập

src/pipeline.py xử lý corpus; src/stage2.py và src/stage3_bertopic_model.py chứa các nhánh lịch sử. src/batterybert_full_document.py thực hiện continuation; src/full_document_inference.py suy luận cùng pooling; src/full_document_retrieval.py triển khai hai phương pháp search full-document. src/revised_topics.py đọc catalog mới và kiểm tra activation manifest. app.py và src/final_dashboard.py cung cấp giao diện.

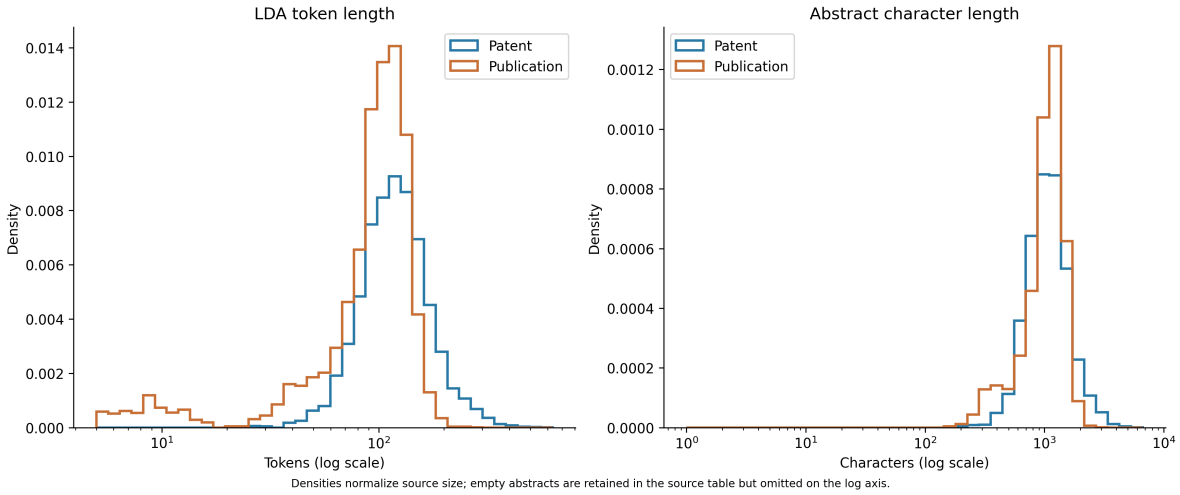
Mỗi output quan trọng lưu ID theo thứ tự, cấu hình và hash để phát hiện nhầm checkpoint hoặc ma trận. Pipeline resume có pending/running/failed/completed, receipt, checkpoint và log theo giai đoạn. Nếu output đã hoàn thành đổi hash, hệ thống báo lỗi thay vì ghi đè âm thầm. Đây là cơ chế tái lập vận hành; không thay cho đánh giá chất lượng mô hình.

Bảng 3.2: Vai trò của từng thành phần trong hệ thống.

Thành phần	Vai trò và trạng thái
LDA Stage2 K20	Lựa chọn K trong lưới lịch sử; phân bố topic xác suất.
LDA K10	Đối chứng catalog 10 topic, khác thí nghiệm chọn K20.
BERTopic–BGE / Battery-BERT	Encoder → UMAP → HDBSCAN → c-TF-IDF; catalog gộp K10 giữ outlier.
BatteryBERT KMeans pretrained	Đối chứng phân cụm 10 nhóm từ embedding pretrained.
BatteryBERT optimized / full-document	Catalog source projection và KMeans 10; encoder có trạng thái train khác nhau.
BatteryBERT stable topics	Catalog mới nhất, n_init 50 và parser v2, đã kích hoạt bằng manifest riêng.
TF-IDF / dense / RRF	Sáu phương pháp được đánh giá search trên cùng pool.
MiniLM cross-encoder	Thí nghiệm rerank Top 30 bị loại sau gate; không bật trong hybrid hiện hành.



Hình 3.2: Kết quả làm sạch và sàng lọc dữ liệu.
Nguồn: outputs/figures/data_preparation/figure_05_cleaning_summary.png.



Hình 3.3: Phân bố độ dài văn bản; số từ khác số WordPiece tokens.
Nguồn: outputs/figures/stage2/eda_05_length_distributions.png.

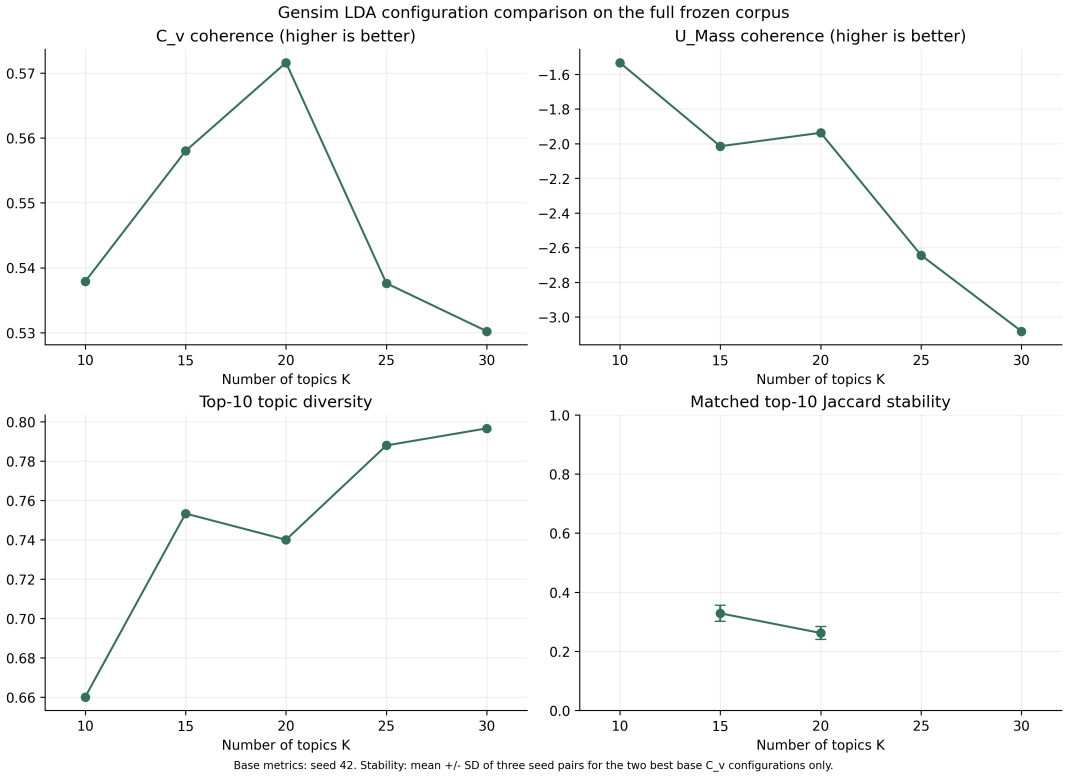
Chương 4

Huấn luyện mô hình và kết quả train

4.1 Huấn luyện LDA và BERTopic

LDA được fit bằng Gensim trên BoW. Lưới Stage2 gồm $K \in \{10, 15, 20, 25, 30\}$, passes = 10, iterations = 100, α asymmetric và η symmetric. Hai K có coherence tốt tại seed cơ sở được kiểm tra stability bổ sung; điểm tổng hợp chọn K20. Bản K20 đạt $C_v = 0,5716$, diversity = 0,7400 và Jaccard stability sau Hungarian = 0,2620. Việc chọn này chỉ tối ưu trong lưới đã khảo sát.

BERTopic không huấn luyện một bộ phân loại topic có nhãn: encoder tạo embedding, UMAP học biểu diễn 5 chiều, HDBSCAN tạo cụm và c-TF-IDF mô tả cụm. Cấu hình lịch sử dùng UMAP 15 neighbors, min_dist = 0, cosine; HDBSCAN min_cluster_size = 30, min_samples = 10, EOM. Catalog K10 được gộp từ các topic sau phân cụm; HDBSCAN không được yêu cầu sinh đúng 10 cụm. UMAP2D dành cho hình minh họa.



Hình 4.1: Lưới lựa chọn số topic LDA Stage2; kết quả lịch sử K20.
Nguồn: outputs/figures/stage2/lda_01_model_comparison.png.

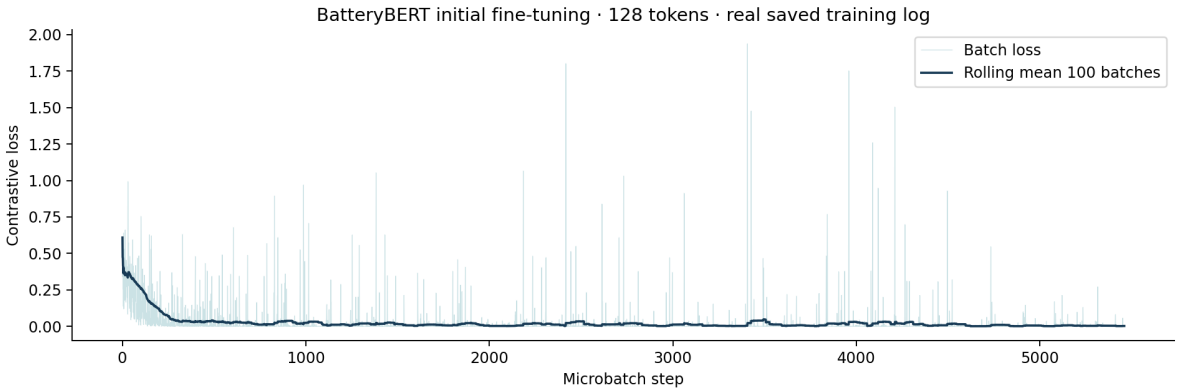
4.2 BGE và BatteryBERT trước continuation

BGE dùng checkpoint BAAI/bge-base-en-v1.5, vector CLS chuẩn hóa L2; BatteryBERT dùng batterydata/batterybert-cased, pooling token theo attention mask và chuẩn hóa L2. BatteryBERT được pretrained bằng masked language modeling trên tài liệu pin, do đó cần thực nghiệm riêng khi dùng làm sentence/document embedding [4].

Fine-tuning BatteryBERT ban đầu chỉ cập nhật block cuối, khoảng 7,09 triệu trong 107,72 triệu tham số. Cặp train là Title–Abstract rút gọn tối đa 128 tokens, batch 2, accumulation 2, một epoch, AdamW learning rate 2×10^{-5}, temperature 0,05. Negative chỉ nằm trong từng microbatch; accumulation không biến loss batch 2 thành loss batch 4. Không gọi nhánh ban đầu này là full-Abstract training.

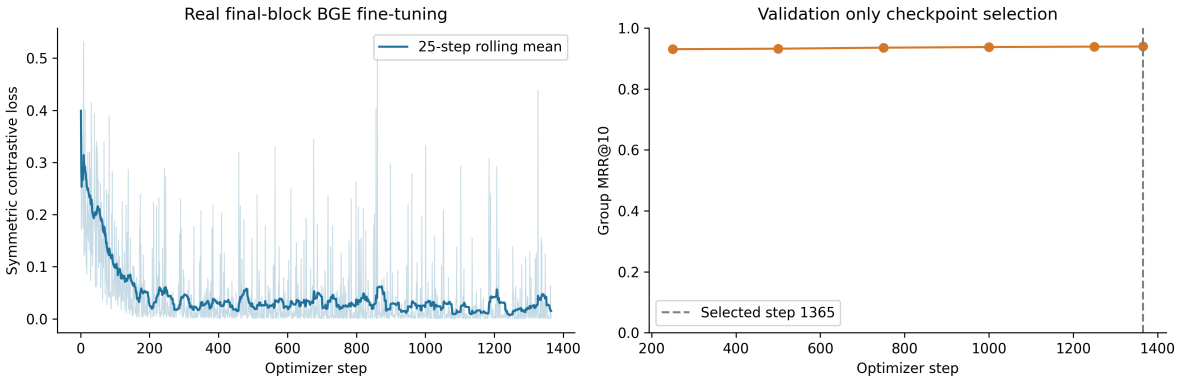
Nguồn: outputs/model_comparison_v2/batterybert_finetuned/training_plan.json.

Log BatteryBERT128 ghi 5.460 microbatches, 2.730 optimizer updates, 10.921 cặp đã thấy và best validation proxy 0,823240 tại step 5.460; frozen hash trước/sau không đổi, reload parity max error 0. Thời gian phiên train đã lưu khoảng 3.542,67 giây. Điểm 0,823240 khác protocol full-document ở phần sau nên không so trực tiếp để quy gain cho một yếu tố.



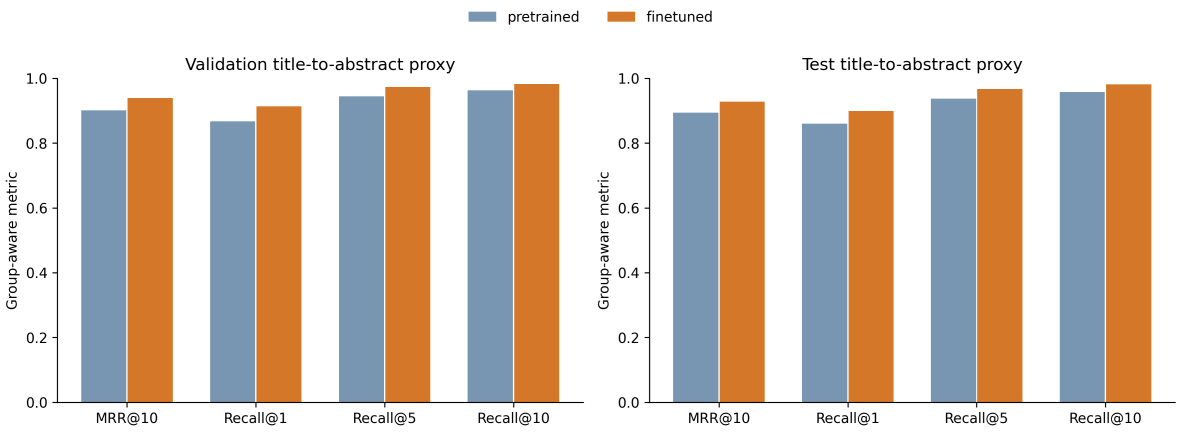
Hình 4.2: Loss BatteryBERT128 từ training_history.csv; accumulation không mở rộng tập negatives.

Nguồn: outputs/model_comparison_v2/batterybert_finetuned/training_history.csv.



Hình 4.3: Đường huấn luyện encoder BGE ở Stage3 lịch sử; không phải continuation BatteryBERT.

Nguồn: outputs/figures/stage3/bert_01_training.png.



Hình 4.4: Đối chứng biểu diễn trước/sau fine-tuning Stage3 lịch sử.

Nguồn: outputs/figures/stage3/bert_02_before_after.png.

4.3 Continuation full-document

Continuation bắt đầu từ checkpoint BatteryBERT fine-tuned có sẵn. Mười một block đầu đóng băng; chỉ block thứ 12 cập nhật. Mỗi tài liệu được chia cửa sổ 256, overlap 64, có Title context. Pooling cấp chunk chỉ lấy các token Abstract và loại SEP; vector chunk chuẩn hóa được tổng hợp theo số token Abstract mới, rồi L2. Nhánh Title-only sử dụng nội dung thực đang có.

Đặt h_{dj} là vector chunk đã chuẩn hóa, a_{dj} là số token mới của chunk j. Biểu diễn tài liệu là:

$$e_d = \text{norm}_2 \left(\frac{\sum_j a_{dj} h_{dj}}{\sum_j a_{dj}} \right). \tag{4.1}$$

Trọng số tránh đếm độ dài overlap hai lần ở bước tổng hợp; overlap vẫn ảnh hưởng ngữ cảnh bên trong từng chunk. Toàn bộ chunk đóng góp vào gradient; không chỉ train đoạn đầu rồi gọi kết quả là train toàn tài liệu.

Với $S_{ij} = e_{q_i}^\top e_{d_j}/\tau$, loss đối xứng là:

$$L_{q \to d} = -\frac{1}{B} \sum_i \log \frac{\exp S_{ii}}{\sum_{j \in A_i} \exp S_{ij}}, \tag{4.2}$$

$$L_{\text{CL}} = \tfrac{1}{2}(L_{q \to d} + L_{d \to q}), \tag{4.3}$$

$$L = L_{\text{CL}} + \frac{0,02}{B} \sum_i (\|e_{q_i} - e_{q_i}^0\|_2^2 + \|e_{d_i} - e_{d_i}^0\|_2^2). \tag{4.4}$$

A_i giữ positive và negatives hợp lệ, e^0 là embedding tham chiếu từ checkpoint trước continuation, $\tau = 0,05$. Distillation nhẹ hạn chế dịch chuyển biểu diễn quá xa. Nhãn positive là cùng tài liệu, không phải qrels của truy vấn độc lập.

4.4 Gradient caching và quy trình tối ưu

Gradient caching [10] cho phép tính loss trên batch 32 cặp trong khi replay encoder theo microbatch 2 chunks. Lần đầu tính các embedding không giữ toàn bộ đồ thị; sau đó tính gradient loss theo embedding, truyền qua phép pooling và replay block cuối để nhận gradient trọng số. Dropout tắt nhằm bảo đảm forward và replay nhất quán. Cache prefix float32 của các block đóng băng được dùng lại; bổ sung các chunk còn thiếu.

1. Kiểm tra corpus, split, checkpoint và độ bao phủ offsets của các chunk.
2. Thử learning rate 2×10^{-6} và 5×10^{-6} qua pilot 24 steps trên train, đo validation.
3. Tiếp tục cấu hình được chọn qua một lượt train đầy đủ, 342 batches; checkpoint mỗi 12 steps, validation định kỳ 96 steps.
4. Chọn checkpoint tốt nhất theo validation Group MRR@10, có baseline trong tập ứng viên; ngưỡng gain tối thiểu 0,002.

5. Export và reload checkpoint, kiểm tra parity, chuẩn L2 và ID; đánh giá test sau lựa chọn.

AdamW dùng weight decay 0,01, gradient clipping 1,0, warmup/decay. Learning rate được chọn là 5×10^{-6}, best step 342. Môi trường log ghi PyTorch CPU; không suy diễn thành thí nghiệm trên GPU. Cấu hình dùng bốn threads.

Nguồn: configs/batterybert_full_document.yaml;outputs/batterybert_full_document_20261024_v1/training_protocol.json.

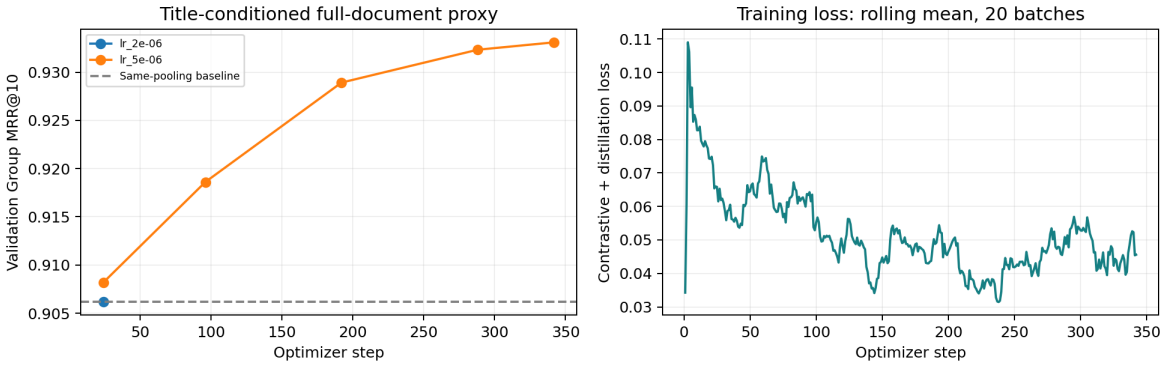
4.5 Kết quả huấn luyện và đối chứng cùng protocol

Bảng 4.1: Kết quả continuation trên cùng full-document proxy.

Đo lường	Giá trị
Validation baseline	0,906174
Validation selected	0,933093
Gain validation	0,026919
Test baseline	0,887839
Test selected	0,924704
Checkpoint / learning rate	Step 342 / 5e-6
Tài liệu / chunks / token Abstract train	10.921 / 26.147 / 3.420.215

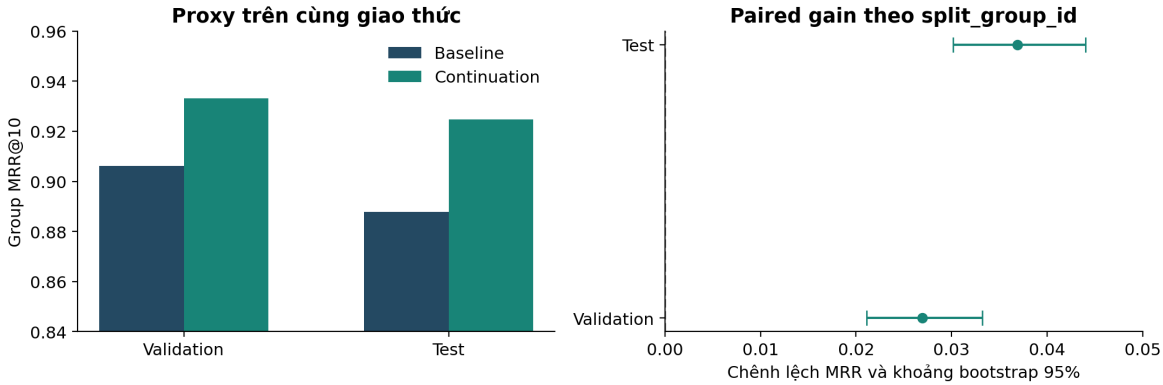
Nguồn: outputs/batterybert_full_document_20261024_v1/selection.json;paired_training_effect.json.

Một lượt continuation đã xử lý đủ 10.921 tài liệu, 26.147 chunks và 3.420.215 token Abstract duy nhất theo tài liệu; không có validation/test trong optimizer. L2 thay đổi block cuối export là 0,312042. Các kiểm tra reload/forward parity xác nhận đường suy luận sử dụng đúng trọng số đã huấn luyện.



Hình 4.5: Loss và validation của continuation BatteryBERT full-document; nguồn log train thật.

Nguồn: outputs/batterybert_full_document_20261024_v1/learning_curve.png.



Hình 4.6: Đối chứng cùng full-document pooling trước/sau continuation; proxy có Title context.

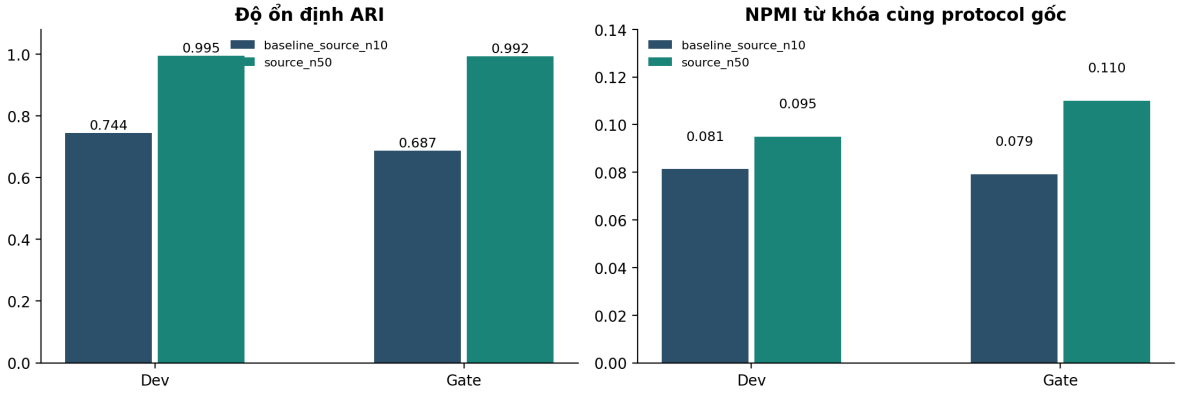
Nguồn: outputs/report_pipeline_20261025/figures/07_training_effect.png.

Đường loss theo batch có thể dao động do độ khó negatives và nội dung khác nhau. Chỉ số validation dùng chọn checkpoint; loss batch không được diễn giải thành phần trăm chính xác. Mức tăng test proxy $0,036865$ là bằng chứng trên cùng pooling full-document, không được gán riêng cho độ bao phủ hoặc xem là cải thiện relevance người dùng. Title hiện diện trong document context tạo lợi thế cho proxy ghép Title–document.

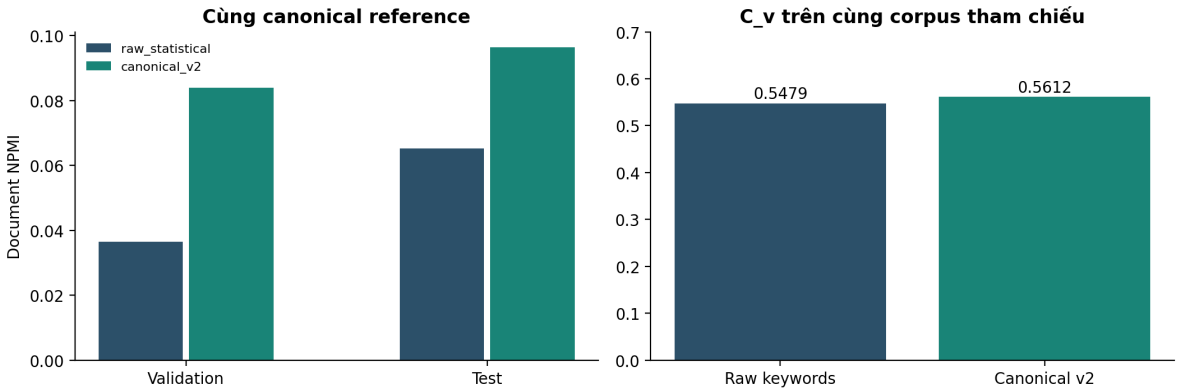
4.6 Clustering sau encoder và các thử nghiệm không đạt

Source projection fit trên train loại một hướng chênh lệch trung bình giữa Patent và Publication. KMeans 10 với n_init 50 cải thiện ổn định so với n_init 10 trên seed giữ riêng: ARI 0,686587 lên 0,991808; NPMI theo stream gốc0,079191 lên 0,110046. Source Cramér V tăng 0,3254 lên 0,3291 và top2 share tăng 23,10% lên 27,49%, do đó không phải mọi tiêu chí đều tốt hơn.

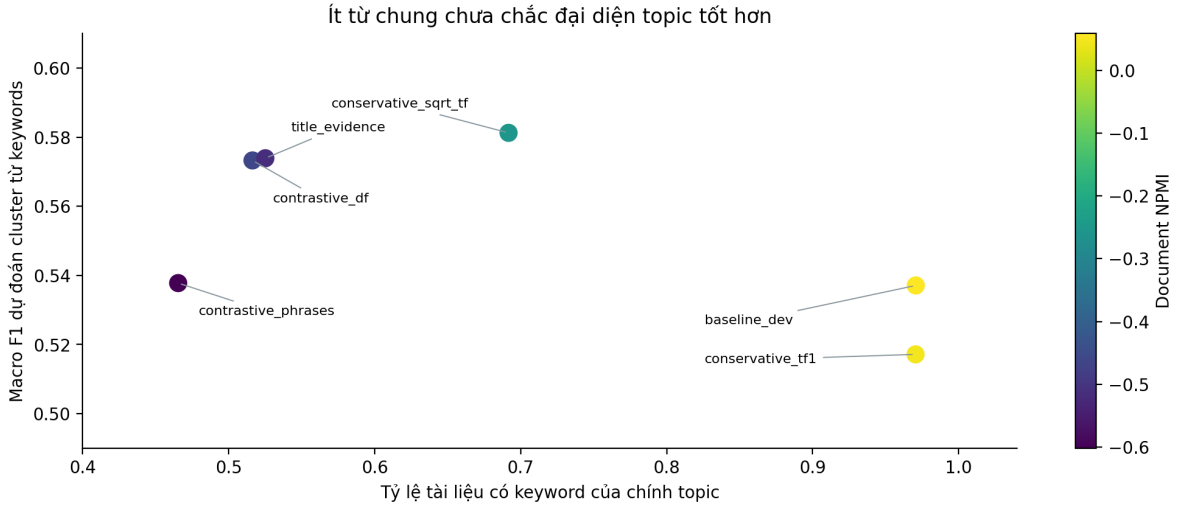
Sau sửa parser công thức, so trên cùng canonical reference, heldout document NPMI tăng 0,065294 lên 0,096332 và C_v0,547907 lên 0,561193; diversity giảm 0,79 xuống 0,75. Đây là phép đo khác geometry gate và phải báo riêng. Năm cách lọc từ khóa đều trượt ít nhất một gate; hệ thống giữ weighting gốc và xuất audit thay vì xóa từ rộng sau khi đã xem điểm.



Hình 4.7: Ảnh hưởng số khởi tạo KMeans; embeddings được giữ nguyên.
Nguồn:
outputs/research_revision_20261025_v1/visualizations/geometry_before_after.png.



Hình 4.8: Ảnh hưởng sửa công thức khi so keyword trên cùng canonical reference.
Nguồn: outputs/research_revision_20261025_v1/visualizations/canonical_correctness_effect.png.



Hình 4.9: Các recipe lọc keyword bị loại do đánh đổi coherence và coverage.
Nguồn: outputs/research_revision_20261025_v1/visualizations_v2/keyword_failed_hypotheses.png.

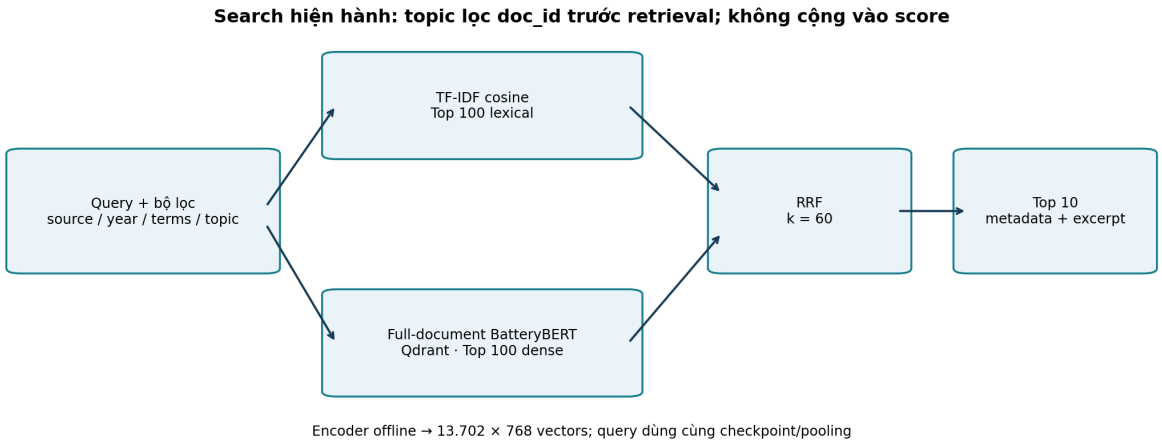
Chương 5

Thiết kế và vận hành search engine

5.1 Mục tiêu thiết kế và hợp đồng đầu vào

Search engine nhận một câu tiếng Anh mô tả nhu cầu nghiên cứu, tùy chọn nguồn Patent/Publication, khoảng năm, required terms và topic ID. Đầu ra tối đa10 tài liệu, mỗi tài liệu có doc_id, tiêu đề, Abstract, identifier, nguồn, năm, điểm và đoạn trích. Truy vấn cần có chữ hoặc số và không rỗng. Suy luận full-document không âm thầm cắt phần cuối query; nó chia cửa sổ theo tokenizer rồi tổng hợp.

Luồng hiện hành là BATTERYBERT_FULLDOC_HYBRID. Phương pháp semantic dùng cùng encoder và index nhưng không có nhánh TF-IDF. Cấu hình hiện hành được xác minh từ deployment.json; các chế độ Search v2/v3 và SE1/SE2/SE3 được giữ làm lịch sử, không dùng để mô tả nhầm thuật toán đang mặc định.



Hình 5.1: Chi tiết luồng search full-document hybrid theo mã nguồn hiện hành. *Nguồn:* src/full_document_retrieval.py;src/final_search.py.

5.2 Lập chỉ mục offline

5.2.1 Chỉ mục lexical TF-IDF

Văn bản lexical nối Title và Abstract sau xử lý tokenizer. TfidfVectorizer dùng lowercase=False vì tokenizer đã kiểm soát chuẩn hóa, norm=L2, use_idf=True,

smooth_idf=True, sublinear_tf=False, dtype=float32. Với $df(t)$ là số tài liệu có term t:

$$\text{idf}(t) = \log \frac{1+N}{1+df(t)} + 1, \tag{5.1}$$

$$\widetilde{x}_{dt} = f(t,d)\,\text{idf}(t), \qquad x_d = \frac{\widetilde{x}_d}{\|\widetilde{x}_d\|_2}, \tag{5.2}$$

$$s_L(q,d) = x_q^\top x_d. \tag{5.3}$$

IDF fit trên corpus search đóng băng, không fit lại theo mỗi query. Ma trận sparse CSR giảm bộ nhớ cho các term vắng. Query dùng vectorizer đã lưu; từ ngoài vocabulary không tự tạo feature mới. Chỉ các điểm lexical dương mới được đưa vào Top 100 lexical. Nếu query không có lexical support nhưng dense có kết quả, full-document hybrid vẫn có thể trả danh sách từ nhánh dense; đây khác support gate của Search v2 lịch sử.

TF-IDF có ích với công thức, tên vật liệu và cụm từ đặc hiệu nhưng yếu với đồng nghĩa, phủ định và quan hệ. IDF cao cũng có thể khuếch đại một token sai metadata. Vì vậy lexical score chỉ là một kênh chứng cứ; không thay thế đọc Abstract.

5.2.2 Chỉ mục vector và Qdrant

Mỗi tài liệu được mã hóa một lần bằng checkpoint full-document đã chọn thành vector768 chiều. Ma trận có 13.702 hàng theo ordered_doc_ids.json. Qdrant lưu vector cùng payload nguồn, năm và ID. Trước khi dùng index, code đối chiếu tên collection, hash weights, hash vectors và số tài liệu với manifest. Query phải được encode bằng cùng checkpoint và pooling tương thích; vector từ hai checkpoint khác nhau không được trộn chỉ vì cùng768 chiều.

Các benchmark hiện có dùng Qdrant local và kiểm tra exact parity với ma trận NumPy. Vì vậy báo cáo không suy ra hiệu năng ANN phân tán hoặc tải đồng thời. Với vector chuẩn hóa:

$$s_D(q,d) = \frac{e_q^\top e_d}{\|e_q\|_2 \|e_d\|_2} = e_q^\top e_d. \tag{5.4}$$

Cosine đo gần nhau trong không gian học được, không phải xác suất tài liệu đúng hay mức thỏa đủ điều kiện hóa học.

5.3 Lọc trước truy hồi

Mask đầu tiên kiểm nguồn và năm. Required terms tạo evidence filter theo token được chuẩn hóa. Nếu có topic ID0–9, hệ thống đọc assignments hiện hành và chuyển thành tập doc_id được phép. Mask này áp dụng cho cả nhánh lexical và dense trước khi lấy ứng viên. Việc lọc trước giúp Top 100 không bị tiêu hao bởi những tài liệu sau đó sẽ bị

loại.

Topic không cộng bonus vào cosine hoặc RRF của cấu hình hiện hành. Khi catalog mới đổi membership, danh sách doc_id lọc cũng đổi; không dùng payload topic cũ trong vector index. Đổi tên/topic metadata do đó không yêu cầu encode lại tài liệu. Người dùng cần hiểu rằng lọc topic làm hẹp không gian tìm kiếm và có thể bỏ sót tài liệu gán nhầm.

Required terms xác nhận sự hiện diện token, chưa xác nhận chúng cùng nói về một thí nghiệm hay cùng một cell. Ví dụ có “hard carbon”, “layered oxide” và “additive” ở các đoạn khác nhau không chứng minh nghiên cứu full cell kết hợp đủ cả ba. Phủ định và vai trò cathode/anode cũng không được giải quyết chỉ bằng token matching.

5.4 Sinh ứng viên và hợp nhất thứ hạng

Hai nhánh độc lập lấy tối đa100 ứng viên sau lọc. Hợp ứng viên có nhiều nhất200 doc_id, có thể ít hơn do trùng hoặc nhánh lexical rỗng. RRF với $k = 60$ tính:

$$s_{\text{RRF}}(q, d) = \frac{\mathbf{1}[d \in L_q]}{60 + r_L(d)} + \frac{\mathbf{1}[d \in D_q]}{60 + r_D(d)}. \tag{5.5}$$

Mỗi hạng bắt đầu từ 1; tài liệu vắng một list chỉ nhận điểm ở list còn lại. Hai nhánh có trọng số bằng nhau. Không cộng trực tiếp TF-IDF cosine với dense cosine vì hình dạng phân bố điểm có thể khác nhau. RRF đổi sự chênh lệch score lấy thông tin thứ hạng [11].

Ví dụ minh họa toán học: tài liệu A đứng lexical hạng1, dense hạng10 thì nhận $1/61 + 1/70 \approx 0,030679$; B đứng hạng4 và 4 nhận $2/64 = 0,03125$, nên B đứng trên A. Tài liệu C chỉ có lexical hạng1 nhận $1/61 \approx 0,016393$. Đây là ví dụ giải thích công thức, không phải số đo từ benchmark. Điểm RRF không thuộc phân bố xác suất và không nên hiển thị thành “độ chính xác 3,1%”.

5.5 Các bước thực thi một truy vấn

1. Chuẩn hóa query và kiểm tra tham số; tạo allowed mask từ nguồn, năm, required terms và topic.
2. Nếu tập hợp lệ rỗng, trả danh sách rỗng với trạng thái rõ ràng.
3. Encode toàn query bằng FullDocumentEncoder; ghi thông tin coverage của query.
4. Dense retrieval Top 100 trên collection đúng checkpoint; TF-IDF Top 100 trên cùng mask.
5. Hợp nhất RRF 60, loại trùng doc_id và lấy Top 10; semantic-only bỏ bước fusion.
6. Ghép metadata theo doc_id, thêm rank từng nhánh, semantic cosine, TF-IDF cosine

và RRF khi có.

7. Ghép topic hiện hành và chọn đoạn trích; xuất JSON/CSV/giao diện với ý nghĩa score.

Nếu tài liệu lexical được lấy vào Top 10 nhưng nằm ngoài dense Top 100, code có thể tính cosine trực tiếp từ hàng embedding để bổ sung thông tin hiển thị. Thao tác đó không thay thứ hạng RRF. Đoạn trích trong nhánh này chọn câu Abstract có overlap lexical tốt nhất; nhãn passage_method ghi rõ đây không phải lời giải thích relevance của một mạng neural.

Nguồn: src/full_document_retrieval.py;src/final_search.py.

5.6 So sánh sáu phương pháp search

Bảng 5.1: Sáu phương pháp trong đánh giá 703 Silver Labels.

Phương pháp	Cách xếp hạng
TF-IDF	Cosine lexical từ Title–Abstract.
BatteryBERT semantic	Dense pretrained BatteryBERT; không continuation full-document.
BatteryBERT hybrid	TF-IDF và dense pretrained, RRF 60.
BGE semantic	Dense BGE, đối chứng encoder.
Full-document semantic	Dense BatteryBERT continuation với pooling full-document.
Full-document hybrid	TF-IDF và dense continuation, RRF 60; cấu hình hiện hành.

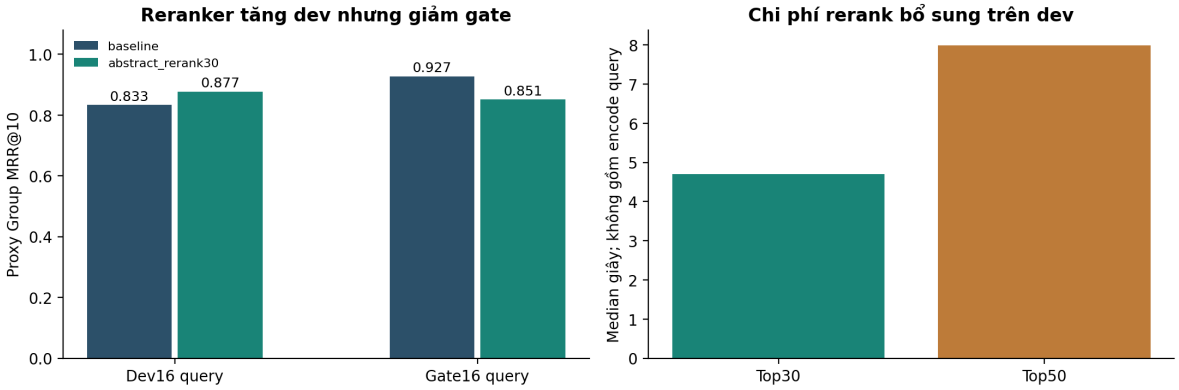
Tên phương pháp phải được giữ cùng provenance. Không gộp BatteryBERT pre-trained, fine-tuned128 và continuation full-document thành một model duy nhất khi phân tích. Bảng sáu phương pháp không chứa reranker thử nghiệm bị loại.

5.7 Reranker: cách hoạt động và lý do không triển khai

Cross-encoder MiniLM nhận query và passage đồng thời, có thể mô hình hóa tương tác token tốt hơn bi-encoder nhưng phải chạy cho từng cặp. Trong thí nghiệm revision, candidate budget gồm Top 30 hoặc Top 50; passages lấy từ Abstract và xử lý query windows. Reranker không thể tìm lại tài liệu đã vắng trong candidate set.

Trên 16 title anchors phát triển, Top 30 tăng Group MRR@10 từ 0,832813 lên 0,877083. Nhưng 16 anchors giữ riêng giảm từ 0,927083 xuống 0,850694; Success@1 giảm 0,8750 xuống 0,8125. Vì không chuyển giao sang gate, reranker không được kích

hoạt. Proxy này cũng có thiên lệch Title trong vector/TF-IDF; không phải relevance search của người dùng.



Hình 5.2: Reranker tăng dev nhưng giảm gate; không được kích hoạt. *Nguồn:* outputs/research_revision_20261025_v1/visualizations/search_gate_rejection.png.

Chi phí rerank là phần bổ sung ngoài encoding query, retrieval và metadata. Các số baseline bằng0 trong bảng dùng cache không chứng minh baseline miễn phí. Việc chọn mô hình phức tạp hơn phải dựa trên chất lượng, độ trễ và tập giữ riêng; kết quả ở đây ủng hộ giữ hybrid mặc định.

5.8 Các hệ tìm kiếm lịch sử

SE1 so cosine các posterior LDA; SE2 xếp lại Top 100 dense bằng bonus centroid topic hệ số0,1; SE3 hợp thứ hạng SE1/SE2 bằng RRF 60. Search v2 dùng BM25 có trọng số Title2/Abstract1, dense BGE và MiniLM rerank Top 50. Chúng giải thích lịch sử phát triển, không phải kiến trúc hiện hành. Các hình Stage4 Top 5 trong phụ lục được ghi rõ là lịch sử.

BM25 lịch sử dùng term frequency bão hòa và hiệu chỉnh độ dài:

$$B(q,d) = \sum_{t \in q} IDF(t) \frac{f(t,d)(k_1+1)}{f(t,d) + k_1(1 - b + b|d|/avgdl)}, \tag{5.6}$$

với $k_1 = 1,5$, $b = 0,75$ [12]. Công thức này cần để hiểu đối chứng cũ; TF-IDF hiện hành không tự động trở thành BM25 vì cùng là lexical retrieval.

5.9 Ví dụ output thực tế và hình kết quả

Q01 hỏi “Hard carbon anodes derived from biomass for sodium-ion batteries”. Bảng sau lấy đúng thứ hạng đã khóa, ghép nhãn Silver sau retrieval; không đổi rank theo

nhãn. Nhãn2 ở các vị trí2–10 và nhãn 1 ở vị trí1 cho P@10 =0,9, RR@10 =0,5. Bài hạng1 có thể khớp lexical tốt nhưng thiếu điều kiện chi tiết theo rubric; đây là lý do cosine/RRF không thể thay relevance.

Bảng 5.2: Top 10 thực tế của full-document hybrid cho Q01 và nhãn Silver ghép sau retrieval.

Hạng	Tiêu đề	RRF	Nhãn
1	Biomass-derived carbon anodes for sodium-ion batteries	0,03028	1
2	Biomass hard carbon of high initial coulombic efficiency for sodium-ion batteries: Preparation and application	0,02878	2
3	Biochars from various biomass types as precursors for hard carbon anodes in sodium-ion batteries	0,02731	2
4	Revealing the sodium storage behavior of biomass-derived hard carbon by using pure lignin and cellulose as model precursors	0,02650	2
5	A Stable Biomass-Derived Hard Carbon Anode for High-Performance Sodium-Ion Full Battery	0,02513	2
6	High Capacity and High Efficiency Maple Tree-Biomass-Derived Hard Carbon as an Anode Material for Sodium-Ion Batteries	0,02492	2
7	Hard carbon derived for lignin with robust and low-potential sodium ion storage	0,02432	2
8	Biomass derived hard carbon used as a high performance anode material for sodium ion batteries	0,02312	2
9	Pectin, Hemicellulose, or Lignin? Impact of the Biowaste Source on the Performance of Hard Carbons for SodiumIon Batteries	0,02256	2
10	A porous biomass-derived anode for high-performance sodium-ion batteries	0,02158	2

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

Hình kết quả được dựng từ file output đã lưu, không giả làm ảnh chụp giao diện đang chạy. Các ảnh giao diện gốc hiện có được giữ trong phụ lục và ghi đúng snapshot. Ví

Q01 · Full-document hybrid · frozen Top 10
Reconstructed from saved output · AI Silver labels

Rank	Title	RRF	Silver
1	Biomass-derived carbon anodes for sodium-ion batteries	0.03028	1
2	Biomass hard carbon of high initial coulombic efficiency for sodium-ion batteries: Preparation and application	0.02878	2
3	Biochars from various biomass types as precursors for hard carbon anodes in sodium-ion batteries	0.02731	2
4	Revealing the sodium storage behavior of biomass-derived hard carbon by using pure lignin and cellulose as model precursors	0.02650	2
5	A Stable Biomass-Derived Hard Carbon Anode for High-Performance Sodium-Ion Full Battery	0.02513	2
6	High Capacity and High Efficiency Maple Tree-Biomass-Derived Hard Carbon as an Anode Material for Sodium-Ion Batteries	0.02492	2
7	Hard carbon derived for lignin with robust and low-potential sodium ion storage	0.02432	2
8	Biomass derived hard carbon used as a high performance anode material for sodium ion batteries	0.02312	2
9	Pectin, Hemicellulose, or Lignin? Impact of the Biowaste Source on the Performance of Hard Carbons for SodiumIon Batteries	0.02256	2
10	A porous biomass-derived anode for high-performance sodium-ion batteries	0.02158	2

Hình 5.3: Hình Top 10 dựng lại từ output đã lưu của Q01; không phải ảnh chụp phiên giao diện mới.
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

dụ thứ hai là Q20: một bài nhãn 2 nằm trong pool nhưng full-document hybrid không đưa vào Top 10; BGE semantic tìm thấy ở hạng10. Đây là lỗi recall ứng viên/xếp hạng cần đọc cùng điều kiện full cell và electrolyte additive.

5.10 Độ trễ, bộ nhớ và giới hạn vận hành

Bảng 5.3: Độ trễ requests đã lưu, đơn vị giây;19 warm requests/method, khác phiên chạy.

Phương pháp	n	Mean	Median	Max
BatteryBERT hybrid	19	0,239	0,226	0,307
BatteryBERT semantic	19	0,224	0,210	0,385
BGE semantic	19	0,487	0,454	1,046
TF-IDF	19	0,019	0,018	0,028
Full-document hybrid	19	0,543	0,537	0,620
Full-document semantic	19	0,632	0,575	1,072

Nguồn: outputs/research_completion_v1/latency.csv;outputs/batterybert_full_document_20261024_v1/benchmark_latency.csv.

Các số đo lấy từ log thật, median warm requests; lần đầu có tải checkpoint/index nên không trộn vào trung vị. Thời gian phụ thuộc độ dài query, filter và trạng thái cache. Benchmark chưa đo nhiều người dùng đồng thời; local Qdrant cần quản lý vòng đời owner process. Ma trận float32 riêng cho 13.702×768 tốn khoảng 42,15MB thập phân, chưa gồm weights, sparse matrix, payload và index.

Độ phức tạp dense exact đối chiếu toàn corpus xấp xỉ $O(Nh)$ với $h = 768$; sparse lexical phụ thuộc postings/feature không zero; fusion tối đa200 candidates có chi phí nhỏ hơn neural encoding. Query dài và required terms có thể làm chi phí lọc hoặc encode tăng. Không suy ra SLA từ 20 queries nghiên cứu.

5.11 Phân tích tình huống lỗi và hướng sửa có kiểm chứng

Nhóm lỗi chính gồm đúng họ vật liệu nhưng sai vai trò, thiếu một điều kiện trong query, ghép chứng cứ từ các hệ pin khác nhau, nhầm công đoạn chế tạo, nhầm tái chế Li-ion để tạo vật liệu SIB với tái chế spent SIB, và hiểu BMS như thermal management. Các lỗi đòi hỏi kiểm tra quan hệ và intent, không chỉ tăng trọng số tên vật liệu.

Hướng tiếp theo là mở rộng pool có kiểm soát, gắn nhãn từng điều kiện, tách tập phát triển mới và thử passage/multi-vector retrieval. Không sửa quy tắc theo query_id

củа20 query đã dùng để báo cáo. Dữ liệu có Abstract thiếu hoặc role label đáng nghi cần người đọc xác minh; tự sửa theo kiến thức nền có thể làm nhãn không còn bám bằng chứng nguồn.

Chương 6

Giao thức đánh giá và so sánh kết quả

6.1 Tách ba lớp đánh giá

Đánh giá được tổ chức theo ba mục tiêu. Topic coherence/diversity/stability đo cấu trúc và từ khóa. Title–document Group MRR đo proxy biểu diễn và chọn checkpoint. Relevance Top 10 đo mức đáp ứng20 truy vấn nghiên cứu theo nhãn 0–2. Ba lớp không có cùng ground truth; báo cáo không quy chúng thành một "accuracy" chung.

6.2 Các chỉ số topic

Với danh sách Top 10 từ của mỗi topic, diversity là tỷ lệ số từ duy nhất trên $10K$; outlier rate là tỷ lệ tài liệu có ID-1. KMeans gán mọi tài liệu nên outlier 0 là thuộc tính thuật toán. C_v kết hợp NPMI cửa sổ và cosine ngữ cảnh; U_Mass dựa trên đồng xuất hiện tài liệu. Không so coherence của các token stream/reference khác nhau để kết luận thắng tuyệt đối.

Stability KMeans đo ARI giữa các lần gán trên cùng tập. Đặt n_{ij} là số tài liệu chung giữa cụmi của lần A vàj của lần B, $a_i = \sum_j n_{ij}$, $b_j = \sum_i n_{ij}$: Đặt các số cặp $A = \sum_{ij} n_{ij}(n_{ij}-1)/2$, $B = \sum_i a_i(a_i-1)/2$, $C = \sum_j b_j(b_j-1)/2$ và $M = N(N-1)/2$. Khi đó:

$$ARI = \frac{A - BC/M}{(B+C)/2 - BC/M}. \tag{6.1}$$

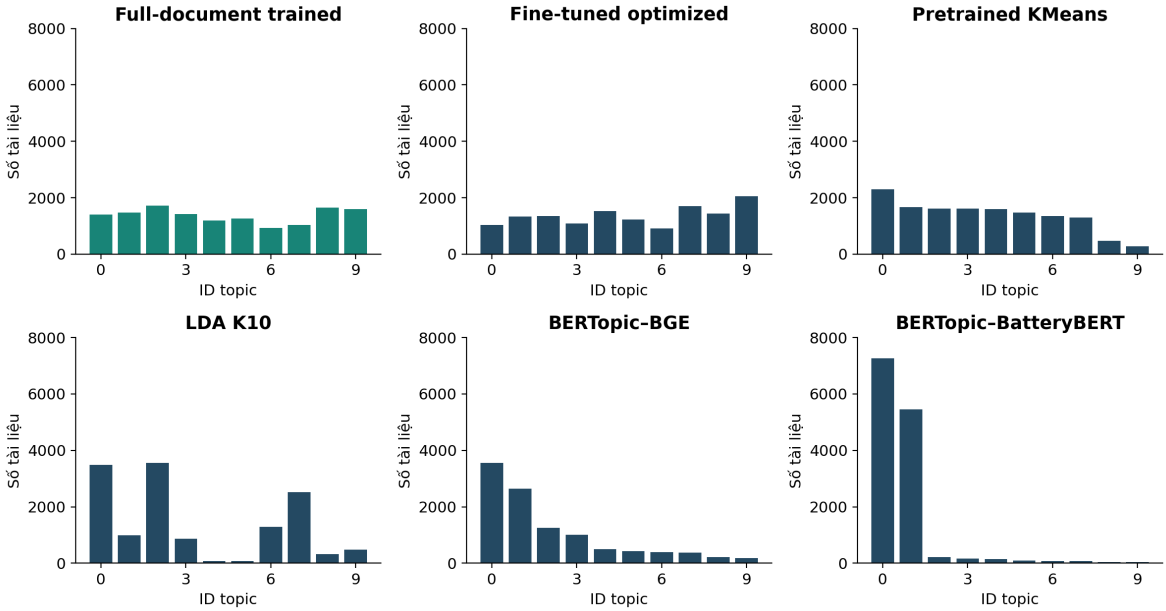
ARI cao biểu thị đồng thuận sau hiệu chỉnh ngẫu nhiên, không xác nhận tên topic đúng khoa học. Source Cramér V đo liên hệ giữa topic và nguồn: $V = \sqrt{\chi^2/[N\min(r-1, c-1)]}$. Phải đọc V cùng đại diện, kích thước cụm và coherence; nguồn có thể liên quan nội dung thật.

Bảng 6.1: Đối chứng K10 cùng protocol lịch sử; nhánh fine-tuned BERTopic chưa hoàn thành không có điểm.

Catalog	C_v	U_Mass	Diversity	Outlier
LDA K=10	0,5379	-1,5323	0,6600	–
BERTopic + BGE	0,6455	-2,9818	0,8600	22,77%
BERTopic + BatteryBERT pretrained	0,7445	-3,0954	0,9200	0,80%

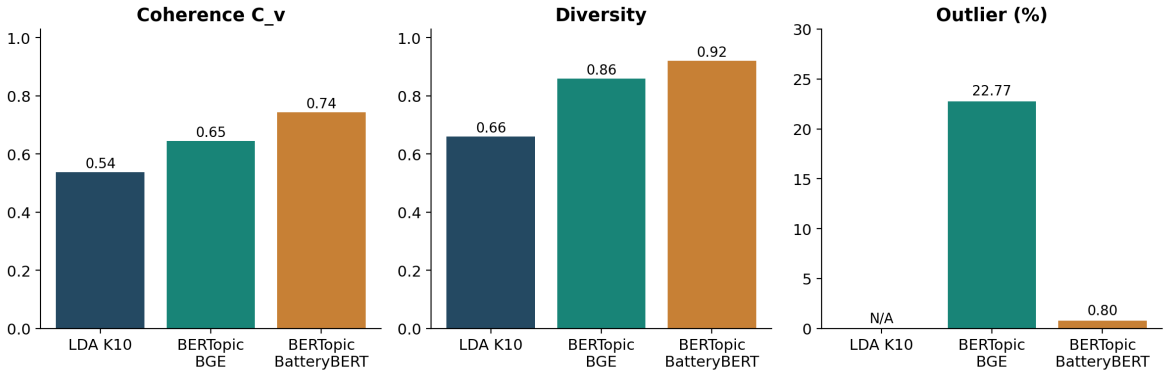
Nguồn: outputs/model_comparison_v2/evaluation/model_comparison.csv.

BERTopic–BatteryBERT pretrained có C_v lịch sử cao nhưng hai cụm rộng chứa 92,76% corpus. Điều này minh họa coherence cao không bảo đảm phân loại hữu ích. BGE có 3.120 outliers, thể hiện đánh đổi phân tách và bao phủ. Các catalog source projection cần báo thêm độ ổn định và mức tập trung nguồn thay vì chỉ trưng bày từ khóa đẹp.



Hình 6.1: Phân bố10 topic của sáu catalog lịch sử; chưa bao gồm stable topics mới nhất.

Nguồn: outputs/report_pipeline_20261025/figures/04_six_distributions.png.



Hình 6.2: So sánh các catalog theo protocol lịch sử; không xếp hạng chung với canonical reference mới.

Nguồn: outputs/report_pipeline_20261025/figures/05_historical_comparison.png.

6.3 Protocol relevance703 Silver Labels

Pool có 703 cặp duy nhất từ hợp Top 10 của sáu phương pháp trên 20 queries. AI đọc Query–Title–Abstract trước khi ghép rank/model, gán nhãn 0 (không đáp ứng),1 (liên quan một phần) hoặc2 (đáp ứng trực tiếp). Có143 nhãn 0,302 nhãn 1,258 nhãn 2;70 trường hợp cần review và 28 bản ghi thiếu Abstract. Các trường hợp này vẫn có nhãn số tạm thời theo bằng chứng đang có.

Đây là một lượt chấm AI, chưa có human ground truth. Không tính accuracy/F1 của nhãn hoặc kappa giữa người chấm khi chưa có chuẩn và người chấm thứ hai. Confidence high/medium/low chưa được hiệu chuẩn. Các nhãn chưa dùng để chọn encoder, clustering hoặc reranker trong báo cáo.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/protocol.json;label_summary.json.

6.4 Công thức P@10, MRR@10 và nDCG@10

Với nhãn $g_{qi} \in \{0, 1, 2\}$, đặt $r_{qi} = \mathbf{1}[g_{qi} = 2]$. Trên cùng20 queries:

$$P@10(q) = \frac{1}{10} \sum_{i=1}^{10} r_{qi}, \tag{6.2}$$

$$RR@10(q) = \begin{cases} 1/j, & j = \min\{i \leq 10 : r_{qi} = 1\}, \\ 0, & \text{không có nhãn2 trong Top10}, \end{cases} \tag{6.3}$$

$$MRR@10 = \frac{1}{|Q|} \sum_{q \in Q} RR@10(q), \tag{6.4}$$

$$DCG@10(q) = \sum_{i=1}^{10} \frac{2^{g_{qi}} - 1}{\log_2(i+1)}, \tag{6.5}$$

$$nDCG@10(q) = \begin{cases} DCG@10(q)/IDCG@10(q), & IDCG > 0, \\ 0, & IDCG = 0. \end{cases} \tag{6.6}$$

IDCG lấy10 grades tốt nhất trong toàn pool chung của query, không chỉ một method. Nhãn1 có gain1 và nhãn 2 gain3. Mỗi method được macro-average trên đủ 20 query, kể cả query khó. Thiếu nhãn không được tự đổi thành 0. Các metric này đo ranking trên pool đánh giá, chưa chứng minh Recall toàn corpus [13].

Recall trong pool được tính bổ sung là số nhãn 2 trong Top 10 chia tổng nhãn 2 của query trong pool. Q08 không có nhãn 2 nên Recall_pool undefined, không gán0 rồi xem là có đánh giá. Q08 còn có nDCG1 nhưng P@10 và MRR0: thứ tự tối ưu trong pool chỉ có bài nhãn 1, chưa có bài thỏa đủ mọi điều kiện.

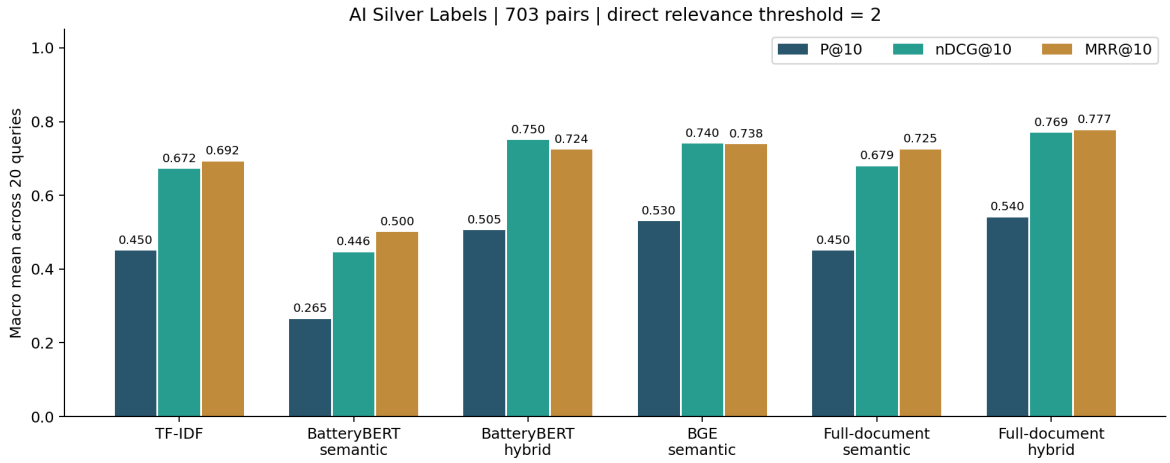
6.5 Kết quả trung bình của sáu phương pháp

Bảng 6.2: So sánh search trên 703 nhãn AI Silver; chưa xác minh bởi con người.

Phương pháp	P@10	nDCG@10	MRR@10
TF-IDF	0,4500	0,6719	0,6917
BatteryBERT semantic	0,2650	0,4457	0,5005
BatteryBERT hybrid	0,5050	0,7499	0,7238
BGE semantic	0,5300	0,7399	0,7383
Full-document semantic	0,4500	0,6786	0,7250
Full-document hybrid	0,5400	0,7693	0,7767

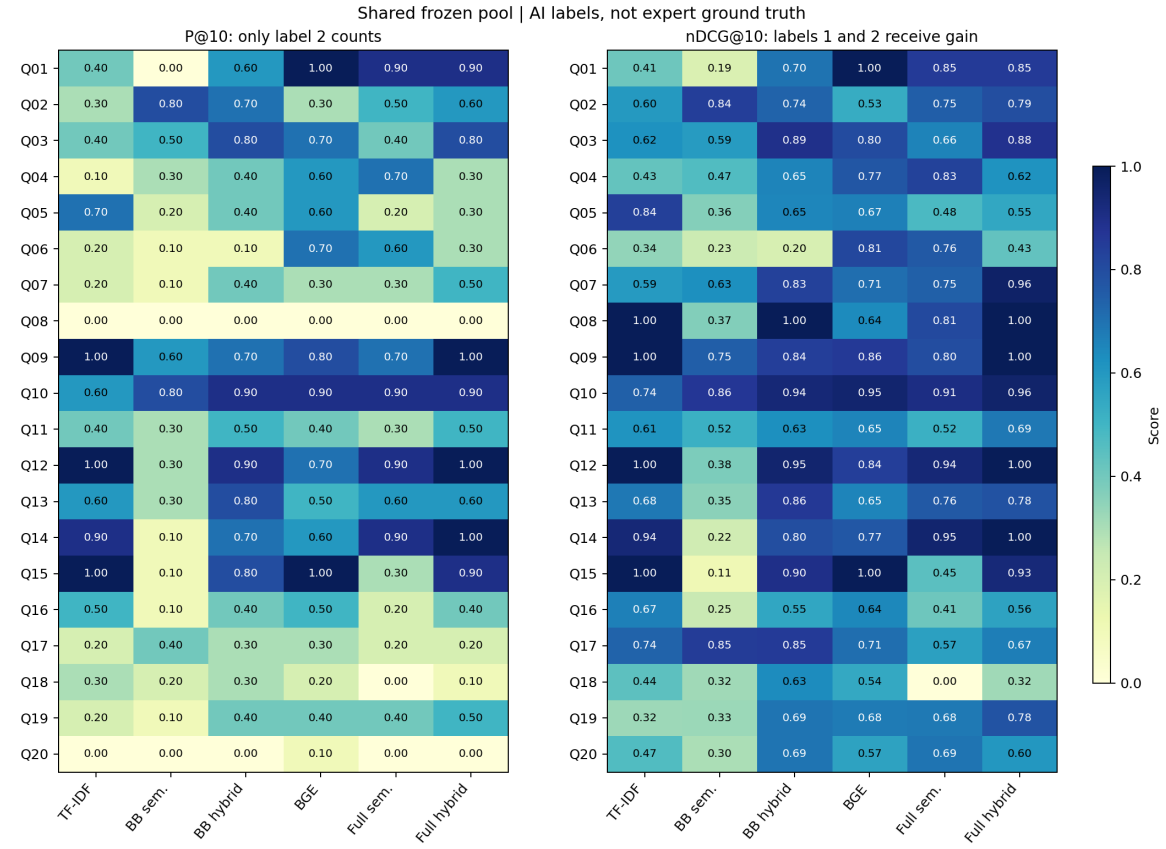
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/metrics_summary.csv.

Full-document hybrid đạt trung bình cao nhất ở ba chỉ số chính. So với TF-IDF, P@10 tăng 0,0900, nDCG@10 tăng 0,097454 và MRR@10 tăng 0,0850. Diễn giải P@10=0,54 là trung bình5,4 tài liệu nhãn 2 trong10 kết quả, không phải accuracy toàn hệ thống54%. So với BGE, lợi thế P@10 chỉ 0,01; cần đọc khoảng tin cậy và chênh lệch ghép cặp trước khi chọn model.

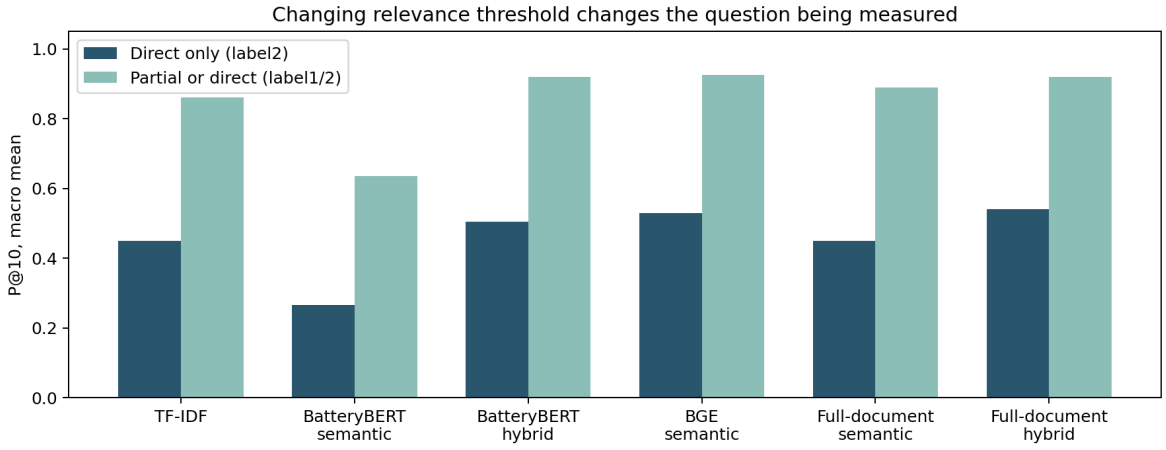


Hình 6.3: P@10, nDCG@10 và MRR@10 trên 703 Silver Labels, cùng20 queries và sáu methods.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/method_comparison.png.



Hình 6.4: Điểm từng query; P@10 và nDCG cần được đọc cùng nhau.
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/query_heatmaps.png.



Hình 6.5: Độ nhạy với ngưỡng relevance; nhãn 1 và nhãn 2 trả lời mục tiêu khác nhau.
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/threshold_sensitivity.png.

6.6 Chi tiết từng truy vấn và ví dụ tính từ output

Bảng 6.3: Full-document hybrid theo từng truy vấn; cùng pool Silver.

Query	P@10	nDCG@10	RR@10	Nhãn2 trong pool
Q01	0,9000	0,8533	0,5000	25
Q02	0,6000	0,7938	1,0000	14
Q03	0,8000	0,8845	1,0000	17
Q04	0,3000	0,6168	1,0000	13
Q05	0,3000	0,5496	1,0000	12
Q06	0,3000	0,4312	1,0000	13
Q07	0,5000	0,9649	1,0000	5
Q08	0,0000	1,0000	0,0000	0
Q09	1,0000	1,0000	1,0000	13
Q10	0,9000	0,9576	1,0000	21
Q11	0,5000	0,6866	1,0000	12
Q12	1,0000	1,0000	1,0000	20
Q13	0,6000	0,7833	1,0000	13
Q14	1,0000	1,0000	1,0000	23
Q15	0,9000	0,9306	1,0000	26
Q16	0,4000	0,5646	0,3333	14
Q17	0,2000	0,6695	0,5000	4
Q18	0,1000	0,3198	0,2000	4
Q19	0,5000	0,7788	1,0000	8
Q20	0,0000	0,6020	0,0000	1

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/metrics_per_query.csv.

Q09, Q12 và Q14 đạt 10/10 nhãn 2 ở full-document hybrid. Q18 chỉ 1/10 và bài đầu tiên ở rank 5; Q17 đạt 2/10; Q20 không có bài nhãn 2 trong Top 10 dù pool có một bài. Những trường hợp này gợi ý lỗi điều kiện/intent, không chứng minh mọi tài liệu trong corpus đều không phù hợp.

Bảng 6.4: Tính DCG từ output Q01, full-document hybrid.

Rank	Grade	Gain	log2(rank+1)	DCG thành phần
1	1	1	1,0000	1,00000
2	2	3	1,5850	1,89279
3	2	3	2,0000	1,50000
4	2	3	2,3219	1,29203
5	2	3	2,5850	1,16056
6	2	3	2,8074	1,06862
7	2	3	3,0000	1,00000
8	2	3	3,1699	0,94639
9	2	3	3,3219	0,90309
10	2	3	3,4594	0,86719

$DCG = 11,630678$, $IDCG = 13,630678$, $nDCG = 0,853272$; $P@10 = 0,9$, $RR@10 = 0,5$. Bảng tính sử dụng đúng grades theo thứ hạng và IDCG từ pool. Nếu chỉ kiểm tra tiêu đề hoặc nhìn cosine, kết quả có thể bị đánh giá quá cao. Q08 là phản ví dụ quan trọng cho việc dùng nDCG riêng lẻ như thước đo thành công tuyệt đối.

6.7 Bất định, độ nhạy và kiểm chứng số học

Bootstrap 10.000 lần theo query, seed 20261026, dùng cùng resamples cho mọi method. CI95% full-document hybrid là P@10[0,395;0,685], nDCG@10[0,6793;0,8534], MRR@10[0,6117;0,9250]. Đây là bất định do20 query với nhãn giữ cố định, không bao gồm sai số AI judge. Paired CI với BGE và BatteryBERT hybrid chứa 0 cho cả ba chỉ số, nên chưa kết luận thắng chắc chắn.

Thay đồng thời70 nhãn review thành 0 hoặc2 cho P@10 full-document hybrid0,525/0,600; đây là kịch bản nhạy cảm, không phải nhãn mới hoặc cận tin cậy. Đếm cả nhãn 1 làm relevance sẽ nâng điểm nhưng đổi câu hỏi đánh giá. Các45 so sánh thăm dò chưa hiệu chỉnh đa kiểm định.

Evaluator kiểm đủ 120 nhóm query–method và 1.200 vị trí Top 10, rank 1–10 liên tục, mọi ID thuộc pool và text khớp nguồn. nDCG được đối chiếu sklearn trên 120 nhóm với sai lệch tối đa $4,44 \times 10^{-16}$; P/MRR đối chiếu trực tiếp. Đây là kiểm chứng phép tính, không phải chứng minh nhãn AI đúng.

Bảng 6.5: Các lỗi search cần ưu tiên sau phân tích nhãn.

Query	Vấn đề
Q04–Q06	Đúng họ cathode nhưng thiếu water/vacancy/coating/low-cost; role labels có thể mâu thuẫn.
Q08	Chưa có nhãn 2 trong pool cho NaFSI + ether + nhiệt độ thấp.
Q16	Nhầm electrode coating với particle coating, film wrapping hoặc cutting.
Q17	BMS và voltage balancing không tự là thermal management ở cấp pack.
Q18	Nhầm tái chế nguyên liệu ngoài SIB để chế tạo anode với tái chế spent SIB.
Q20	HC, layered oxide và electrolyte additive phải cùng một full cell.

6.8 Tổng hợp lỗi và giới hạn kết luận

Một bộ20 queries và nhãn AI chưa đại diện mọi người dùng, ngôn ngữ hay hướng vật liệu. Pool hữu hạn có thể thiếu tài liệu tốt ngoài sáu methods. Vì vậy kết luận chính là chất lượng tương đối trên protocol đã mô tả; cần human annotation và query families mới trước khi công bố ưu thế khái quát.

Chương 7

Mười topic của từng mô hình và phân tích

7.1 Cách đọc catalog

Phần này đưa đủ bảy catalog: sáu catalog đã xuất ngày 24/10 và catalog stable topics mới nhất. Mỗi catalog có đúng 10 topic, mỗi topic có tên diễn giải, số tài liệu và đủ 10 keywords đúng thứ hạng. ID chỉ có ý nghĩa nội bộ; topic 0 của hai model không tự tương ứng. BERTopic còn có outlier -1 ngoài 10 topic. KMeans luôn gán mọi tài liệu, nên không dùng outlier 0 để tuyên bố chính xác hơn.

Mỗi hình keywords lấy trọng số đúng file kết quả của model; thang weight không dùng so trực tiếp giữa LDA, c-TF-IDF và weighting source-corrected. Tên gọi chưa là nhãn chuyên gia. Các từ rộng hoặc thao tác như solution/dry vẫn giữ trong bảng để phản ánh output thật; không sửa danh sách sau khi nhìn điểm.

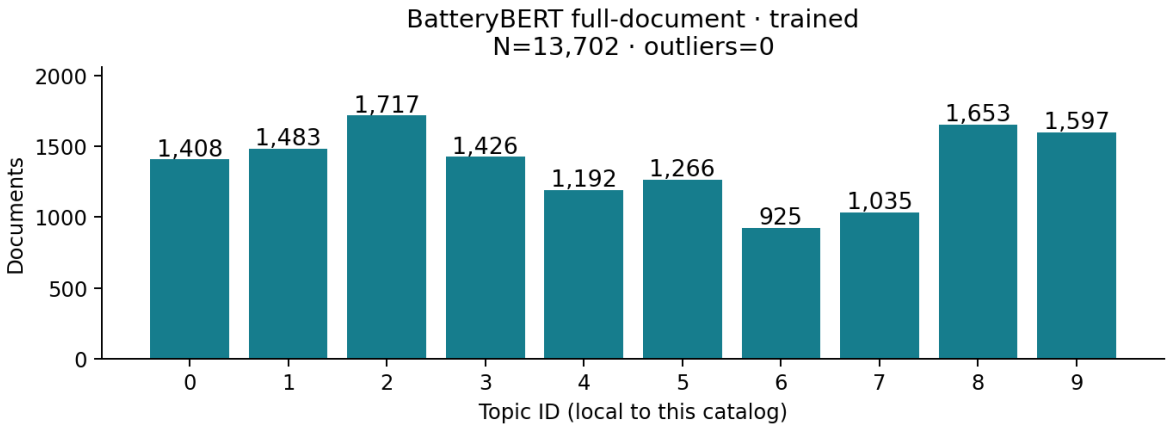
7.2 BatteryBERT full-document · trained

Catalog có 10 topic; 13.702 tài liệu được gán topic và 0 outliers ngoài catalog.

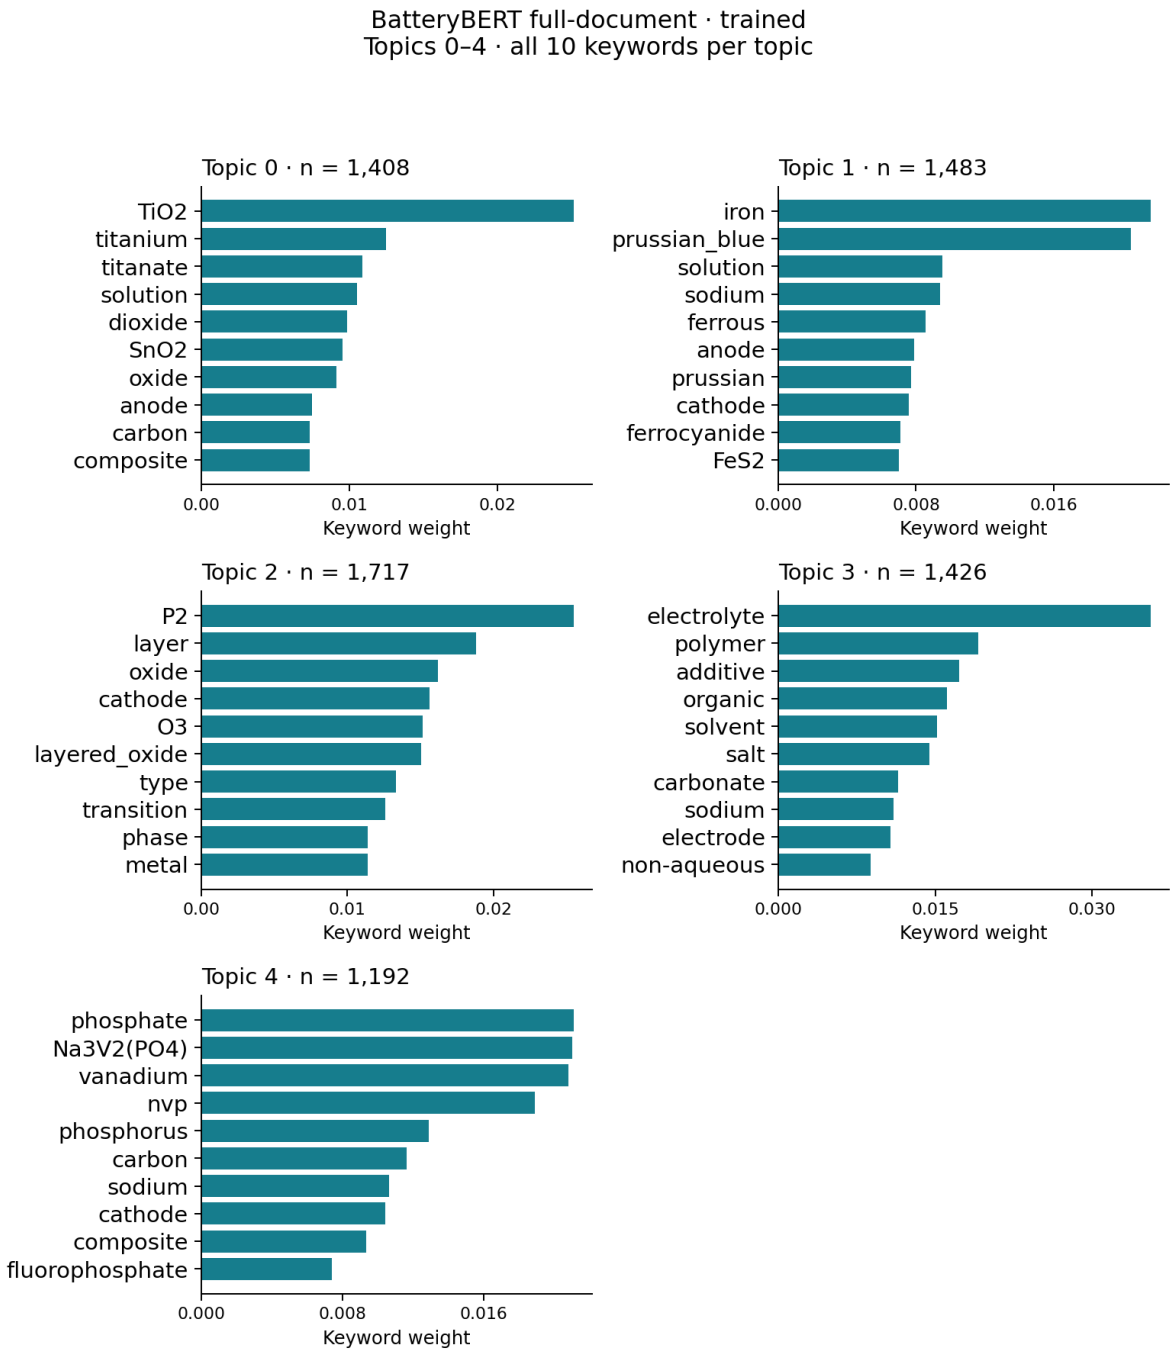
Bảng 7.1: Đủ10 topic và 10 keywords/topic: BatteryBERT full-document · trained

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 1.408	Oxide Ti/Sn, titanate và composite điện cực TiO2, titanium, titanate, solution, dioxide, SnO2, oxide, anode, carbon, composite
1 / 1.483	Prussian blue và các hợp chất điện cực chứa sắt iron, prussian_blue, solution, sodium, ferrous, anode, prussian, cathode, ferrocyanide, FeS2
2 / 1.717	Oxide lớp P2/O3 và biến đổi cấu trúc điện cực P2, layer, oxide, cathode, O3, layered_oxide, type, transition, phase, metal
3 / 1.426	Điện ly, polymer, muối và phụ gia giao diện electrolyte, polymer, additive, organic, solvent, salt, carbonate, sodium, electrode, non-aqueous
4 / 1.192	Phosphate vanadium, NVP/NASICON và composite carbon phosphate, Na3V2(PO4), vanadium, nvp, phosphorus, carbon, sodium, cathode, composite, fluorophosphate
5 / 1.266	Anode hợp kim Sn/Sb, graphene và MXene graphene, antimony, mxene, sb, anode, composite, sn, alloy, electrode, tin
6 / 925	Phần cứng cell và thiết bị chế tạo, kiểm tra pin connect, plate, device, end, pole, piece, body, electric, electrode, collector
7 / 1.035	Cấu trúc pha, trật tự vacancy và dẫn ion phase, na, NaxCoO2, sodium, compound, electrode, cathode, ion, solid_electrolyte, active
8 / 1.653	Hard carbon, carbon xốp và tiền chất sinh khối hard_carbon, carbon, biomass, porous, carbonize, precursor, carbonization, dry, asphalt, anode
9 / 1.597	Sulfide/selenide, MoS2 và composite carbon MoS2, sulfide, disulfide, molybdenum, carbon, composite, selenide, anode, solution, SnS2

Nguồn: outputs/batterybert_full_document_20261024_v1/topics/topic_keywords.csv; topic_assignments.csv.

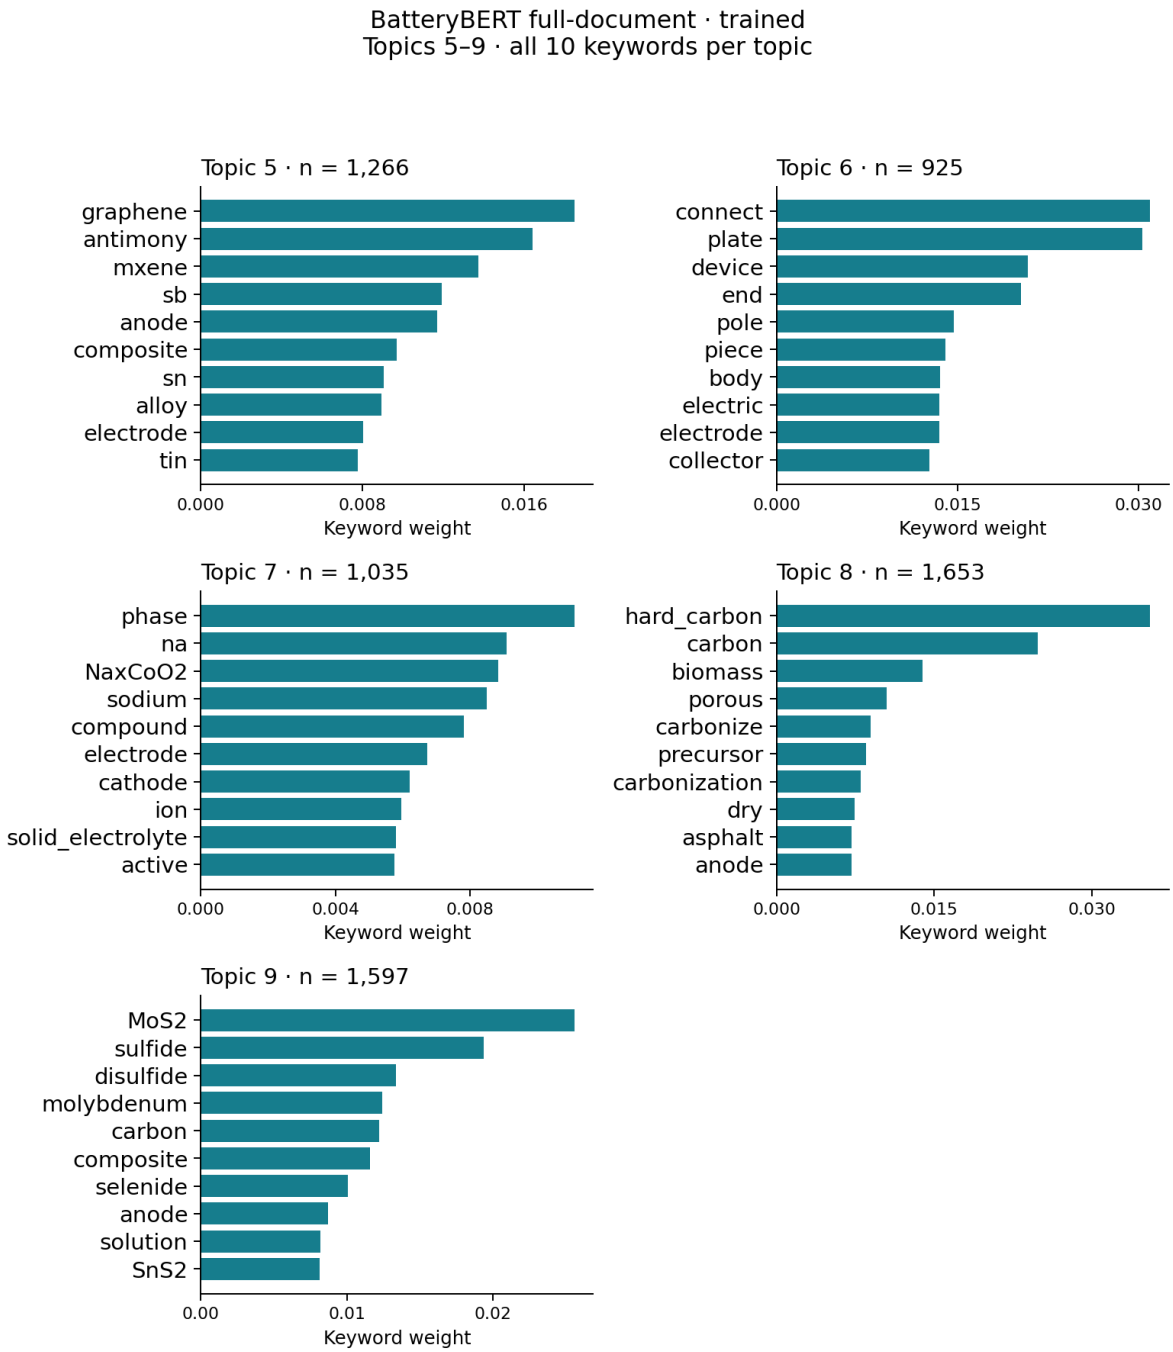


Hình 7.1: Phân bố đầy đủ 10 topic: BatteryBERT full-document · trained
Nguồn:
outputs/batterybert_full_document_20261024_v1/topics/topic_assignments.csv.



Hình 7.2: Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT full-document · trained

Nguồn: outputs/batterybert_full_document_20261024_v1/topics/topic_keywords.csv.



Hình 7.3: Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT full-document · trained

Nguồn: outputs/batterybert_full_document_20261024_v1/topics/topic_keywords.csv.

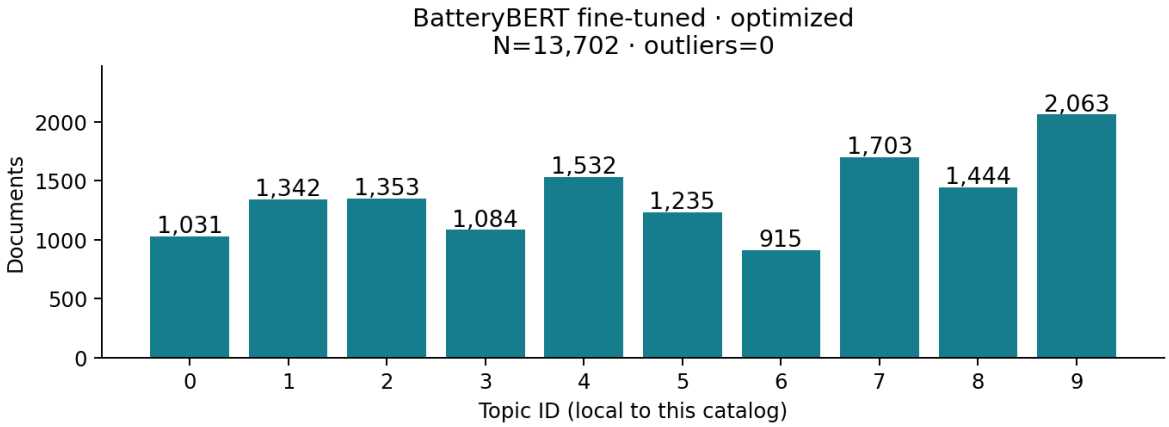
7.3 BatteryBERT fine-tuned · optimized

Catalog có 10 topic; 13.702 tài liệu được gán topic và 0 outliers ngoài catalog.

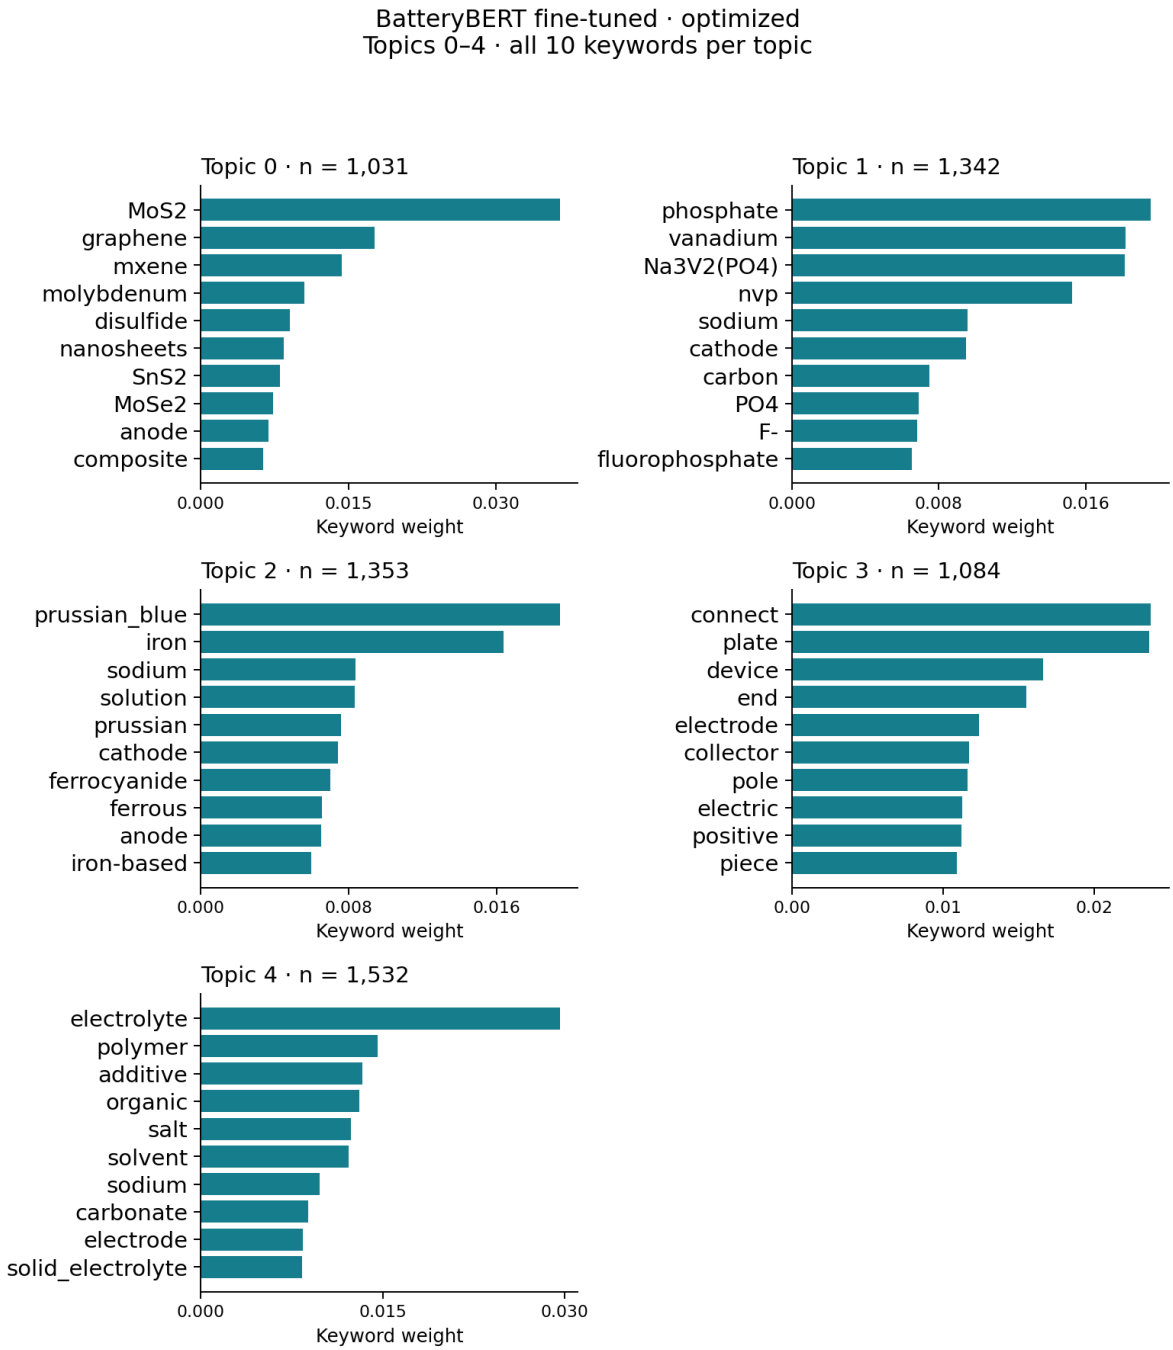
Bảng 7.2: Đủ10 topic và 10 keywords/topic: BatteryBERT fine-tuned · optimized

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 1.031	Anode MoS2, dichalcogenide lớp và MXene MoS2, graphene, mxene, molybdenum, disulfide, nanosheets, SnS2, MoSe2, anode, composite
1 / 1.342	Cathode phosphate vanadium và NASICON phosphate, vanadium, Na3V2(PO4), nvp, sodium, cathode, carbon, PO4, F-, fluorophosphate
2 / 1.353	Cathode Prussian blue và hợp chất sắt prussian_blue, iron, sodium, solution, prussian, cathode, ferrocyanide, ferrous, anode, iron-based
3 / 1.084	Cấu trúc cell, bộ góp dòng và lắp ráp pin connect, plate, device, end, electrode, collector, pole, electric, positive, piece
4 / 1.532	Điện ly, muối, dung môi và polymer electrolyte, polymer, additive, organic, salt, solvent, sodium, carbonate, electrode, solid_electrolyte
5 / 1.235	Anode sulfide/selenide và composite carbon sulfide, carbon, composite, selenide, CoSe2, cobalt, FeS2, anode, solution, nickel
6 / 915	Anode hợp kim Sn/Sb, phosphorus và chuyển hóa antimony, sb, tin, sn, anode, alloy, composite, carbon, phosphorus, Sb2S3
7 / 1.703	Hard carbon, carbon xốp và tiền chất sinh khối hard_carbon, carbon, biomass, porous, carbonize, precursor, carbonization, dry, anode, asphalt
8 / 1.444	Anode oxide Ti/Sn và titanate TiO2, titanium, titanate, dioxide, SnO2, solution, oxide, anode, sodium, composite
9 / 2.063	Cathode oxide lớp P2/O3 và kim loại chuyển tiếp P2, layer, oxide, cathode, O3, layered_oxide, phase, transition, type, metal

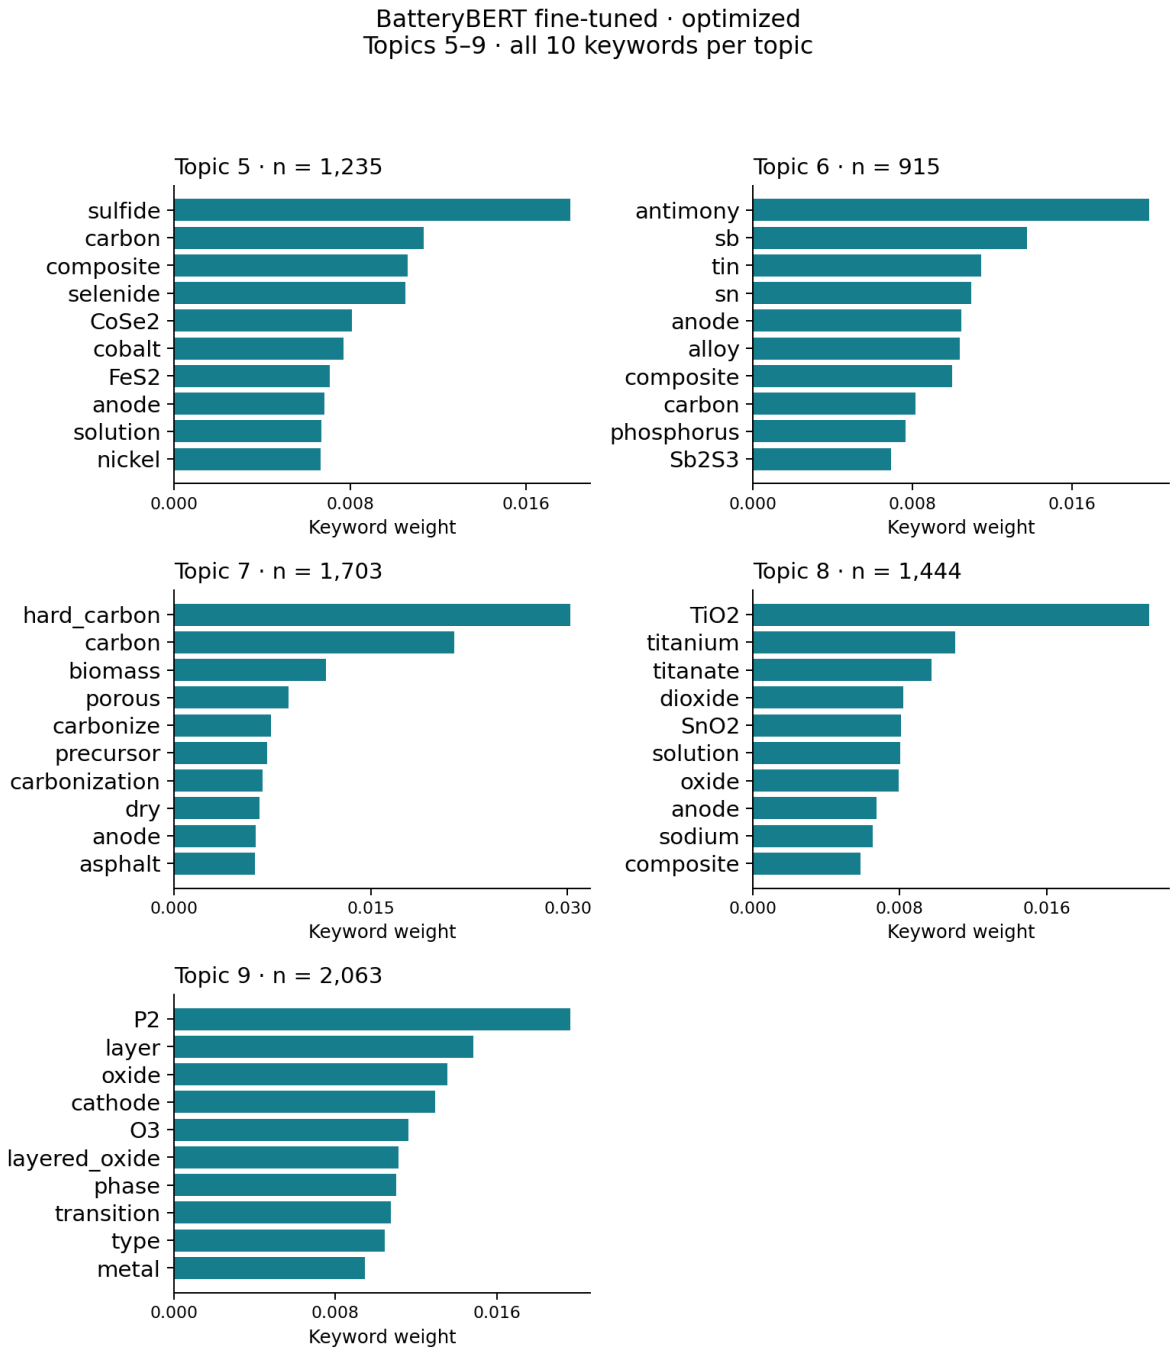
Nguồn: outputs/batterybert_optimization_20261023_v1/topic_keywords.csv;topic_assignments.csv.



Hình 7.4: Phân bố đầy đủ 10 topic: BatteryBERT fine-tuned · optimized
Nguồn: outputs/batterybert_optimization_20261023_v1/topic_assignments.csv.



Hình 7.5: Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT fine-tuned · optimized
Nguồn: outputs/batterybert_optimization_20261023_v1/topic_keywords.csv.



Hình 7.6: Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT fine-tuned · optimized
Nguồn: outputs/batterybert_optimization_20261023_v1/topic_keywords.csv.

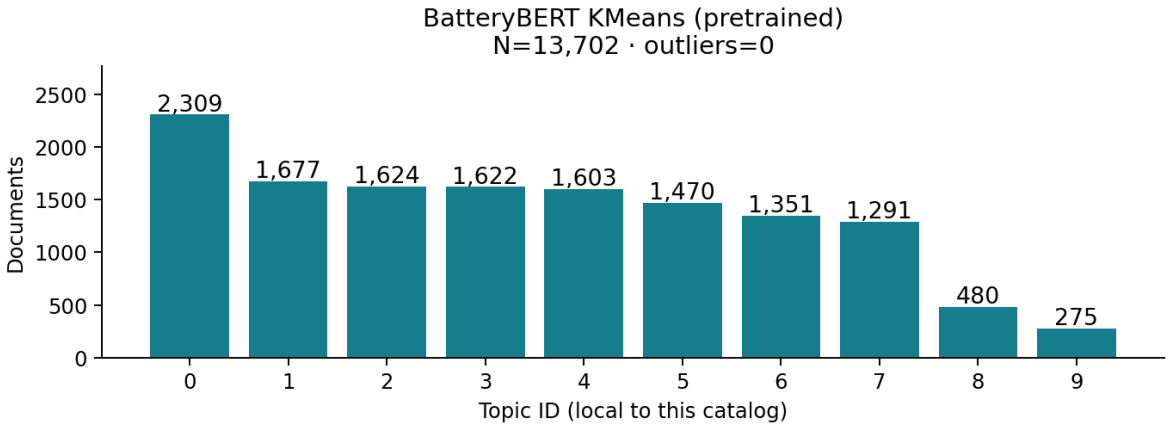
7.4 BatteryBERT KMeans (pretrained)

Catalog có 10 topic; 13.702 tài liệu được gán topic và 0 outliers ngoài catalog.

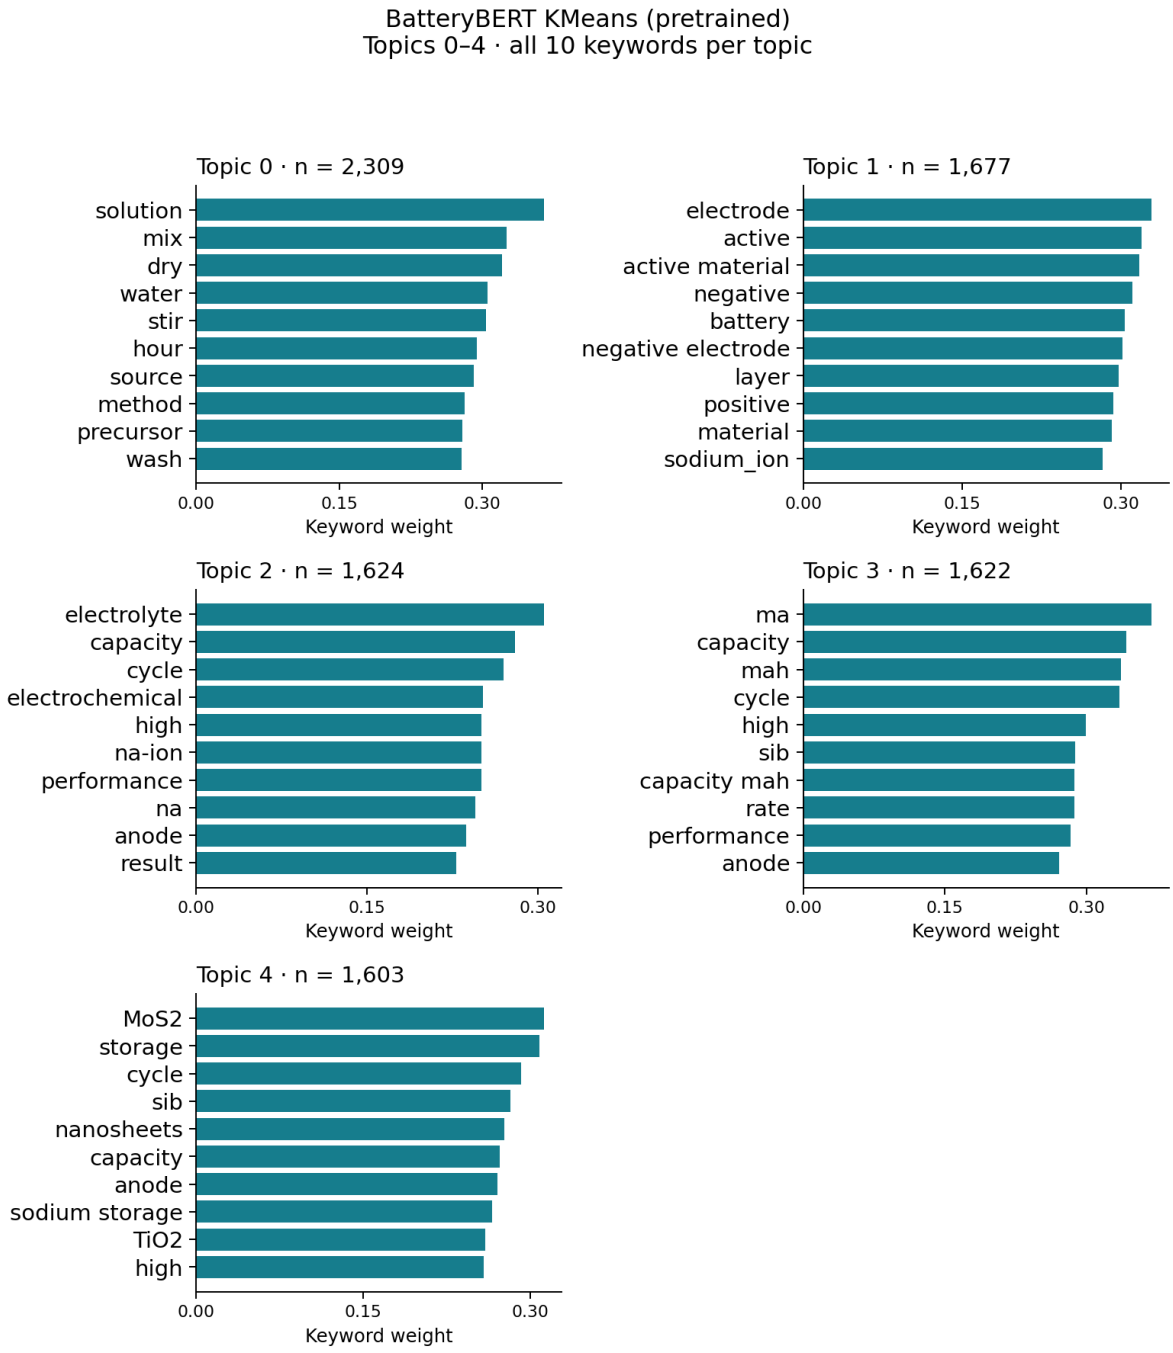
Bảng 7.3: Đủ10 topic và 10 keywords/topic: BatteryBERT KMeans (pretrained)

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 2.309	Wet-chemical synthesis of electrode materials solution, mix, dry, water, stir, hour, source, method, precursor, wash
1 / 1.677	Active-material formulations and electrode coatings electrode, active, active material, negative, battery, negative electrode, layer, positive, material, sodium_ion
2 / 1.624	Mixed electrode performance and electrolyte studies electrolyte, capacity, cycle, electrochemical, high, na-ion, performance, na, anode, result
3 / 1.622	Anode composites and cycling performance ma, capacity, mah, cycle, high, sib, capacity mah, rate, performance, anode
4 / 1.603	Sulfide/selenide-carbon composite anodes MoS2, storage, cycle, sib, nanosheets, capacity, anode, sodium storage, TiO2, high
5 / 1.470	Inorganic electrode compositions and chemical claims sodium, formula, material, metal, oxide, anode material, compound, anode, sodium_ion, sodium_ion battery
6 / 1.351	Layered-oxide and phosphate cathode materials P2, cathode, capacity, Na3V2(PO4), type, cycle, cathode material, O3, electrochemical, P2 type
7 / 1.291	Crystal structure, redox and intercalation studies na, phase, redox, structural, na-ion, property, Na+, structure, x-ray, diffusion
8 / 480	Cell hardware and assembly equipment connect, plate, device, end, box, rod, cover, fix, electric, groove
9 / 275	Reviews and research perspectives sib, application, energy_storage, advance, design, strategy, mechanism, focus, perspective, cost

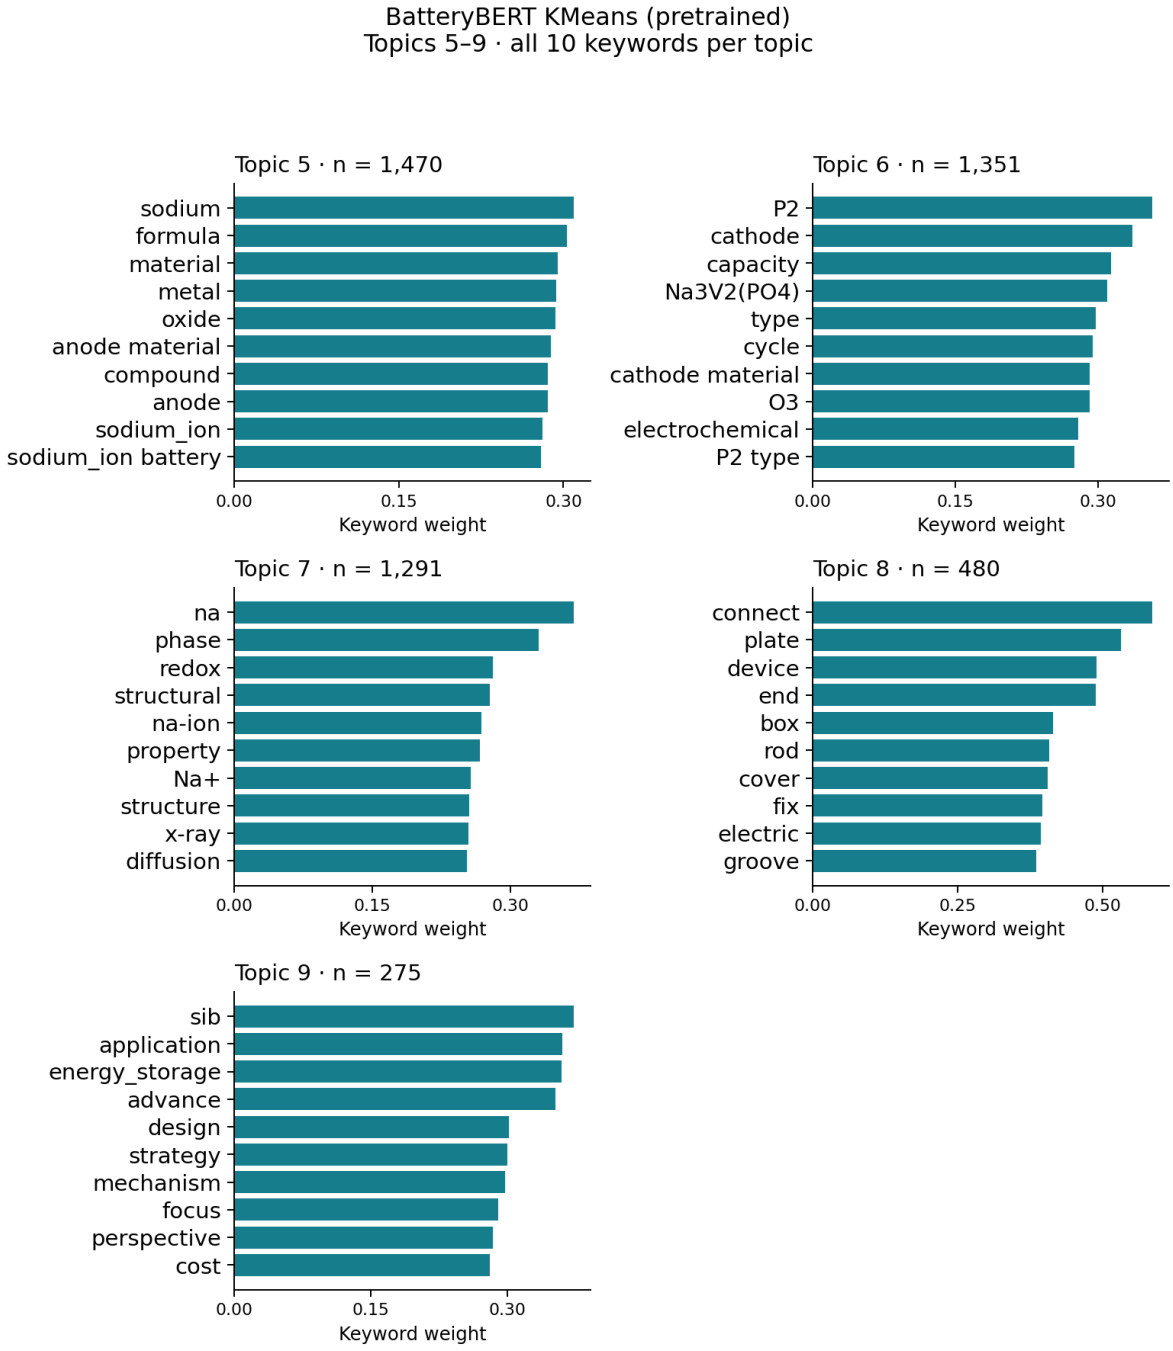
Nguồn: outputs/research_completion_v1/topics/topic_keywords.csv;topic_assignments.csv.



Hình 7.7: Phân bố đầy đủ 10 topic: BatteryBERT KMeans (pretrained)
Nguồn: outputs/research_completion_v1/topics/topic_assignments.csv.



Hình 7.8: Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT KMeans (pretrained)
Nguồn: outputs/research_completion_v1/topics/topic_keywords.csv.



Hình 7.9: Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT KMeans (pretrained)
Nguồn: outputs/research_completion_v1/topics/topic_keywords.csv.

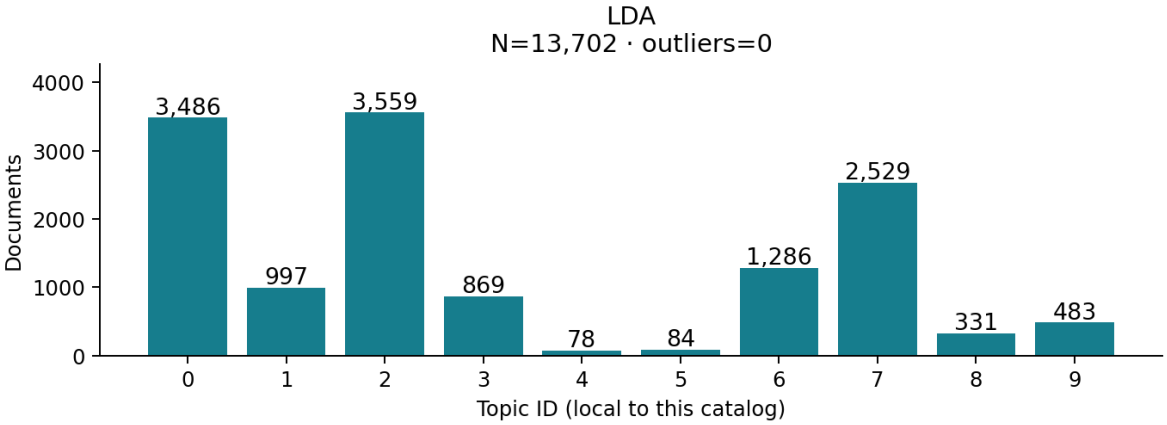
7.5 LDA

Catalog có 10 topic; 13.702 tài liệu được gán topic và 0 outliers ngoài catalog.

Bảng 7.4: Đủ10 topic và 10 keywords/topic: LDA

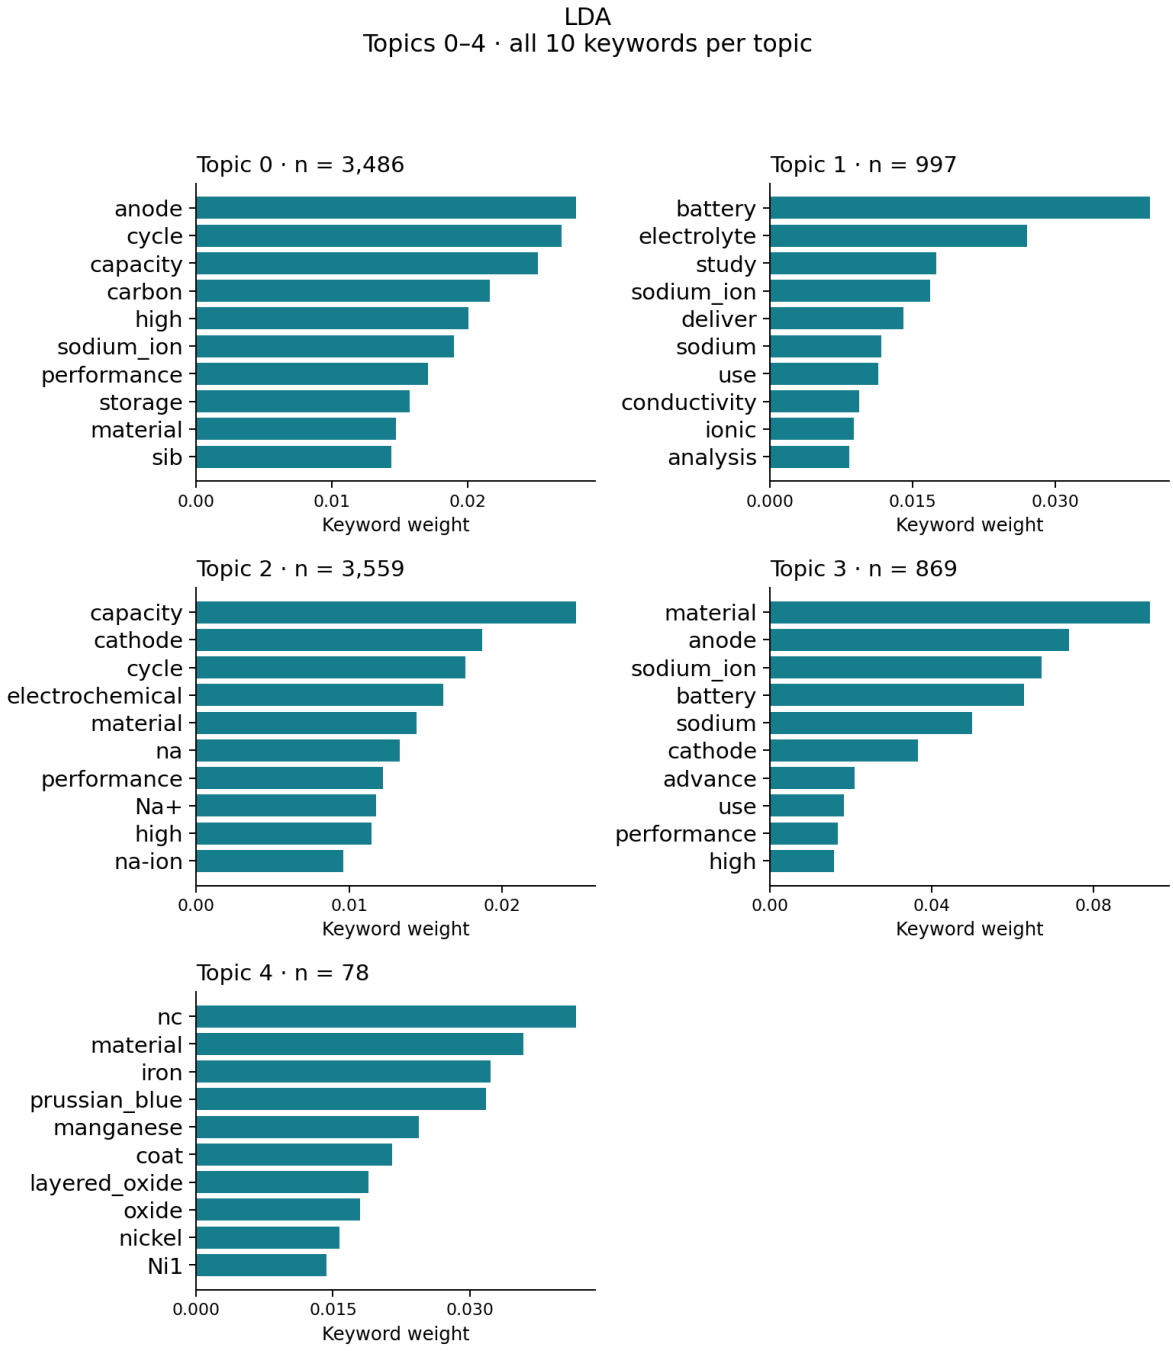
ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 3.486	Sodium-storage anodes and carbon composites anode, cycle, capacity, carbon, high, sodium_ion, performance, storage, material, sib
1 / 997	Non-aqueous electrolytes and ionic transport battery, electrolyte, study, sodium_ion, deliver, sodium, use, conductivity, ionic, analysis
2 / 3.559	Cathode electrochemistry and vanadium phosphates capacity, cathode, cycle, electrochemical, material, na, performance, Na+, high, na-ion
3 / 869	Electrode-material inventions (mixed materials) material, anode, sodium_ion, battery, sodium, cathode, advance, use, performance, high
4 / 78	Transition-metal and Prussian-white formulations nc, material, iron, prussian_blue, manganese, coat, layered_oxide, oxide, nickel, Ni1
5 / 84	Layered oxide cathodes and P2/O3 structures layer, transition, P2, phase, metal, cathode, oxide, type, O3, material
6 / 1.286	Active electrode materials and characterization electrode, battery, material, use, sodium_ion, positive, layer, spectroscopy, active, negative
7 / 2.529	Material synthesis and preparation processes solution, obtain, material, prepare, development, mix, add, battery, sodium_ion, water
8 / 331	Battery devices, housings and assembly successfully, battery, connect, device, plate, sodium_ion, shell, provide, core, end
9 / 483	Hard-carbon preparation and related materials carbon, material, hard_carbon, precursor, mxene, obtain, prepare, method, use, temperature

Nguồn: outputs/model_comparison_v2/lda_k10/topic_keywords.csv;topic_assignments.csv.

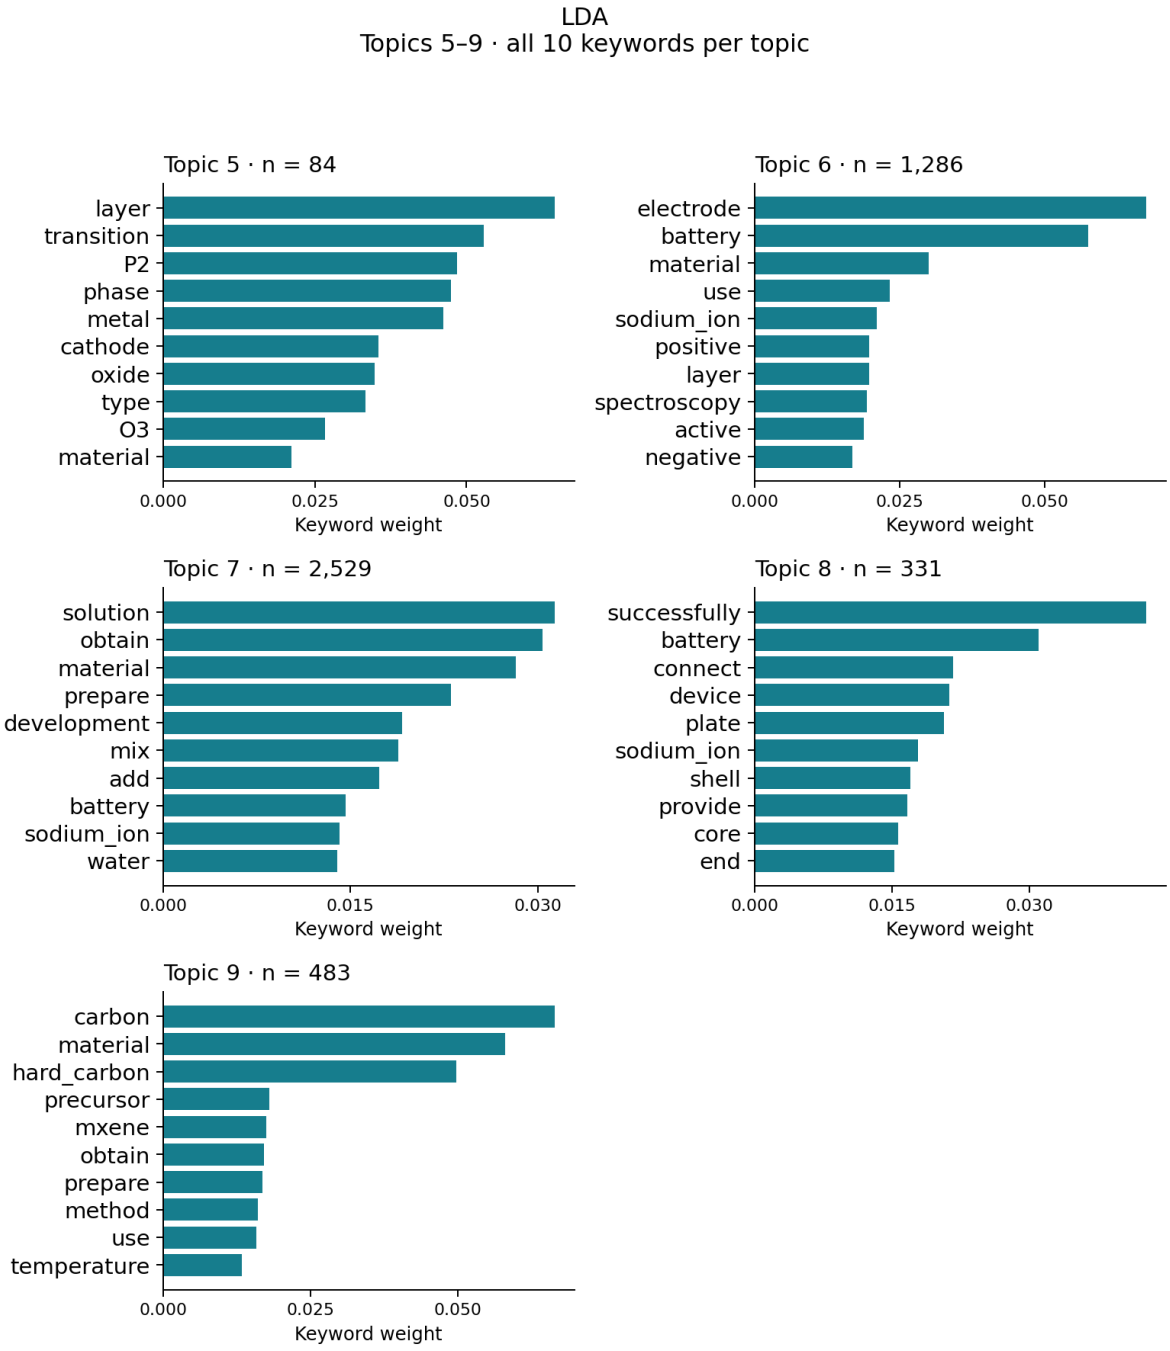


Hình 7.10: Phân bố đầy đủ 10 topic: LDA

Nguồn: outputs/model_comparison_v2/lda_k10/topic_assignments.csv.



Hình 7.11: Đủ10 từ khóa và trọng số cho topic 0–4: LDA
Nguồn: outputs/model_comparison_v2/lda_k10/topic_keywords.csv.



Hình 7.12: Đủ10 từ khóa và trọng số cho topic 5–9: LDA
Nguồn: outputs/model_comparison_v2/lda_k10/topic_keywords.csv.

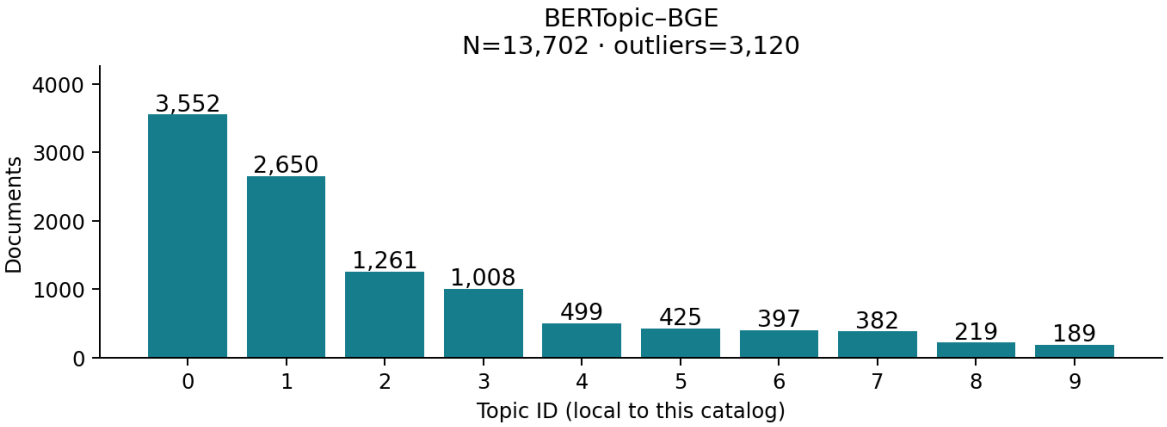
7.6 BERTopic–BGE

Catalog có 10 topic; 10.582 tài liệu được gán topic và 3.120 outliers ngoài catalog.

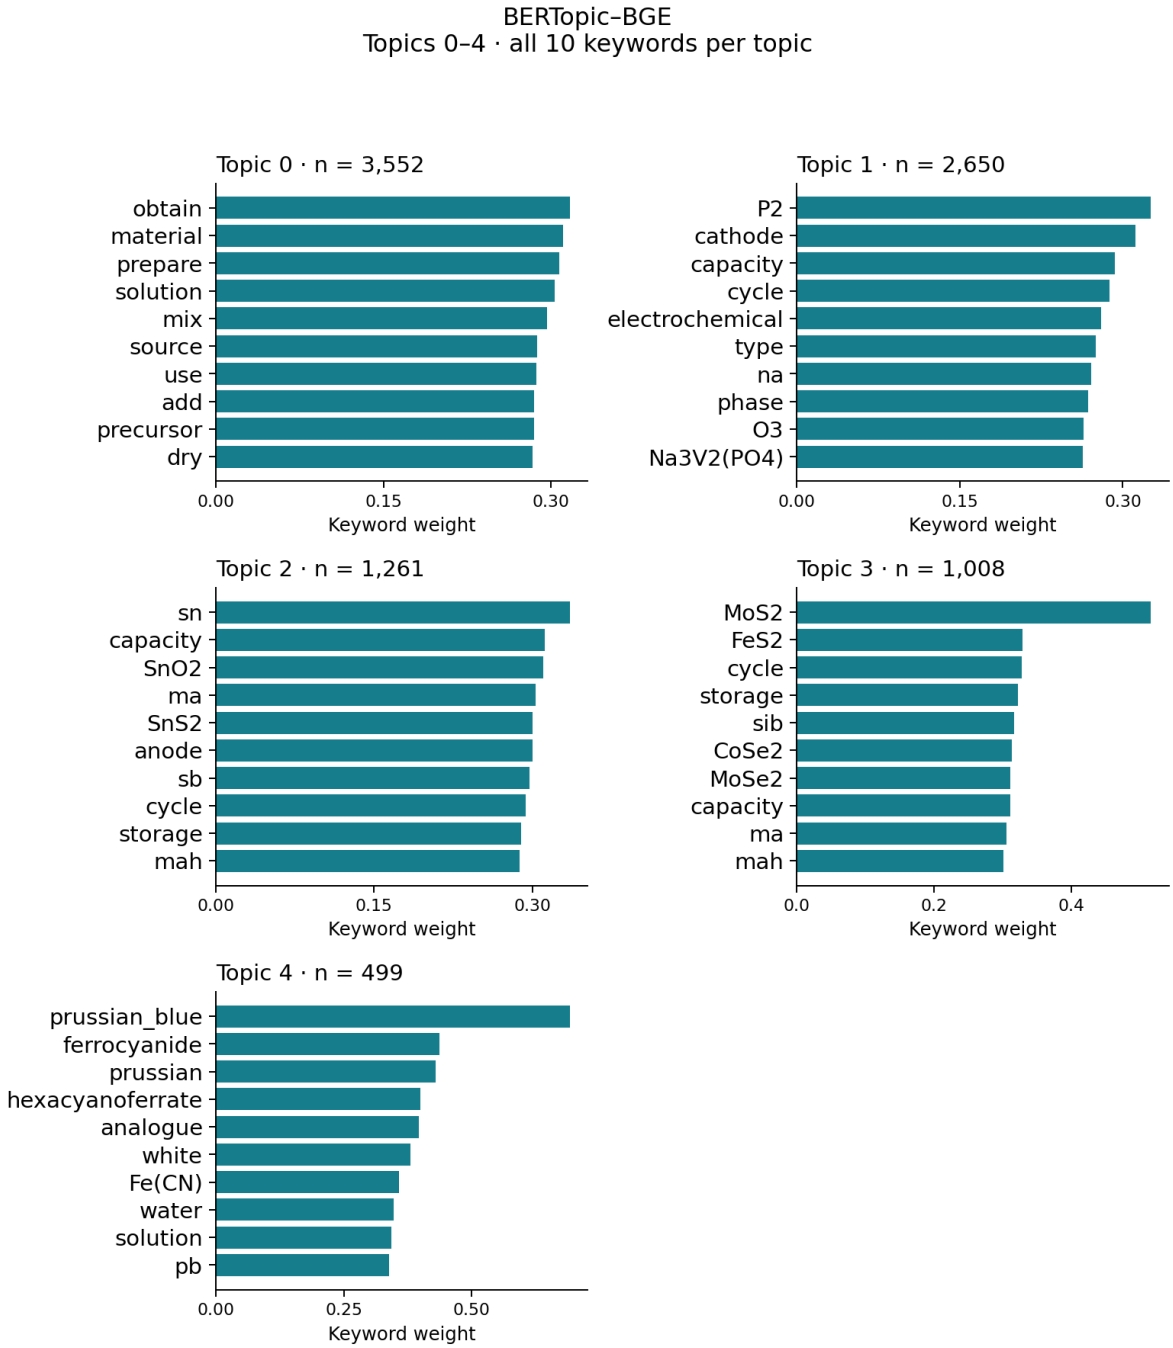
Bảng 7.5: Đủ10 topic và 10 keywords/topic: BERTopic–BGE

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 3.552	Electrode-material preparation patents obtain, material, prepare, solution, mix, source, use, add, precursor, dry
1 / 2.650	Layered-oxide and polyanion cathodes P2, cathode, capacity, cycle, electrochemical, type, na, phase, O3, Na3V2(PO4)
2 / 1.261	Alloy/conversion and carbon-based anodes sn, capacity, SnO2, ma, SnS2, anode, sb, cycle, storage, mah
3 / 1.008	Sulfide/selenide and carbon-composite anodes MoS2, FeS2, cycle, storage, sib, CoSe2, MoSe2, capacity, ma, mah
4 / 499	Prussian-blue analogue cathodes prussian_blue, ferrocyanide, prussian, hexacyanoferrate, analogue, white, Fe(CN), water, solution, pb
5 / 425	Titanate and TiO2 anodes TiO2, Na2Ti3O7, anatase, nto, ma, cycle, titanate, storage, capacity, anode
6 / 397	Electrolyte salts, solvents and additives electrolyte, additive, solvent, salt, non-aqueous, solid_electrolyte, organic, polymer, sodium, carbonate
7 / 382	Battery hardware and manufacturing devices connect, plate, device, end, fixedly, box, rod, fix, cover, frame
8 / 219	Sodium cobalt oxides and superconductivity NaxCoO2, NaCrO2, cuo, Co3O4, CoO2, superconducting, yh, superconductivity, phase, magnetic
9 / 189	MXene-based sodium-storage electrodes mxene, Ti3C2Tx, mxenes, Ti3C2, carbide, mxene-based, two-dimensional, titanium, etch, TiS2

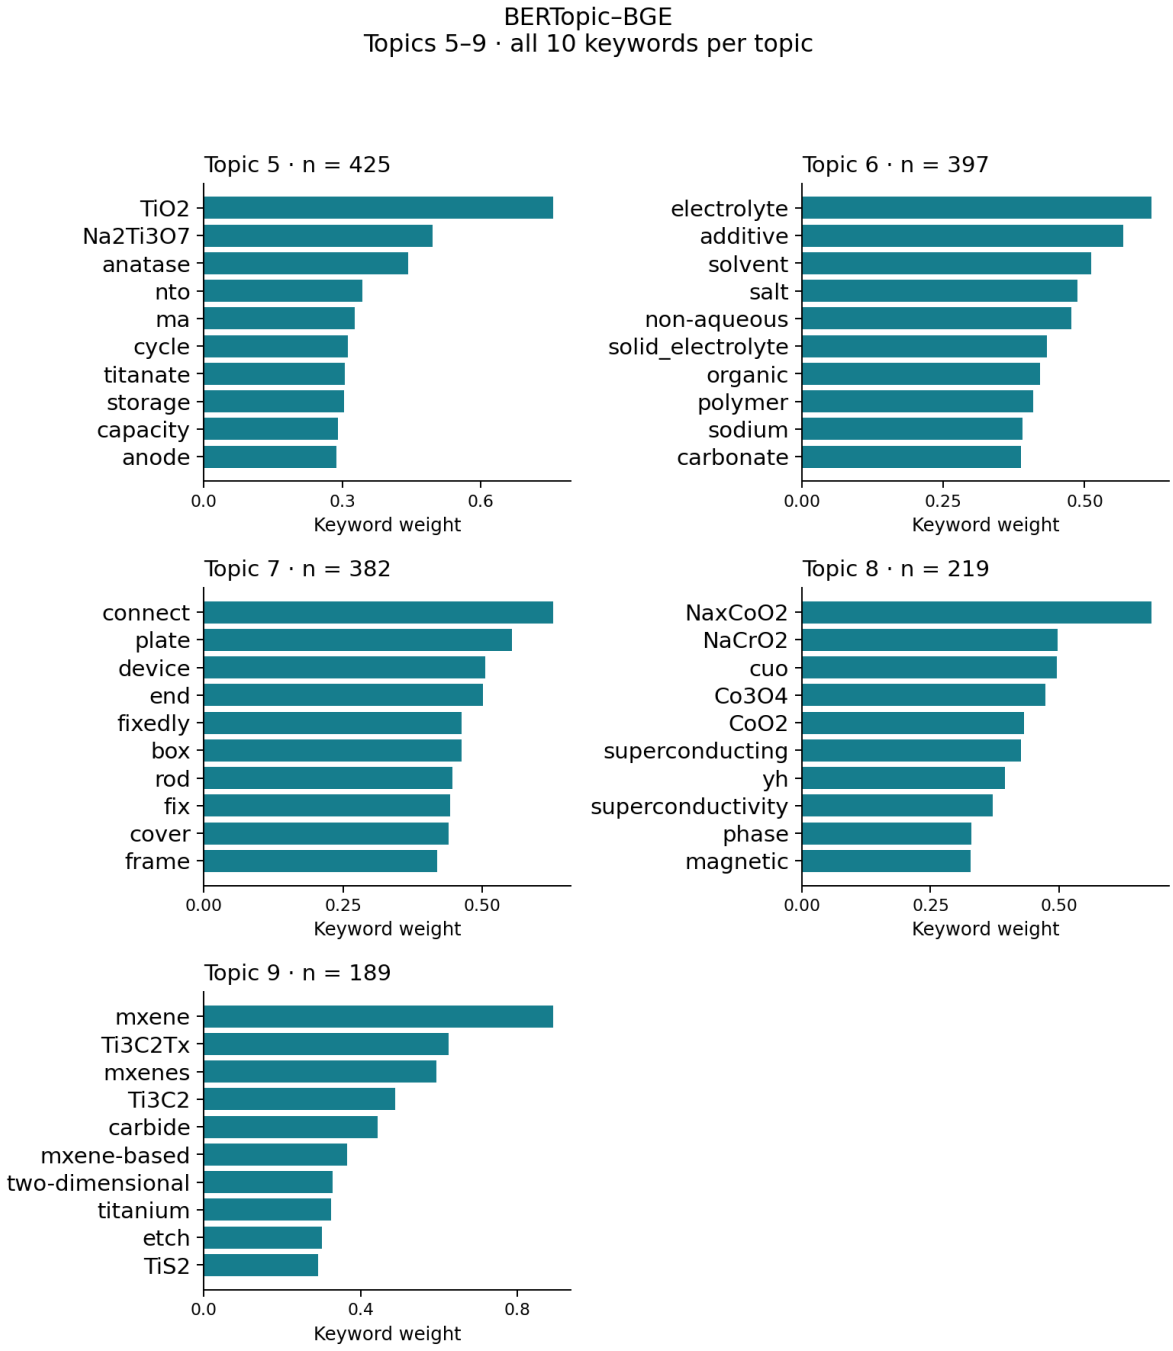
Nguồn: outputs/model_comparison_v2/bertopic_bge_k10/topic_keywords.csv;topic_assignments.csv.



Hình 7.13: Phân bố đầy đủ 10 topic: BERTopic–BGE
Nguồn: outputs/model_comparison_v2/bertopic_bge_k10/topic_assignments.csv.



Hình 7.14: Đủ10 từ khóa và trọng số cho topic 0–4: BERTopic–BGE
Nguồn: outputs/model_comparison_v2/bertopic_bge_k10/topic_keywords.csv.



Hình 7.15: Đủ10 từ khóa và trọng số cho topic 5–9: BERTopic–BGE
Nguồn: outputs/model_comparison_v2/bertopic_bge_k10/topic_keywords.csv.

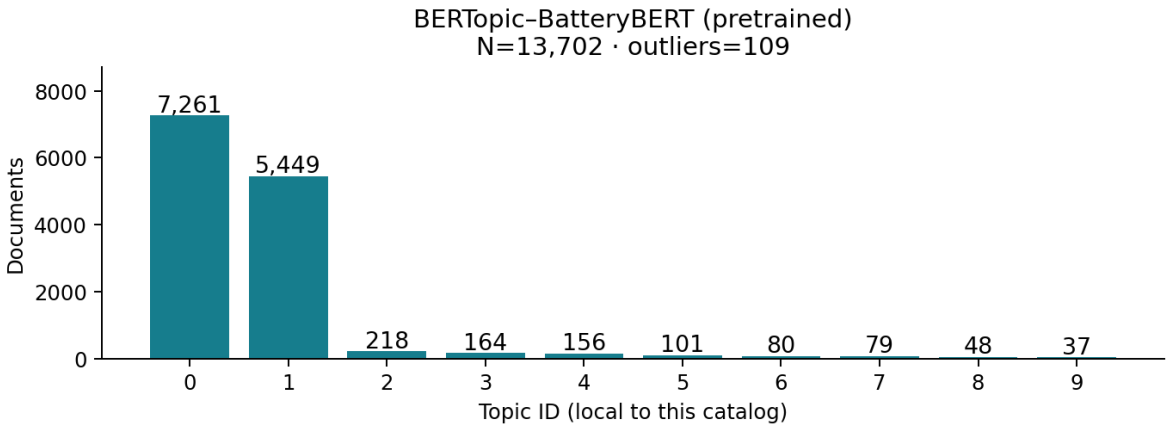
7.7 BERTopic–BatteryBERT (pretrained)

Catalog có 10 topic; 13.593 tài liệu được gán topic và 109 outliers ngoài catalog.

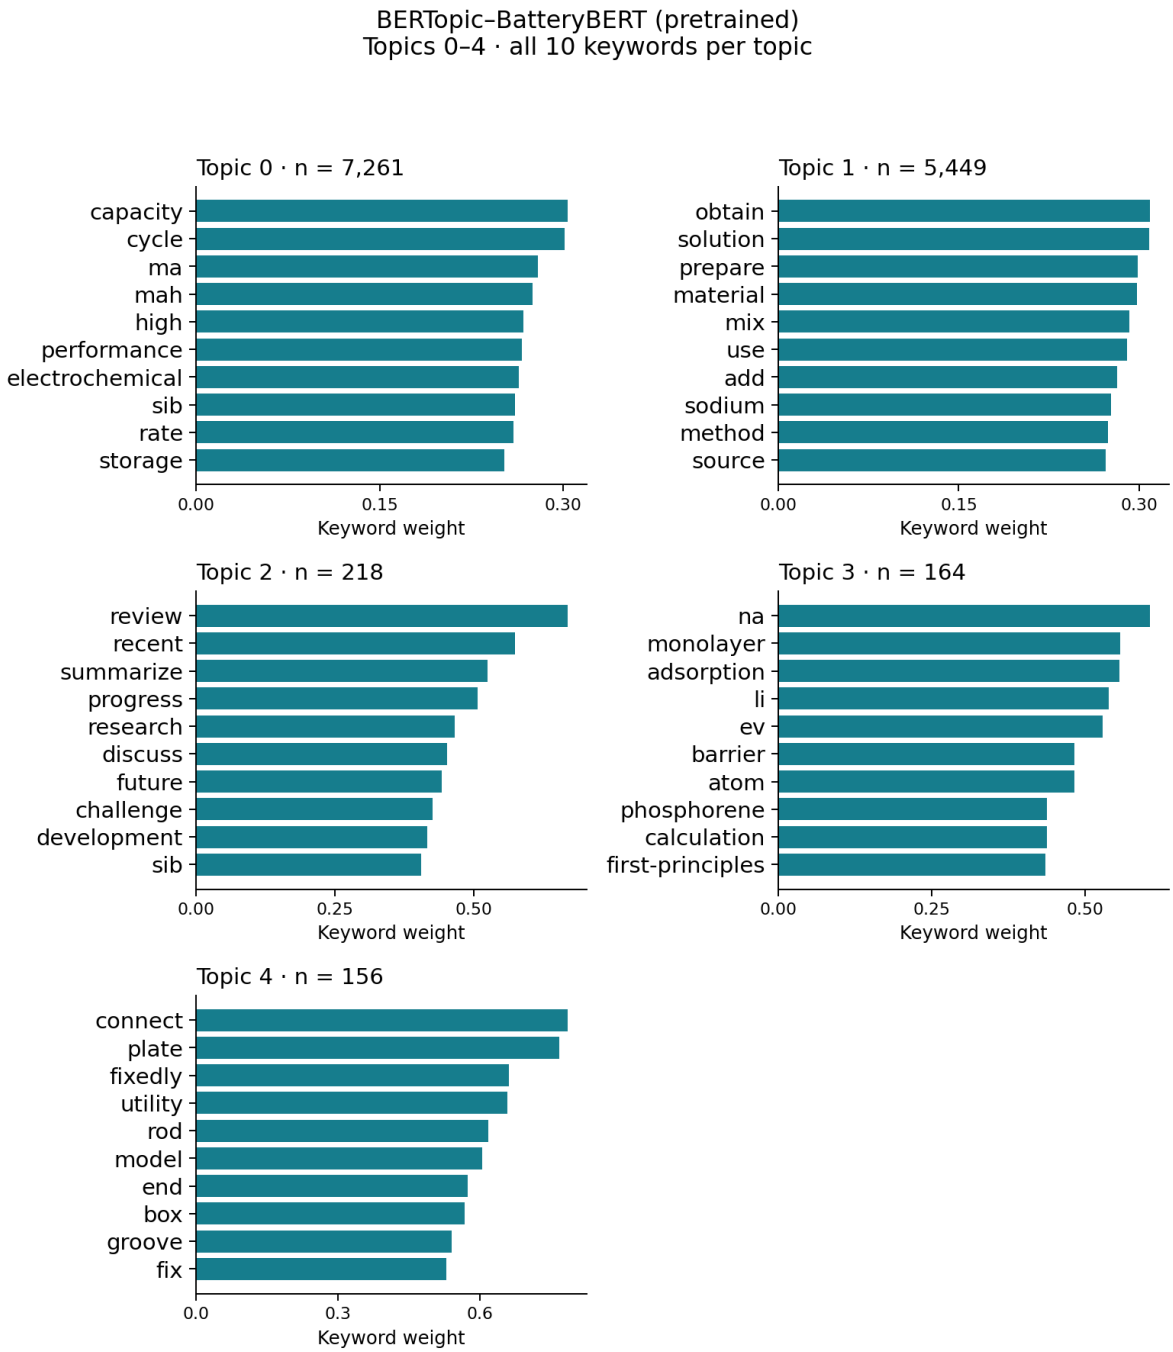
Bảng 7.6: Đủ10 topic và 10 keywords/topic: BERTopic–BatteryBERT (pretrained)

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 7.261	Electrode performance (broad Publication cluster) capacity, cycle, ma, mah, high, performance, electrochemical, sib, rate, storage
1 / 5.449	Material preparation methods (broad Patent cluster) obtain, solution, prepare, material, mix, use, add, sodium, method, source
2 / 218	Reviews and research outlook review, recent, summarize, progress, research, discuss, future, challenge, development, sib
3 / 164	2D anodes and first-principles calculations na, monolayer, adsorption, li, ev, barrier, atom, phosphorene, calculation, first-principles
4 / 156	Fixtures, protection and inspection equipment connect, plate, fixedly, utility, rod, model, end, box, groove, fix
5 / 101	Assembly, heating and mechanical equipment device, connect, plate, fix, frame, rotate, roller, rod, box, end
6 / 80	Battery packs, management and control module, unit, voltage, pack, data, battery, charge, power, management, detect
7 / 79	Sodium cobaltate superconductivity NaxCoO2, superconducting, yh, CoO2, superconductivity, magnetic, t-c, center, dot, superconductor
8 / 48	Cell housing and terminals portion, terminal, electric, monomer, assembly, toy, second, cover, end, direction
9 / 37	Mixed high-performance electrode materials high-performance, snsb-porous, vapor-redistribution, Se4P4, Na2C12H6O4, ultracycle-stable, photoassisted, krohnkite-type, na-ion, superior

Nguồn: outputs/model_comparison_v2/bertopic_batterybert_k10/pretrained/topic_keywords.csv;topic_assignments.csv.

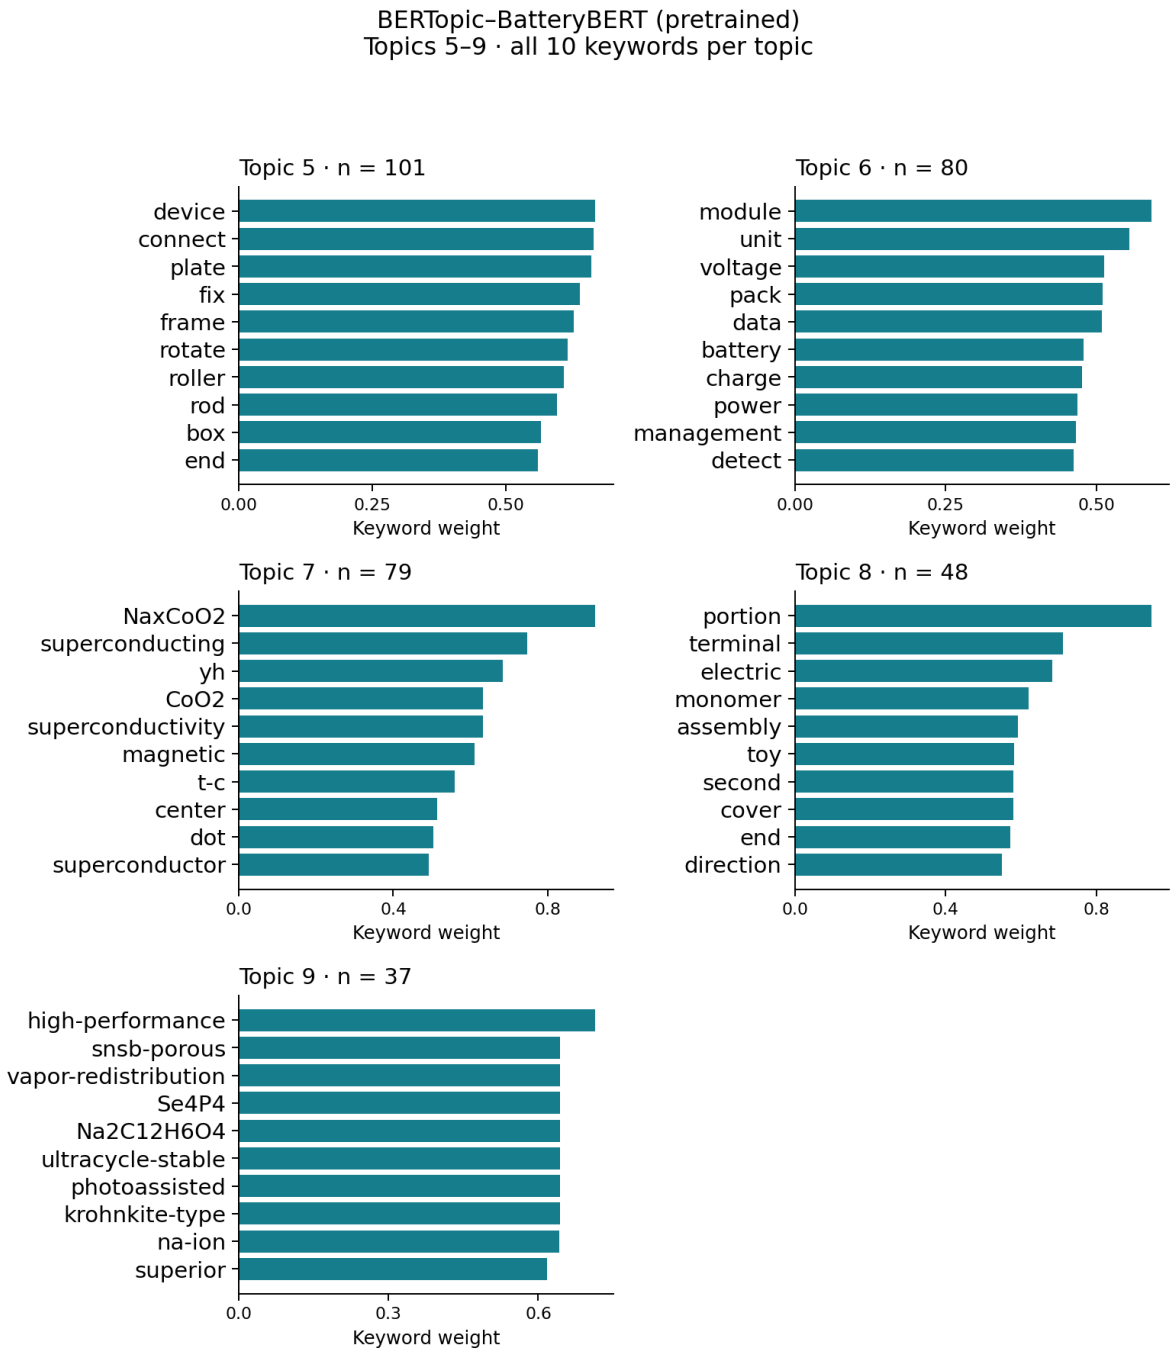


Hình 7.16: Phân bố đầy đủ 10 topic: BERTopic–BatteryBERT (pretrained)
Nguồn: outputs/model_comparison_v2/bertopic_batterybert_k10/pretrained/topic_assignments.csv.



Hình 7.17: Đủ10 từ khóa và trọng số cho topic 0–4: BERTopic–BatteryBERT (pretrained)

Nguồn: outputs/model_comparison_v2/bertopic_batterybert_k10/pretrained/topic_keywords.csv.



Hình 7.18: Đủ10 từ khóa và trọng số cho topic 5–9: BERTopic–BatteryBERT (pretrained)

Nguồn: outputs/model_comparison_v2/bertopic_batterybert_k10/pretrained/topic_keywords.csv.

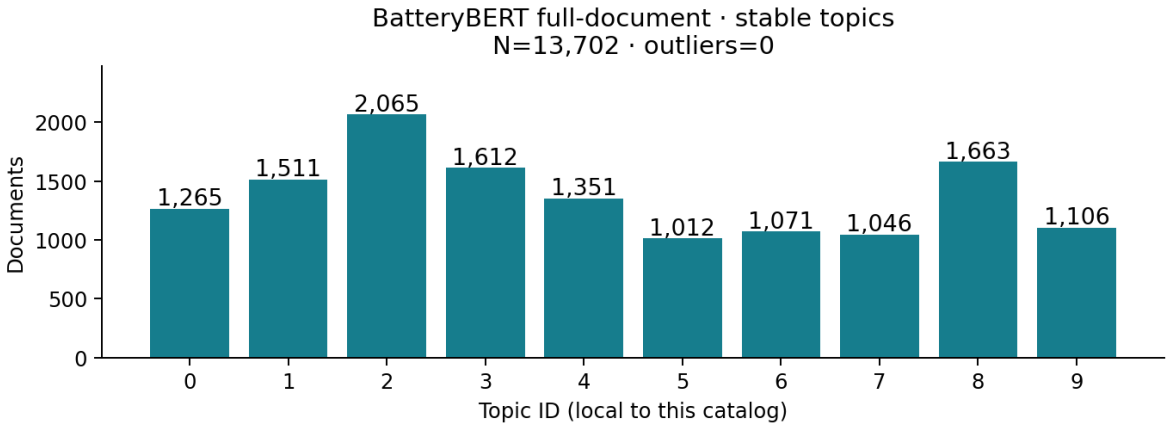
7.8 BatteryBERT full-document · stable topics

Catalog có 10 topic; 13.702 tài liệu được gán topic và 0 outliers ngoài catalog.

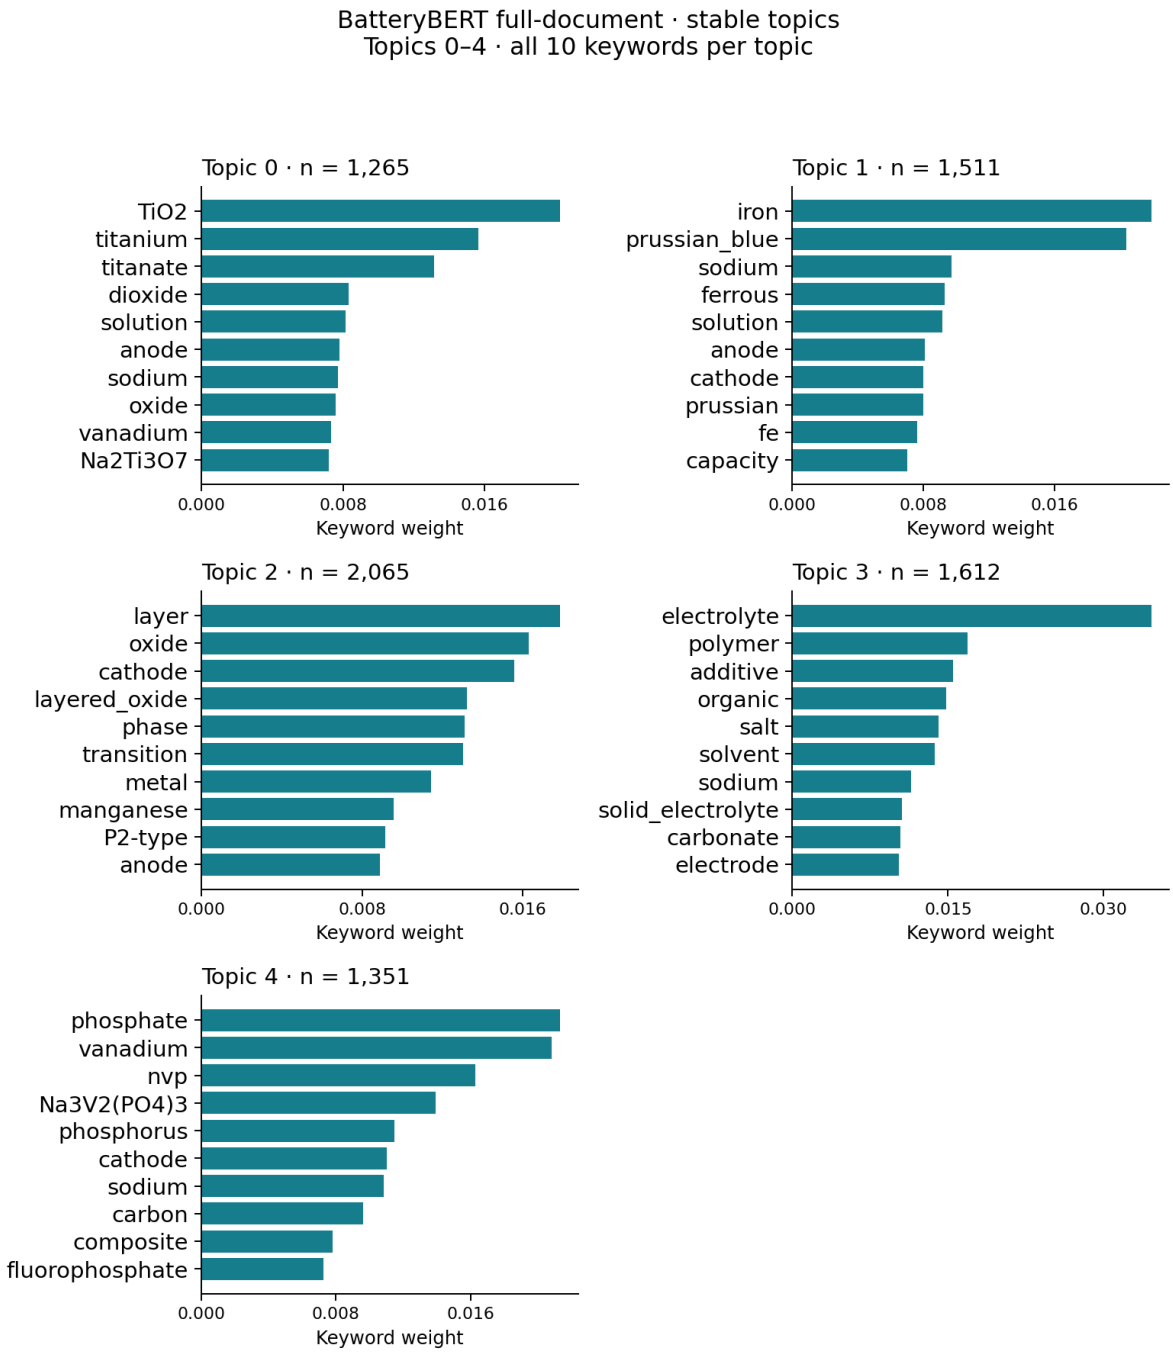
Bảng 7.7: Đủ10 topic và 10 keywords/topic: BatteryBERT full-document · stable topics

ID / Số bài	Tên diễn giải và Top 10 keywords
0 / 1.265	Anode oxide titan và titanate TiO2, titanium, titanate, dioxide, solution, anode, sodium, oxide, vanadium, Na2Ti3O7
1 / 1.511	Prussian blue và vật liệu điện cực chứa sắt iron, prussian_blue, sodium, ferrous, solution, anode, cathode, prussian, fe, capacity
2 / 2.065	Cathode oxide lớp và biến đổi cấu trúc pha layer, oxide, cathode, layered_oxide, phase, transition, metal, manganese, P2-type, anode
3 / 1.612	Điện ly polymer và giao diện trong các hệ pin natri electrolyte, polymer, additive, organic, salt, solvent, sodium, solid_electrolyte, carbonate, electrode
4 / 1.351	Cathode phosphate vanadium và NASICON phosphate, vanadium, nvp, Na3V2(PO4)3, phosphorus, cathode, sodium, carbon, composite, fluorophosphate
5 / 1.012	Anode chứa Sn và Sb cùng composite chuyển hóa tin, antimony, sn, sb, composite, alloy, anode, carbon, graphene, SnO2
6 / 1.071	Cấu trúc cell bộ góp dòng và thiết bị pin connect, plate, device, end, draw, electrode, pole, collector, electric, piece
7 / 1.046	Anode MoS2 và vật liệu hai chiều graphene MXene MoS2, graphene, mxene, molybdenum, disulfide, nanosheets, anode, composite, electrode, mxenes
8 / 1.663	Hard carbon và tiền chất sinh khối hard_carbon, carbon, biomass, porous, carbonize, precursor, carbonization, anode, dry, asphalt
9 / 1.106	Sulfide selenide kim loại chuyển tiếp và composite carbon sulfide, cobalt, carbon, composite, selenide, nickel, solution, hollow, metal, anode

Nguồn: outputs/research_revision_20261025_v1/final_topics/topic_keywords.csv;topic_assignments.csv.

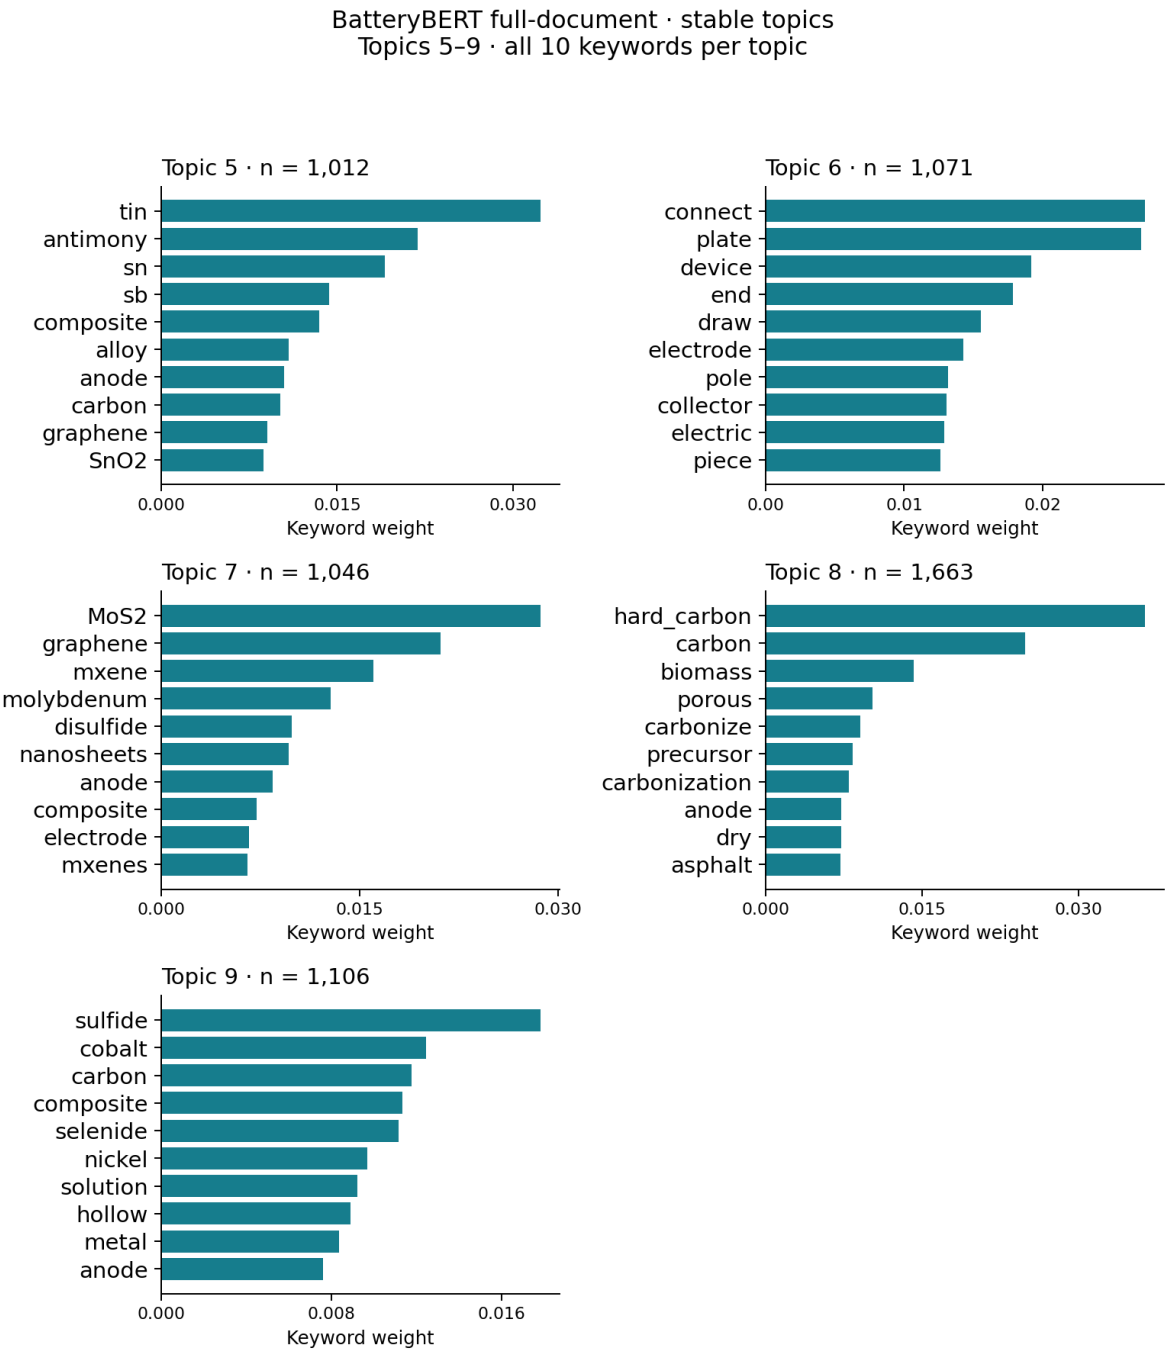


Hình 7.19: Phân bố đầy đủ 10 topic: BatteryBERT full-document · stable topics
Nguồn: outputs/research_revision_20261025_v1/final_topics/topic_assignments.csv.



Hình 7.20: Đủ10 từ khóa và trọng số cho topic 0–4: BatteryBERT full-document · stable topics

Nguồn: outputs/research_revision_20261025_v1/final_topics/topic_keywords.csv.



Hình 7.21: Đủ10 từ khóa và trọng số cho topic 5–9: BatteryBERT full-document · stable topics

Nguồn: outputs/research_revision_20261025_v1/final_topics/topic_keywords.csv.

7.9 Nhận xét đối chiếu giữa các mô hình

LDA K10 tạo các nhóm lớn về anode, cathode và chế tạo vật liệu; posterior cho phép mỗi tài liệu thuộc nhiều topic nhưng bảng chỉ thống kê topic trội. BERTopic–BGE nhận diện một số họ chuyên biệt như Prussian blue, titanate và MXene nhưng có nhiều outlier. BERTopic–BatteryBERT pretrained có hai nhóm rộng chi phối corpus, cho thấy embedding miền pin chưa tự bảo đảm các cụm chuyên sâu phù hợp.

Các catalog KMeans/source projection phân chia đều hơn, nhưng số cụm cố định có thể ép tài liệu đa chủ đề vào một nhóm. Catalog stable cải thiện consistency nhiều seed và bảo toàn công thức NVP sau sửa parser. Topic MoS2/MXene ở ID7 gần như đổi nội dung so với catalog full-document cũ; giữ ID bằng Hungarian chỉ phục vụ tính liên tục giao diện. Không giữ nhãn pha/vacancy cũ khi đại diện đã thay đổi.

Topic điện ly có đại diện sodium-metal và topic thiết bị có tài liệu đa hệ pin; tên diễn giải được đặt đủ rộng và cần review thành viên biên. Mức chi tiết khoa học của nhãn phải theo bằng chứng của cả nhóm, không suy từ một keyword đơn lẻ.

Chương 8

Thực nghiệm nâng cấp Search và Search Radar Pilot

8.1 Phạm vi cập nhật ngày 30/10/2026

Phần bổ sung này ghi các lần chạy mới trên corpus và checkpoint cũ, tách biệt với kết quả ngày 26/10. Mọi artifacts mới lưu trong namespace outputs/search_radar_20261030_v1. Search mặc định và các nhãn, split, checkpoint, Qdrant collection gốc được giữ nguyên; hash trước/sau xác nhận bảo toàn. A0 exact matrix tái hiện đúng thứ tự Top 10 của baseline ở cả 20/20 query.

Bảng 8.1: Các cấu hình pilot, không thay Search mặc định.

Cấu hình	Thành phần
A0	TF-IDF + full-document
A1	TF-IDF + BGE
A2	BGE + full-document
A3	Ba nhánh, RRF đều
A3 weighted	Ba nhánh, trọng số cố định 1:1:2
A4	A3 + số điều kiện khớp từ vựng, Top 30
A5	A3 + chunk: max / unique-token mean
A6	A3 + bằng chứng từ vựng trong câu, Top 20/30/50
A7	Chưa chọn: thiếu nhãn development độc lập

8.2 Truy hồi ba nhánh và phân tích truy vấn

Mỗi nhánh áp dụng cùng bộ lọc nguồn, năm, topic và required terms trước lấy ứng viên. Candidate depth lần lượt 50, 100 và 200. Fusion dùng $s(d) = \sum_i w_i/(60 + rank_i(d))$; chỉ hợp thứ hạng, không cộng raw cosine khác không gian. Trọng số 1:1:2 là ablation cố định trước đánh giá, chưa được lựa chọn bằng development.

Parser rule-based giữ nguyên Na3V2(PO4)3, NaFSI và P2/O3; trích vật liệu, vai trò điện cực, hệ pin, tính chất, điều kiện, quy trình, optional và excluded concepts. Evidence inspector lưu trường, offsets và câu gốc; phân biệt thiếu bằng chứng, phủ định tường minh và mâu thuẫn. Đồng xuất hiện trong câu chỉ là proxy từ vựng, không tự xác nhận quan hệ khoa học hoặc sửa role metadata. A4/A6 là các đối chứng heuristic; chưa có neural evidence model phù hợp được xác minh.

8.3 Độ phủ ứng viên và phần chưa có nhãn

Trên 19 query có grade 2 trong pool AI Silver, Candidate Recall@100 của A0 là 0,9253; A3 đạt 1,0000. Chênh lệch 0,0747, CI95% theo query [0,0081; 0,1892]. Đây là độ phủ các tài liệu đã biết trong pool, không phải Recall trên toàn corpus. Q08 không có grade 2 nên mẫu số không xác định.

Top 10 mới có 119 cặp query–document chưa chấm khi hợp các cấu hình và depth. Không gán các cặp này thành 0. Ở K=100, A3 có 14/20 query được chấm đủ; A0 có 20/20. Giao đủ nhãn của toàn bộ ablation có thể rỗng; chỉ số tổng hợp khi đó để trống. Mỗi so sánh cặp dùng cùng query cho baseline và ứng viên, không dùng mẫu số khác nhau rồi tuyên bố model thắng tổng thể.

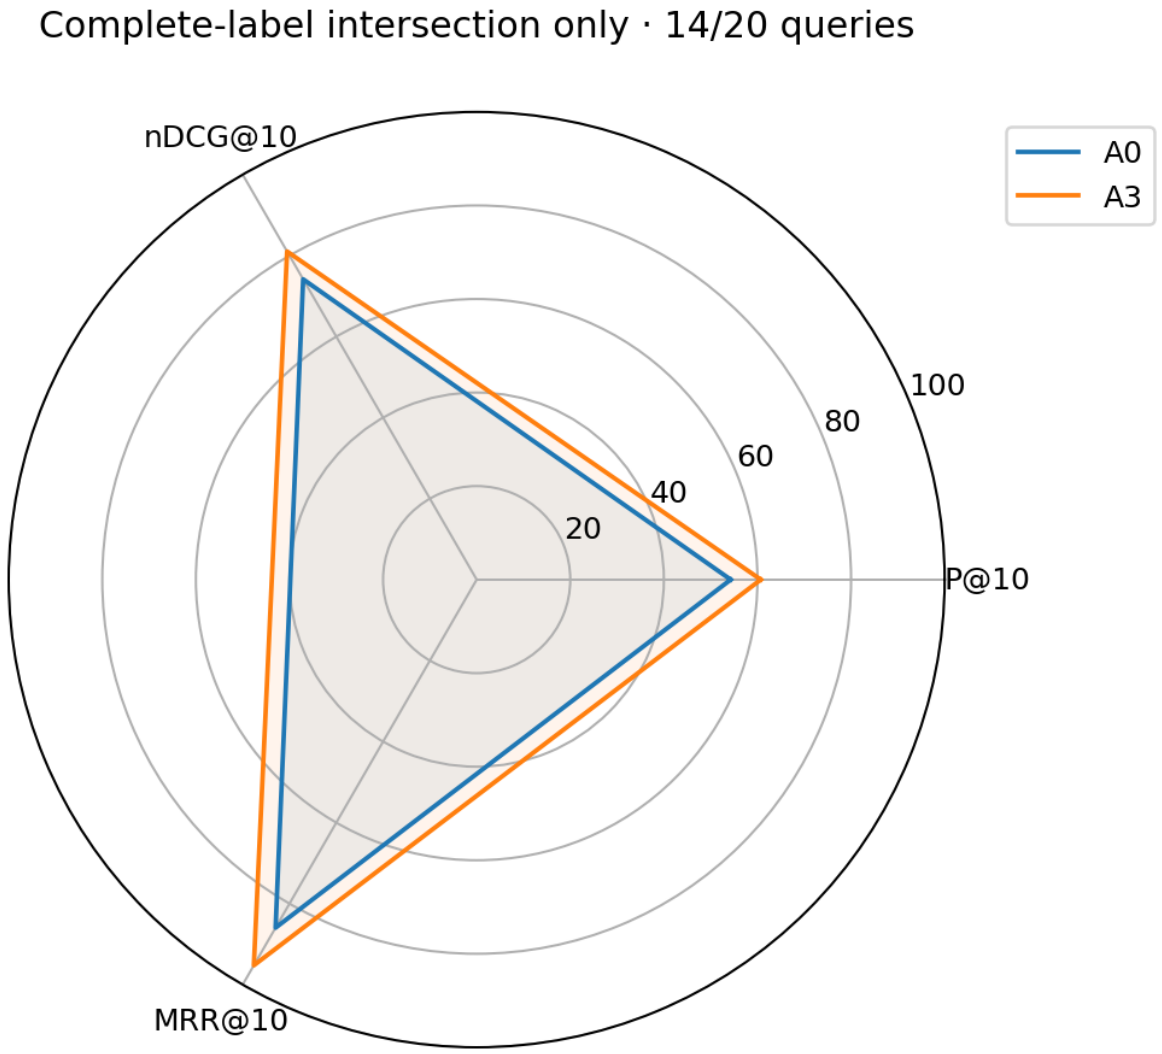
8.4 Kết quả A0–A3 trên tập giao lịch sử

Trên cùng 14/20 query đủ nhãn, A0 đạt P@10=0,5429, nDCG@10=0,7416, MRR@10=0,8595; A3 đạt tương ứng 0,6071, 0,8103, 0,9524. Chênh lệch dương này chỉ có giá trị chẩn đoán trên tập giao được chấm sẵn. Việc điều kiện hóa theo độ phủ nhãn có thể tạo thiên lệch. Không diễn giải thành kết quả trên đủ 20 query hoặc dữ liệu độc lập.

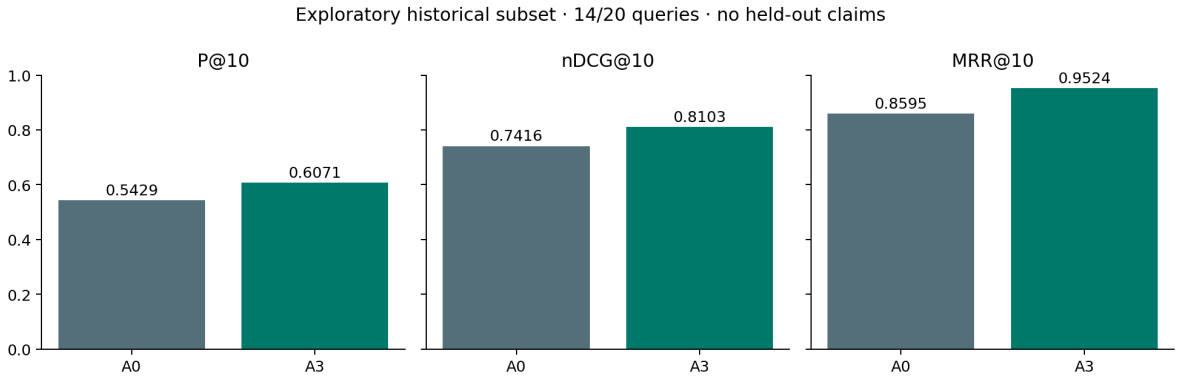
Bootstrap ghép cặp 10.000 lần, seed 20261030, giữ nhãn AI cố định; bảng CSV lưu khoảng tin cậy từng chỉ số và danh sách query. Chưa hiệu chỉnh đa kiểm định giữa các ablation; không dùng kết quả này chọn trọng số hoặc A7.

Bảng 8.2: Ablation trên giao query đủ nhãn với A0, K=100. Các dòng có mẫu số khác nhau; không xếp hạng giữa các dòng.

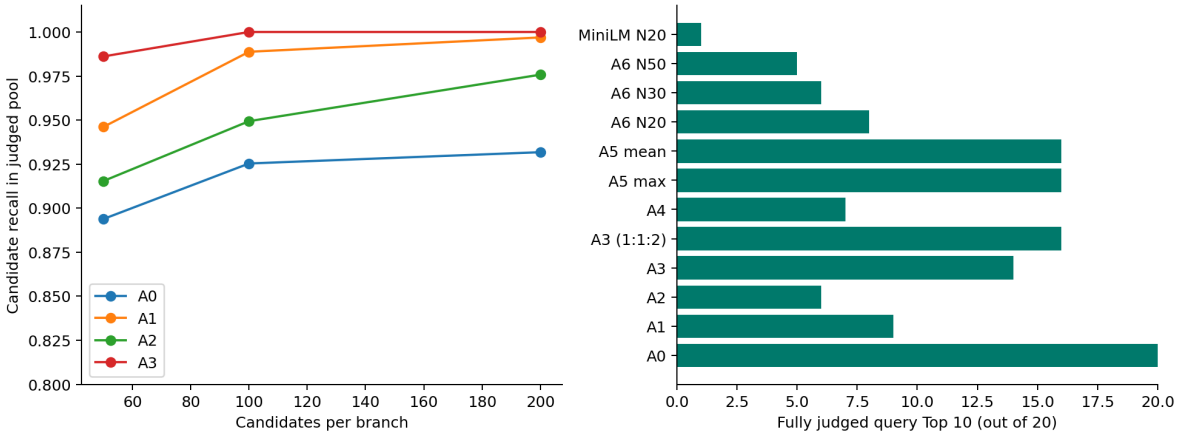
Cấu hình	n/20	P@10	ΔP	ΔnDCG	ΔMRR
A1	9	0,6778	-0,0333	-0,0046	0,0056
A2	6	0,5500	0,0000	0,0328	-0,0833
A3	14	0,6071	0,0643	0,0687	0,0929
A3 (1:1:2)	16	0,5875	0,0437	0,0458	0,0604
A4	7	0,6571	0,0857	0,0792	0,0714
A6 N20	8	0,6250	0,0750	0,0794	0,0833
A6 N30	6	0,6500	0,0833	0,0869	0,0833
A6 N50	5	0,6400	0,0600	0,0744	0,1000
A5 max	16	0,6062	0,0437	0,0545	0,0604
A5 mean	16	0,6062	0,0312	0,0311	-0,0125
MiniLM N20	1	1,0000	0,1000	0,0694	0,0000



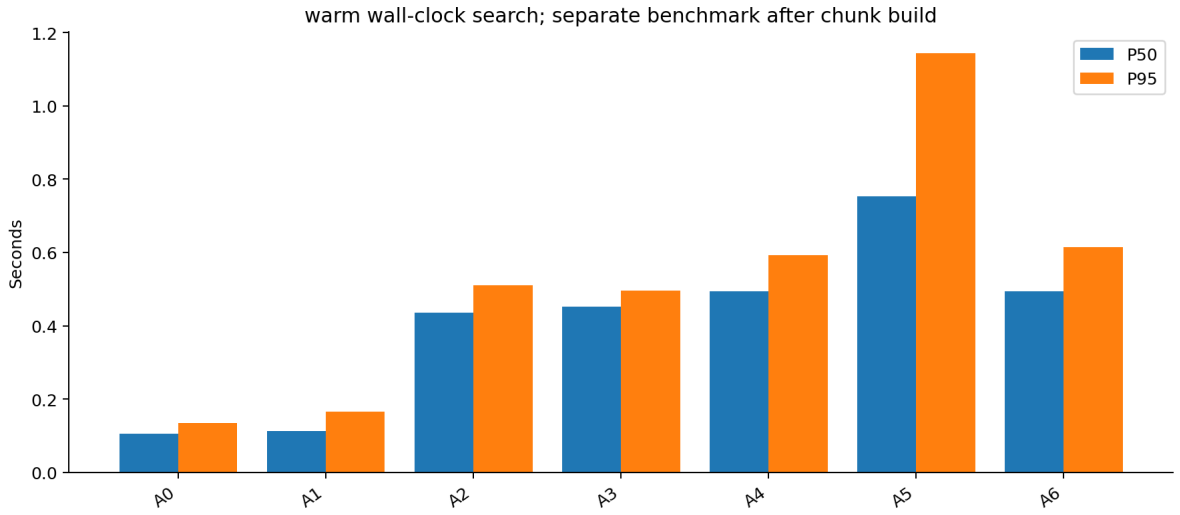
Hình 8.1: Radar mới trên giao 14/20 query đủ nhãn của A0 và A3. Thang 100 lần giá trị gốc; tập giao có thể thiên lệch.



Hình 8.2: P@10, nDCG@10 và MRR@10 trên cùng 14 query lịch sử đủ nhãn, không phải held-out.



Hình 8.3: Độ phủ ứng viên trong pool AI Silver và số query có Top 10 được chấm đủ. Q08 bị loại khỏi mẫu số candidate recall.



Hình 8.4: Độ trễ thực nghiệm CPU; đọc phạm vi đo kèm bảng và protocol, không so đơn vị latency với trục chất lượng.

8.5 Chunk retrieval và chi phí vận hành

Index mới có 32,669 chunks, bao phủ 13,702 tài liệu. Chỉ chạy block cuối trên frozen-prefix cache đã kiểm hash, không huấn luyện và không encode lại toàn encoder. Sai lệch lớn nhất khi gộp lại thành document vector là 8.94e-08; kiểm trên toàn bộ corpus. Thời gian dựng 1639.0 giây; vector index 95.71 MiB. Context, offsets và checkpoint hash lưu trong records.parquet. Max chọn một chunk mạnh nhất; unique mean dùng số token mới để chống đếm overlap. Chưa có nhãn span độc lập để đo độ đúng đoạn bằng chứng.

Với K=100, A0 P50/P95 là 0,106/0,134 giây; A3 là 0,452/0,496 giây. Phạm vi đo: warm wall-clock search; separate benchmark after chunk build. RSS peak được lấy mẫu mỗi 20 ms, trong tiến trình mới cho từng phương pháp; gồm model và các index đã nạp, không phải chỉ riêng tensor encoder. P95 của A3/A0 bằng 3,70 lần trong lần đo này. MiniLM chạy riêng như đối chứng Top 20, không được tự kích hoạt trong Search. Gate chi phí A3 theo ngưỡng 1,5 lần latency P95 và RSS có trạng thái FAIL; gate chất lượng độc lập vẫn chưa đủ nhãn, nên không thay production.

Bảng 8.3: Độ trễ và RSS trong benchmark CPU, K=100. Phạm vi đo được ghi trong nội dung.

Cấu hình	P50 (s)	P95 (s)	RSS (MiB)
A0	0,106	0,134	1238,9
A1	0,114	0,166	1277,5
A2	0,436	0,510	1693,6
A3	0,452	0,496	1567,1
A4	0,494	0,592	1574,2
A5	0,753	1,145	1571,1
A6	0,494	0,615	1584,5

8.6 Pilot độc lập, kiểm thử và quyết định gate

Đã tạo 12 query mới, chia sáu family development và sáu family held-out không trùng. Đây là đề xuất hệ thống, cần chuyên gia xác nhận intent và chấm relevance. Đã chạy retrieval, gom pool và xuất biểu mẫu trống, không tạo nhãn con người. Held-out chưa có qrels, nên chưa tính P/nDCG/MRR held-out; A7 giữ trạng thái chưa chọn. Importer yêu cầu VERIFIED HUMAN_INDEPENDENT, người chấm khác người xác minh, thời điểm, rationale và nguồn review query. Held-out cần cấu hình đã khóa sau gate development.

Trang Streamlit có bảy tab: Search Overview, Radar Comparison, Query Inspector, Evidence Inspector, Pilot Evaluation, Error Analysis và Ablation & Latency. Radar dùng 100 lần giá trị [0,1], hover giữ giá trị gốc; latency hiển thị riêng. Condition Satisfaction Rate chưa có nhãn điều kiện kiểm chứng nên chưa đưa lên radar. Có lưu phiên bản và xuất CSV, JSON, PNG, Markdown.

Kiểm thử tự động: 42/42 qua, bao gồm tính RRF, ID/bộ lọc, overlap chunk, parser công thức, missing labels, offsets, metric, UI bảy tab và regression backend. Lỗi fixture cũ do catalog revised trên đĩa xen vào corpus giả đã được cô lập bằng mock, không đổi production logic. Q04–Q06, Q08, Q16–Q18 và Q20 được xuất riêng để review quan hệ. Chưa có nhãn span/condition độc lập và chưa có bằng chứng cải thiện trên held-out; không chọn tất cả thành phần chỉ vì đã triển khai.

Nguồn: outputs/search_radar_20261030_v1/historical;outputs/search_radar_20261030_v1/pilot;docs/SEARCH_FINAL_RESEARCH_REPORT.md.

Chương 9

Kết luận và hướng phát triển

9.1 Những kết quả đã đạt được

Đồ án đã xây dựng pipeline từ hai nguồn Excel đến corpus 13.702 tài liệu, các nhánh LDA/BERTopic/KMeans và hệ thống tìm kiếm kết hợp có lọc. Các output giữ ID, hash, cấu hình, checkpoint và ảnh kết quả để truy vết. Báo cáo trình bày bảy catalog với 70 topic và 700 vị trí từ khóa, cùng ảnh huấn luyện, phân bố topic và đánh giá search.

Continuation full-document đã cập nhật block cuối trên toàn bộ Abstract train; test Group MRR@10 proxy tăng từ 0,887839 lên 0,924704. KMeans nhiều khởi tạo cải thiện ARI giữ riêng; parser mới bảo toàn công thức NVP. Các kết quả vẫn cần chuyên gia xác nhận.

Search hybrid TF-IDF và BatteryBERT full-document đạt P@10 = 0,5400; nDCG@10 = 0,7693; MRR@10 = 0,7767 trên 703 Silver Labels và 20 queries. Kết quả cao nhất về trung bình trong lần chấm nhưng CI ghép cặp với các đối chứng gần nhất còn chứa 0. Reranker được giữ tách biệt do giảm điểm gate, thể hiện vai trò của đối chứng và ghi nhận kết quả âm.

9.2 Kết quả bổ sung Search Radar Pilot ngày 30/10

Nhánh thử nghiệm hợp ba encoder đã được triển khai cùng dashboard bảy tab, truy vết candidate/rank/evidence và xuất artifacts có phiên bản. A0 exact matrix tái hiện đúng Top 10 baseline trên 20/20 query. Candidate Recall@100 trong pool có nhãn tăng từ 0,9253 lên 1,0000 trên 19 query có grade 2 khi thêm BGE. Trên cùng 14 query được chấm đủ, A3 tăng P@10 từ 0,5429 lên 0,6071; các kết quả này chỉ là chẩn đoán trên AI Silver lịch sử.

Các ablation rule-based, evidence và chunk được giữ riêng để đối chứng; chưa có human relevance/condition/span labels mới hoặc đánh giá held-out đầy đủ. Bộ 12 query mới đã chạy retrieval và xuất biểu mẫu trống, cần chuyên gia review. Vì vậy A7 chưa được chọn và Search mặc định được giữ nguyên. Chương trước lưu độ trễ, độ phủ nhãn, kiểm thử và các giới hạn thực nghiệm.

9.3 Hạn chế

Dữ liệu chỉ có Title–Abstract, không có toàn văn. Một số bản ghi thiếu Abstract hoặc mâu thuẫn vai trò điện cực. Proxy Title–document có thể hưởng lợi từ Title context. Nhiều vòng phát triển đã sử dụng split lịch sử; seed mới không tạo external dataset mới. Keyword coherence phụ thuộc token stream/reference, và các topic chưa có nhãn chuyên gia.

Đánh giá search có 20 query, một lượt chấm AI và pool hữu hạn; confidence chưa hiệu chuẩn,70 nhãn cần review. Chưa có dữ liệu người dùng mới, kiểm thử đa ngôn ngữ hay benchmark concurrency. Vì vậy không công bố search accuracy hoặc kết luận model thắng tổng thể.

9.4 Hướng phát triển

Ưu tiên human annotation theo intent, có phân xử độc lập và query-family mới ngoài phát triển. Sau đó thử passage/multi-vector retrieval, đánh giá từng điều kiện và đo chất lượng–độ trễ. Dữ liệu toàn văn mới cần version riêng, nguồn và ID để đối chứng; corpus hiện tại vẫn chỉ là Title–Abstract.

Nhánh topic cần chuyên gia rà soát đại diện trung tâm, thành viên biên, nguồn, kích thước cụm và vai trò vật liệu; giữ baseline và protocol cố định khi thử cải thiện.

Tài liệu tham khảo

[1] D. M. Blei, A. Y. Ng, and M. I. Jordan, “Latent dirichlet allocation,” *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003. [Online]. Available: https://www.jmlr.org/papers/v3/blei03a.html

[2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of NAACL-HLT*, 2019, pp. 4171–4186. [Online]. Available: https://aclanthology.org/N19-1423/

[3] BAAI, “bge-base-en-v1.5: Model card,” Hugging Face, nguồn tham khảo từ snapshot 19-10-2026; cấu hình thực nghiệm lấy từ checkpoint cục bộ. [Online]. Available: https://huggingface.co/BAAI/bge-base-en-v1.5

[4] BatteryData, “Batterybert-cased: Model card,” Đối chiếu ngày 26-10-2026; thông số thực nghiệm theo checkpoint cục bộ. [Online]. Available: https://huggingface.co/batterydata/batterybert-cased

[5] M. Grootendorst, “BERTopic: Neural topic modeling with a class-based TF-IDF procedure,” arXiv:2203.05794, 2022.

[6] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform manifold approximation and projection for dimension reduction,” arXiv:1802.03426, 2018.

[7] L. McInnes, J. Healy, and S. Astels, “hdbscan: Hierarchical density based clustering,” *Journal of Open Source Software*, vol. 2, no. 11, p. 205, 2017.

[8] M. Grootendorst, “BERTopic api: Classtfidftransformer,” nguồn tham khảo từ snapshot 19-10-2026; đối chiếu source thư viện cài đặt. [Online]. Available: https://maartengr.github.io/BERTopic/api/ctfidf.html

[9] M. Röder, A. Both, and A. Hinneburg, “Exploring the space of topic coherence measures,” in *Proceedings of WSDM*, 2015, pp. 399–408. [Online]. Available: https://wse-research.org/publications/2015_acm_2684822.2685324

[10] L. Gao, Y. Zhang, J. Han, and J. Callan, “Scaling deep contrastive learning batch size under memory limited setup,” in *Proceedings of RepL4NLP*, 2021. [Online]. Available: https://arxiv.org/abs/2101.06983

[11] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proceedings of SIGIR*, 2009, pp. 758–759.

[12] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.

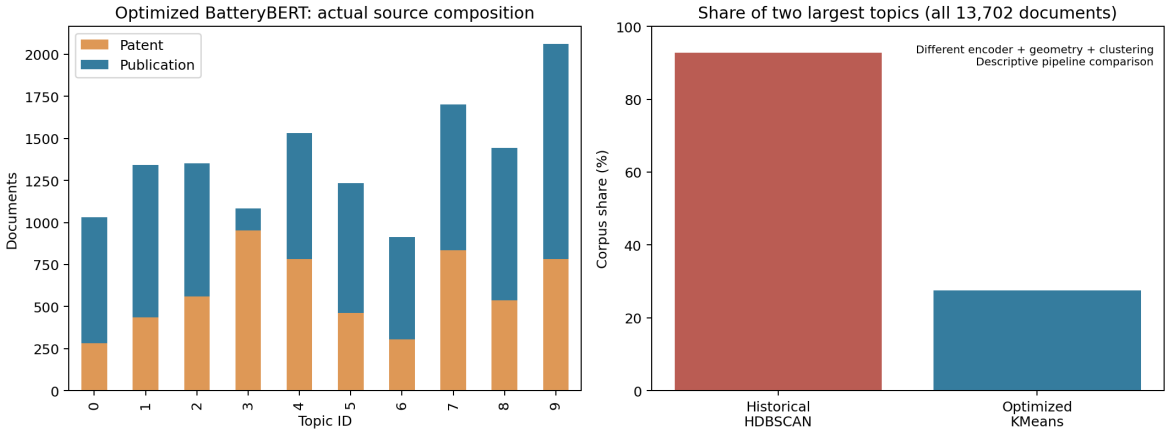
[13] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008. [Online]. Available: https://nlp.stanford.edu/IR-book/

Phụ lục A

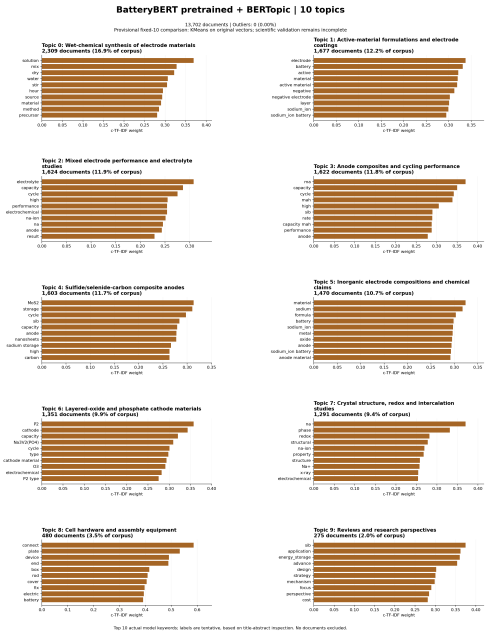
Toàn bộ hình kết quả bổ sung theo giai đoạn

Phụ lục giữ các ảnh kết quả có sẵn chưa xuất hiện ở phần chính, gồm EDA, LDA, BERTopic chunked, giao diện, đối chứng và các đánh giá lịch sử. Ảnh trùng nội dung được nhúng một lần theo SHA-256; hình phiên bản mới thay bản cũ khi chỉ sửa nhãn/bố cục và được ghi trong inventory. Các ảnh QA trang PDF, contact sheet lặp lại và công thức raster không phải kết quả mô hình được bỏ khỏi tập hình chính; công thức đã trình bày bằng LaTeX.

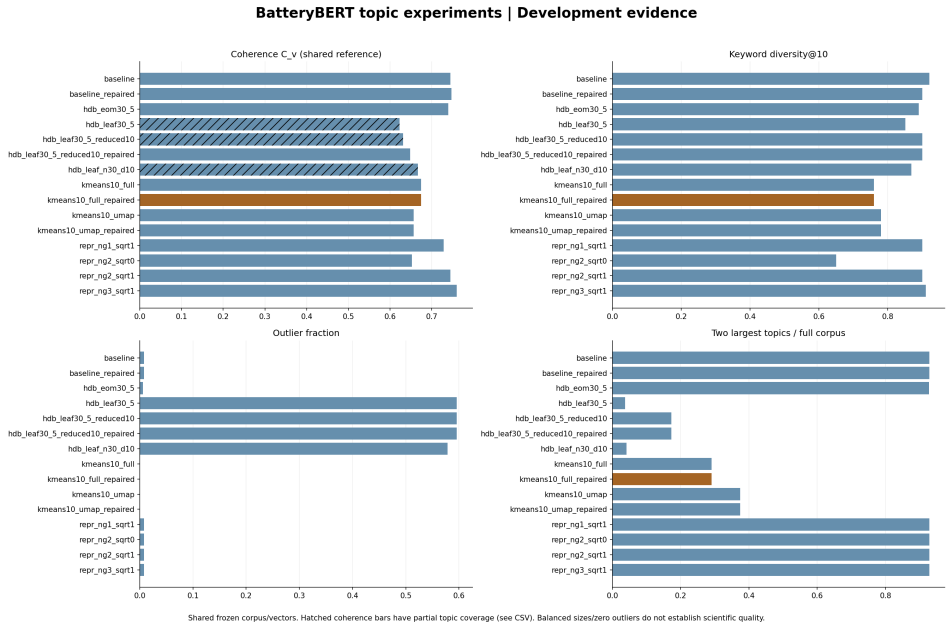
Ảnh có chữ "lịch sử" không đại diện cấu hình hiện hành. Đặc biệt Top 5/AI consensus cũ không thay đánh giá 703 Silver Labels Top 10. Các màn hình lưu trước đây chỉ minh họa chức năng đã có tại snapshot đó. Chất lượng/chữ nhỏ trong hình nguồn không được cải thiện bằng cách tạo lại số liệu giả; người đọc có thể mở PNG gốc trong bộ nguồn.



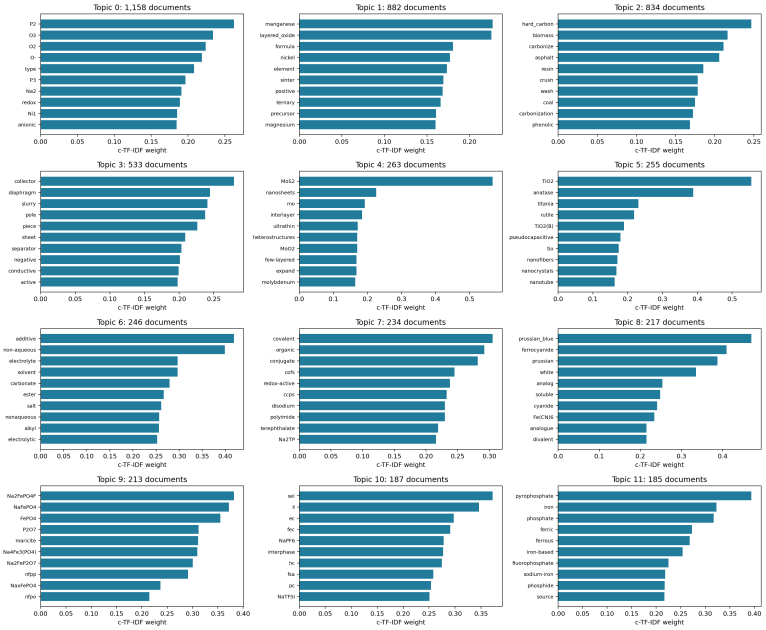
Hình A.1: Độ tập trung topic trước/sau optimization BatteryBERT ngày 23/10.
Nguồn: outputs/batterybert_optimization_20261023_v1/topic_balance.png.



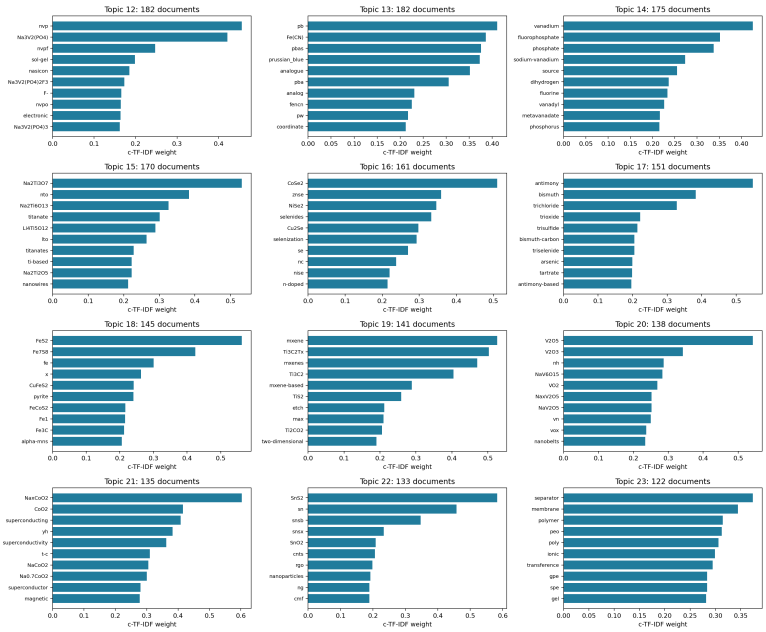
Hình A.2: Kết quả10 topic tại phiên topic audit ngày 22/10.
Nguồn: outputs/batterybert_topic_audit_20261022_v1/bertopic_final_10_topics.png.



Hình A.3: Các cấu hình clustering được so tại phiên topic audit ngày 22/10.
Nguồn: outputs/batterybert_topic_audit_20261022_v1/experiment_comparison.png.

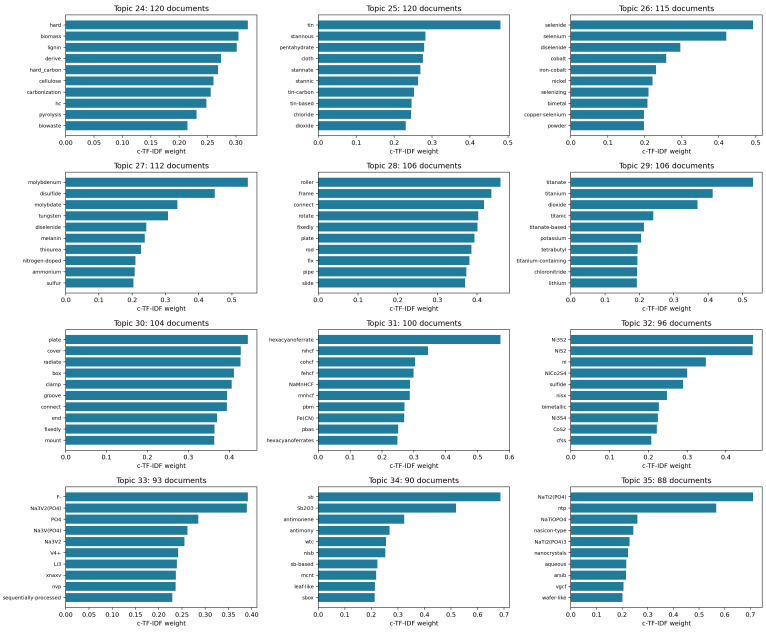


Hình A.4: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 01. Cả7 trang được giữ đủ.
Nguồn: outputs/bertopic_chunked/figures/top10_keywords_01.png.



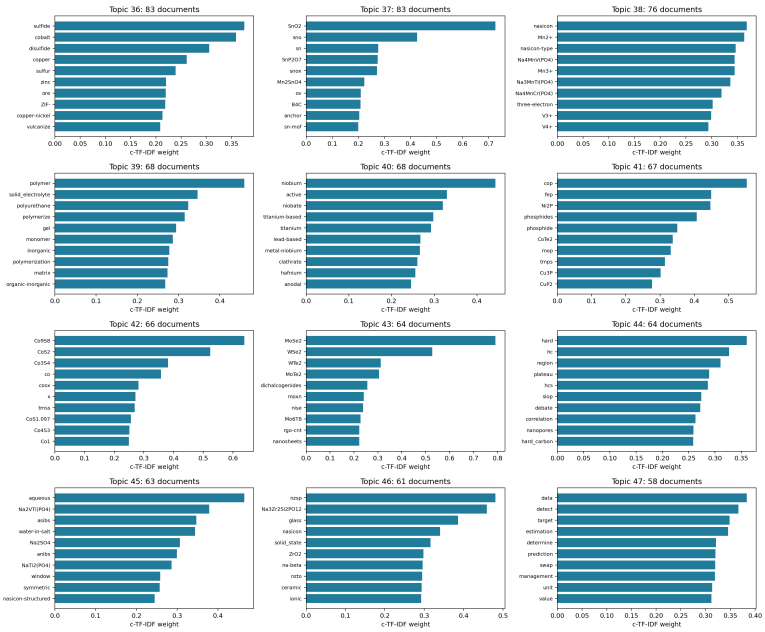
Hình A.5: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 02. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_02.png.



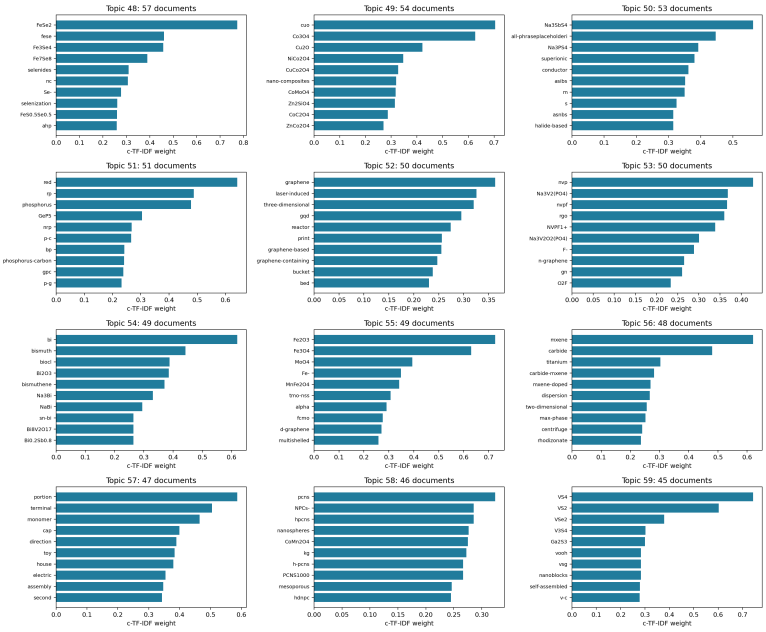
Hình A.6: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 03. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_03.png.



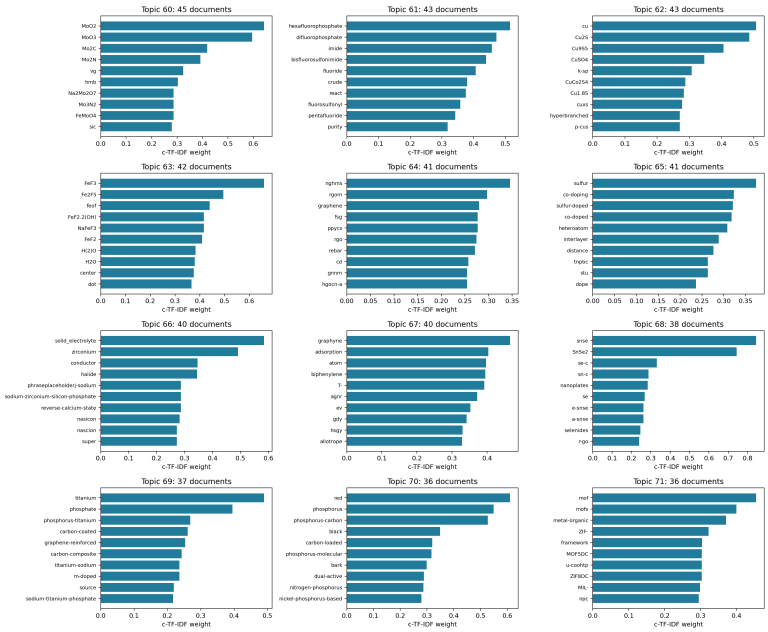
Hình A.7: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 04. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_04.png.



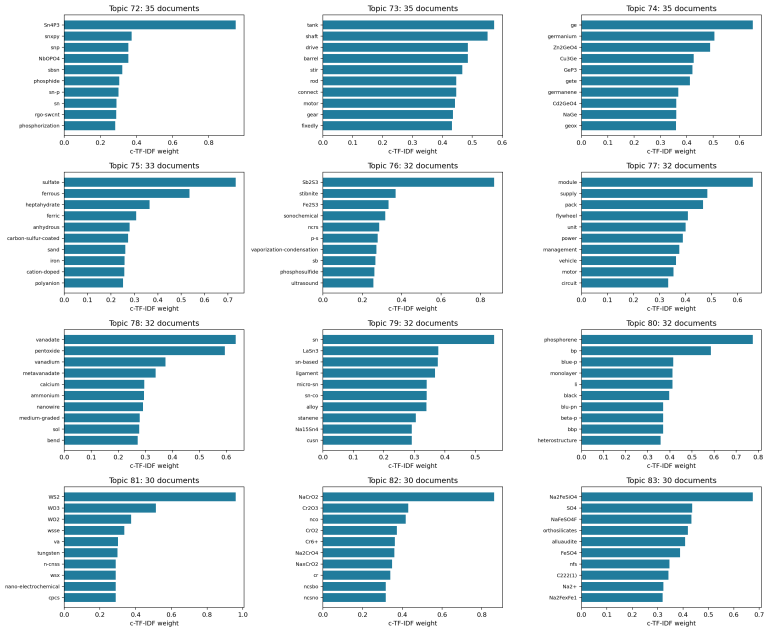
Hình A.8: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 05. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_05.png.



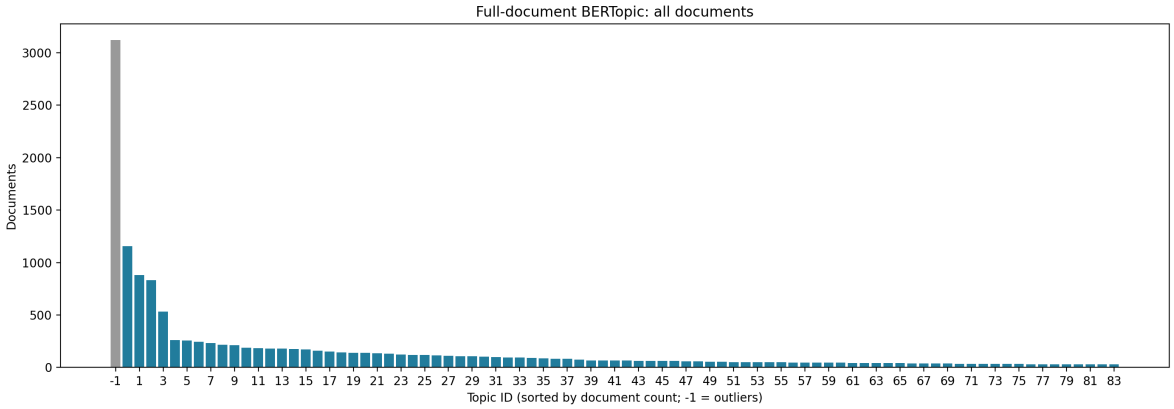
Hình A.9: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 06. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_06.png.

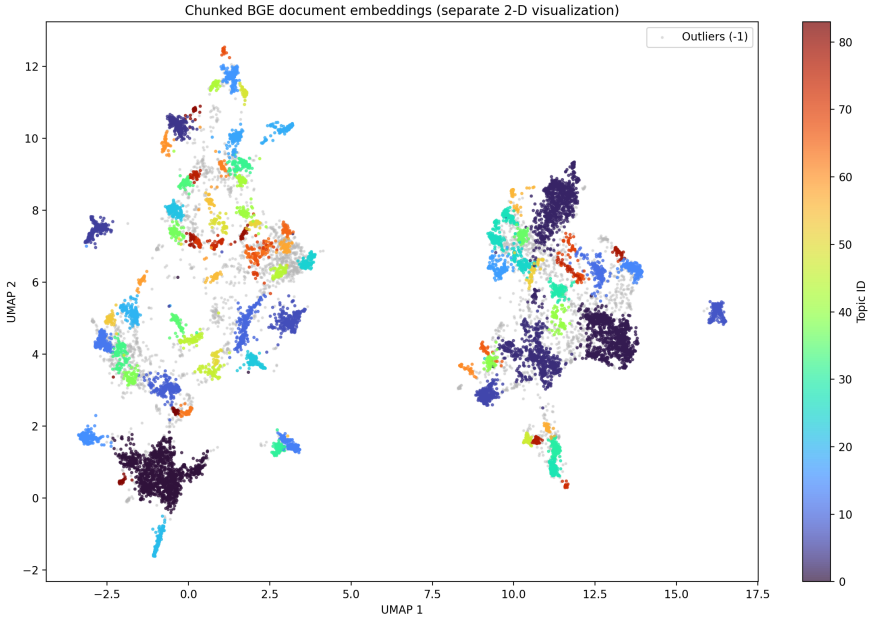


Hình A.10: BERTopic chunked lịch sử: Top 10 keywords của các topic, trang 07. Cả7 trang được giữ đủ.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_07.png.



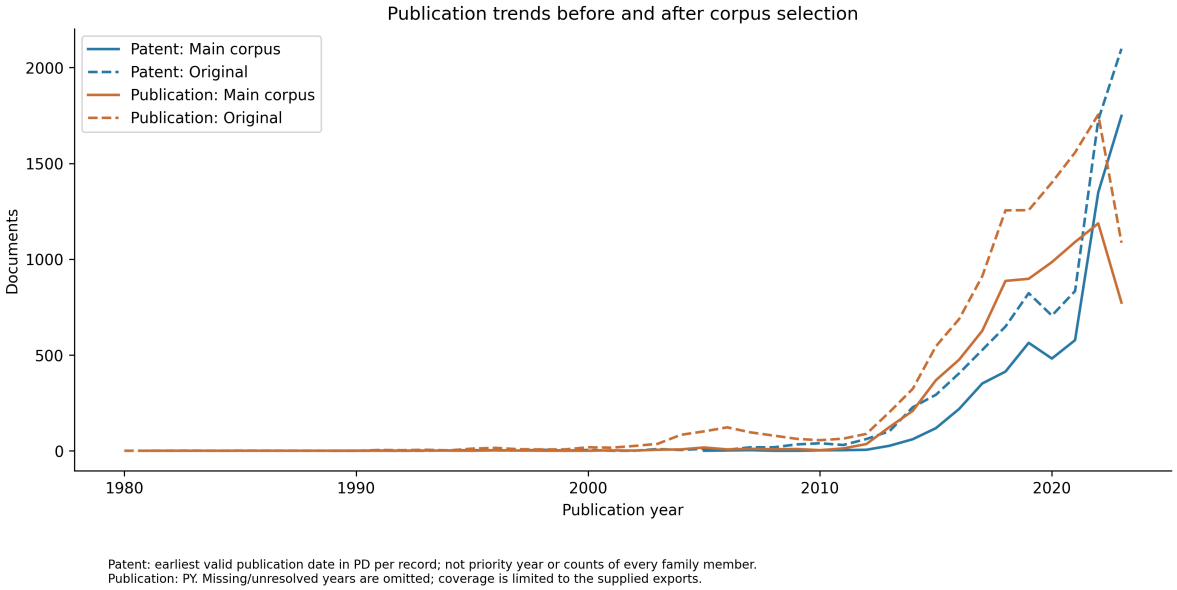
Hình A.11: Phân bố84 topic BERTopic chunked lịch sử, trước bước gộp K10. *Nguồn:* outputs/bertopic_chunked/figures/topic_distribution.png.



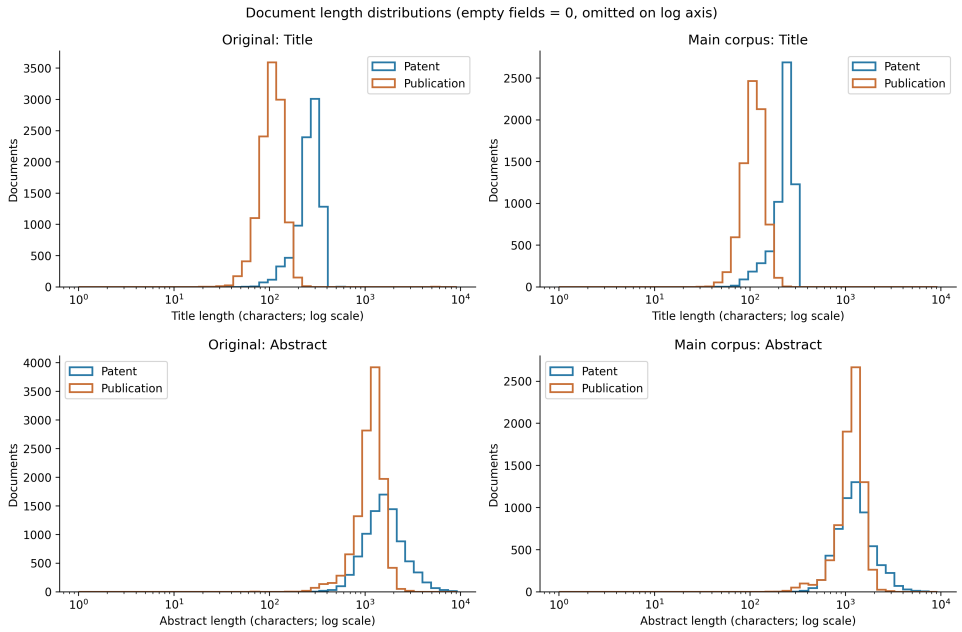
Hình A.12: UMAP2D BERTopic chunked lịch sử; clustering dùng không gian khác. *Nguồn:* outputs/bertopic_chunked/figures/umap_2d.png.



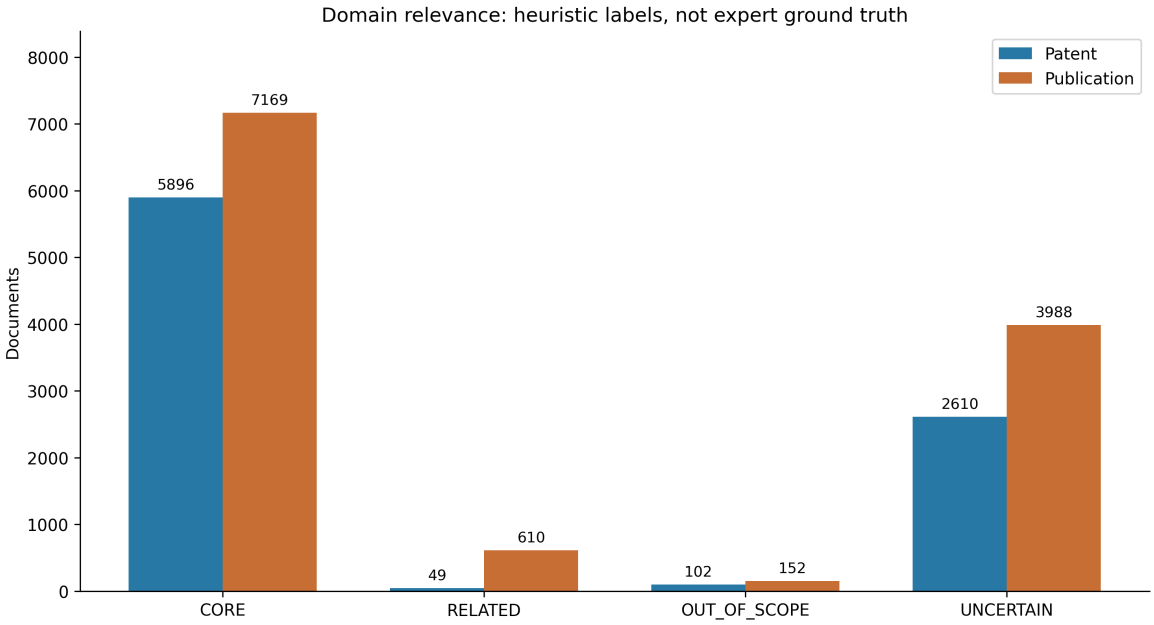
Hình A.13: Mức thiếu trường dữ liệu trong giai đoạn chuẩn bị.
Nguồn: outputs/figures/data_preparation/figure_02_missing_values.png.



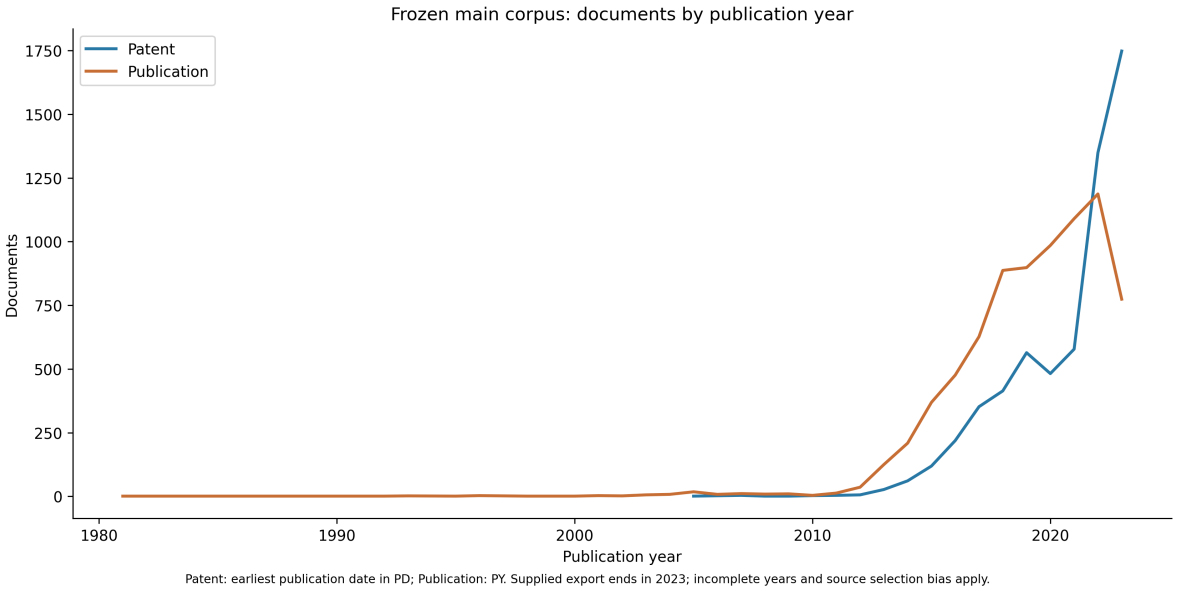
Hình A.14: Phân bố tài liệu theo năm và nguồn khi chuẩn bị dữ liệu.
Nguồn: outputs/figures/data_preparation/figure_03_publication_trends.png.



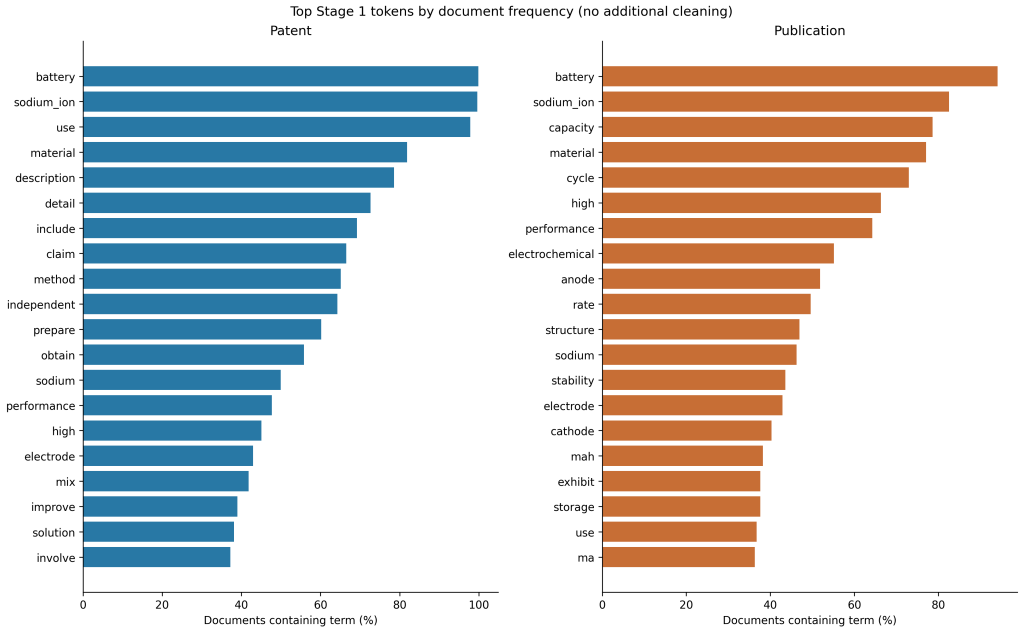
Hình A.15: Phân bố độ dài Title và Abstract ban đầu.
Nguồn: outputs/figures/data_preparation/figure_04_document_lengths.png.



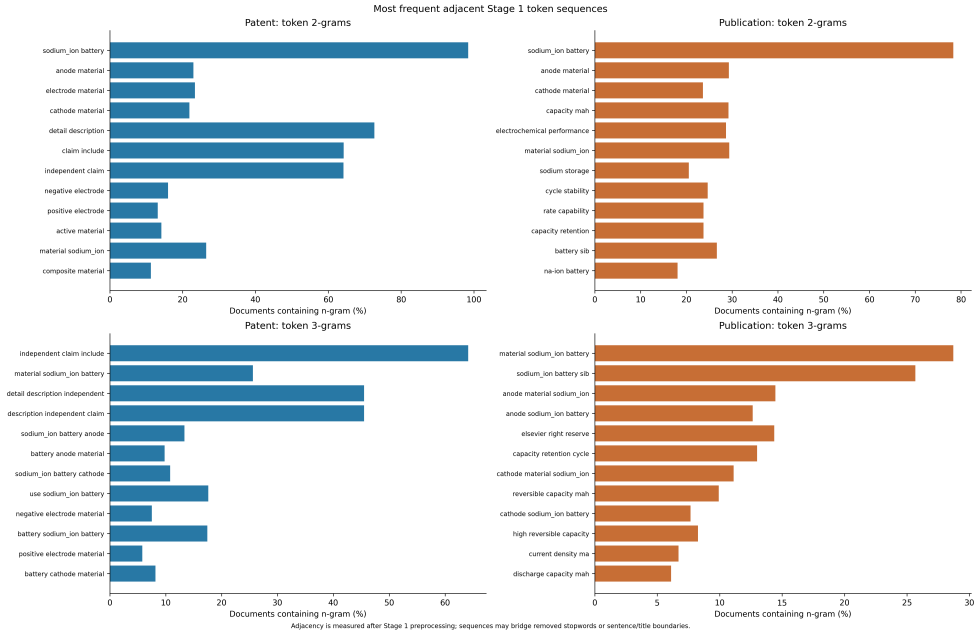
Hình A.16: Kết quả heuristic sàng lọc phạm vi sodium-ion.
Nguồn: outputs/figures/data_preparation/figure_06_domain_relevance.png.



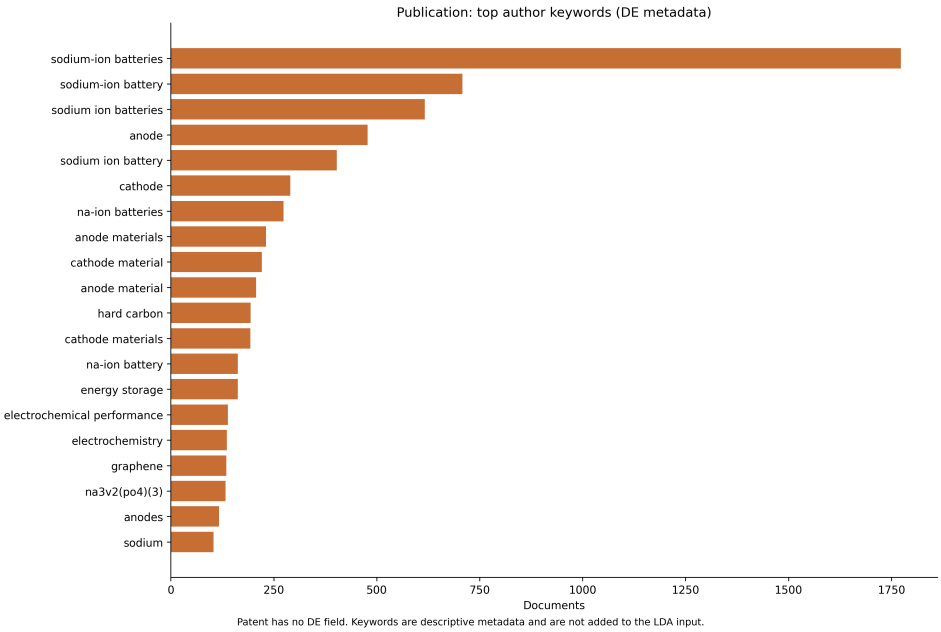
Hình A.17: Xu hướng tài liệu theo năm của corpus đã chuẩn hóa.
Nguồn: outputs/figures/stage2/eda_01_publication_trends.png.



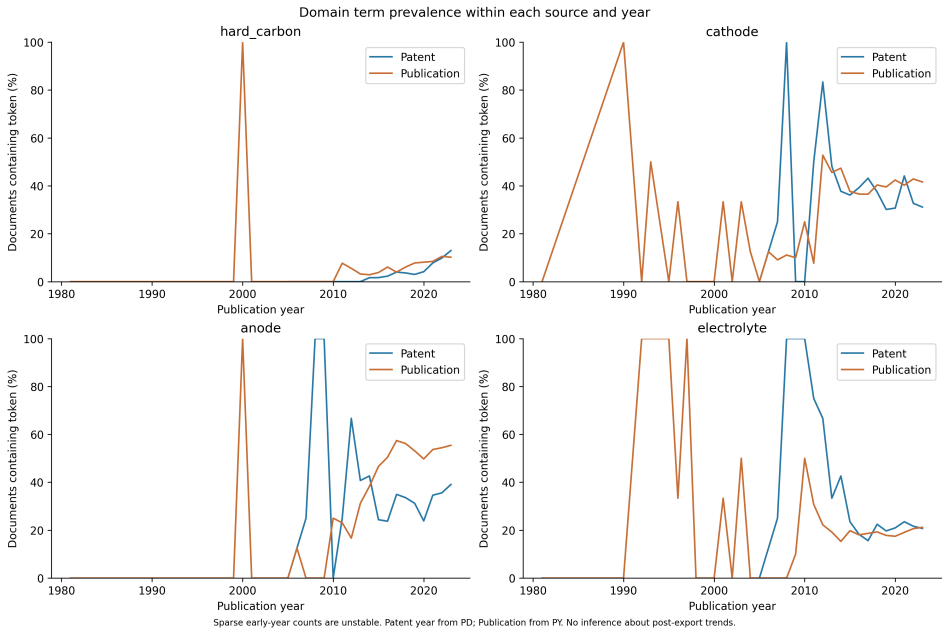
Hình A.18: Các term phổ biến trong corpus.
Nguồn: outputs/figures/stage2/eda_02_top_terms.png.



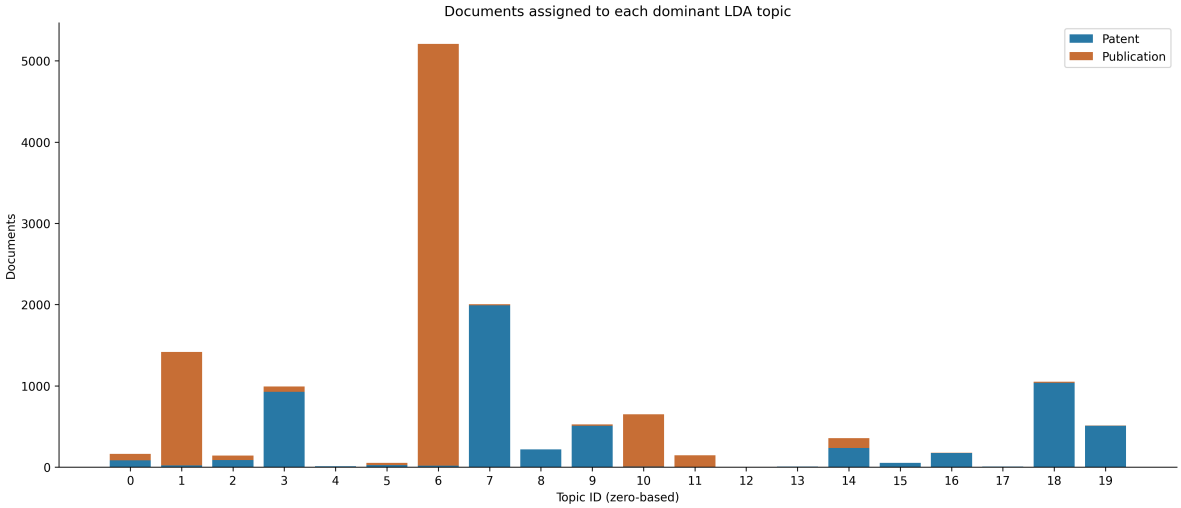
Hình A.19: Các n-gram phổ biến; cần đọc cùng quy tắc ranh giới token. *Nguồn:* outputs/figures/stage2/eda_03_ngrams.png.



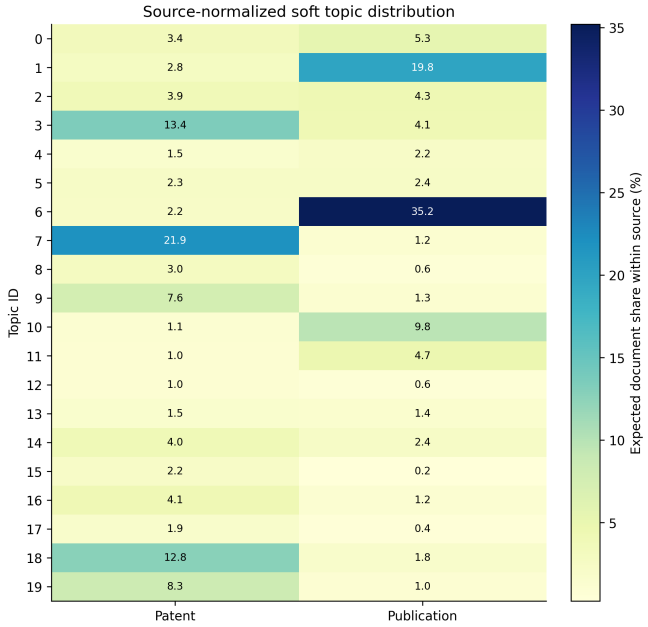
Hình A.20: Author keywords xuất hiện trong dữ liệu có sẵn. *Nguồn:* outputs/figures/stage2/eda_04_author_keywords.png.



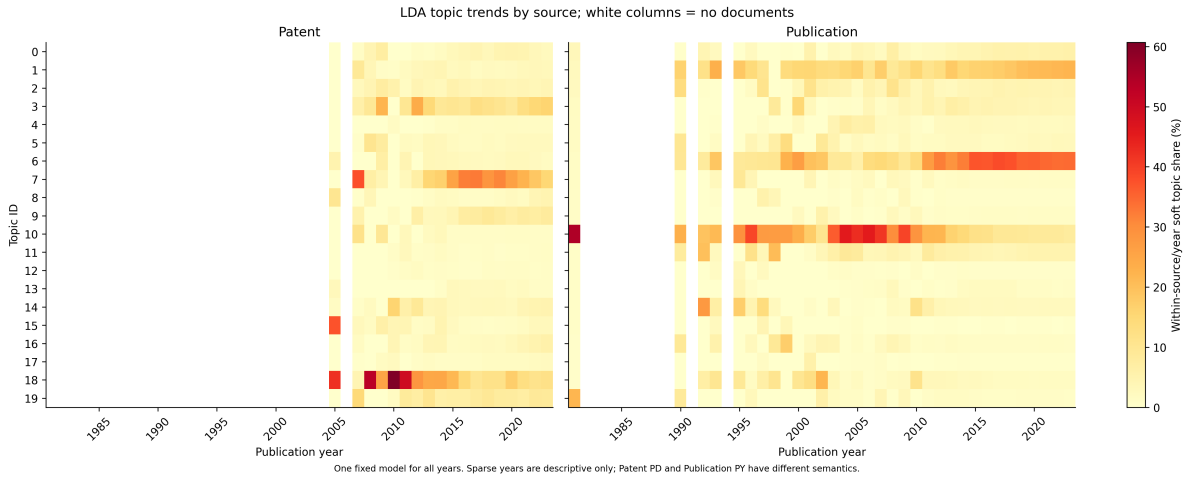
Hình A.21: Xu hướng các term miền theo năm.
Nguồn: outputs/figures/stage2/eda_06_domain_term_trends.png.



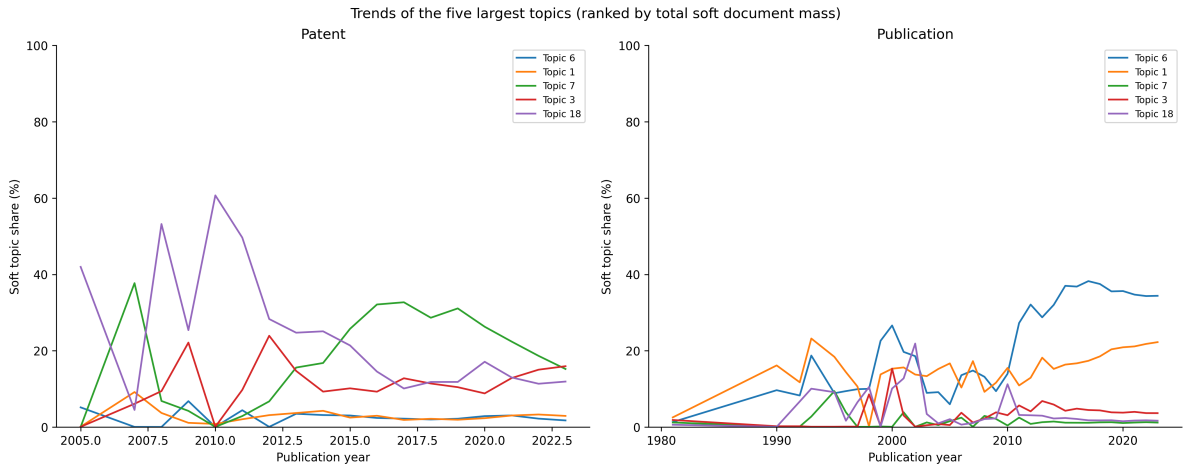
Hình A.22: Phân bố topic LDA Stage2 K20 lịch sử.
Nguồn: outputs/figures/stage2/lda_02_topic_distribution.png.



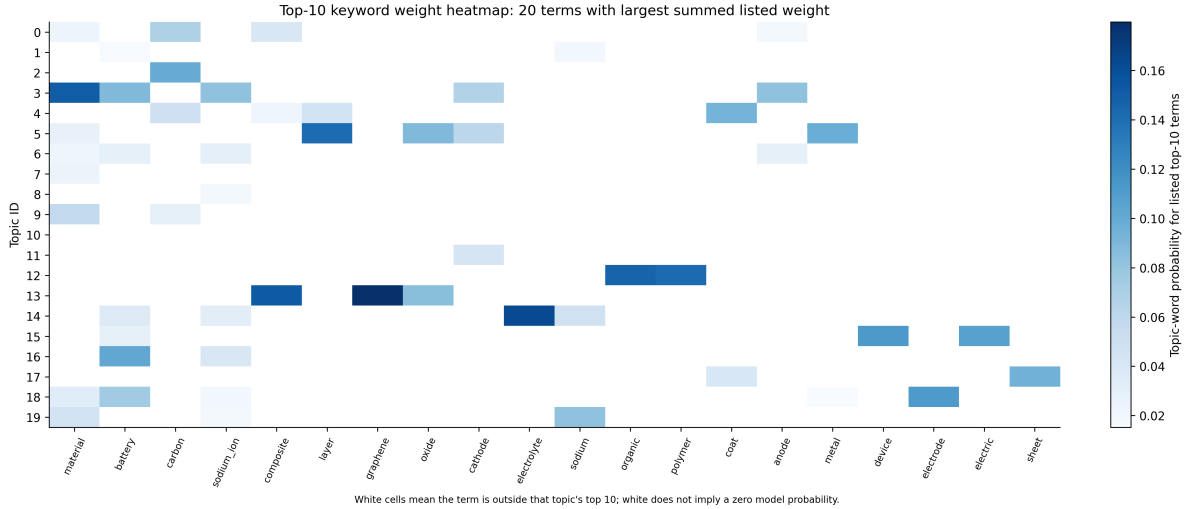
Hình A.23: Topic LDA theo nguồn Patent/Publication, Stage2 lịch sử.
Nguồn: outputs/figures/stage2/lda_03_topic_source_heatmap.png.



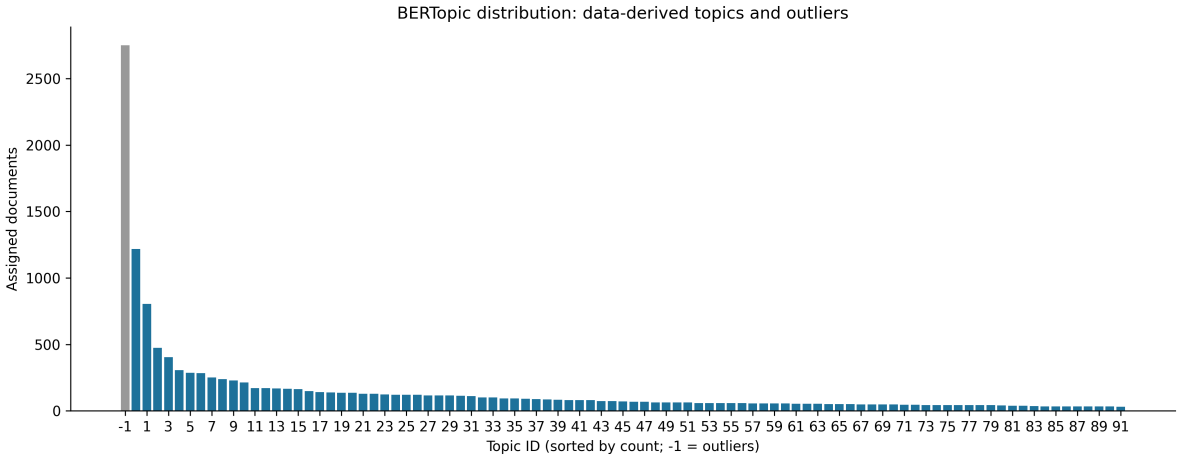
Hình A.24: Topic LDA theo năm, Stage2 lịch sử.
Nguồn: outputs/figures/stage2/lda_04_topic_year_heatmap.png.



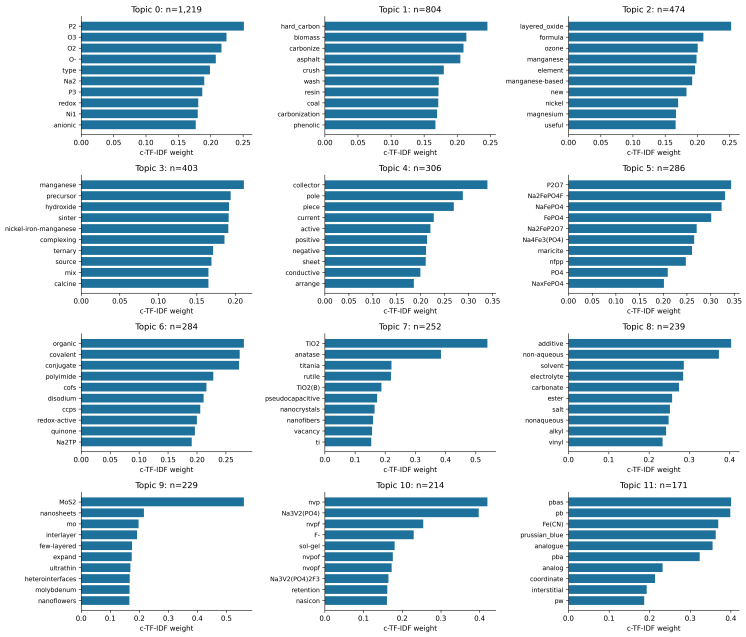
Hình A.25: Xu hướng các topic LDA lớn, Stage2 lịch sử.
Nguồn: outputs/figures/stage2/lda_05_largest_topic_trends.png.



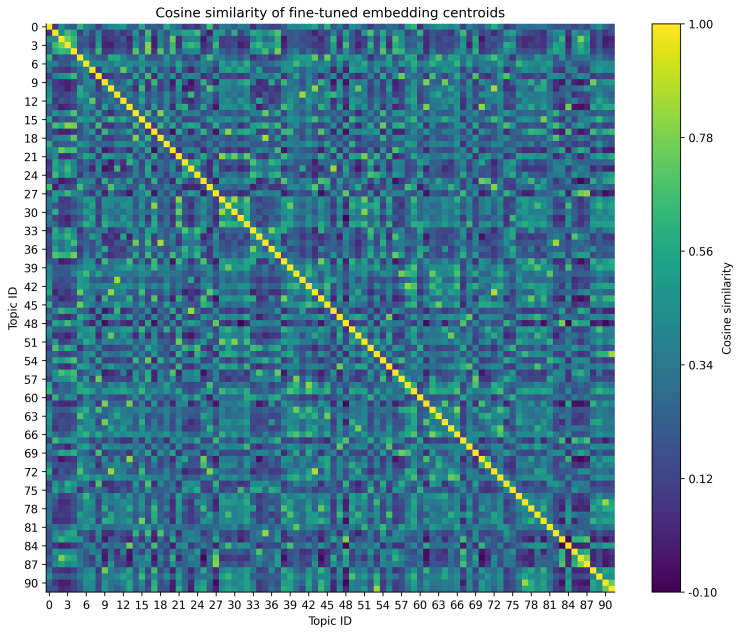
Hình A.26: Từ khóa các topic LDA, Stage2 K20 lịch sử.
Nguồn: outputs/figures/stage2/lda_06_keyword_heatmap.png.



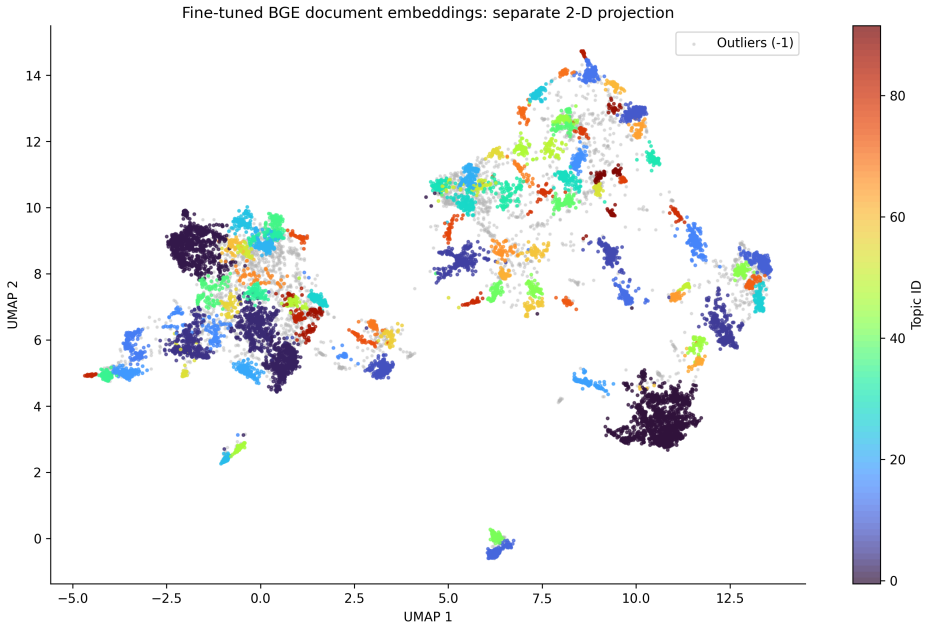
Hình A.27: Phân bố BERTopic Stage3 lịch sử, trước catalog K10.
Nguồn: outputs/figures/stage3/bertopic_01_distribution.png.



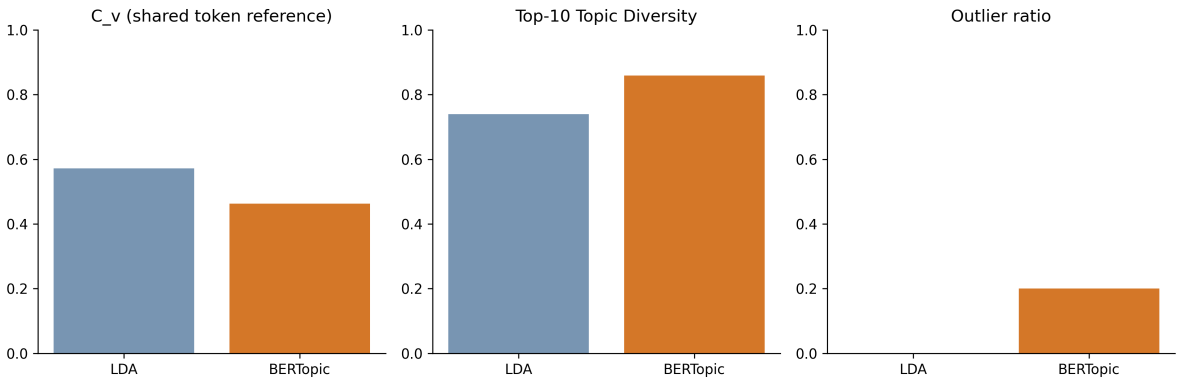
Hình A.28: Từ khóa BERTopic Stage3 lịch sử.
Nguồn: outputs/figures/stage3/bertopic_02_keywords.png.



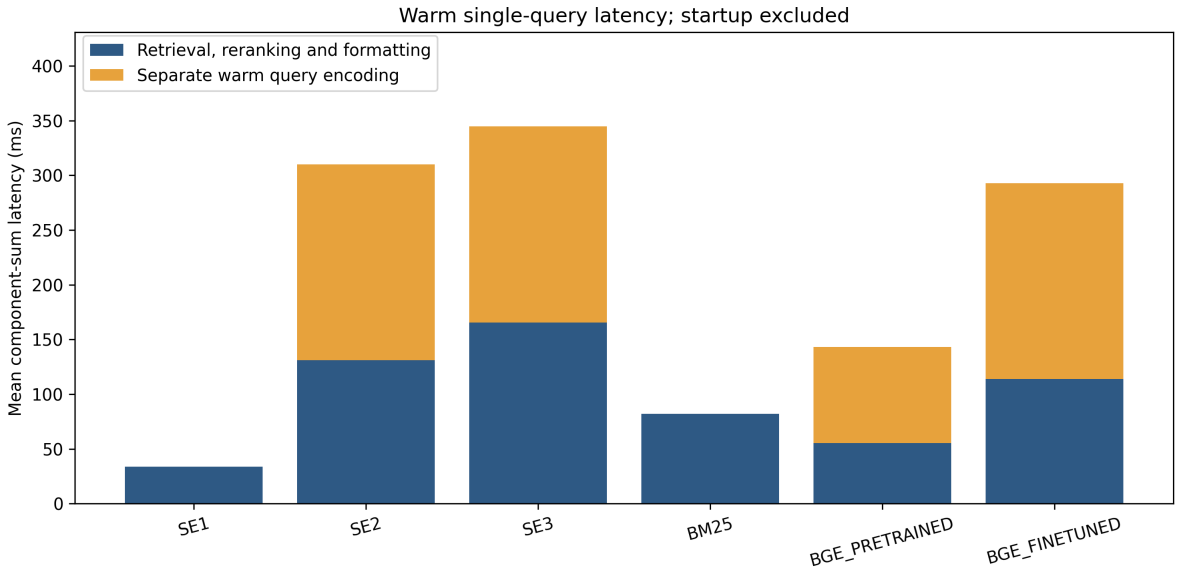
Hình A.29: Độ tương tự giữa các topic BERTopic Stage3 lịch sử.
Nguồn: outputs/figures/stage3/bertopic_03_similarity_heatmap.png.



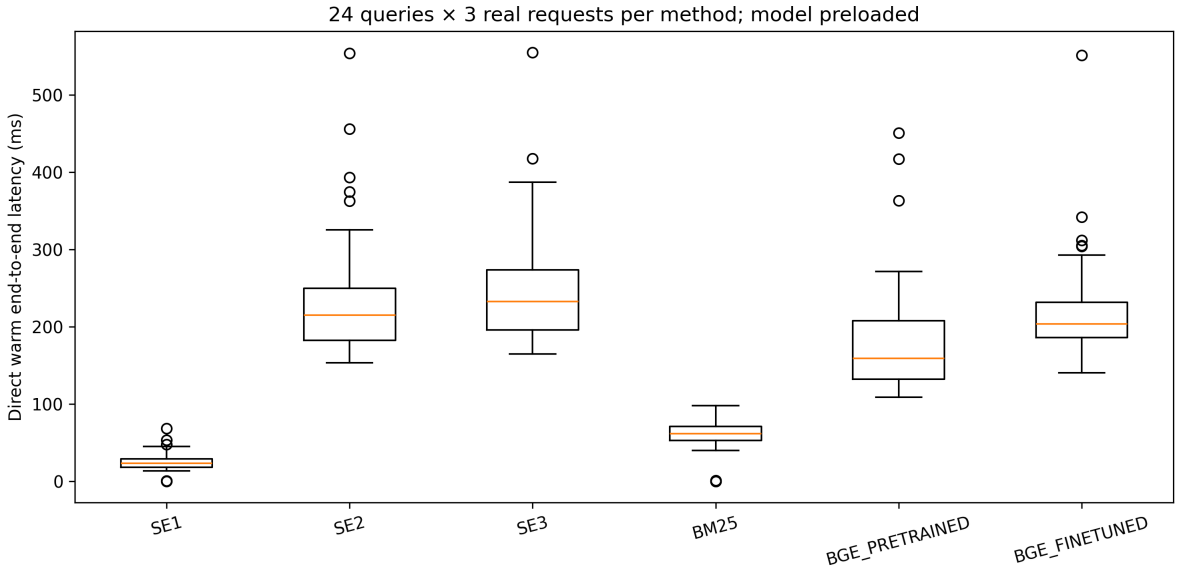
Hình A.30: UMAP2D BERTopic Stage3; chỉ là trực quan hóa.
Nguồn: outputs/figures/stage3/bertopic_04_umap_2d.png.



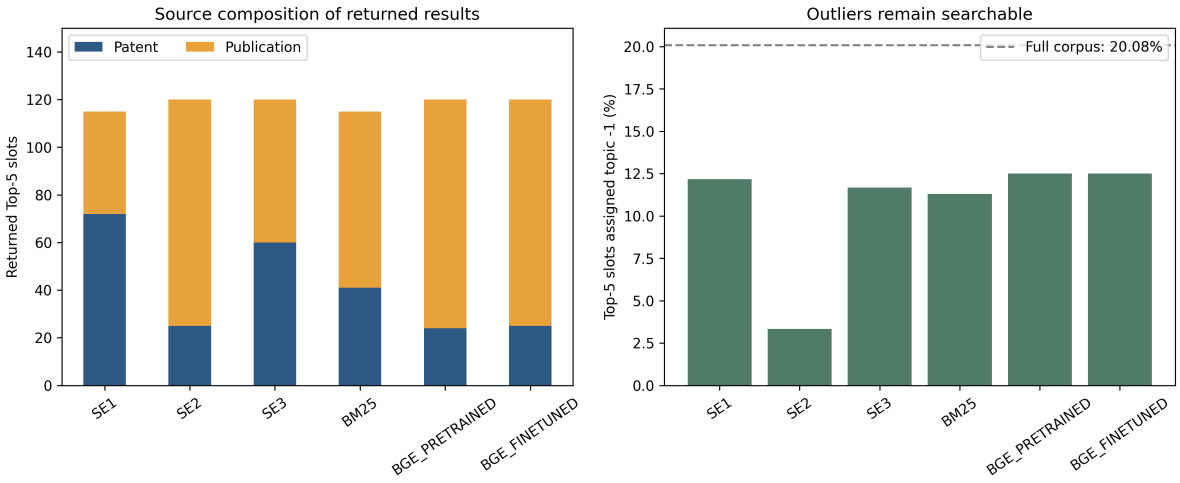
Hình A.31: Đối chiếu topic LDA/BERTopic theo protocol Stage3 lịch sử.
Nguồn: outputs/figures/stage3/comparison_01_topics.png.



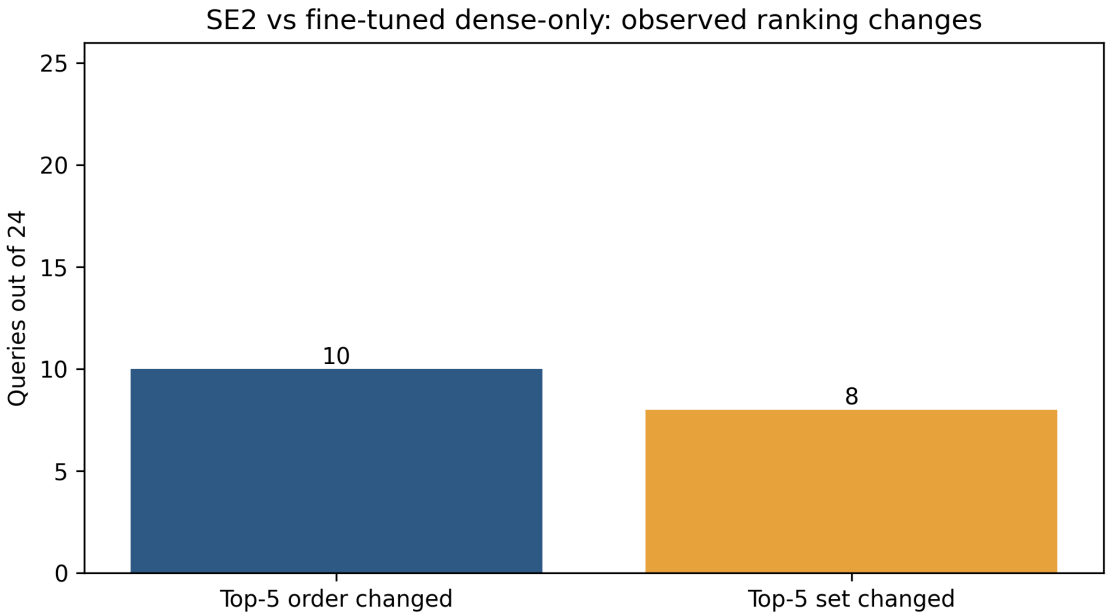
Hình A.32: Các thành phần độ trễ SE1/SE2/SE3, Stage4 Top 5 lịch sử.
Nguồn: outputs/figures/stage4/latency_components.png.



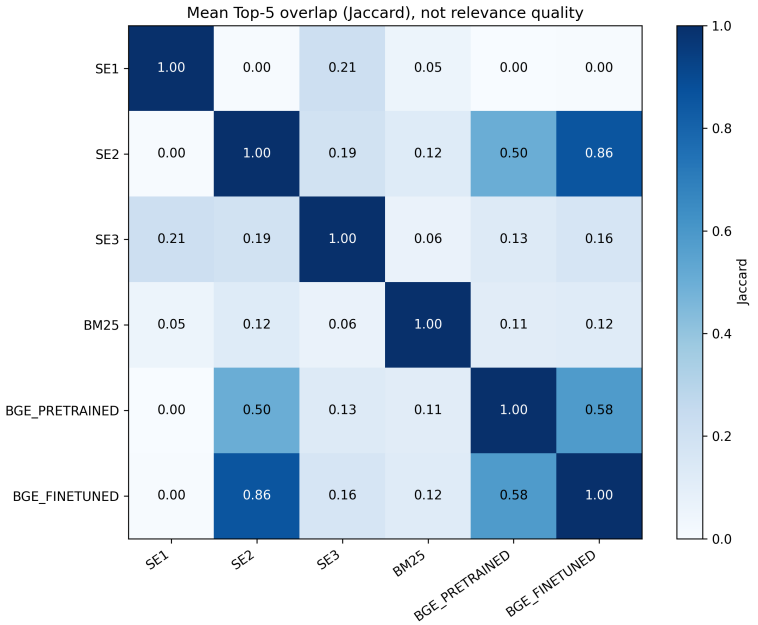
Hình A.33: Phân bố độ trễ SE1/SE2/SE3, Stage4 Top 5 lịch sử.
Nguồn: outputs/figures/stage4/latency_distribution.png.



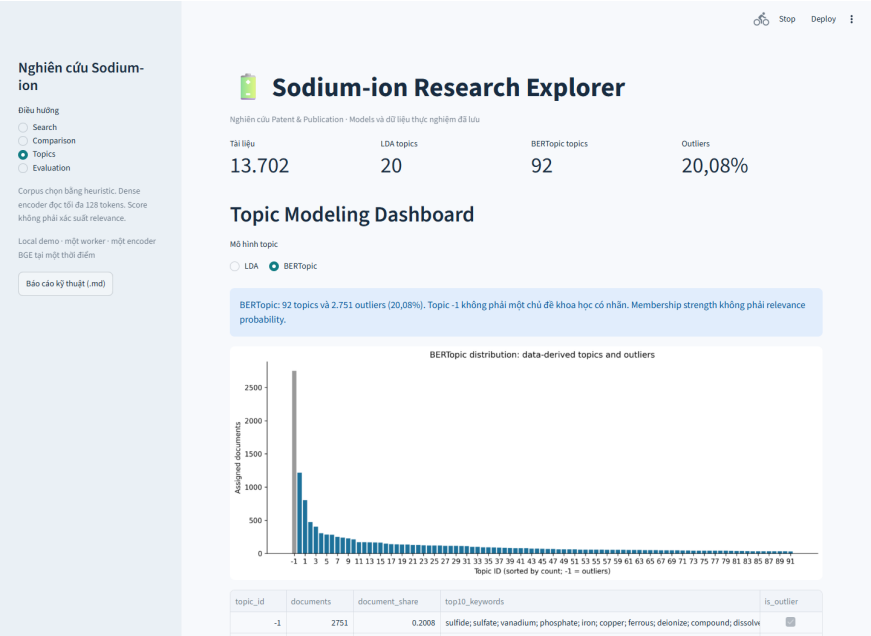
Hình A.34: Thành phần nguồn trong kết quả, Stage4 Top 5 lịch sử.
Nguồn: outputs/figures/stage4/result_composition.png.



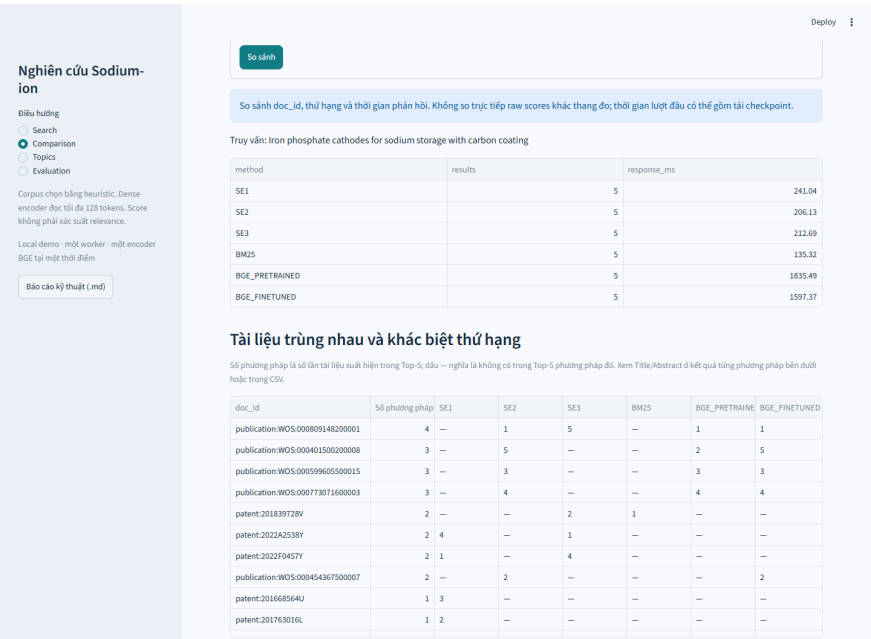
Hình A.35: Thay đổi thứ hạng do topic bonus SE2 lịch sử.
Nguồn: outputs/figures/stage4/se2_reranking_changes.png.



Hình A.36: Độ giao Top 5 giữa các search engine Stage4 lịch sử.
Nguồn: outputs/figures/stage4/top5_overlap_heatmap.png.



Hình A.37: Ảnh dashboard BERTopic đã lưu ở Stage5 lịch sử. *Nguồn:* outputs/figures/stage5/bertopic_dashboard.png.

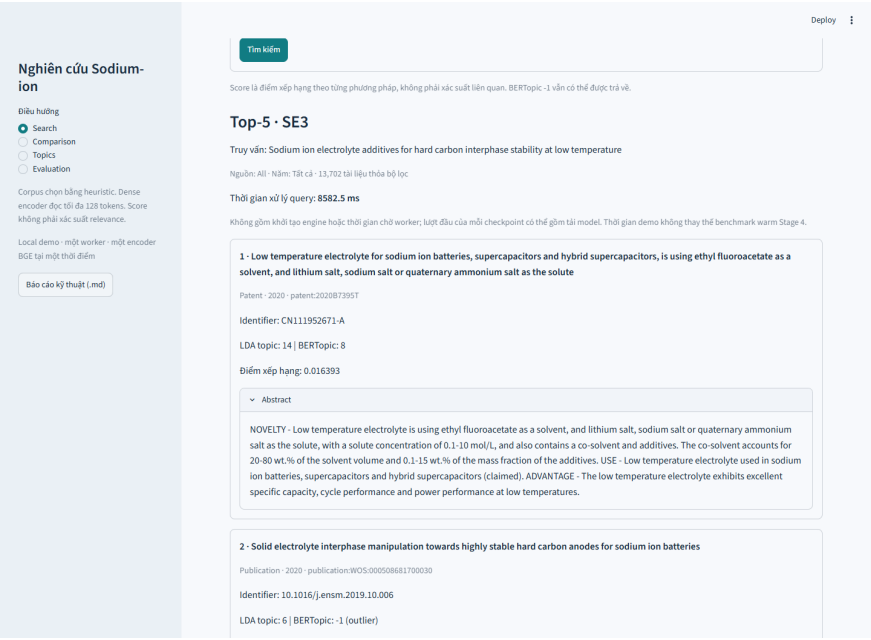


Hình A.38: Ảnh giao diện so sánh mô hình đã lưu ở Stage5 lịch sử. *Nguồn:* outputs/figures/stage5/comparison.png.

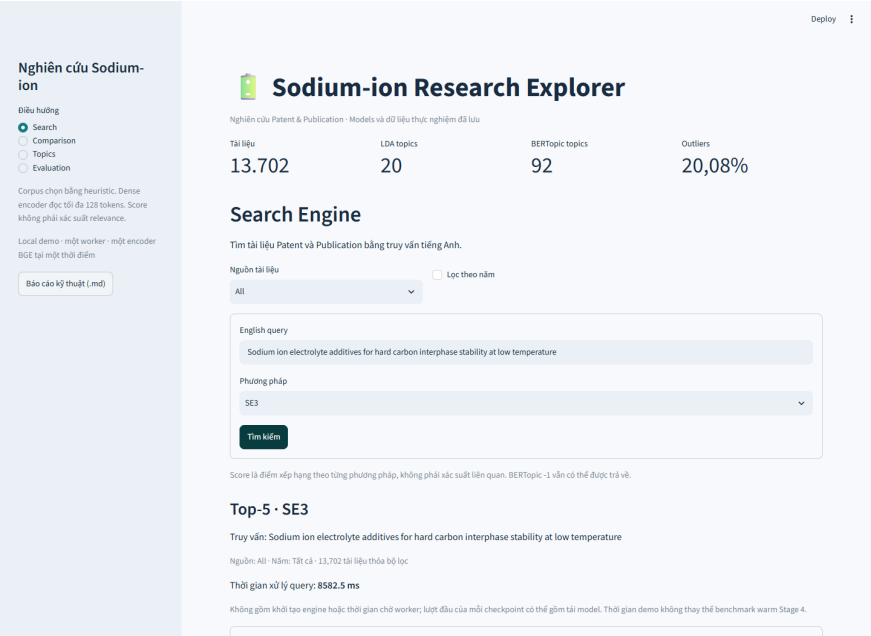


Hình A.39: Ảnh giao diện đánh giá ở Stage5 lịch sử; không phải kết quả703 Silver Labels.

Nguồn: outputs/figures/stage5/evaluation.png.



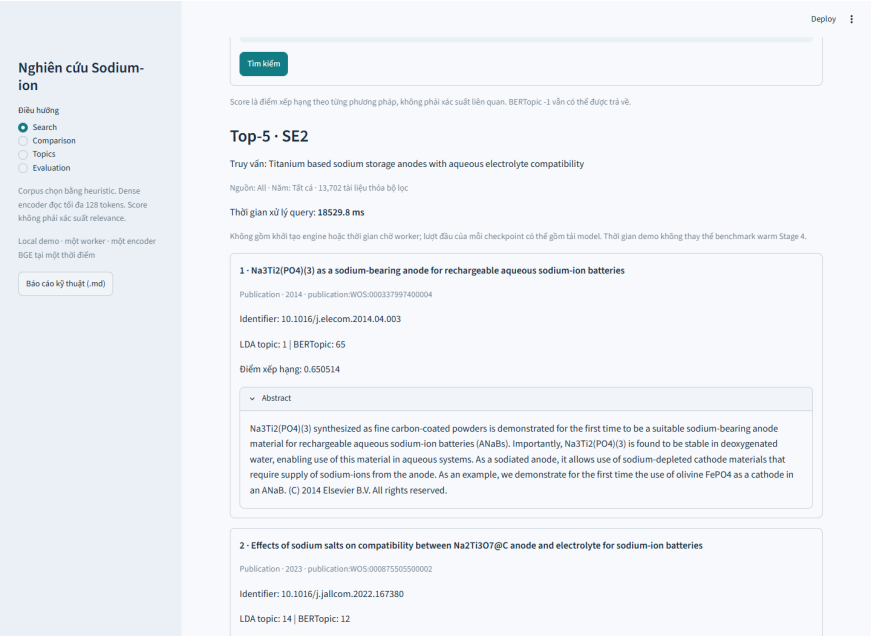
Hình A.40: Ảnh giao diện và kết quả search đã lưu ở Stage5 lịch sử.
Nguồn: outputs/figures/stage5/initial_search.png.



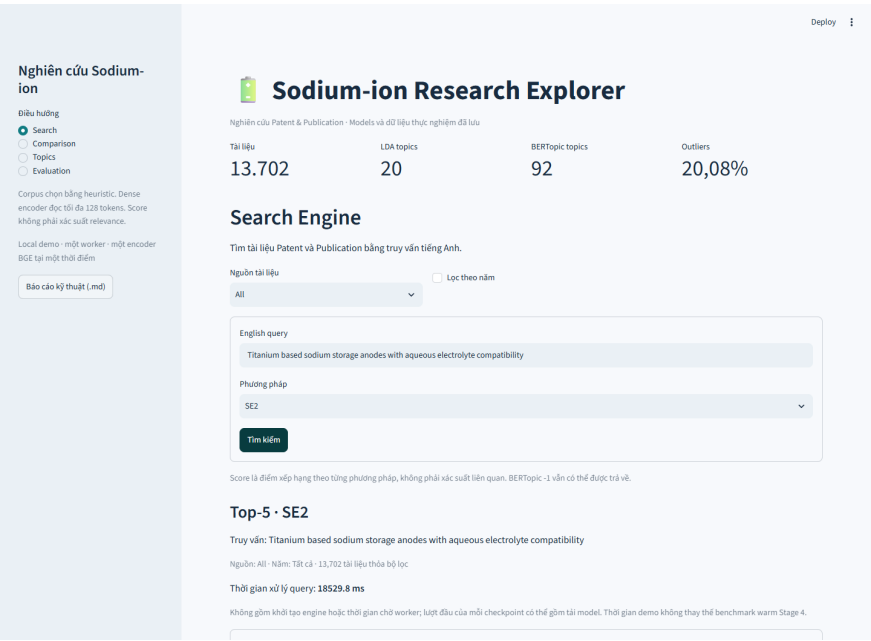
Hình A.41: Form search đã lưu ở Stage5 lịch sử.
Nguồn: outputs/figures/stage5/initial_search_form.png.



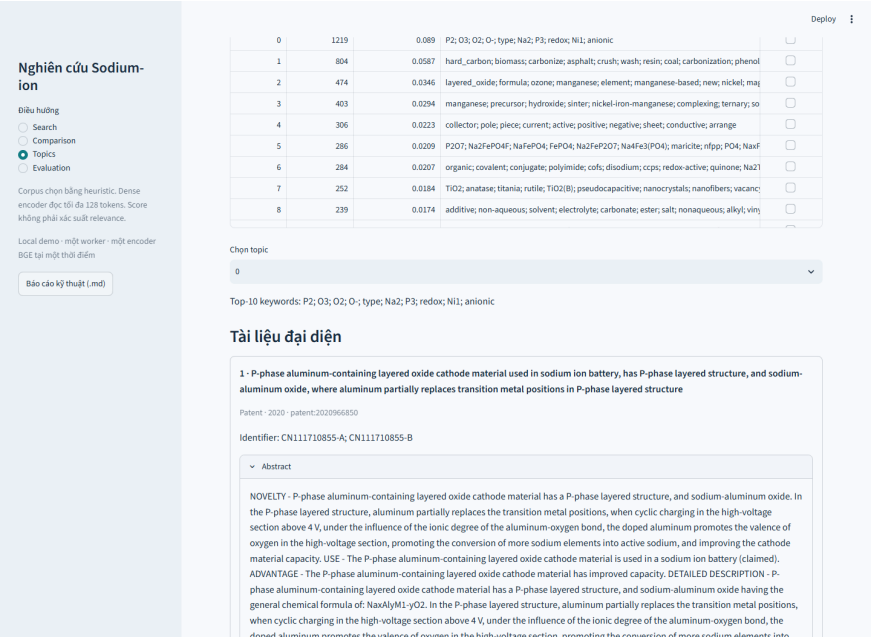
Hình A.42: Ảnh dashboard LDA đã lưu ở Stage5 lịch sử.
Nguồn: outputs/figures/stage5/lda_dashboard.png.



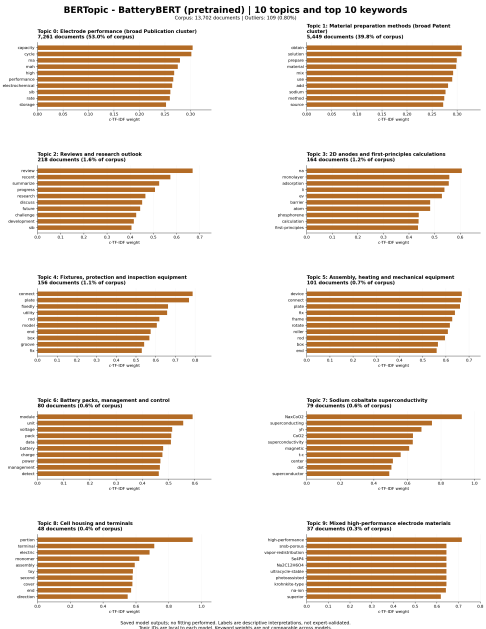
Hình A.43: Kết quả kiểm tra search sau khởi động lại ở Stage5 lịch sử. *Nguồn:* outputs/figures/stage5/restart_search.png.



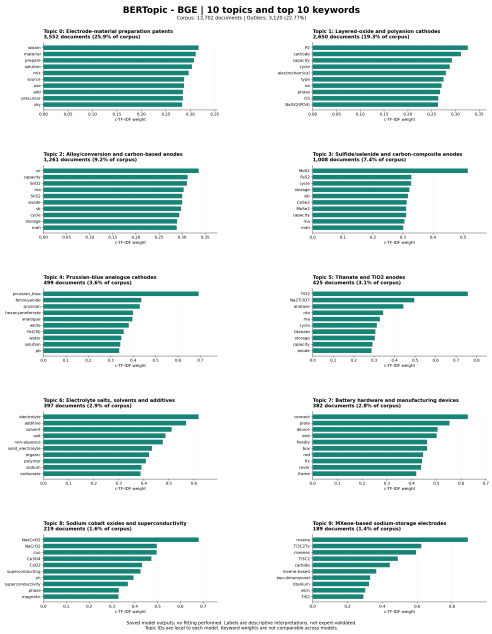
Hình A.44: Form search sau khởi động lại ở Stage5 lịch sử. *Nguồn:* outputs/figures/stage5/restart_search_form.png.



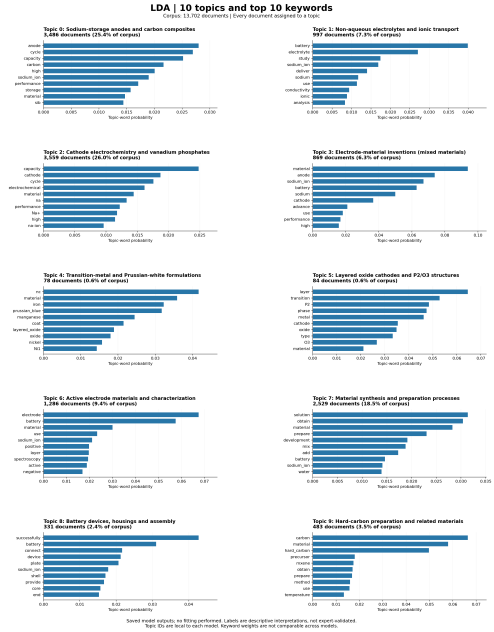
Hình A.45: Ảnh giao diện các tài liệu đại diện topic, Stage5 lịch sử.
Nguồn: outputs/figures/stage5/topic_representatives.png.



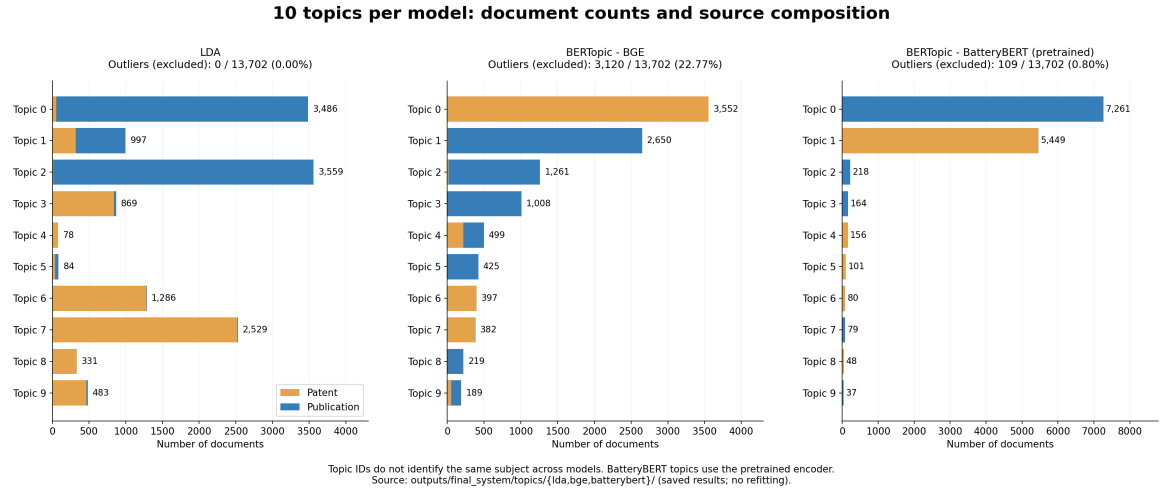
Hình A.46: Đủ10 topic BERTopic–BatteryBERT pretrained, ảnh output gốc.
Nguồn: outputs/final_system/topic_figures/batterybert_10_topics.png.



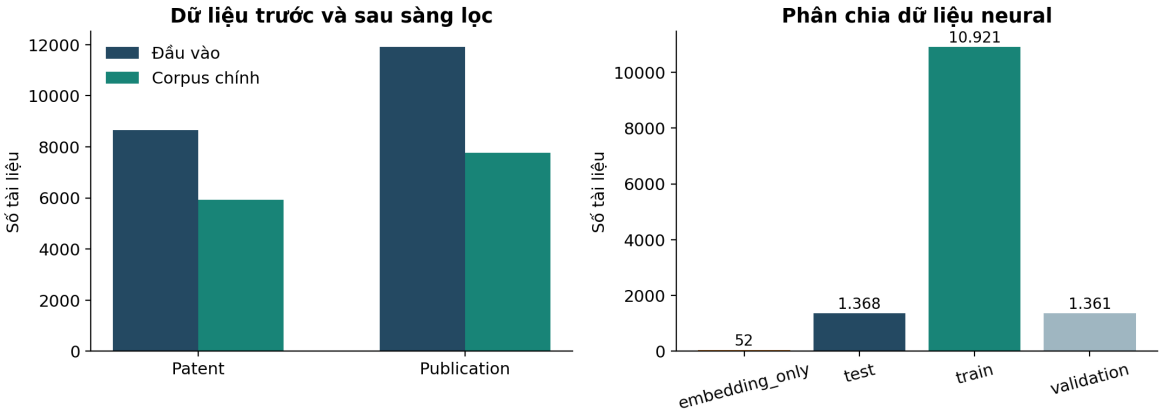
Hình A.47: Đủ10 topic BERTopic–BGE, ảnh output gốc.
Nguồn: outputs/final_system/topic_figures/bge_10_topics.png.



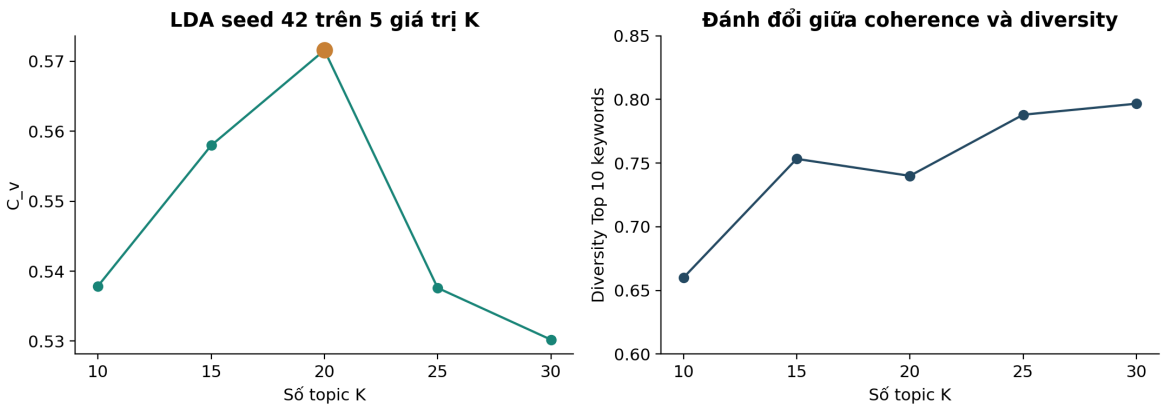
Hình A.48: Đủ10 topic LDA K10, ảnh output gốc.
Nguồn: outputs/final_system/topic_figures/lda_10_topics.png.



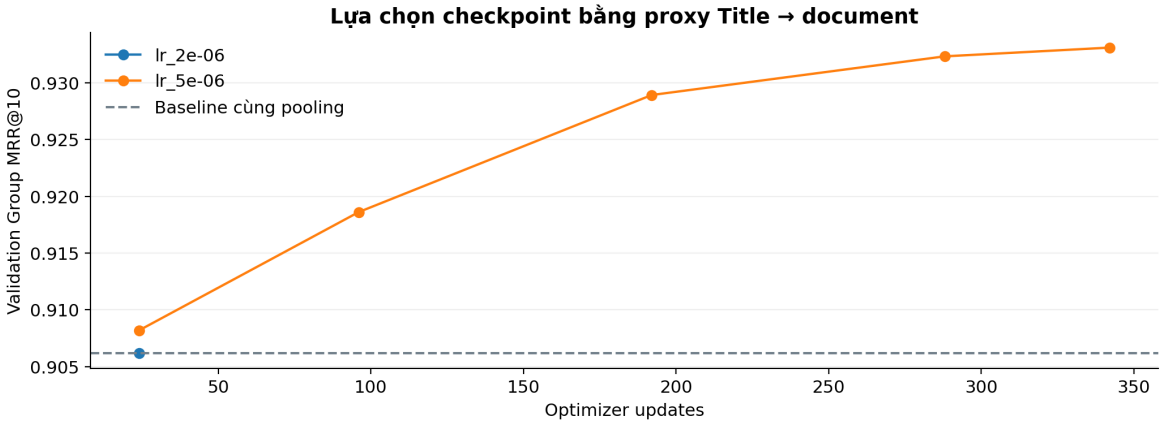
Hình A.49: So sánh ba catalog K10, ảnh output gốc.
Nguồn: outputs/final_system/topic_figures/three_models_10_topics.png.



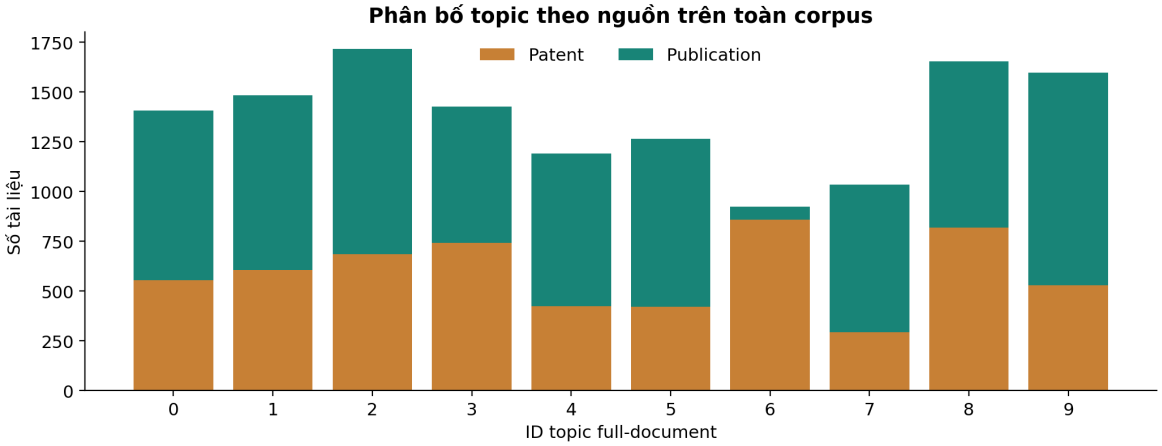
Hình A.50: Quy mô dữ liệu và split trong báo cáo pipeline25/10.
Nguồn: outputs/report_pipeline_20261025/figures/02_data.png.



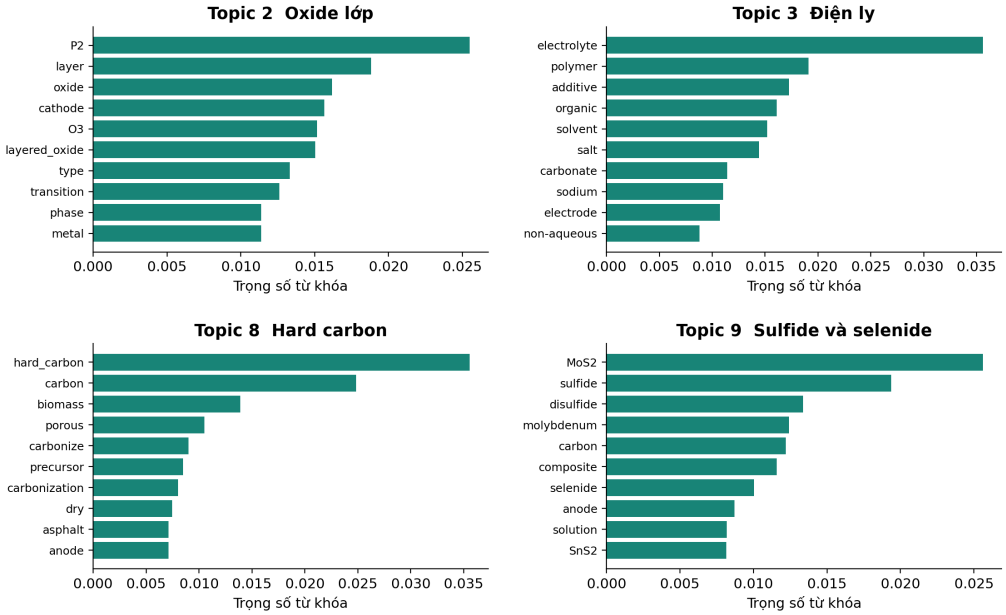
Hình A.51: Lựa chọn K của LDA Stage2, hình tổng hợp25/10.
Nguồn: outputs/report_pipeline_20261025/figures/03_lda_selection.png.



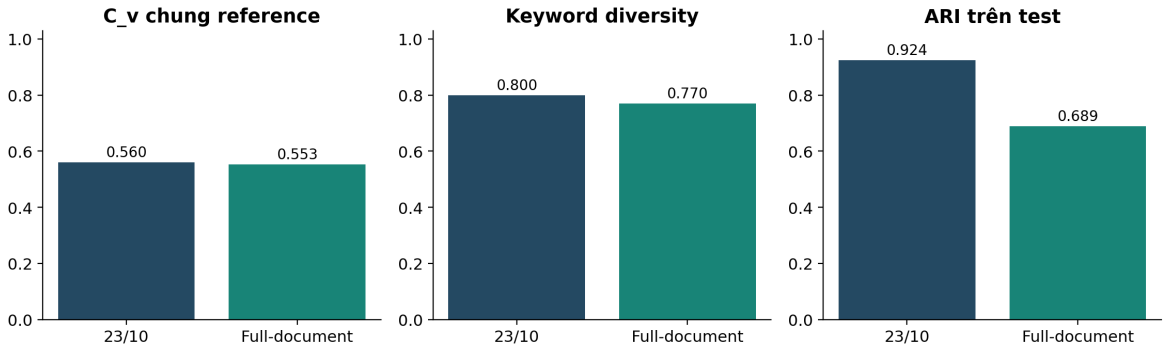
Hình A.52: Đường train BatteryBERT full-document, hình tổng hợp25/10.
Nguồn: outputs/report_pipeline_20261025/figures/06_learning_curve.png.



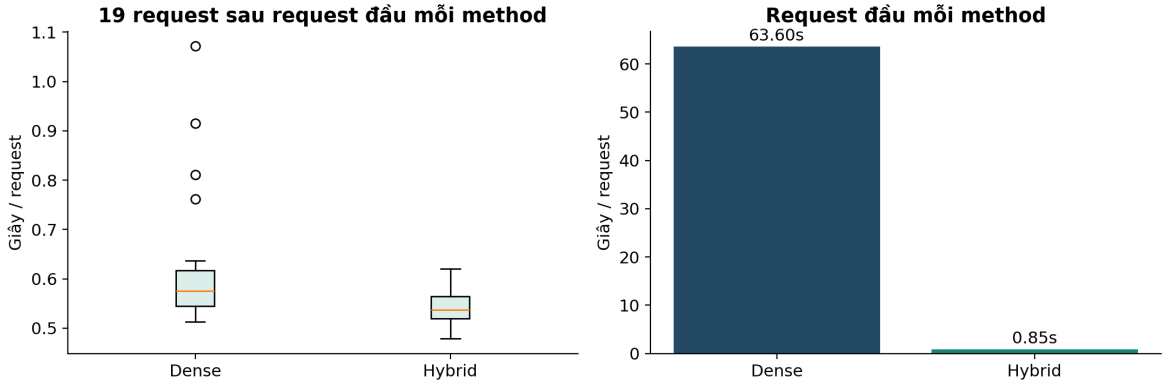
Hình A.53: Phân bố nguồn của catalog full-document24/10 trước stable revision. *Nguồn:* outputs/report_pipeline_20261025/figures/08_topic_sources.png.



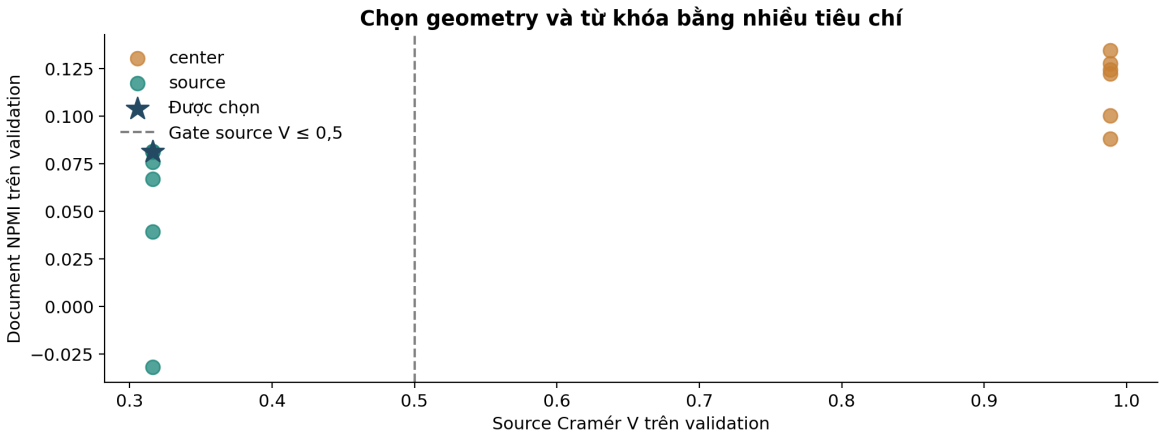
Hình A.54: Từ khóa catalog full-document24/10 trước stable revision. *Nguồn:* outputs/report_pipeline_20261025/figures/09_keywords.png.



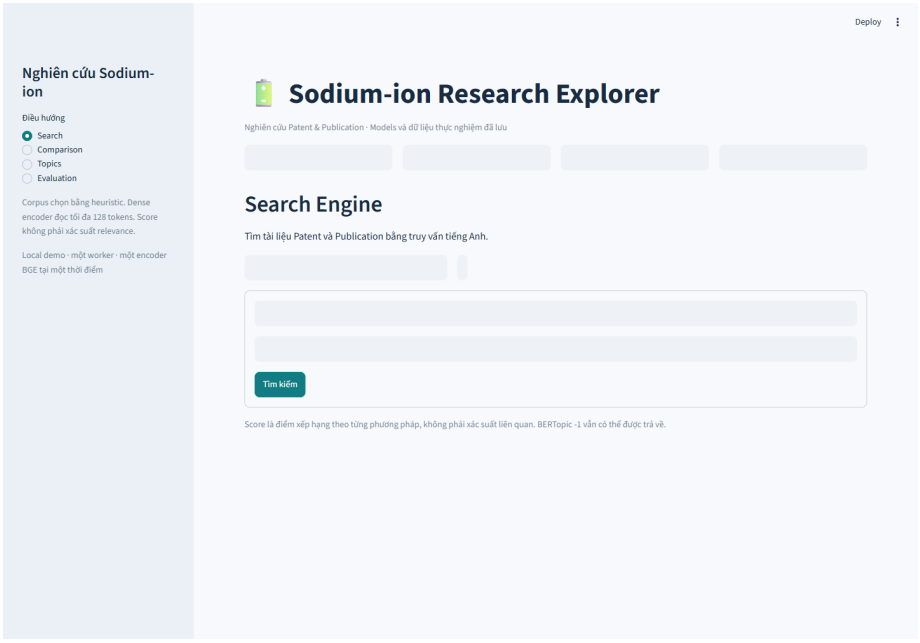
Hình A.55: Đánh đổi giữa các chỉ số topic, hình tổng hợp25/10.
Nguồn: outputs/report_pipeline_20261025/figures/10_topic_tradeoffs.png.



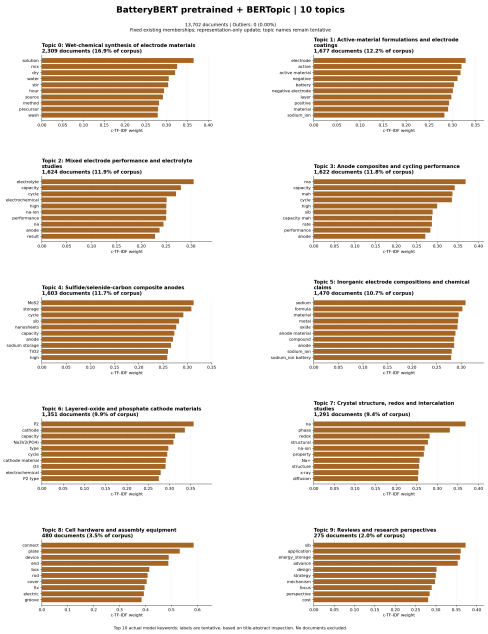
Hình A.56: Độ trễ search theo benchmark đã lưu, hình tổng hợp25/10.
Nguồn: outputs/report_pipeline_20261025/figures/11_latency.png.



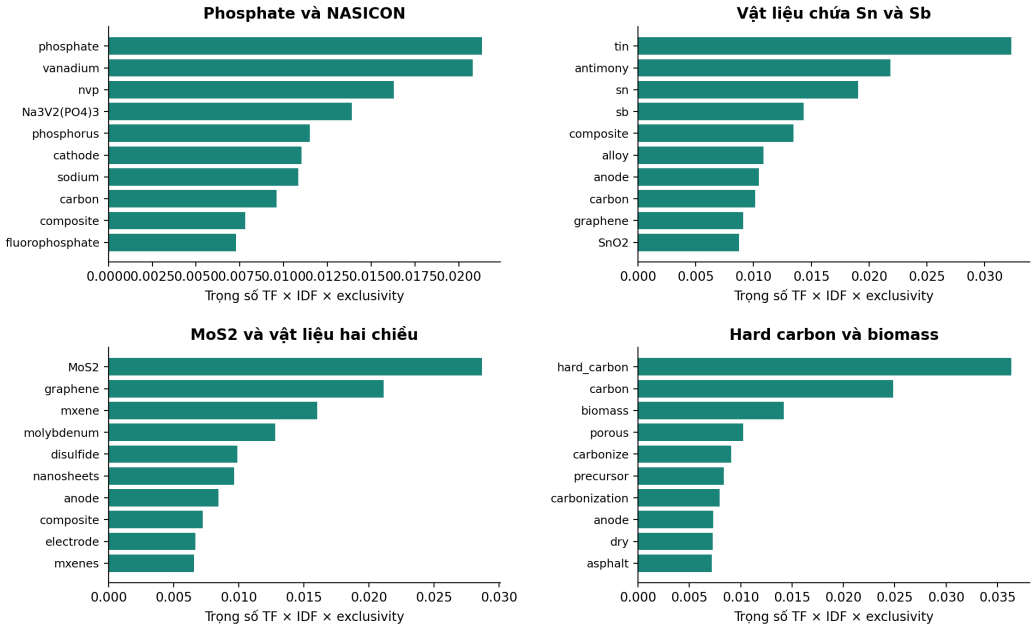
Hình A.57: Các ứng viên topic validation, hình tổng hợp25/10.
Nguồn: outputs/report_pipeline_20261025/figures/12_validation_tradeoff.png.



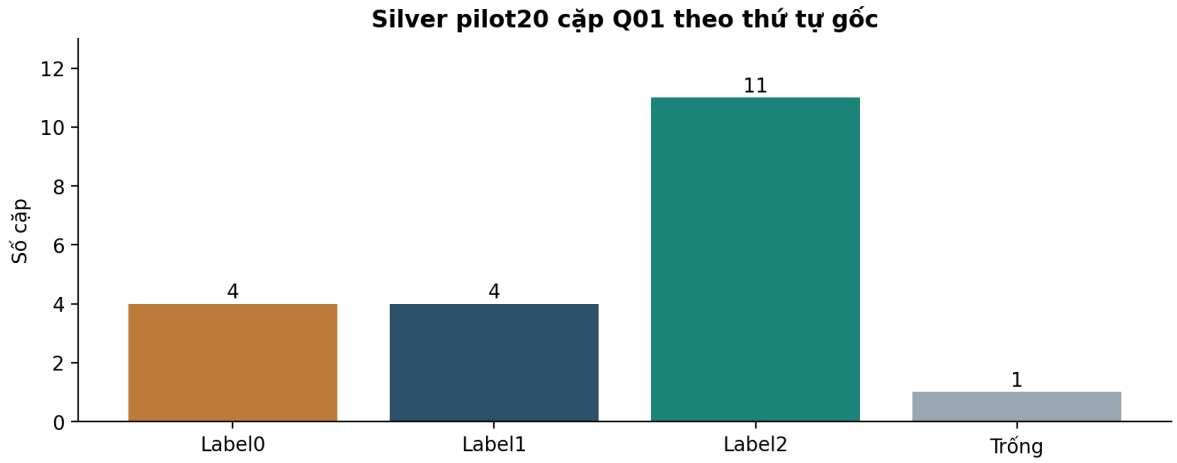
Hình A.58: Ảnh giao diện và kết quả search đã lưu ở Stage5 lịch sử.
Nguồn: outputs/reports/stage5/initial_search.png.



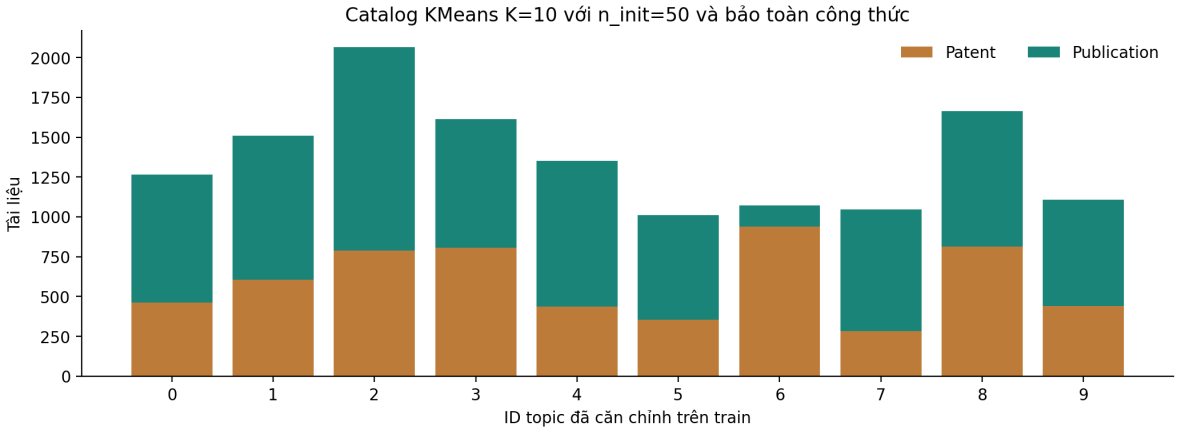
Hình A.59: Đủ10 topic KMeans BatteryBERT pretrained, ảnh output gốc.
Nguồn: outputs/research_completion_v1/topics/topic_keywords_10_topics.png.



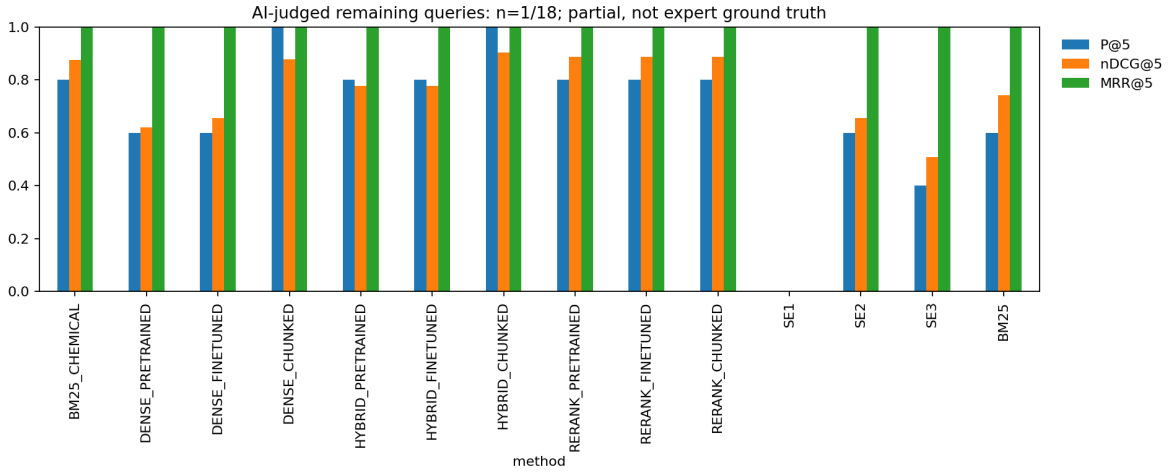
Hình A.60: Một số topic stable với Top 10 keywords, ảnh revision gốc.
Nguồn: outputs/research_revision_20261025_v1/visualizations/revised_top10_keywords.png.



Hình A.61: Pilot20 cặp AI lịch sử; đã được mở rộng thành 703 nhãn ở phần chính. *Nguồn:* outputs/research_revision_20261025_v1/visualizations/silver_pilot20.png.

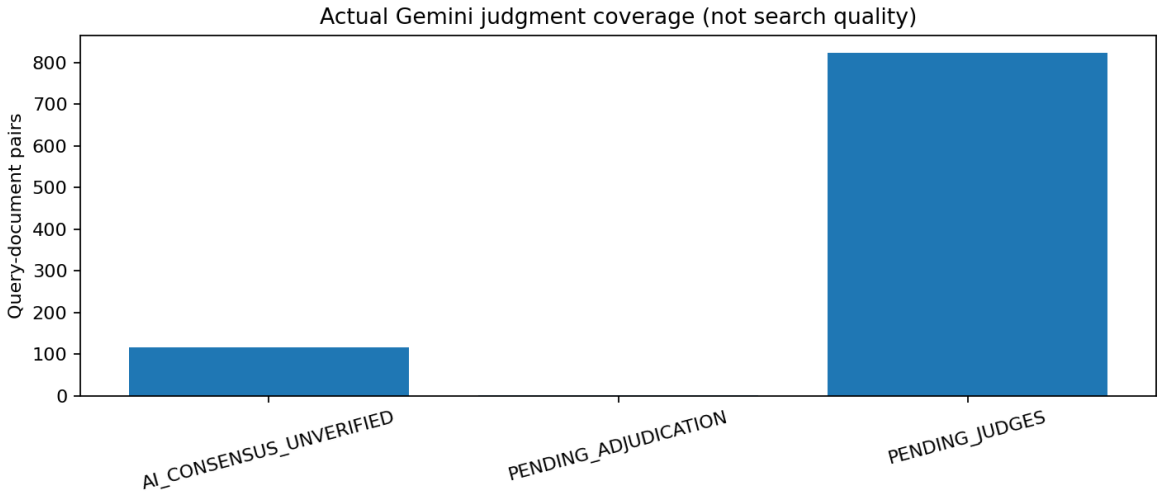


Hình A.62: Phân bố nguồn của catalog stable topics mới nhất. *Nguồn:* outputs/research_revision_20261025_v1/visualizations_v2/revised_topic_sources.png.



Hình A.63: Điểm trên phần AI consensus đủ pool Top 5 lịch sử; không dùng thay Silver703.

Nguồn: outputs/retrieval_ai_evaluation_v1/ai_relevance_metrics_remaining.png.



Hình A.64: Coverage AI consensus Top 5 lịch sử, trước bộ Silver703.

Nguồn: outputs/retrieval_ai_evaluation_v1/judgment_coverage.png.

Phụ lục B

Danh sách truy vấn đánh giá và nguồn bằng chứng

Bảng B.1: Toàn bộ20 query tiếng Anh đã khóa trước chấm.

ID	Nhóm	Truy vấn
Q01	hard_carbon	Hard carbon anodes derived from biomass for sodium-ion batteries
Q02	hard_carbon	Initial Coulombic efficiency and sodium storage mechanisms in hard carbon
Q03	cathode	P2 and O3 layered oxide cathodes with reversible anionic redox
Q04	cathode	Prussian blue analogues with low vacancies and low water content
Q05	cathode	Na3V2(PO4)3 NASICON cathodes with carbon coating
Q06	cathode	Low-cost iron phosphate and pyrophosphate cathode materials
Q07	electrolyte	Fluoroethylene carbonate additives and stable SEI on hard carbon
Q08	electrolyte	NaFSI ether electrolytes for low-temperature sodium-ion batteries
Q09	solid_state	Na3PS4 and Na3SbS4 sulfide solid electrolytes
Q10	solid_state	NASICON Na3Zr2Si2PO12 ceramic ionic conductivity
Q11	anode	Ti3C2Tx MXene interlayer engineering for sodium storage
Q12	anode	MoS2 nanosheets and expanded interlayer spacing for sodium storage
Q13	anode	Sn4P3 alloying anodes and volume expansion control
Q14	anode	Organic quinone and covalent framework sodium-ion electrodes
Q15	manufacturing	Slurry binders and current collectors for sodium-ion electrodes
Q16	manufacturing	Roll pressing and electrode coating equipment for sodium-ion batteries

ID	Nhóm	Truy vấn
Q17	safety	Thermal management and safety of sodium-ion battery packs
Q18	recycling	Recycling spent sodium-ion batteries and recovery of cathode metals
Q19	aqueous	Aqueous sodium-ion batteries with water-in-salt electrolytes
Q20	full_cell	Hard carbon full cells with layered oxide cathodes and electrolyte additives

Nguồn: outputs/batterybert_full_document_20261024_v1/queries.csv.

B.1 Nguồn và cách tái lập báo cáo

Script build_report.py chỉ đọc artifacts, sao chép hình, sinh bảng và các hình tổng hợp từ dữ liệu đã có. Không train encoder, không encode corpus, không mở Qdrant và không gọi dịch vụ AI. Manifest kèm hash nguồn, catalog70 topic, figure inventory và validation PDF. Các checkpoint/model weights không đóng vào ZIP do dung lượng; nguồn báo cáo và tất cả hình được nhúng có đầy đủ.

Biên dịch bằng XeLaTeX/BibTeX hoặc Tectonic; xem hướng dẫn README.md. Muốn chạy ứng dụng dùng .venv/Scripts/python.exerun_demo.py tại gốc dự án với môi trường đã cài. Chạy train hoặc benchmark mới là công việc riêng, không cần để mở báo cáo. Các số kiểm thử lịch sử102 PASS mô tả phiên revision đã lưu; quá trình biên soạn này chỉ chạy kiểm tra artifact/PDF, không tuyên bố chạy lại102 tests.

Bảng B.2: Các nguồn bằng chứng chính.

Nội dung	Nguồn
Corpus và split	data/processed/main_corpus.parquet;data/stage3/split_assignments.parquet
Train và checkpoint	outputs/batterybert_full_document_20261024_v1/training_protocol.json;selection.json
Topic K10 lịch sử	docs/TOP10_TOPICS_ALL_MODELS_20261024.csv
Catalog stable	outputs/research_revision_20261025_v1/final_topics;review/topic_labels.csv;deployment.json

Nội dung	Nguồn
Rank và nhãn	outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv
Metrics và bất định	outputs/ai_silver_labels_703_20261026_v1/evaluation/metrics_summary.csv;confidence_intervals.csv;paired_deltas.csv
Toàn bộ hình	figure_inventory.jsontrongbộnguồnbáocáo
Hash nguồn đã đọc	evidence_manifest.jsontrongbộnguồnbáocáo