BÁO CÁO PIPELINE KHÁM PHÁ CHỦ ĐỀ VÀ TÌM KIẾM TÀI LIỆU PIN SODIUM ION

Sodium ion Research Explorer

Tổng hợp mã nguồn và kết quả thực nghiệm đã lưu trong D:\daln
Ngày biên soạn 25 tháng 10 năm 2026

Báo cáo trình bày toàn bộ đường đi từ dữ liệu Patent và Publication đến LDA, BERTopic, các biến thể BatteryBERT và kết quả Search Top 10. Mỗi phần liên kết phương pháp với bảng output, hình kết quả và giới hạn diễn giải.

Dữ liệu hiện có	Đầu ra topic	Đầu ra Search
13.702 Title–Abstract	6 catalog và 60 topic 600 vị trí từ khóa	20 query benchmark 703 cặp chờ nhãn người

Kết quả chính

LDA Stage2 chọn K = 20; bảng đối chứng dùng LDA K10. BERTopic–BatteryBERT pretrained có coherence lịch sử cao nhưng hai cụm chiếm 92,8% corpus. Nhánh full-document mới đọc đủ Abstract, cải thiện proxy ghép Title–document và tạo catalog KMeans10 đang được ứng dụng sử dụng.

Test proxy của continuation tăng từ 0,887839 lên 0,924704. Kết quả topic có đánh đổi: coherence, diversity và ARI giảm so với bản optimized trước. Chưa có nhãn relevance độc lập để tuyên bố model Search nào tốt nhất.

Phạm vi dữ liệu là Title và Abstract, chưa có toàn văn bài báo. Các số đo dưới đây được đọc từ output hiện có; báo cáo này không huấn luyện lại model.

Nội dung báo cáo

Báo cáo đi theo đường xử lý dữ liệu, giải thích từng họ mô hình, trình bày output và đánh giá sau khi sinh kết quả. Phụ lục giữ đủ catalog để người đọc kiểm tra lại từng topic và danh sách từ khóa.

Nội dung	Mục	Trang
Pipeline tổng thể	1	3
Dữ liệu và thiết kế thí nghiệm	2 đến 3	4 đến 5
LDA và kết quả chọn số topic	4 đến 5	6 đến 7
BGE và BatteryBERT	6	8
BERTopic và sáu catalog đối chứng	7 đến 9	9 đến 11
KMeans và huấn luyện full document	10 đến 13	12 đến 15
Output topic và đánh giá Top 10 keywords	14 đến 17	16 đến 19
Search Top 10 và đánh giá relevance	18 đến 21	20 đến 23
Thảo luận và đối chiếu nguồn output	22 đến 23	24 đến 25
Đủ 60 topic và 600 vị trí keywords	Phụ lục A đến F	26 đến 31

Cách đọc các kết quả

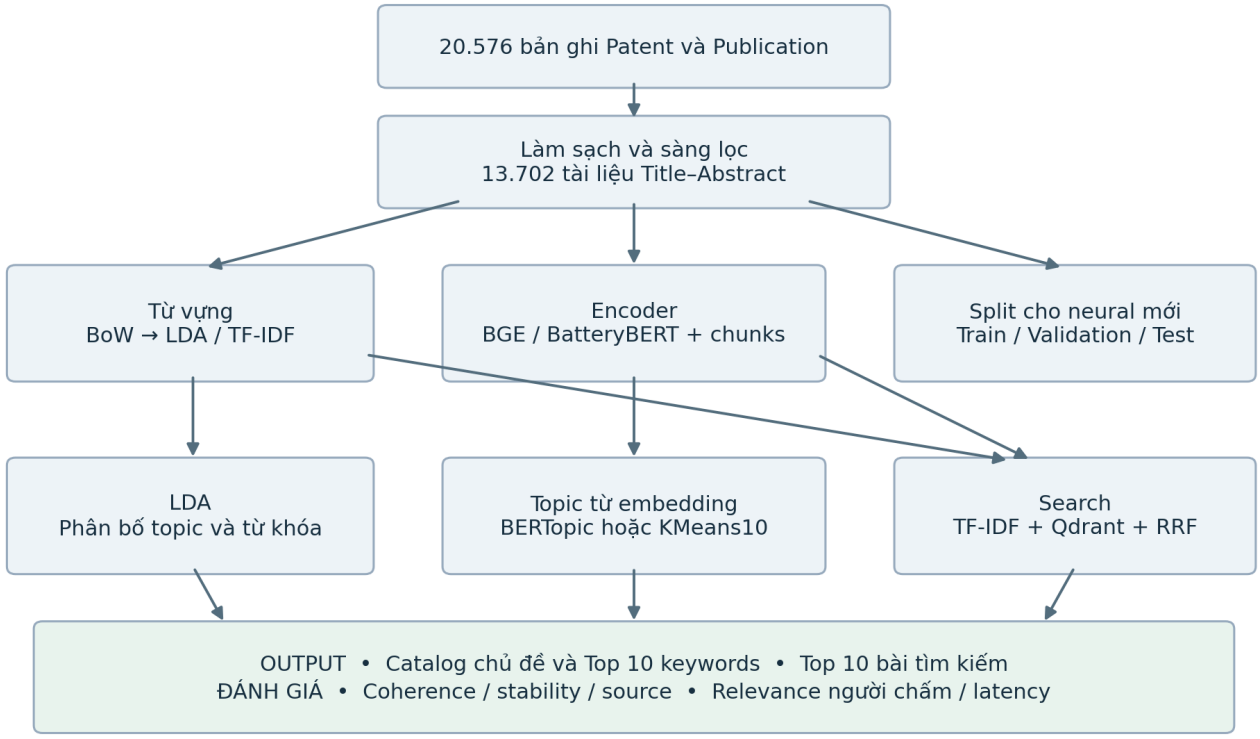
Các bảng có chữ lịch sử mô tả artifacts của lượt chạy trước. Các bảng full-document mô tả lượt continuation ngày 24/10. Những thước đo khác protocol được trình bày riêng để tránh so sánh sai phạm vi.

Ba loại Top 10 có ý nghĩa khác nhau: 10 topic là số nhóm của catalog; Top 10 keywords mô tả từng topic; Top 10 bài là kết quả truy hồi cho một query. Coherence đánh giá từ khóa, còn relevance có nhãn đánh giá kết quả tìm kiếm.

Biểu đồ trong báo cáo được dựng lại trực tiếp từ output CSV và JSON đã lưu. Các công thức được render thành hình để giữ đúng ký hiệu trong PDF; bản Markdown đi kèm giữ biểu thức và đường dẫn ảnh để có thể chỉnh sửa.

1 Bài toán và pipeline tổng thể

Mục tiêu thứ nhất là tổ chức tài liệu thành các nhóm chủ đề để người dùng khảo sát hướng nghiên cứu. Mục tiêu thứ hai là trả về các bài liên quan tới truy vấn. Hai mục tiêu chia sẻ dữ liệu và encoder nhưng sử dụng tiêu chí đánh giá khác nhau.



Hình 1. Pipeline từ dữ liệu đến hai đầu ra topic và Search. Sơ đồ được dựng từ các module hiện có.

Nguồn output: src/pipeline.py; src/model_comparison.py; src/final_search.py

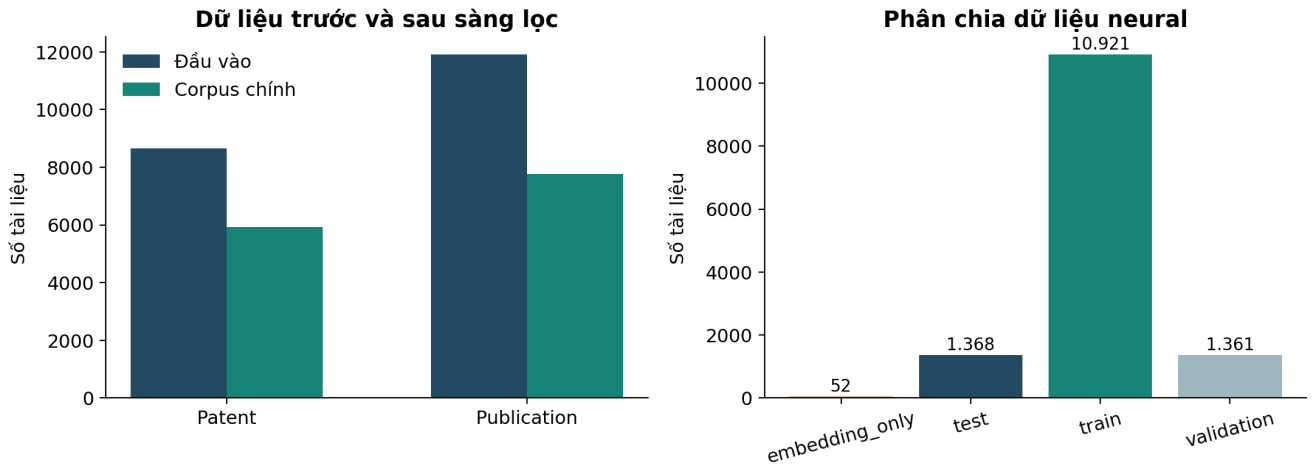
Huấn luyện, encode corpus và xây chỉ mục chạy offline. Khi khởi động, ứng dụng đọc artifacts đã chuẩn bị. Lúc tìm kiếm, hệ thống chỉ xử lý query, áp dụng bộ lọc, truy hồi và hợp nhất thứ hạng. Topic hỗ trợ duyệt và lọc, không được cộng như điểm thưởng vào ranking.

Giai đoạn	Input	Output cụ thể
Chuẩn bị dữ liệu	Excel Patent và Publication	main_corpus.parquet; lda_tokens.parquet; bert_texts.parquet
Topic lexical	Tokens và BoW	LDA posterior; keywords; representatives
Topic neural	Embeddings BGE hoặc BatteryBERT	Assignments; catalog topic; diagnostics
Search	Query và bộ lọc	Top 10 bài; cosine; RRF; thời gian

2 Dữ liệu và sàng lọc chất lượng

Hai tập nguồn có tổng cộng 20.576 bản ghi. Clean master giữ provenance của toàn bộ đầu vào; corpus chính dùng 13.702 tài liệu sau các quy tắc sàng lọc. Nhãn CORE và RELATED là heuristic, không phải đánh giá khoa học độc lập.

Nguồn	Đầu vào	Corpus chính	Giữ lại
Patent	8.657	5.933	68,53%
Publication	11.919	7.769	65,18%



Hình 2. Số tài liệu trước và sau sàng lọc và phân chia dữ liệu cho nhánh neural mới.

Nguồn output: outputs/reports/stage1_summary.json; outputs/batterybert_full_document_20261024_v1/text_length_summary.csv

Disposition	Số bản ghi	Diễn giải
MAIN_CORPUS	13.702	Dùng trong corpus chính
RELEVANCE_REVIEW	6.596	Cần rà soát mức liên quan
OUT_OF_SCOPE	254	Ngoài phạm vi theo heuristic
LANGUAGE_REVIEW	15	Cần kiểm tra ngôn ngữ
RETRACTED / DUPLICATE / TEXT	9	4 thu hồi; 3 trùng xác nhận; 2 chất lượng văn bản

Quy trình gồm sửa cấu trúc bảng, chuẩn hóa metadata và văn bản, kiểm tra ngôn ngữ, thu hồi, trùng lặp và phạm vi. Giữ doc_id, nguồn, năm, identifier và split_group_id; không tạo Abstract giả cho bản ghi thiếu.

3 Biểu diễn văn bản và thiết kế thí nghiệm

Nhánh lexical dùng chuỗi token đã xử lý và Dictionary chung. LDA sử dụng số đếm Bag-of-Words. Nhánh neural giữ văn bản để tokenizer của encoder xử lý; không đưa chuỗi đã bỏ toàn bộ ngữ cảnh vào Transformer.

Dữ liệu	Số tài liệu	Vai trò
Train	10.921	Optimizer; fit geometry, KMeans và vocabulary của nhánh inductive mới
Validation	1.361	Chọn learning rate, checkpoint và recipe topic
Test	1.368	Đánh giá sau khi chọn; không đưa vào optimizer
Title only	52	Chỉ inference; không tham gia contrastive training

Grouped split giữ các tài liệu cùng split_group_id trong một tập nhằm hạn chế rò rỉ giữa train, validation và test. Việc này không chứng minh đã nhận diện mọi trường hợp trùng ý hoặc mọi patent family.

Phân biệt hai phạm vi đánh giá

LDA và BERTopic đối chứng lịch sử là khám phá trên corpus đã đóng băng; coherence toàn corpus mô tả cấu trúc quan sát được. Nhánh optimized và full-document mới fit geometry, KMeans và từ vựng trên train, dùng validation để chọn và test để đánh giá. Hai giao thức không nên bị gọi chung là một phép thử held-out.

Loại output	Ý nghĩa điểm	Không suy ra được
LDA posterior	Tỷ trọng topic theo mô hình xác suất	Độ đúng khoa học của tên topic
BERTopic affinity	Cosine BoW với c-TF-IDF, chuẩn hóa L1	Posterior đã hiệu chuẩn
Dense cosine / RRF	Điểm dùng để xếp hạng tài liệu	Xác suất bài trả lời đúng query
Proxy Title → document	Khả năng tìm lại cặp hoặc nhóm tài liệu	Relevance query tự nhiên độc lập

Nguồn output: configs/stage2.yaml; configs/stage3.yaml; configs/model_comparison.yaml; outputs/batterybert_full_document_20261024_v1/training_protocol.json

4 LDA và bản chất mô hình chủ đề xác suất

LDA giả định mỗi tài liệu là hỗn hợp nhiều topic và mỗi topic là một phân bố từ. Dữ liệu quan sát là các từ; biến ẩn là topic của từng vị trí từ và tỷ trọng topic trong tài liệu. Nền tảng phương pháp xem tài liệu tham khảo [1].

$$\theta_d \sim \mathrm{Dir}(\alpha), \quad \phi_k \sim \mathrm{Dir}(\eta), \quad P(w \mid d) = \sum_{k=1}^{K} \theta_{dk}\phi_{kw}$$

θ_dk là tỷ trọng topic k trong tài liệu d; φ_kw là xác suất từ w trong topic k. α và η là prior Dirichlet. Với từng vị trí từ, LDA giả định chọn topic từ θ_d rồi chọn từ từ φ của topic đó. Gensim suy luận các biến ẩn bằng phương pháp biến phân.

Pipeline LDA trong dự án

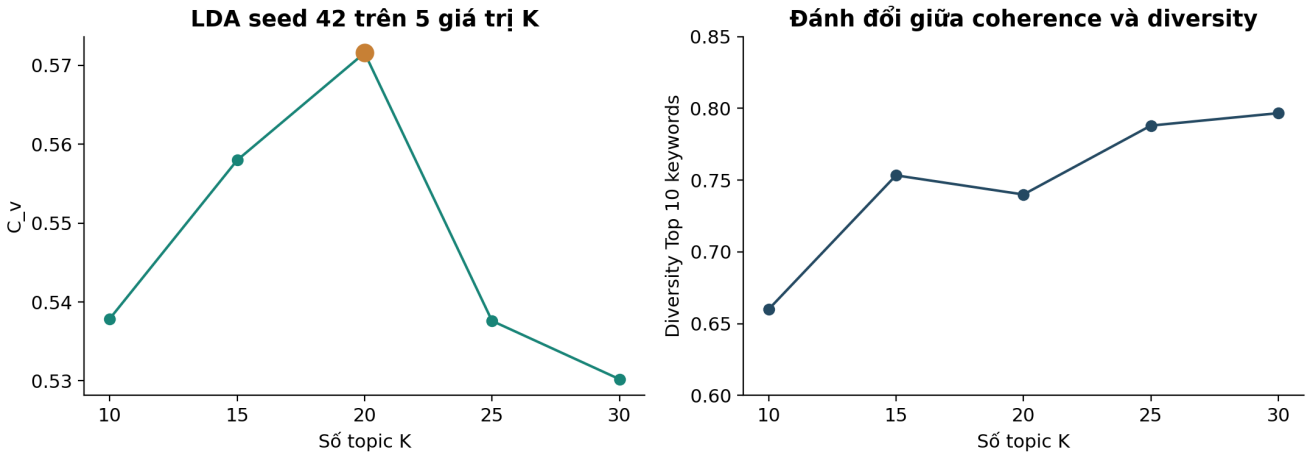
Tokens Stage1 → Dictionary không lọc thêm → BoW → fit LDA → posterior tài liệu–topic → lấy argmax để hiển thị một nhãn chính → lấy 10 từ có P(w|topic) cao nhất → chọn tài liệu đại diện có posterior cao.

Tham số	Giá trị	Tác động
Số topic K	10, 15, 20, 25, 30	Kiểm tra nhiều mức chi tiết
passes / iterations	10 / 100	Ngân sách cập nhật và suy luận
alpha / eta	asymmetric / symmetric	Prior tài liệu–topic và topic–word
Seeds	42; thêm 123 và 2026	Đo ổn định ở hai cấu hình triển vọng
Top keywords / C_v window	10 / 110 token	Cố định đầu ra và protocol coherence

BoW bỏ thứ tự từ, nên LDA khai thác đồng xuất hiện và phân bố từ thay vì quan hệ ngữ cảnh đầy đủ. Một tài liệu có thể thuộc nhiều chủ đề trong posterior, dù giao diện hiển thị topic trội nhất. Tên chủ đề là bước diễn giải sau mô hình.

Nguồn output: src/stage2.py; configs/stage2.yaml; src/model_comparison.py

5 Kết quả LDA và lựa chọn số topic



Hình 3. Kết quả năm cấu hình LDA seed 42. Chấm cam đánh dấu K20 được chọn ở Stage2.

Nguồn output: outputs/tables/stage2/lda_base_metrics.csv

K	C_v	U_Mass	Diversity
10	0,5379	-1,5323	0,6600
15	0,5580	-2,0147	0,7533
20	0,5716	-1,9372	0,7400
25	0,5376	-2,6434	0,7880
30	0,5302	-3,0826	0,7967

Stage2 chọn K20, seed 42, với C_v = 0,5716, diversity = 0,7400 và stability Jaccard sau ghép Hungarian = 0,2620. Stability này khác định nghĩa ARI của KMeans và không được so trực tiếp như cùng một chỉ số.

Quy tắc chọn: sàng lọc hai K theo C_v ở seed cơ sở, sau đó kết hợp C_v chuẩn hóa 50%, U_Mass chuẩn hóa 15%, diversity 15% và stability 20%. Đây là lựa chọn trong lưới đã thử, không phải tối ưu toàn cục.

Catalog LDA K10 trong phần so sánh giữ K bằng các nhánh khác. K10 có C_v = 0,537876 ở protocol lịch sử; khác kết quả K20 Stage2. Trong K10, hai topic lớn nhất có 3.559 và 3.486 tài liệu, cho thấy các nhóm tương đối rộng.

Nguồn output: outputs/reports/stage2/selected_model.json; outputs/tables/stage2/lda_comparison.csv; docs/TOP10_TOPICS_ALL_MODELS_20261024.csv

6 BGE và BatteryBERT trong pipeline neural

BGE và BatteryBERT là encoder; BERTopic và KMeans là các cách khai thác embedding để tạo topic. BGE được dùng cho biểu diễn và truy hồi; BatteryBERT đưa tri thức ngôn ngữ miền pin vào encoder. Checkpoint gốc được ghi tại [3] và [4].

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Attention tạo hidden state phụ thuộc ngữ cảnh. Q và K xác định trọng số tương tác; V cung cấp thông tin được tổng hợp. Vector tài liệu được tạo từ hidden state qua pooling và chuẩn hóa. Encoder tốt cho dự đoán ngôn ngữ miền pin chưa tự đảm bảo khoảng cách tài liệu phù hợp với mọi mục tiêu phân cụm.

Nhánh	Đặc điểm thực thi	Output
BGE Stage3	bge-base-en-v1.5; cập nhật block cuối; proxy độ dài 128	Checkpoint và embeddings; BERTopic lịch sử
BatteryBERT pretrained	batterybert-cased; chưa cập nhật theo corpus dự án	Embeddings chunked và catalog đối chứng
BatteryBERT fine-tuned cũ	Title–Abstract contrastive; train tối đa 128 token	Checkpoint dùng cho optimization 23/10
BatteryBERT full-document	Continuation block cuối; tất cả chunks Abstract	Checkpoint và 13.702 embeddings mới

Kết quả proxy BGE lịch sử

Phép thử	Pretrained	Fine-tuned
Test Group MRR@10	0,893567	0,928083
Queries / candidates	1.368 / 1.368	1.368 / 1.368
Độ dài proxy	128 token	128 token

Đây là proxy Title → Abstract trong cùng split lịch sử. Không so trực tiếp điểm BGE 128 token với proxy full-document có Title context để kết luận encoder nào tốt hơn về Search.

Nguồn output: outputs/reports/stage3/pretrained_test_metrics.json; outputs/reports/stage3/finetuned_test_metrics.json

7 BERTopic từ embedding đến topic và từ khóa

BERTopic kết hợp biểu diễn ngữ nghĩa và mô tả từ vựng. Pipeline sử dụng embeddings đã encode trước, UMAP giảm chiều, HDBSCAN tìm cụm theo mật độ, rồi c-TF-IDF để mô tả từ khóa [2, 5].

Bước	Cấu hình thực tế	Ý nghĩa
Embedding	BGE hoặc BatteryBERT; chunked khi tương ứng	Vị trí tài liệu trong không gian vector
UMAP	15 neighbors; 5 chiều; min_dist 0; cosine; seed 42	Tạo không gian để phân cụm
HDBSCAN	min_cluster_size 30; min_samples 10; eom	Tìm cụm và outlier −1
c-TF-IDF	Frozen vocabulary; reduce_frequent_words=True	Xếp hạng từ khóa trong cụm
Gộp topic	Gộp về 10 nếu ban đầu có nhiều hơn	Giữ nguyên outlier để so sánh K10

$$w_{c,t} = \sqrt{\frac{n_{c,t}}{\sum_v n_{c,v}}} \log\left(1 + \frac{A}{f_t}\right)$$

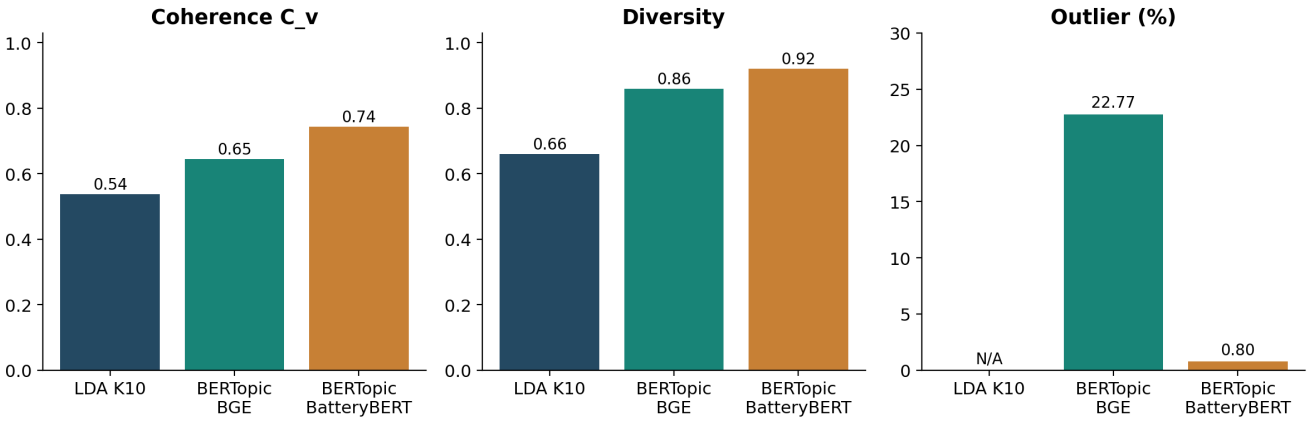
n_ct là số lần từ t xuất hiện trong cụm c; A là trung bình tổng token của các tài liệu cấp cụm; f_t là tổng tần suất từ qua các cụm. Căn bậc hai của TF giảm sự áp đảo của từ quá thường xuyên. Đây là công thức tương ứng nhánh c-TF-IDF mặc định có reduce_frequent_words, không áp dụng thay cho công thức keywords của nhánh optimized.

Trong bản xuất so sánh, ma trận document–topic của BERTopic là cosine affinity giữa BoW và c-TF-IDF, chuẩn hóa L1. Nó không phải posterior xác suất như LDA. Assignments và outlier lấy từ clustering đã lưu, không suy lại bằng argmax affinity.

Hình UMAP hai chiều phục vụ hiển thị. Clustering được fit trong không gian UMAP năm chiều; khoảng cách và độ tách cụm trên hình hai chiều chỉ có tính mô tả.

Nguồn output: src/model_comparison.py; src/stage3_bertopic_model.py; configs/model_comparison.yaml

8 Kết quả BERTopic đối chứng lịch sử



Hình 4. So sánh lịch sử LDA K10 và hai nhánh BERTopic. C_v và diversity cao không đủ để xác nhận chất lượng khoa học.

Nguồn output: outputs/final_system/topic_comparison.csv

Model	C_v	Diversity	Outlier
LDA K10	0,5379	0,6600	N/A
BERTopic–BGE	0,6455	0,8600	22,77%
BERTopic–BatteryBERT pretrained	0,7445	0,9200	0,80%

BERTopic–BGE có các nhóm Prussian blue, điện ly, TiO2/titanate và MXene, nhưng 3.120 tài liệu là outlier. Tỷ lệ này mô tả phần corpus không được đưa vào topic, không tự chứng minh tất cả outlier là dữ liệu kém.

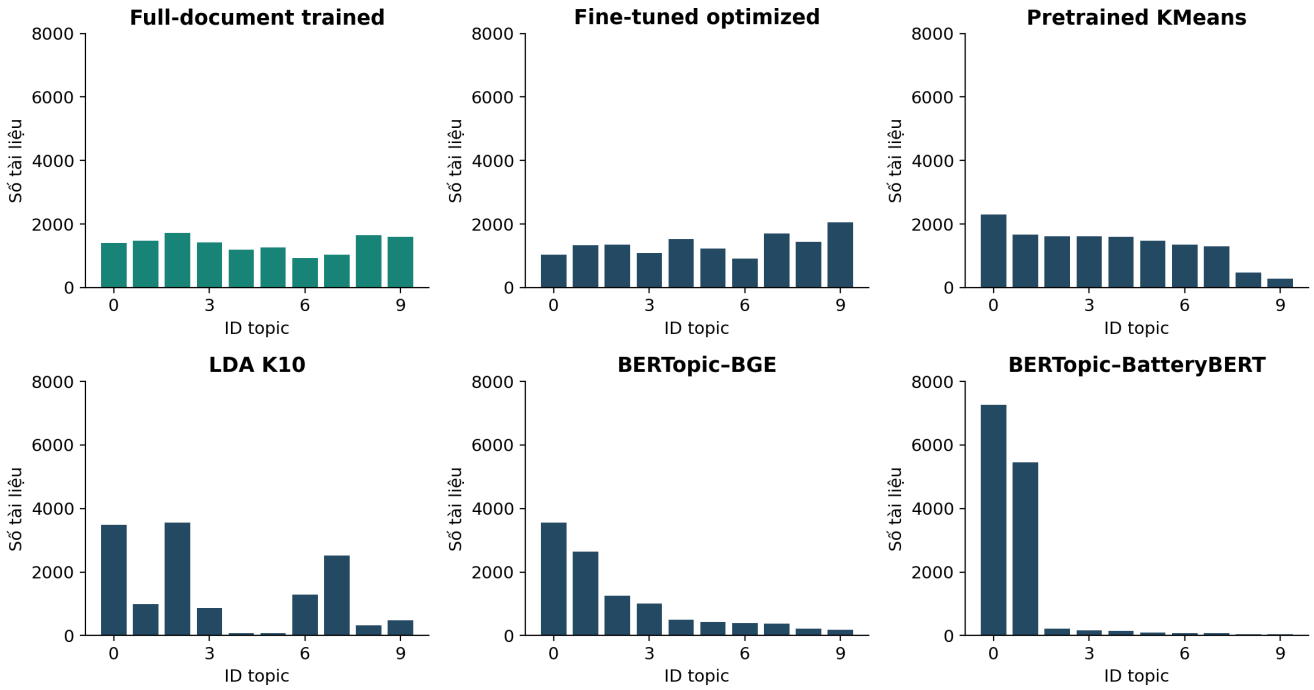
BERTopic–BatteryBERT pretrained có 109 outlier và C_v cao nhất trong ba nhánh lịch sử. Tuy nhiên, hai cụm lớn nhất gồm 7.261 và 5.449 tài liệu, tổng 92,76% corpus. Chúng được diễn giải là nhóm publication về hiệu năng và nhóm patent về phương pháp chế tạo. Đây là dấu hiệu các nhóm lớn có thể bị chi phối bởi nguồn hoặc cách viết.

Catalog cũng còn nhóm sodium cobaltate và siêu dẫn. Cần rà soát phạm vi corpus và tài liệu đại diện trước khi gọi đây là các hướng nghiên cứu pin sodium ion đã được xác nhận.

Nhánh BERTopic–BatteryBERT fine-tuned có trong code nhưng báo cáo model_comparison lịch sử ghi not_completed tại thời điểm xuất. Không dùng kết quả BatteryBERT KMeans để thay thế cho nhánh BERTopic chưa có kết quả hoàn tất.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; outputs/model_comparison_v2/reports/MODEL_COMPARISON_REPORT.md

9 Sáu catalog và cấu trúc phân bố topic



Hình 5. Số tài liệu theo topic ở sáu catalog. Cùng thang tung giúp thấy sự tập trung ở BERTopic–BatteryBERT.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv

Catalog	Cụm lớn nhất	Hai cụm / corpus	Outlier
Full-document trained	1.717	24,59%	0
Fine-tuned optimized	2.063	27,49%	0
Pretrained KMeans	2.309	29,09%	0
LDA K10	3.559	51,42%	0
BERTopic–BGE	3.552	45,26%	3.120
BERTopic–BatteryBERT	7.261	92,76%	109

Topic ID chỉ có nghĩa trong từng catalog. Topic 0 của LDA không tương ứng topic 0 của BatteryBERT. Bảng 10 topic ở phụ lục liệt kê toàn bộ nhóm của mỗi catalog theo ID, không xếp hạng 10 chủ đề tốt nhất.

KMeans gán mọi tài liệu vào một trong K cụm, vì vậy outlier bằng 0 là đặc điểm thuật toán. Với LDA, tài liệu vẫn có posterior hỗn hợp dù bảng catalog chỉ đếm topic trội nhất.

10 Hiệu chỉnh hình học và BatteryBERT KMeans

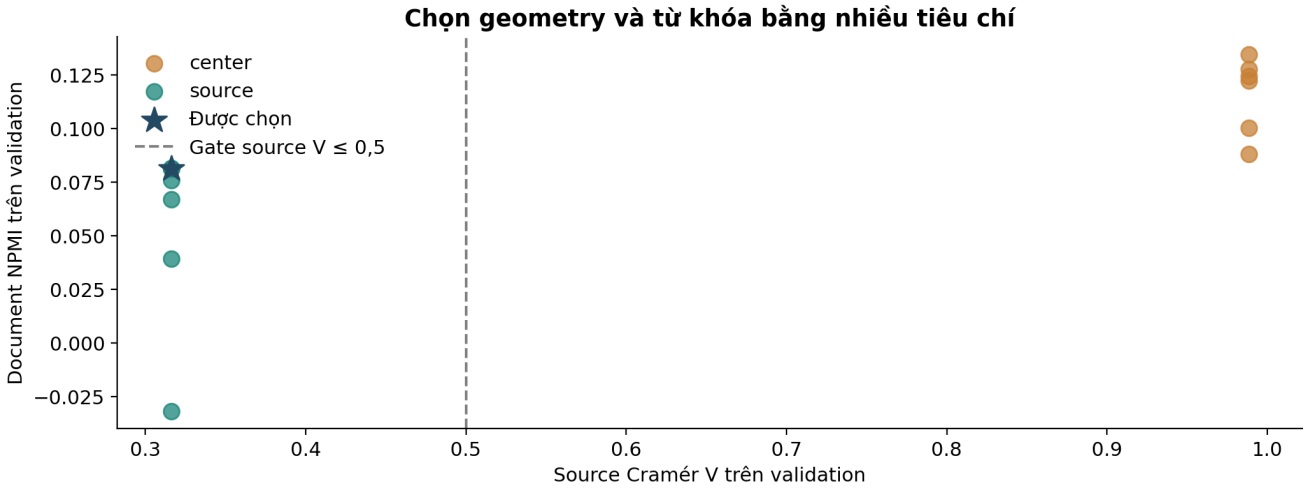
Nhánh optimized kiểm tra giả thuyết embedding bị chi phối bởi nguồn. Phép source projection fit trên train loại thành phần nằm trên hướng chênh lệch trung bình hai nguồn rồi chuẩn hóa vector.

$$u = \frac{\mu_1 - \mu_2}{\|\mu_1 - \mu_2\|}, \quad z = \mathrm{norm}\left[(x - \mu) - ((x - \mu)^T u)u\right]$$

μ là trung bình toàn bộ train; μ1 và μ2 là trung bình theo nguồn. Phép biến đổi chỉ loại một hướng tuyến tính; hướng này có thể chứa cả phong cách viết lẫn nội dung có ích. Do đó cần đánh giá tác động thay vì mặc định đây là khử toàn bộ thiên lệch.

$$\min_{a,\,\nu} \sum_i \|z_i - \nu_{a_i}\|^2$$

KMeans tìm 10 tâm cụm sao cho tổng bình phương khoảng cách từ mỗi tài liệu đến tâm được gán nhỏ nhất. K = 10 là cấu hình tổ chức catalog, không phải kết luận lĩnh vực có đúng 10 chủ đề tự nhiên.



Hình 6. Các recipe center/source của nhánh full-document trên validation. Điểm NPMI cao vẫn có thể trượt gate lệch nguồn.

Nguồn output: outputs/batterybert_full_document_20261024_v1/topics/validation_comparison.csv

Có 12 recipe: hai geometry × ba mức exclusivity × hai mức phrase boost. Cấu hình được chọn là source_ex0.25_pb1.0. Các cấu hình center có source Cramér V khoảng 0,988 trên validation; vì vậy không được chọn chỉ vì NPMI cao.

11 Huấn luyện BatteryBERT đọc đủ Abstract

Nhánh ngày 24/10 tiếp tục train từ checkpoint fine-tuned đã có. Mục tiêu là mọi chunk Abstract đóng góp vào biểu diễn tài liệu và gradient của block cuối, thay cho train chỉ trên phần đầu 128 token.

Thành phần	Cấu hình
Cửa sổ / overlap	256 / 64 token; ngân sách Abstract phụ thuộc Title và special tokens
Block cập nhật	Block cuối; 11 block đầu đóng băng, cache float32
Batch loss / microbatch chunk	32 cặp / 2 chunks; gradient caching hai tầng
Temperature / distillation	0,05 / 0,02
Learning rate được chọn	5e-6; pilot thêm 2e-6
Epoch / optimizer	Một lượt train; AdamW; warmup/decay; clipping norm 1

$$c_j = \mathrm{norm}\left(\frac{\sum_t m_{jt} h_{jt}}{\sum_t m_{jt}}\right), \quad d = \mathrm{norm}\left(\frac{\sum_j w_j c_j}{\sum_j w_j}\right)$$

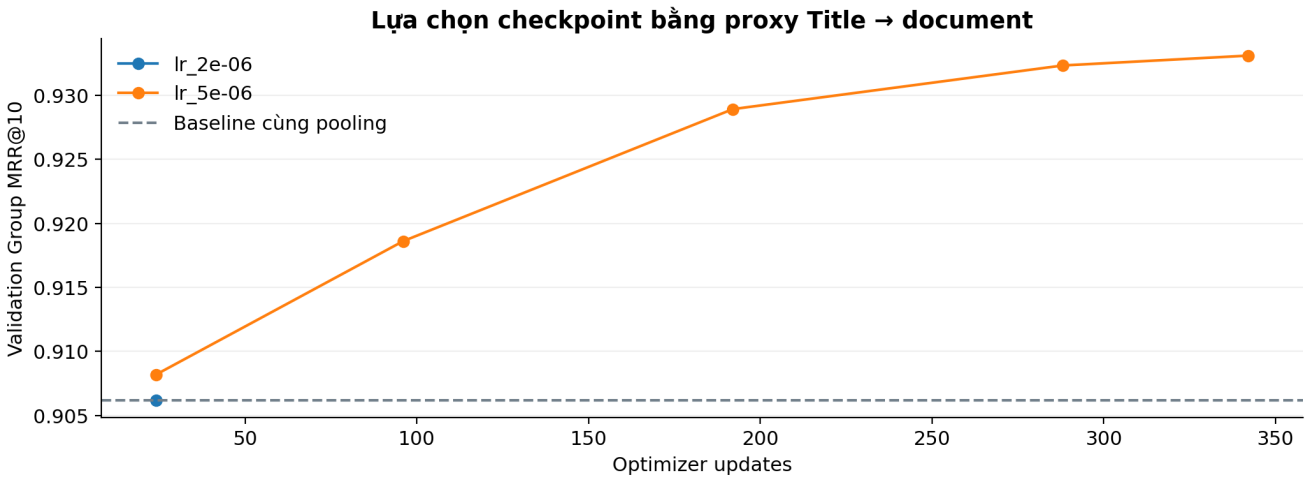
m_jt chọn token Abstract và loại SEP; Title vẫn là context trong encoder nhưng không trực tiếp vào mean pooling của chunk Abstract. w_j là số token mới được bao phủ. Overlap vẫn ảnh hưởng hidden state, vì vậy weighting này không tương đương mỗi token chỉ ảnh hưởng đúng một lần.

$$S_{ij} = q_i^T d_j / \tau, \quad \mathcal{L}_{q \to d} = -\frac{1}{B}\sum_i \log \frac{\exp(S_{ii})}{\sum_{j \in A_i} \exp(S_{ij})}$$

Loss lấy trung bình hai chiều Title → document và document → Title, có mask false negatives cùng group hoặc title rất giống; thêm khoảng cách bình phương tới embedding tham chiếu. Gradient caching tính loss chung của batch rồi replay từng nhóm chunk, giữ tập negatives lớn với RAM giới hạn [6]. Dropout tắt để replay nhất quán.

Nguồn output: configs/batterybert_full_document.yaml; src/batterybert_full_document.py

12 Output huấn luyện và lựa chọn checkpoint



Hình 7. Validation Group MRR@10 theo optimizer updates của hai learning rate. Đây là proxy Title → document có Title context.

Nguồn output: outputs/batterybert_full_document_20261024_v1/all_validation_checkpoints.csv

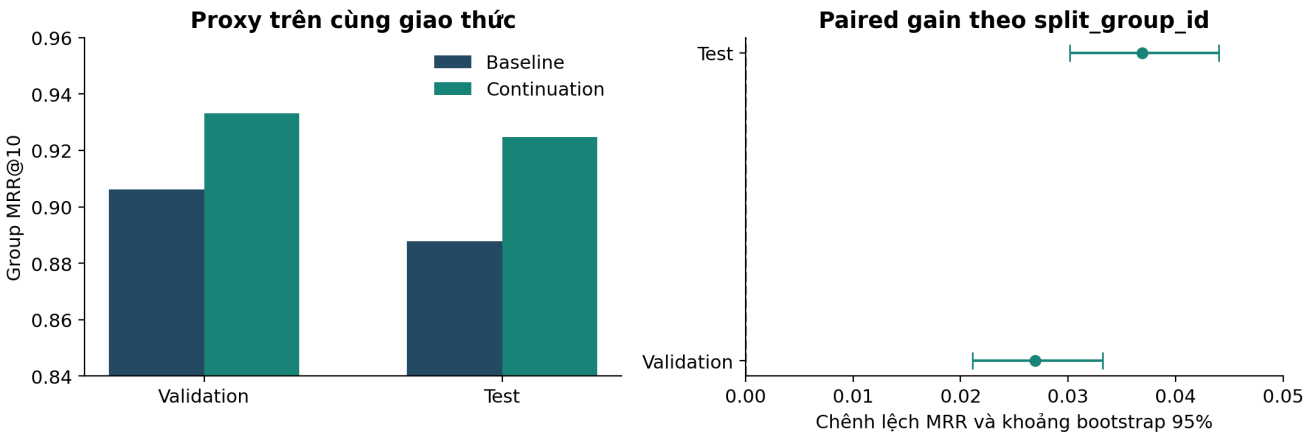
Output thực thi	Giá trị
Tài liệu train đã tham gia	10.921
Chunk đã backpropagate	26.147
Token Abstract duy nhất theo tài liệu	3.420.215
Số lần val và test vào optimizer	0
Checkpoint được chọn	Step 342; learning rate 5e-06
Toàn corpus được encode lại	13.702 vector tài liệu

Checkpoint được chọn sau 342 optimizer updates và đã thấy toàn bộ 10.921 tài liệu của lượt continuation. Validation chọn learning rate và checkpoint; test không dùng để chọn. Test vẫn là split lịch sử đã được sử dụng trước đó, không phải external test mới.

Các output chứng minh độ bao phủ và thay đổi trọng số thật: training_coverage.json, training_document_coverage.csv, selection.json và embedding_success.json. Kiểm thử kỹ thuật kiểm tra gradient cache, ảnh hưởng phần cuối văn bản và parity giữa cache với full forward.

Nguồn output: outputs/batterybert_full_document_20261024_v1/training_coverage.json; outputs/batterybert_full_document_20261024_v1/selection.json; outputs/batterybert_full_document_20261024_v1/embedding_success.json

13 Hiệu quả continuation trên proxy cố định



Hình 8. Baseline và checkpoint mới trên cùng full-document pooling; khoảng bootstrap dùng split_group_id.

Nguồn output: outputs/batterybert_full_document_20261024_v1/paired_training_effect.json

Split	Baseline	Sau train	Gain	Khoảng 95% của gain
validation	0,906174	0,933093	0,026919	0,021105 đến 0,033229
test	0,887839	0,924704	0,036865	0,030158 đến 0,044017

So sánh ghép cặp giữ cùng dữ liệu và pooling, vì vậy gain phù hợp để mô tả tác động của continuation trong protocol này. Bootstrap 10.000 lần theo split_group_id phản ánh biến động lấy mẫu có điều kiện trên model và tập đã dùng.

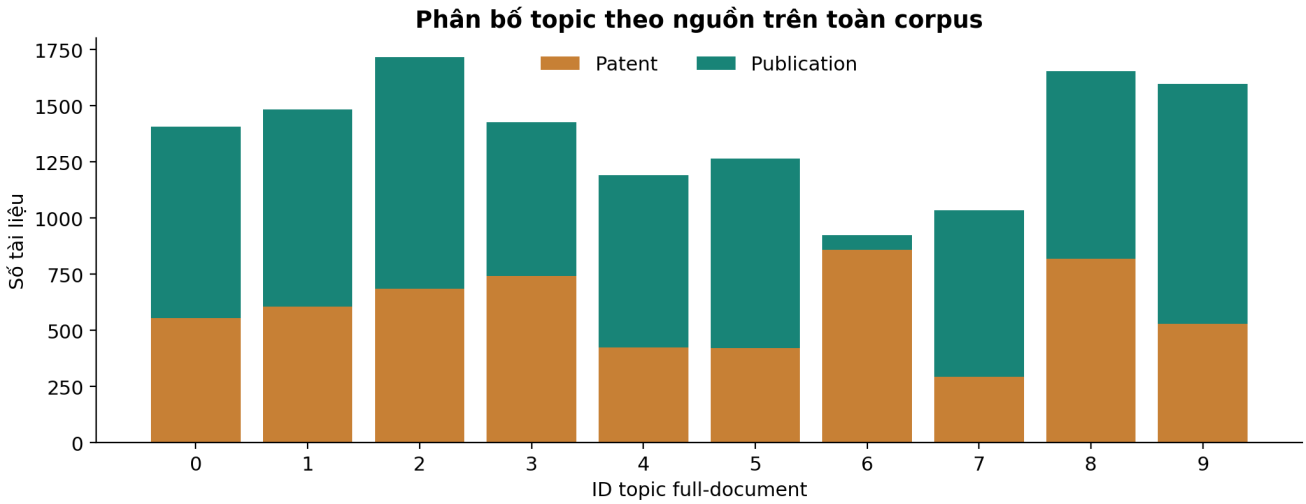
Khoảng validation chịu ảnh hưởng lựa chọn checkpoint trên chính validation. Khoảng test không bao hàm toàn bộ uncertainty do annotation, lựa chọn thiết kế trước đó hoặc training seed.

Giới hạn ý nghĩa

Document chunks chứa Title context trong các block đóng băng. Do đó proxy Title → document có thể hưởng lợi từ thông tin Title. Điểm test 0,924704 là Group MRR@10 của phép ghép cặp, không phải Search chính xác 92,47%.

Không quy mọi chênh lệch giữa proxy 128 token cũ và proxy full-document mới cho training, vì độ dài và pooling khác nhau. Kết quả trong bảng này sử dụng baseline cùng protocol để tránh nhầm lẫn đó.

14 Output catalog topic full document



Hình 9. Phân bố nguồn trong 10 topic đang kích hoạt. Topic 6 chủ yếu gồm Patent.

Nguồn output: outputs/batterybert_full_document_20261024_v1/topics/topic_source_distribution.csv

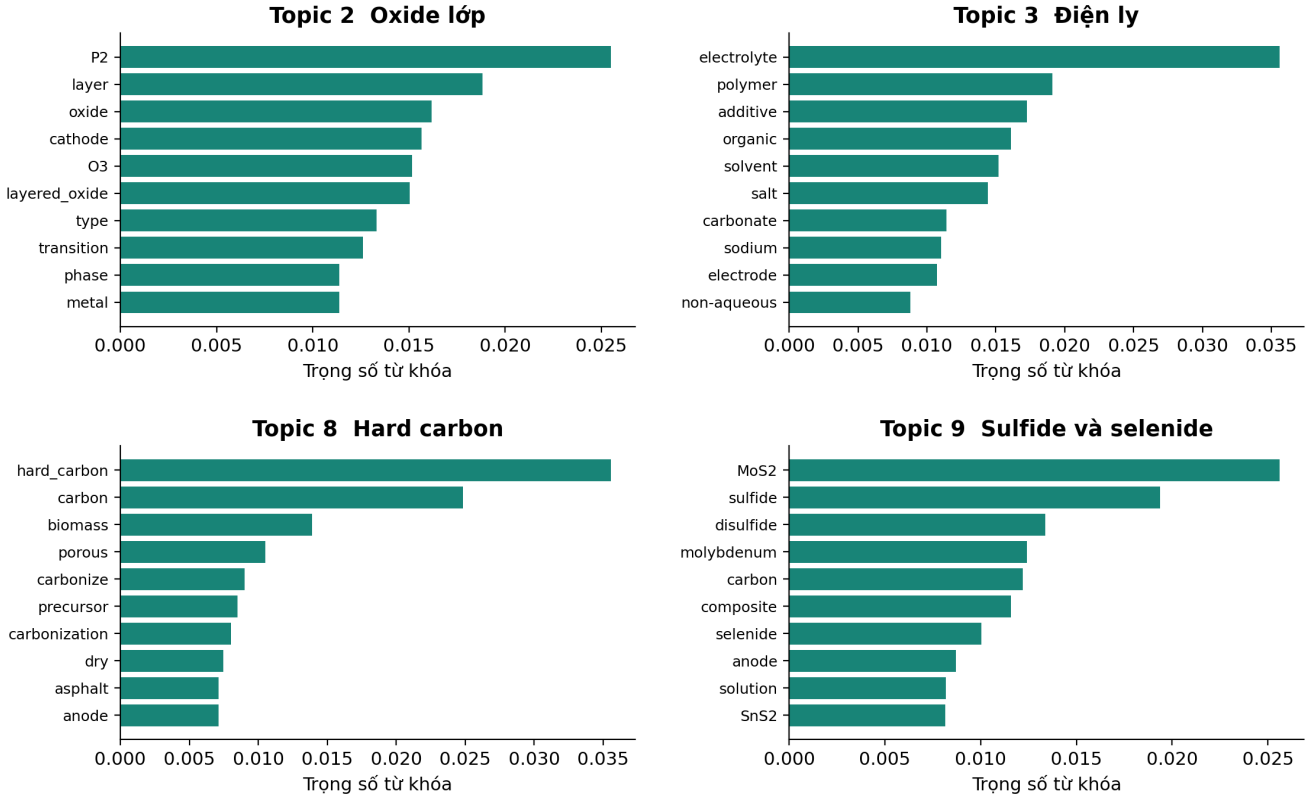
ID	Diễn giải topic	Tài liệu
0	Oxide Ti/Sn, titanate và composite điện cực	1.408
1	Prussian blue và các hợp chất điện cực chứa sắt	1.483
2	Oxide lớp P2/O3 và biến đổi cấu trúc điện cực	1.717
3	Điện ly, polymer, muối và phụ gia giao diện	1.426
4	Phosphate vanadium, NVP/NASICON và composite carbon	1.192
5	Anode hợp kim Sn/Sb, graphene và MXene	1.266
6	Phần cứng cell và thiết bị chế tạo, kiểm tra pin	925
7	Cấu trúc pha, trật tự vacancy và dẫn ion	1.035
8	Hard carbon, carbon xốp và tiền chất sinh khối	1.653
9	Sulfide/selenide, MoS2 và composite carbon	1.597

Cụm lớn nhất chiếm 12,53%; hai cụm lớn nhất chiếm 24,59%; source Cramér V toàn corpus = 0,3036. Nhãn là diễn giải tạm thời từ keywords và tài liệu đại diện; agent review chưa phải expert ground truth.

15 Top 10 keywords được sinh và kiểm tra thế nào

$$S(c,w) = TF(c,w)\log\left(1+\frac{N}{df(w)}\right)\left(\frac{df(c,w)+1}{df(w)+10}\right)^{0.25}$$

Công thức trên là recipe cuối của nhánh full-document: TF tương đối trong cụm, IDF theo số tài liệu train, và exclusivity để ưu tiên từ đặc trưng cho cụm. Phrase boost của cấu hình được chọn bằng 1. Mỗi keyword có ít nhất 5 tài liệu train trong cụm hỗ trợ; tránh các từ/cụm từ bao hàm nhau.



Hình 10. Top 10 keywords và trọng số ở bốn topic minh họa. Thang điểm mô tả từ khóa, không phải xác suất khoa học.

Nguồn output: outputs/batterybert_full_document_20261024_v1/topics/topic_keywords.csv

Nhánh scientific keyword stream đọc raw fields và giữ ranh giới stopword, dấu câu và Title/Abstract trước khi tạo ngram. Điều này tránh tạo phrase giả do xóa từ ở giữa. Chuỗi token LDA lịch sử đã mất thông tin khoảng cách không thể dùng để xác nhận phrase liền kề trong văn bản gốc.

Nguồn output: src/scientific_keyword_stream.py; scripts/evaluate_batterybert_full_document.py; docs/KEYWORD_ADJACENCY_CORRECTION_20261024.md

16 Đánh giá sau khi đã sinh Top 10 từ khóa

Điểm dùng để lấy Top 10 keywords không đồng nghĩa với chất lượng topic. Sau khi sinh từ khóa, đánh giá cần dùng thống kê corpus và kiểm tra tài liệu độc lập với thứ tự trọng số đã chọn.

$$\mathrm{NPMI}(w_i, w_j) = \frac{\log[P(w_i, w_j)/(P(w_i)P(w_j))]}{-\log P(w_i, w_j)}$$

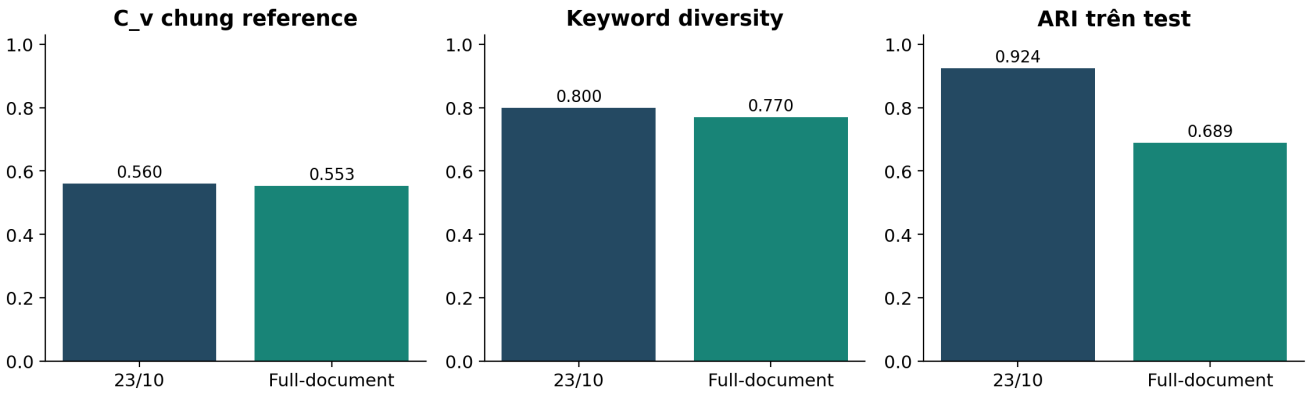
Chỉ số	Dữ liệu tham chiếu	Diễn giải và giới hạn
C_v	Top 10 keywords; cửa sổ 110 token	Coherence gián tiếp; cao không đảm bảo cụm có ý nghĩa khoa học
U_Mass	BoW và đồng xuất hiện cấp tài liệu	Cao hơn thường tốt hơn trong cùng protocol
Document NPMI	Có/không của keywords trong tài liệu	Dùng chọn recipe mới; khác sliding-window C_v
Diversity	Từ khóa khác nhau / 100 vị trí	Ít lặp không tự chứng minh relevance
ARI	Assignments qua các seed	Agreement của phân hoạch; không phải accuracy
Source Cramér V	Bảng topic × source	Chẩn đoán lệch nguồn; cần đọc nội dung

Protocol coherence lịch sử dùng tokens Stage1. Bản common-reference dùng quy tắc phrase và dictionary tham chiếu đã sửa cho các danh sách từ khóa. C_v 0,537876 lịch sử của LDA và 0,529681 trong common-reference là hai phép tính khác protocol; không trộn thành một bảng xếp hạng duy nhất.

Đánh giá chuyên môn cần người đọc xem các tài liệu đại diện, độ đồng nhất nội dung, mức khớp keywords–label và các trường hợp nằm sát biên. Trong dự án hiện tại, nhãn khoa học chưa được chuyên gia xác nhận.

Nguồn output: scripts/evaluate_topic_candidates.py; outputs/batterybert_full_document_20261024_v1/topics/scientific_review_protocol.json

17 So sánh topic mới với bản optimized trước



Hình 11. Các chỉ số có đánh đổi giữa bản optimized 23/10 và full-document 24/10. Không có chiến thắng trên mọi thước đo.

Nguồn output: outputs/batterybert_full_document_20261024_v1/topics/common_coherence.csv; outputs/batterybert_optimization_20261023_v1/final_test.json

Thước đo	Optimized trước	Full-document
C_v toàn corpus cùng reference	0,560261	0,553022
Keyword diversity	0,80	0,77
Test stability ARI	0,924481	0,688833
Test document NPMI	0,088294	0,079191
Test source Cramér V	0,337499	0,325436
Test top 2 share	27,05%	23,10%

Nhánh mới có phân bố cân hơn theo top2 share và source V trên test giảm nhẹ, trong khi ARI, NPMI, diversity và C_v giảm. Việc kích hoạt là quyết định theo mục tiêu đọc đầy đủ và cổng kỹ thuật đa tiêu chí, không phải chứng minh catalog mới tốt nhất về khoa học.

Các gate đặt giới hạn cho source, stability, coherence, độ lớn cụm, coverage và diversity. Promotion gate của output hiện tại đạt; vẫn cần đánh giá chuyên môn độc lập. Các catalog cũ được giữ để đối chứng.

18 Pipeline Search và tiêu chí xếp hạng Top 10

Query → lọc nguồn, năm, required terms và topic nếu có → encode query đầy đủ qua các cửa sổ → lấy tối đa 100 ứng viên dense từ Qdrant → lấy tối đa 100 ứng viên TF-IDF → hợp nhất bằng RRF → trả Top 10.

$$s(q,d) = \frac{q^T d}{\|q\|\|d\|}, \quad \mathrm{RRF}(d) = \sum_{m\,:\,d \in L_m} \frac{1}{60 + \mathrm{rank}_m(d)}$$

Nhánh	Bằng chứng dùng xếp hạng	Output điểm
TF-IDF	Từ ngữ trùng giữa query và Title–Abstract	Cosine lexical
Dense	Embedding query và document đúng checkpoint	Cosine semantic
Hybrid	Đồng thuận thứ hạng lexical và dense	RRF k = 60

Cosine của các vector L2-normalized bằng dot product. RRF cộng nghịch đảo thứ hạng, giúp kết hợp hai thang điểm khác nhau. Bài thiếu trong một danh sách không có đóng góp từ danh sách đó. Cả cosine lẫn RRF đều chưa được hiệu chuẩn thành xác suất relevance.

Ví dụ tính tay: A có lexical rank 1 và dense rank 10 thì RRF = 1/61 + 1/70 ≈ 0,03068. B có rank 3 ở cả hai nhánh thì RRF = 2/63 ≈ 0,03175. B đứng trước do đồng thuận hai nhánh cao hơn.

Required terms là bằng chứng từ vựng; có đủ token chưa xác nhận quan hệ hóa học, vai trò anode/cathode hay phủ định. Topic chỉ lọc phạm vi tài liệu khi người dùng chọn; không có topic bonus trong ranking.

Nguồn output: src/full_document_retrieval.py; src/full_document_inference.py; src/final_search.py

19 Output thực tế của một truy vấn Search

Query Q01: Hard carbon anodes derived from biomass for sodium-ion batteries

Method: BatteryBERT full-document hybrid. Bảng dưới lấy trực tiếp từ rankings_top10.csv; giữ nguyên thứ hạng và điểm. Đây là kết quả hệ thống đã sinh, chưa phải danh sách đã được người chấm xác nhận relevance.

Hạng	Tiêu đề bài	Nguồn năm	RRF
1	Biomass-derived carbon anodes for sodium-ion batteries	Publication 2023	0,03028
2	Biomass hard carbon of high initial coulombic efficiency for sodium-ion batteries: Preparation and application	Publication 2022	0,02878
3	Biochars from various biomass types as precursors for hard carbon anodes in sodium-ion batteries	Publication 2018	0,02731
4	Revealing the sodium storage behavior of biomass-derived hard carbon by using pure lignin and cellulose as model precursors	Publication 2022	0,02650
5	A Stable Biomass-Derived Hard Carbon Anode for High-Performance Sodium-Ion Full Battery	Publication 2021	0,02513
6	High Capacity and High Efficiency Maple Tree-Biomass-Derived Hard Carbon as an Anode Material for Sodium-Ion Batteries	Publication 2018	0,02492
7	Hard carbon derived for lignin with robust and low-potential sodium ion storage	Publication 2022	0,02432
8	Biomass derived hard carbon used as a high performance anode material for sodium ion batteries	Publication 2014	0,02312
9	Pectin, Hemicellulose, or Lignin? Impact of the Biowaste Source on the Performance of Hard Carbons for SodiumIon Batteries	Publication 2017	0,02256
10	A porous biomass-derived anode for high-performance sodium-ion batteries	Publication 2018	0,02158

Nguồn output: outputs/batterybert_full_document_20261024_v1/rankings_top10.csv; query_id Q01; method BATTERYBERT_FULLDOC_HYBRID

DOI/identifier, Abstract và đoạn trích evidence của từng kết quả nằm trong CSV. Đoạn evidence được chọn bằng lexical overlap nên không được gọi là lời giải thích đầy đủ cho quyết định của neural encoder.

20 Đánh giá relevance của Search Top 10

Sau khi hệ thống sinh Top 10, cần đánh giá từng cặp query–document theo intent người dùng. Protocol hiện tại dùng nhãn 0 không liên quan, 1 liên quan một phần, 2 liên quan trực tiếp; người chấm không thấy method, rank và score, đồng thời cần verifier độc lập.

$$P@10 = \frac{\sum_{r=1}^{10} \mathbf{1}[g_r = 2]}{10}, \quad DCG@10 = \sum_{r=1}^{10} \frac{2^{g_r} - 1}{\log_2(r+1)}, \quad nDCG = \frac{DCG}{IDCG}$$

MRR@10 lấy nghịch đảo hạng đầu tiên có grade 2, bằng 0 nếu không có trong Top 10, rồi trung bình theo query. nDCG dùng IDCG của pool chung giữa các method; đây là đánh giá theo pool đã thu thập, không phải qrels đầy đủ toàn corpus.

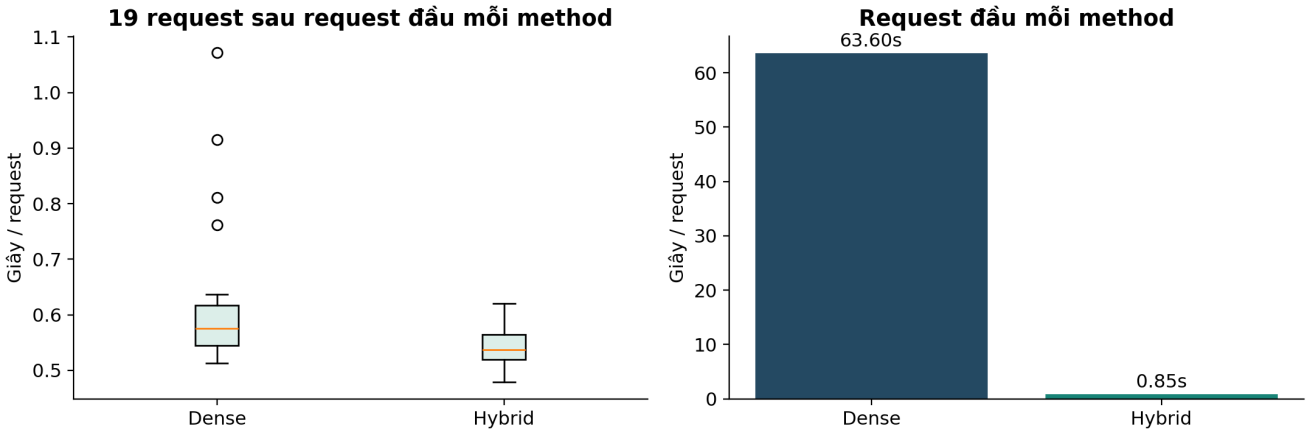
Output đánh giá hiện tại	Giá trị
Số query benchmark	20
Cặp query–document trong pool	703
Nhãn người được chấp nhận	0
Query có pool nhãn hoàn chỉnh	0
Trạng thái	PENDING_HUMAN_ANNOTATION
P@10 / nDCG@10 / MRR@10 relevance	Chưa có kết quả hợp lệ để công bố

Nhãn trống không được xem là 0. Không dùng coherence, cosine, proxy Title–document hoặc AI tự chấm thay cho ground truth người dùng. Không báo Recall@10 vì chưa biết toàn bộ tài liệu relevant trong corpus.

Các query hiện do tác giả soạn và đã dùng cho khảo sát hệ thống; chưa phải một benchmark chuyên gia bên ngoài. Tập đánh giá đã khóa không được tái dùng làm dữ liệu chọn cấu hình sau khi có nhãn.

Nguồn output: outputs/batterybert_full_document_20261024_v1/evaluation_status.json; outputs/batterybert_full_document_20261024_v1/annotation_protocol.json; src/research_completion_evaluation.py

21 Hiệu năng chạy và kiểm chứng kỹ thuật



Hình 12. Độ trễ từ requests benchmark đã lưu. Request đầu tách riêng để không lẫn với thống kê warm.

Nguồn output: outputs/batterybert_full_document_20261024_v1/benchmark_runs.csv

Method	Requests warm	Median giây	Mean giây	Max giây
Hybrid	19	0,537	0,543	0,620
Dense	19	0,575	0,632	1,072

Thống kê warm bỏ request đầu mỗi method, còn 19 requests. Những số này mô tả một máy và workload đã chạy; chưa phải p95 production hay khả năng chịu nhiều người dùng đồng thời. Thứ tự chạy và cache cũng có thể ảnh hưởng chênh lệch giữa dense và hybrid.

Kiểm chứng đã lưu	Kết quả	Phạm vi
Backend và web tests	112 / 112 PASS	Kiểm tra các contract đã mã hóa trong tests
Model reload parity	PASS	Cache prefix + last block so với full forward
Coverage train	PASS	Mọi train ID và chunk của protocol được xử lý
Deployment Search / Topics	True / True	Trạng thái artifacts hiện có

112 tests PASS là kết quả lần chạy được lưu trong verification_summary.json, không phải tuyên bố vừa chạy lại trong lúc biên soạn báo cáo. Các tests xác minh kỹ thuật, không chứng minh relevance hoặc độ đúng khoa học.

22 Thảo luận và hướng phát triển

Dự án đã xây được chuỗi xử lý có dữ liệu rõ nguồn, nhiều baseline topic, huấn luyện neural có kiểm tra độ bao phủ, catalog chủ đề và Search hybrid. Bằng chứng mạnh nhất hiện tại là khả năng tái lập output, continuation thật và cải thiện proxy trên cùng giao thức.

Hạn chế lớn nhất là thiếu đánh giá relevance và nhãn topic khoa học độc lập. Corpus chỉ có Title–Abstract; một số tài liệu có thể nằm ngoài mục tiêu pin sodium ion. Mean pooling qua nhiều chunk có thể làm mất chi tiết quan hệ, và các chunk không có attention toàn cục.

Các thí nghiệm tiếp theo có thể kiểm chứng

Ưu tiên	Thí nghiệm	Cách xác nhận
1	Hoàn thiện nhãn relevance 0–2	Hai người chấm và verifier; P@10, nDCG@10, MRR@10 trên pool khóa
1	Đánh giá topic bởi người có chuyên môn	Đọc tài liệu đại diện và biên; ghi độ đồng nhất, nhãn sai và ngoài phạm vi
2	Tách tác động encoder và clustering	Giữ embedding để so KMeans/HDBSCAN; giữ clustering để so BGE/BatteryBERT
2	Ablation pooling và source projection	Cùng split, checkpoint và ngân sách; công bố cả kết quả giảm
3	Truy hồi nhiều vector theo chunk	Đo chi tiết bị bỏ bởi pooling và đánh đổi latency/index
3	Mở rộng toàn văn khi có dữ liệu	Version corpus mới; đánh giá riêng Methods, Results và quan hệ dài

Báo cáo không chọn một model thắng mọi mục tiêu. LDA cung cấp baseline xác suất; BERTopic cung cấp cụm ngữ nghĩa có outlier; các nhánh KMeans tổ chức catalog cố định; Search cần được kết luận bằng relevance có nhãn. Những hướng trên là đề xuất từ chẩn đoán output, chưa phải kết quả đã thực nghiệm.

23 Đối chiếu output và tài liệu phương pháp

Nội dung	Output chính trong workspace
Dữ liệu và kiểm tra	outputs/reports/stage1_summary.json
LDA chọn K	outputs/tables/stage2/lda_base_metrics.csv; outputs/reports/stage2/selected_model.json
LDA và BERTopic đối chứng	outputs/final_system/topic_comparison.csv; outputs/model_comparison_v2/
Sáu catalog và 600 keywords	docs/TOP10_TOPICS_ALL_MODELS_20261024.csv
Training và proxy mới	outputs/batterybert_full_document_20261024_v1/training_coverage.json; selection.json; paired_training_effect.json
Topic mới	outputs/batterybert_full_document_20261024_v1/topics/final_metrics.json; topic_keywords.csv; topic_assignments.csv
Search và nhãn	outputs/batterybert_full_document_20261024_v1/rankings_top10.csv; evaluation_status.json; annotation_pool.csv
Hiệu năng và tests	outputs/batterybert_full_document_20261024_v1/benchmark_latency.csv; verification_summary.json

Tài liệu tham khảo phương pháp

[1] Blei, Ng và Jordan. Latent Dirichlet Allocation. JMLR 3, 2003. https://www.jmlr.org/papers/v3/blei03a.html

[2] Grootendorst. BERTopic Neural topic modeling with a class based TF IDF procedure. 2022. https://arxiv.org/abs/2203.05794

[3] BAAI. Model card bge base en v1.5. https://huggingface.co/BAAI/bge-base-en-v1.5

[4] BatteryData. Checkpoint BatteryBERT cased. https://huggingface.co/batterydata/batterybert-cased

[5] BERTopic documentation. Algorithm và c-TF-IDF implementation. https://maartengr.github.io/BERTopic/algorithm/algorithm.html ; https://maartengr.github.io/BERTopic/api/ctfidf.html

[6] Gao và cộng sự. Scaling Deep Contrastive Learning Batch Size under Memory Limited Setup. 2021. https://arxiv.org/abs/2101.06983

Nguồn phương pháp giải thích thuật toán. Các số đo thực nghiệm trong báo cáo lấy từ artifacts của dự án, không lấy từ các bài báo tham khảo. Manifest kèm theo ghi SHA-256 của những file đã dùng; hình mới được vẽ lại từ output đã lưu, không refit model.

Phụ lục A BatteryBERT full-document trained

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Oxide Ti/Sn, titanate và composite điện cực 1.408 tài liệu	TiO2, titanium, titanate, solution, dioxide, SnO2, oxide, anode, carbon, composite
1	Prussian blue và các hợp chất điện cực chứa sắt 1.483 tài liệu	iron, prussian_blue, solution, sodium, ferrous, anode, prussian, cathode, ferrocyanide, FeS2
2	Oxide lớp P2/O3 và biến đổi cấu trúc điện cực 1.717 tài liệu	P2, layer, oxide, cathode, O3, layered_oxide, type, transition, phase, metal
3	Điện ly, polymer, muối và phụ gia giao diện 1.426 tài liệu	electrolyte, polymer, additive, organic, solvent, salt, carbonate, sodium, electrode, non-aqueous
4	Phosphate vanadium, NVP/NASICON và composite carbon 1.192 tài liệu	phosphate, Na3V2(PO4), vanadium, nvp, phosphorus, carbon, sodium, cathode, composite, fluorophosphate
5	Anode hợp kim Sn/Sb, graphene và MXene 1.266 tài liệu	graphene, antimony, mxene, sb, anode, composite, sn, alloy, electrode, tin
6	Phần cứng cell và thiết bị chế tạo, kiểm tra pin 925 tài liệu	connect, plate, device, end, pole, piece, body, electric, electrode, collector
7	Cấu trúc pha, trật tự vacancy và dẫn ion 1.035 tài liệu	phase, na, NaxCoO2, sodium, compound, electrode, cathode, ion, solid_electrolyte, active
8	Hard carbon, carbon xốp và tiền chất sinh khối 1.653 tài liệu	hard_carbon, carbon, biomass, porous, carbonize, precursor, carbonization, dry, asphalt, anode
9	Sulfide/selenide, MoS2 và composite carbon 1.597 tài liệu	MoS2, sulfide, disulfide, molybdenum, carbon, composite, selenide, anode, solution, SnS2

Tài liệu ngoài 10 topic được gán outlier −1: 0. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = BatteryBERT full-document · trained

Phụ lục B BatteryBERT fine-tuned optimized

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Anode MoS2, dichalcogenide lớp và MXene 1.031 tài liệu	MoS2, graphene, mxene, molybdenum, disulfide, nanosheets, SnS2, MoSe2, anode, composite
1	Cathode phosphate vanadium và NASICON 1.342 tài liệu	phosphate, vanadium, Na3V2(PO4), nvp, sodium, cathode, carbon, PO4, F-, fluorophosphate
2	Cathode Prussian blue và hợp chất sắt 1.353 tài liệu	prussian_blue, iron, sodium, solution, prussian, cathode, ferrocyanide, ferrous, anode, iron-based
3	Cấu trúc cell, bộ góp dòng và lắp ráp pin 1.084 tài liệu	connect, plate, device, end, electrode, collector, pole, electric, positive, piece
4	Điện ly, muối, dung môi và polymer 1.532 tài liệu	electrolyte, polymer, additive, organic, salt, solvent, sodium, carbonate, electrode, solid_electrolyte
5	Anode sulfide/selenide và composite carbon 1.235 tài liệu	sulfide, carbon, composite, selenide, CoSe2, cobalt, FeS2, anode, solution, nickel
6	Anode hợp kim Sn/Sb, phosphorus và chuyển hóa 915 tài liệu	antimony, sb, tin, sn, anode, alloy, composite, carbon, phosphorus, Sb2S3
7	Hard carbon, carbon xốp và tiền chất sinh khối 1.703 tài liệu	hard_carbon, carbon, biomass, porous, carbonize, precursor, carbonization, dry, anode, asphalt
8	Anode oxide Ti/Sn và titanate 1.444 tài liệu	TiO2, titanium, titanate, dioxide, SnO2, solution, oxide, anode, sodium, composite
9	Cathode oxide lớp P2/O3 và kim loại chuyển tiếp 2.063 tài liệu	P2, layer, oxide, cathode, O3, layered_oxide, phase, transition, type, metal

Tài liệu ngoài 10 topic được gán outlier −1: 0. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = BatteryBERT fine-tuned · optimized

Phụ lục C BatteryBERT KMeans (pretrained)

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Wet-chemical synthesis of electrode materials 2.309 tài liệu	solution, mix, dry, water, stir, hour, source, method, precursor, wash
1	Active-material formulations and electrode coatings 1.677 tài liệu	electrode, active, active material, negative, battery, negative electrode, layer, positive, material, sodium_ion
2	Mixed electrode performance and electrolyte studies 1.624 tài liệu	electrolyte, capacity, cycle, electrochemical, high, na-ion, performance, na, anode, result
3	Anode composites and cycling performance 1.622 tài liệu	ma, capacity, mah, cycle, high, sib, capacity mah, rate, performance, anode
4	Sulfide/selenide-carbon composite anodes 1.603 tài liệu	MoS2, storage, cycle, sib, nanosheets, capacity, anode, sodium storage, TiO2, high
5	Inorganic electrode compositions and chemical claims 1.470 tài liệu	sodium, formula, material, metal, oxide, anode material, compound, anode, sodium_ion, sodium_ion battery
6	Layered-oxide and phosphate cathode materials 1.351 tài liệu	P2, cathode, capacity, Na3V2(PO4), type, cycle, cathode material, O3, electrochemical, P2 type
7	Crystal structure, redox and intercalation studies 1.291 tài liệu	na, phase, redox, structural, na-ion, property, Na+, structure, x-ray, diffusion
8	Cell hardware and assembly equipment 480 tài liệu	connect, plate, device, end, box, rod, cover, fix, electric, groove
9	Reviews and research perspectives 275 tài liệu	sib, application, energy_storage, advance, design, strategy, mechanism, focus, perspective, cost

Tài liệu ngoài 10 topic được gán outlier −1: 0. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = BatteryBERT KMeans (pretrained)

Phụ lục D LDA

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Sodium-storage anodes and carbon composites 3.486 tài liệu	anode, cycle, capacity, carbon, high, sodium_ion, performance, storage, material, sib
1	Non-aqueous electrolytes and ionic transport 997 tài liệu	battery, electrolyte, study, sodium_ion, deliver, sodium, use, conductivity, ionic, analysis
2	Cathode electrochemistry and vanadium phosphates 3.559 tài liệu	capacity, cathode, cycle, electrochemical, material, na, performance, Na+, high, na-ion
3	Electrode-material inventions (mixed materials) 869 tài liệu	material, anode, sodium_ion, battery, sodium, cathode, advance, use, performance, high
4	Transition-metal and Prussian-white formulations 78 tài liệu	nc, material, iron, prussian_blue, manganese, coat, layered_oxide, oxide, nickel, Ni1
5	Layered oxide cathodes and P2/O3 structures 84 tài liệu	layer, transition, P2, phase, metal, cathode, oxide, type, O3, material
6	Active electrode materials and characterization 1.286 tài liệu	electrode, battery, material, use, sodium_ion, positive, layer, spectroscopy, active, negative
7	Material synthesis and preparation processes 2.529 tài liệu	solution, obtain, material, prepare, development, mix, add, battery, sodium_ion, water
8	Battery devices, housings and assembly 331 tài liệu	successfully, battery, connect, device, plate, sodium_ion, shell, provide, core, end
9	Hard-carbon preparation and related materials 483 tài liệu	carbon, material, hard_carbon, precursor, mxene, obtain, prepare, method, use, temperature

Tài liệu ngoài 10 topic được gán outlier −1: 0. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = LDA

Phụ lục E BERTopic–BGE

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Electrode-material preparation patents 3.552 tài liệu	obtain, material, prepare, solution, mix, source, use, add, precursor, dry
1	Layered-oxide and polyanion cathodes 2.650 tài liệu	P2, cathode, capacity, cycle, electrochemical, type, na, phase, O3, Na3V2(PO4)
2	Alloy/conversion and carbon-based anodes 1.261 tài liệu	sn, capacity, SnO2, ma, SnS2, anode, sb, cycle, storage, mah
3	Sulfide/selenide and carbon-composite anodes 1.008 tài liệu	MoS2, FeS2, cycle, storage, sib, CoSe2, MoSe2, capacity, ma, mah
4	Prussian-blue analogue cathodes 499 tài liệu	prussian_blue, ferrocyanide, prussian, hexacyanoferrate, analogue, white, Fe(CN), water, solution, pb
5	Titanate and TiO2 anodes 425 tài liệu	TiO2, Na2Ti3O7, anatase, nto, ma, cycle, titanate, storage, capacity, anode
6	Electrolyte salts, solvents and additives 397 tài liệu	electrolyte, additive, solvent, salt, non-aqueous, solid_electrolyte, organic, polymer, sodium, carbonate
7	Battery hardware and manufacturing devices 382 tài liệu	connect, plate, device, end, fixedly, box, rod, fix, cover, frame
8	Sodium cobalt oxides and superconductivity 219 tài liệu	NaxCoO2, NaCrO2, cuo, Co3O4, CoO2, superconducting, yh, superconductivity, phase, magnetic
9	MXene-based sodium-storage electrodes 189 tài liệu	mxene, Ti3C2Tx, mxenes, Ti3C2, carbide, mxene-based, two-dimensional, titanium, etch, TiS2

Tài liệu ngoài 10 topic được gán outlier −1: 3.120. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = BERTopic–BGE

Phụ lục F BERTopic–BatteryBERT (pretrained)

Output catalog gồm đầy đủ 10 topic và 10 keywords mỗi topic. Thứ tự dòng là ID topic; thứ tự từ khóa là rank trong chính model. Không ghép topic giữa các model bằng ID.

ID	Diễn giải và số tài liệu	Top 10 keywords
0	Electrode performance (broad Publication cluster) 7.261 tài liệu	capacity, cycle, ma, mah, high, performance, electrochemical, sib, rate, storage
1	Material preparation methods (broad Patent cluster) 5.449 tài liệu	obtain, solution, prepare, material, mix, use, add, sodium, method, source
2	Reviews and research outlook 218 tài liệu	review, recent, summarize, progress, research, discuss, future, challenge, development, sib
3	2D anodes and first-principles calculations 164 tài liệu	na, monolayer, adsorption, li, ev, barrier, atom, phosphorene, calculation, first-principles
4	Fixtures, protection and inspection equipment 156 tài liệu	connect, plate, fixedly, utility, rod, model, end, box, groove, fix
5	Assembly, heating and mechanical equipment 101 tài liệu	device, connect, plate, fix, frame, rotate, roller, rod, box, end
6	Battery packs, management and control 80 tài liệu	module, unit, voltage, pack, data, battery, charge, power, management, detect
7	Sodium cobaltate superconductivity 79 tài liệu	NaxCoO2, superconducting, yh, CoO2, superconductivity, magnetic, t-c, center, dot, superconductor
8	Cell housing and terminals 48 tài liệu	portion, terminal, electric, monomer, assembly, toy, second, cover, end, direction
9	Mixed high-performance electrode materials 37 tài liệu	high-performance, snsb-porous, vapor-redistribution, Se4P4, Na2C12H6O4, ultracycle-stable, photoassisted, krohnkite-type, na-ion, superior

Tài liệu ngoài 10 topic được gán outlier −1: 109. Nhãn là diễn giải từ khóa và tài liệu đại diện, chưa được chuyên gia xác nhận.

Nguồn output: docs/TOP10_TOPICS_ALL_MODELS_20261024.csv; model = BERTopic–BatteryBERT (pretrained)