HỆ THỐNG TÌM KIẾM PATENTS VÀ PAPERS VỀ PIN SODIUM-ION

Phần báo cáo độc lập: phương pháp, pipeline, đánh giá và kết quả

Tổng hợp bằng chứng đến ngày 26/10/2026

Tóm tắt. Phần này trình bày search engine trên 13.702 tài liệu patents và papers về pin sodium-ion. Bốn họ phương pháp được đối chiếu: lexical, semantic, hybrid và hybrid có reranker. Cấu hình hiện hành hợp nhất TF-IDF với BatteryBERT full-document bằng RRF, trả Top 10 sau khi áp dụng bộ lọc. Các công thức, sơ đồ và ví dụ dưới đây bám theo mã nguồn và artifacts đã lưu. Kết quả relevance mới nhất dựa trên 703 nhãn AI Silver của 20 truy vấn; những phép đo chưa thực hiện được ghi rõ ở phần kế hoạch hoàn thiện.

1. Bài toán và phạm vi dữ liệu

1.1. Nhu cầu tìm patents và papers

Người nghiên cứu cần tìm papers để khảo sát vật liệu, cơ chế và bằng chứng thí nghiệm, đồng thời tìm patents để khảo sát giải pháp kỹ thuật, thành phần, công đoạn hoặc thiết bị. Hai nguồn có khác biệt văn phong: papers thường nhấn mạnh hiệu năng và cơ chế; patents thường mô tả phương pháp, cấu trúc và quy trình. Hệ thống cần xếp hạng theo nhu cầu thay vì ưu tiên một nguồn chỉ vì số lượng hoặc văn phong.

Đầu vào là truy vấn tiếng Anh q và các bộ lọc F; đầu ra là danh sách tối đa 10 tài liệu:

$$R_{10}(q, F) = \mathrm{Top}_{10}\{s(q, d) : d \in \mathcal{D},\ F(d) = 1\}. \tag{1}$$

Mỗi kết quả phải có doc_id, tiêu đề, nguồn, năm, identifier, đoạn trích và ý nghĩa điểm. Có ba chế độ nguồn: All, Patent và Publication. Topic được dùng để duyệt/lọc, không tự chứng minh một tài liệu đáp ứng truy vấn.

Bảng 1: Dữ liệu Title–Abstract dùng cho search.

Nguồn	Tài liệu	Có Abstract	Thiếu Abstract
Patents	5.933	5.933	0
Papers	7.769	7.717	52

Nguồn: data/processed/main_corpus.parquet.

Corpus hiện tại sử dụng toàn bộ Title–Abstract có sẵn, chưa bao gồm toàn văn papers hoặc toàn bộ mô tả/claims của patents. Thuật ngữ “full-document” trong phần này

nghĩa là đọc đủ văn bản hiện có qua các cửa sổ token. Với patents, cần giữ year_basis và priority_year để không đồng nhất năm ưu tiên với năm công bố paper. Trường classification phải kiểm tra ý nghĩa theo nguồn trước khi gọi là bộ lọc IPC/CPC.

1.2. Câu hỏi nghiên cứu

Phần thực nghiệm trả lời năm câu hỏi: các kênh lexical/semantic bổ trợ nhau thế nào; continuation full-document ảnh hưởng biểu diễn ra sao; reranker có chuyển giao từ dev sang gate không; điểm chung đã đại diện cho từng nguồn chưa; và query nhiều điều kiện thất bại ở bước nào. Đóng góp được xác định là xây dựng và kiểm chứng một hệ thống ứng dụng; không suy thành một thuật toán nền tảng mới.

2. Bốn hướng tiếp cận và cấu hình đã thực hiện

Bảng 2: Bốn họ phương pháp và trạng thái trong dự án.

Hướng	Phương pháp và trạng thái
H1. Lexical	TF-IDF cosine là baseline hiện hành; BM25 thuộc Search v2 lịch sử.
H2. Semantic	Dense BatteryBERT pretrained, BGE và BatteryBERT full-document; đối chứng biểu diễn.
H3. Hybrid	TF-IDF + dense, hợp RRF 60. Full-document hybrid đang là cấu hình mặc định.
H4. Hybrid + rerank	MiniLM xếp lại Top 30/Top 50. Top 30 không qua gate và không được bật.

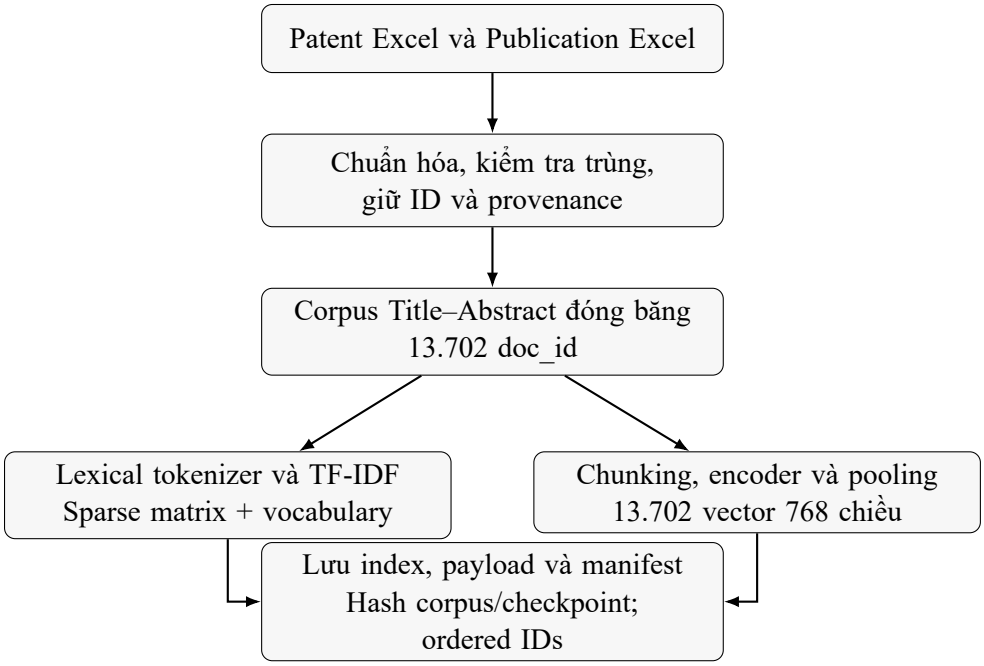
Nguồn: src/final_search.py;src/full_document_retrieval.py;outputs/research_revision_20261025_v1/deployment.json.

Bốn họ phương pháp gồm nhiều cấu hình cụ thể. Bộ đánh giá relevance hiện có so sánh sáu phương pháp: TF-IDF, BatteryBERT semantic, BatteryBERT hybrid, BGE semantic, full-document semantic và full-document hybrid. Reranker revision được thử trên protocol proxy riêng. Các tên SE1/SE2/SE3 và Search v2 chỉ mô tả lịch sử phát triển; không thay cho thuật toán hiện hành.

Hướng hybrid là trục chính vì kết hợp tín hiệu từ khóa đặc hiệu với biểu diễn ngữ nghĩa. Nhánh lexical có thể giữ công thức hoặc tên vật liệu hiếm, còn dense có thể nhận diện diễn đạt gần nhau. Hai nhánh vẫn có thể cùng sai khi query chứa điều kiện về vai trò điện cực, công đoạn hoặc một cấu hình cell cụ thể.

3. Pipeline và kiến trúc hệ thống

3.1. Giai đoạn offline: dữ liệu đến chỉ mục



Hình 1: Pipeline offline: chuẩn bị corpus và hai nhánh chỉ mục. Catalog topic được đọc riêng để tạo allowed doc_ids khi lọc.

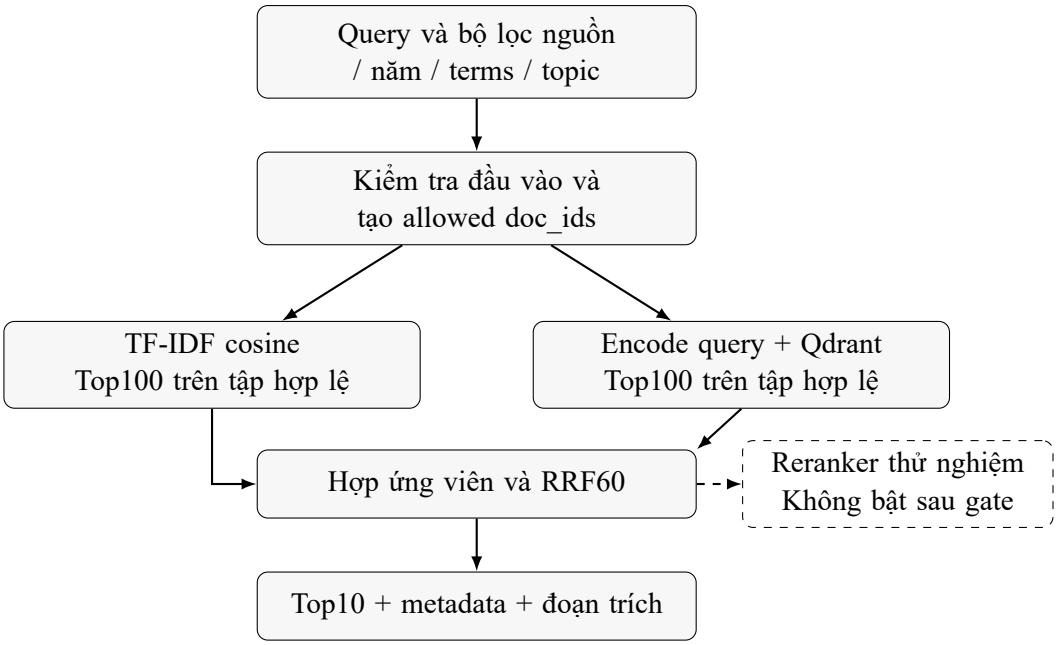
Nguồn: src/pipeline.py;src/final_search.py;src/full_document_inference.py.

Từ hai tệp Excel, pipeline ánh xạ schema, kiểm tra bản ghi thiếu/trùng, chuẩn hóa văn bản và giữ provenance. Corpus đóng băng có doc_id ổn định. Nhánh lexical tạo sparse matrix TF-IDF; nhánh neural chia cửa sổ rồi tạo một vector 768 chiều mỗi tài liệu. Vector và payload được đưa vào Qdrant với manifest của checkpoint, corpus và ordered IDs.

Các góc nhìn văn bản được tách theo mục đích. Title–Abstract gốc dùng hiển thị và chấm nhãn; tokenizer lexical giữ các mẫu công thức; encoder dùng tokenizer của checkpoint. Ví dụ, parser v2 có thể chuẩn hóa có điều kiện Na3V2(PO4)(3) thành Na3V2(PO4)3, nhưng không nối TiO2(101) thành TiO2101. Cú pháp chưa hỗ trợ được giữ raw span, không tự suy tương đương hóa học.

3.2. Giai đoạn online: query đến Top 10

Quy trình hiện hành thực hiện lần lượt: chuẩn hóa query; tạo allowed mask từ nguồn, năm, required terms và topic; encode query đúng checkpoint; lấy Top 100 lexical và Top 100 dense trên cùng tập hợp lệ; hợp nhất RRF 60; chọn Top 10; ghép metadata và đoạn trích. Hợp ứng viên có tối đa 200 ID, có thể ít hơn vì trùng hoặc nhánh lexical rỗng.



Hình 2: Pipeline online hiện hành. Topic tham gia lọc trước retrieval, không cộng điểm RRF. Nhánh reranker được giữ để mô tả thí nghiệm riêng.

Nguồn: src/full_document_retrieval.py;outputs/research_revision_20261025_v1/deployment.json.

Topic filter chuyển assignments hiện hành thành allowed doc_ids trước retrieval. Đổi catalog không yêu cầu encode lại corpus nếu embedding không đổi. Cần tránh lọc bằng payload topic cũ đã lưu trong index. Required terms xác nhận có token, chưa xác nhận các token cùng mô tả một thí nghiệm hoặc không nằm trong mệnh đề phủ định.

3.3. Các đầu ra và kiểm tra tính nhất quán

Index phải khớp corpus, tokenizer, checkpoint và thứ tự ID; cùng số chiều 768 chưa đủ để hai không gian embedding tương thích. Mỗi run cần ghi query, phương pháp, filter, thời gian, rank và doc_id. Hệ thống trả trạng thái rõ khi input không hợp lệ hoặc không còn tài liệu sau lọc. Tài liệu thiếu Abstract dùng Title thật; không sinh Abstract bù.

Qdrant đảm nhiệm lưu trữ/truy vấn vector và payload, không học relevance. Các benchmark hiện có dùng local Qdrant và kiểm tra exact parity với ma trận NumPy; chưa đại diện cho ANN phân tán hoặc nhiều người dùng đồng thời [1].

4. Công thức và phương pháp truy hồi

4.1. H1: TF-IDF và cosine lexical

Gọi N là số tài liệu, $f(t,d)$ là số lần term t xuất hiện trong d và $df(t)$ là số tài liệu chứa t. Với smooth IDF:

$$idf(t) = \log \frac{1+N}{1+df(t)} + 1, \tag{2}$$

$$\widetilde{x}_{dt} = f(t,d)idf(t), \qquad x_d = \frac{\widetilde{x}_d}{\|\widetilde{x}_d\|_2}, \tag{3}$$

$$s_L(q,d) = x_q^\top x_d. \tag{4}$$

Title nối Abstract được token hóa bằng lexical tokenizer. Vectorizer fit một lần trên corpus search đóng băng, dùng L2, TF không sublinear và float32. Query dùng vocabulary đã lưu; từ ngoài vocabulary không tự thêm feature. Chỉ điểm lexical dương được đưa vào Top 100 lexical. TF-IDF của search khác c-TF-IDF dùng mô tả topic [2].

BM25 xuất hiện trong Search v2 lịch sử, với term frequency bão hòa và hiệu chỉnh độ dài:

$$s_{BM25}(q,d) = \sum_{t\in q} IDF(t) \frac{f(t,d)(k_1+1)}{f(t,d) + k_1(1-b+b|d|/avgdl)}. \tag{5}$$

$avgdl$ là độ dài trung bình, $k_1 = 1,5$, $b = 0,75$ ở cấu hình lịch sử. Không gọi baseline TF-IDF hiện hành là BM25 chỉ vì cả hai cùng lexical [3].

4.2. H2: dense retrieval và pooling tài liệu

Encoder tạo hidden states H_i phụ thuộc ngữ cảnh. BatteryBERT dùng token pooling theo mask m_i tương ứng phiên bản:

$$h(x) = \frac{\sum_i m_i H_i}{\sum_i m_i}, \qquad e(x) = \frac{h(x)}{\|h(x)\|_2}. \tag{6}$$

BGE trong dự án dùng CLS chuẩn hóa. BatteryBERT là checkpoint pretrained trên tài liệu pin bằng MLM, không mặc nhiên là một sentence embedding model đã được hiệu chuẩn relevance [4, 5].

Full-document chia cửa sổ 256 tokens, overlap 64. Với e_{dj} là chunk embedding chuẩn hóa, a_{dj} là số token Abstract mới trong chunk j:

$$e_d = \text{L2Norm}\left(\frac{\sum_j a_{dj} e_{dj}}{\sum_j a_{dj}}\right). \tag{7}$$

Title được dùng làm context nhưng không trực tiếp pool vào vector nội dung Abstract của nhánh continuation. Trọng số token mới hạn chế đếm overlap hai lần ở tổng hợp; overlap vẫn ảnh hưởng attention. Bao phủ đủ mọi cửa sổ không tạo attention toàn cục

giữa chúng.

Query được encode bằng cùng checkpoint; với vector L2:

$$s_D(q,d) = \frac{e_q^\top e_d}{\|e_q\|_2 \|e_d\|_2} = e_q^\top e_d. \tag{8}$$

Cosine đo gần nhau trong embedding, không phải xác suất tài liệu đúng hay search accuracy. Mean pooling có thể hòa loãng điều kiện hiếm; đây là một giả thuyết cần kiểm tra khi phân tích query khó.

4.3. Huấn luyện encoder liên quan đến search

Continuation full-document bắt đầu từ checkpoint BatteryBERT fine-tuned, khóa 11 block và cập nhật block cuối. Positive là Title–document cùng bản ghi. Với batch B, temperature τ và tập negatives hợp lệ A_i:

$$S_{ij} = e_{q_i}^\top e_{d_j}/\tau, \tag{9}$$

$$L_{q\to d} = -\frac{1}{B}\sum_i \log \frac{\exp S_{ii}}{\sum_{j\in A_i} \exp S_{ij}}, \tag{10}$$

$$L_{CL} = \tfrac{1}{2}(L_{q\to d} + L_{d\to q}), \tag{11}$$

$$L = L_{CL} + \frac{0,02}{B}\sum_i (\|e_{q_i} - e_{q_i}^0\|_2^2 + \|e_{d_i} - e_{d_i}^0\|_2^2). \tag{12}$$

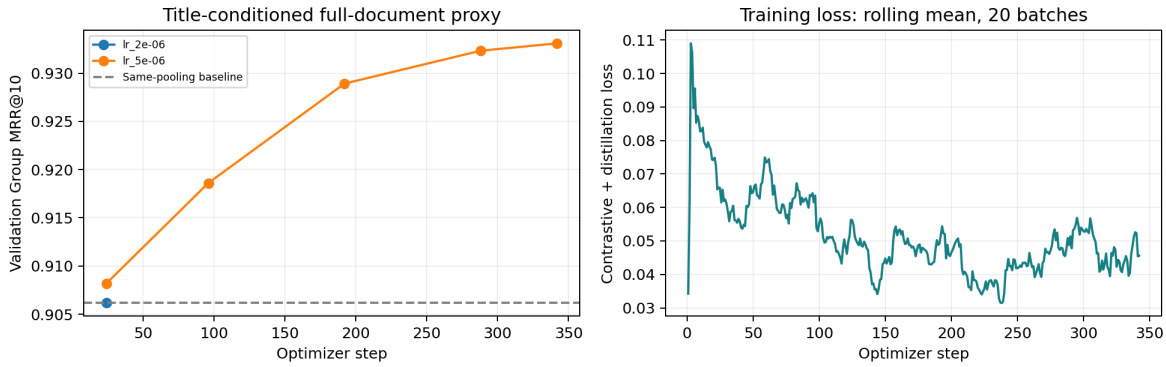
e^0 là embedding tham chiếu trước continuation. Cặp cùng nhóm hoặc có Title Jaccard từ 0,8 được mask để giảm false negatives. Batch32, temperature 0,05 và gradient caching cho phép replay theo microbatch 2 chunks; accumulation thông thường không tự mở rộng negative pool [6].

Một lượt train xử lý 10.921 tài liệu, 26.147 chunks và 3.420.215 token Abstract duy nhất. Validation gồm 1.361 và test 1.368 tài liệu; 52 title-only chỉ inference. Checkpoint step 342, learning rate 5×10^{-6} được chọn bằng validation, không dùng test. Những cặp train là proxy, khác qrels truy vấn tự nhiên.

Bảng 3: Group MRR@10 proxy trên cùng full-document pooling.

Split	Baseline	Selected	Gain
Validation	0,906174	0,933093	0,026919
Test	0,887839	0,924704	0,036865

Nguồn: outputs/batterybert_full_document_20261024_v1/paired_training_effect.json.



Hình 3: Loss và validation của continuation BatteryBERT full-document từ log huấn luyện đã lưu.

Nguồn: outputs/batterybert_full_document_20261024_v1/learning_curve.png.

Gain test proxy là 0,036865 trên cùng full-document pooling. Vì Title có mặt trong document context, điểm 0,924704 không được chuyển thành "92,47% search accuracy". Đây cũng là split lịch sử, chưa là external test mới.

4.4. H3: hợp nhất lexical và semantic bằng RRF

Với L_q, D_q là hai danh sách Top 100, hạng bắt đầu từ 1:

$$s_{RRF}(q,d) = \frac{\mathbf{1}[d \in L_q]}{60 + r_L(d)} + \frac{\mathbf{1}[d \in D_q]}{60 + r_D(d)}. \tag{13}$$

Hai nhánh có trọng số bằng nhau; vắng một list thì không nhận điểm list đó. RRF dùng thứ hạng để tránh cộng trực tiếp các score có phân bố khác nhau, đổi lại không giữ độ lớn chênh lệch score [7].

Ví dụ toán học: A ở lexical hạng 1/dense hạng 10 nhận $1/61 + 1/70 \approx 0,030679$; B ở hạng 4/4 nhận $2/64 = 0,03125$. B đứng trên A. Đây là ví dụ minh họa công thức, không phải kết quả benchmark. RRF không được hiển thị thành phần trăm chính xác.

Full-document hybrid có thể sử dụng dense khi lexical rỗng. Nếu tài liệu lexical lọt Top 10 nhưng ngoài dense Top 100, code có thể tính cosine trực tiếp để bổ sung thông tin hiển thị; thao tác này không đổi thứ hạng RRF. Giao diện cần phân biệt final score, semantic cosine, TF-IDF cosine và rank từng nhánh.

4.5. H4: reranker và kết quả không đạt gate

Cross-encoder đọc query và passage đồng thời; bi-encoder mã hóa riêng để lập index [8]. Phiên revision chia query thành các cửa sổ128/overlap 32 và chọn tối đa hai Abstract passages cho mỗi query window. Với u_w là số token query mới, P_{dw} là các

passages được chọn:

$$s_{CE}(q,d) = \frac{\sum_w u_w \max_{p \in P_{dw}} g_\psi(q_w, p)}{\sum_w u_w}. \tag{14}$$

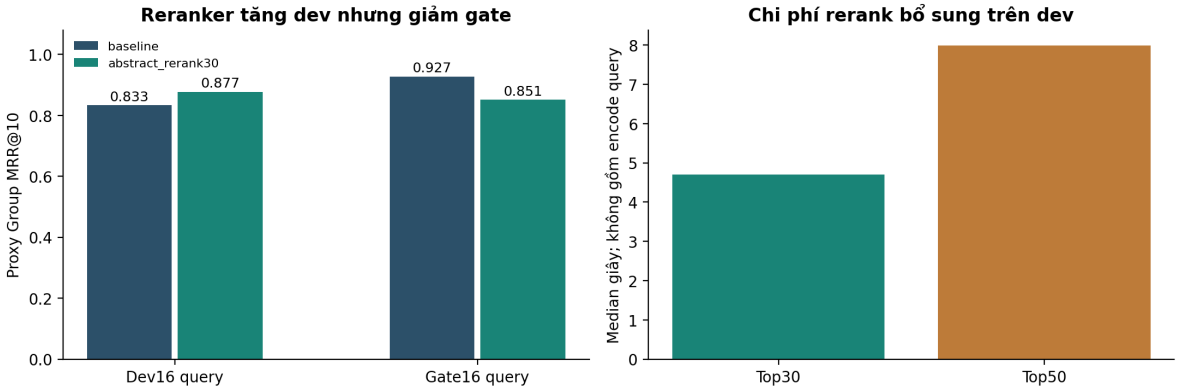
Passage width320/overlap 64, pair tối đa512 tokens. Title chỉ fallback nếu Abstract trống; từng query window đều được đọc. Điểm CE là tín hiệu xếp hạng, không phải xác suất relevance đã hiệu chuẩn. Reranker không bổ sung tài liệu ngoài candidate set.

Bảng 4: Group MRR@10 proxy: baseline và rerank Top 30.

Tập	Hybrid	Rerank30
Dev16	0,832812	0,877083
Gate16	0,927083	0,850694

Nguồn: outputs/research_revision_20261025_v1/comparison/search_proxy_comparison.csv.

Top 30 tăng dev nhưng giảm gate; vì vậy deployment giữ full-document hybrid và không bật reranker. Các con số này là Title-anchor proxy, không gộp vào bảng703 Silver Labels. Median rerank bổ sung ở gate khoảng 3,7655 giây; baseline 0 trong bảng cache không chứng minh retrieval miễn phí.



Hình 4: Reranker cải thiện dev nhưng giảm gate; thí nghiệm được lưu và không kích hoạt vào cấu hình mặc định.

Nguồn: outputs/research_revision_20261025_v1/visualizations/search_gate_rejection.png.

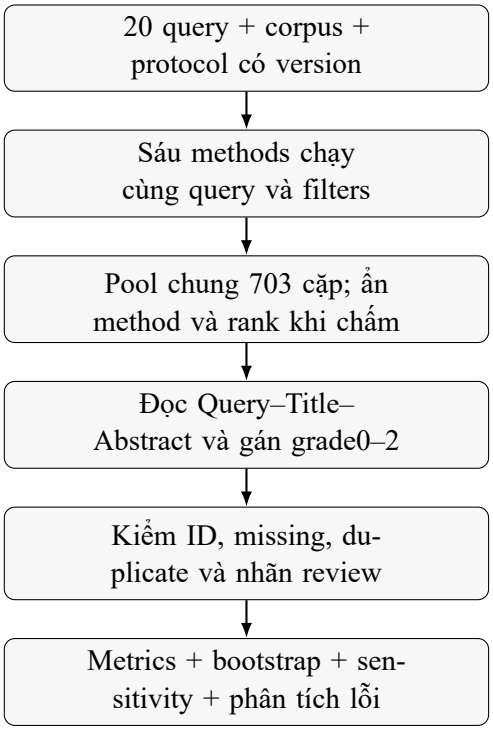
5. Giao thức và công thức đánh giá

5.1. Query, pooling và nhãn relevance

Benchmark hiện có 20 queries Q01–Q20, 703 cặp query–document duy nhất, sáu methods và 1.200 vị trí Top 10. AI đọc Query–Title–Abstract trước khi ghép rank/model, gán grade 0 không đáp ứng, grade 1 liên quan một phần, grade 2 đáp ứng trực tiếp. Có

143 nhãn 0; 302 nhãn 1; 258 nhãn 2. Có 70 trường hợp cần review và 28 bản ghi thiếu Abstract.

Đây là một lượt AI Silver, chưa có chuyên gia độc lập. Confidence chưa hiệu chuẩn; không tính accuracy/F1 của AI label hoặc agreement giữa hai người chấm khi chưa có dữ liệu tương ứng. Nhãn Silver chưa dùng chọn encoder, topic hay reranker. Khác biệt này phải được giữ trong tên bảng và nhận xét.



Hình 5: Giao thức đánh giá relevance hiện có. Nhãn AI Silver được giữ tách biệt với human ground truth.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/protocol.json;evaluation/protocol.json.

5.2. P@10, MRR@10, nDCG@10 và Recall trong pool

Với grade $g_{qi} \in \{0, 1, 2\}$, đặt $rel_{qi} = \mathbf{1}[g_{qi} = 2]$:

$$P@10(q) = \frac{1}{10} \sum_{i=1}^{10} rel_{qi}, \tag{15}$$

$$RR@10(q) = \begin{cases} 1/j, & j = \min\{i \leq 10 : rel_{qi} = 1\}, \\ 0, & \text{không có grade2 trong Top10}, \end{cases} \tag{16}$$

$$MRR@10 = \frac{1}{|Q|} \sum_{q \in Q} RR@10(q), \tag{17}$$

$$DCG@10(q) = \sum_{i=1}^{10} \frac{2^{g_{qi}} - 1}{\log_2(i+1)}, \tag{18}$$

$$nDCG@10(q) = \begin{cases} DCG@10(q)/IDCG@10(q), & IDCG > 0, \\ 0, & IDCG = 0. \end{cases} \tag{19}$$

IDCG lấy 10 grades tốt nhất từ pool chung của query; grade 1 có gain 1, grade 2 có gain 3. Mọi phương pháp được macro-average trên cùng 20 query; thiếu nhãn không được đổi thành 0 [2].

Recall trong pool là số bài grade 2 tìm được chia tổng grade 2 của query trong pool. Nếu mẫu số0 thì undefined; đây không phải recall toàn corpus. Q08 có nDCG 1 nhưng P@10 và MRR 0 vì pool chưa có bài grade 2. nDCG cao khi đó chỉ mô tả thứ tự tương đối của các bài liên quan một phần.

5.3. Bất định và kiểm chứng phép tính

Bootstrap 10.000 lần theo query, cùng resamples giữa methods, seed 20261026. CI95% full-document hybrid: P@10[0,395;0,685], nDCG@10[0,6793;0,8534], MRR@10[0,6117;0,9250]. Đây là biến thiên giữa20 queries với nhãn cố định, không đo sai số của AI judge. Paired CI với BGE và BatteryBERT hybrid chứa0 cho ba chỉ số; chưa có kết luận thắng chắc chắn.

Evaluator kiểm đủ 120 nhóm, rank 1–10 liên tục, ID thuộc pool và text khớp nguồn. nDCG được đối chiếu độc lập với sklearn trên 120 nhóm, sai lệch tối đa $4,44 \times 10^{-16}$. Kiểm chứng số học không xác nhận nhãn đúng về khoa học.

6. Kết quả so sánh các phương pháp

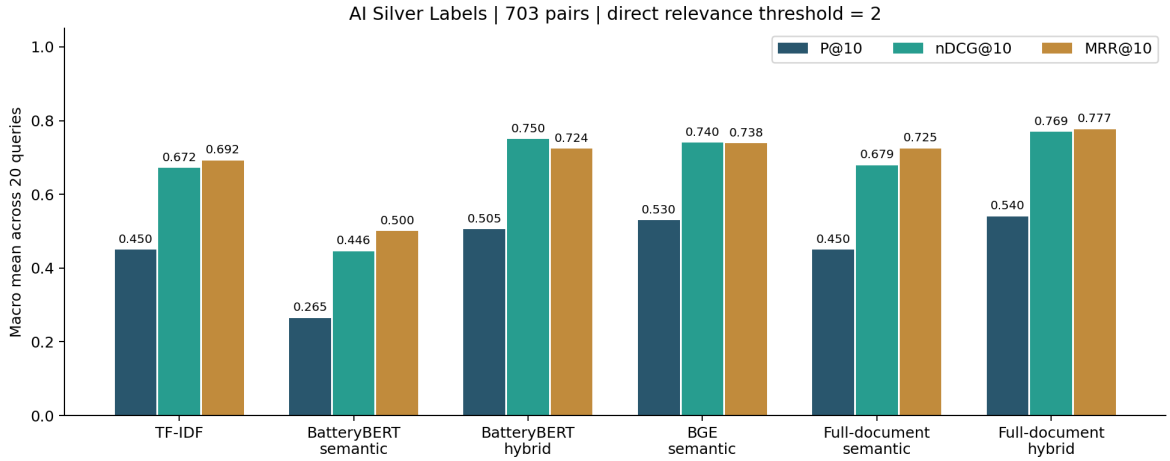
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/metrics_summary.csv.

Full-document hybrid đạt trung bình cao nhất trong lần chấm này. So với TF-IDF, P@10 tăng 0,0900; nDCG@10 tăng 0,097454; MRR@10 tăng 0,0850. P@10=0,54

Bảng 5: Kết quả trên 703 nhãn AI Silver, 20 queries; chưa xác minh bởi chuyên gia.

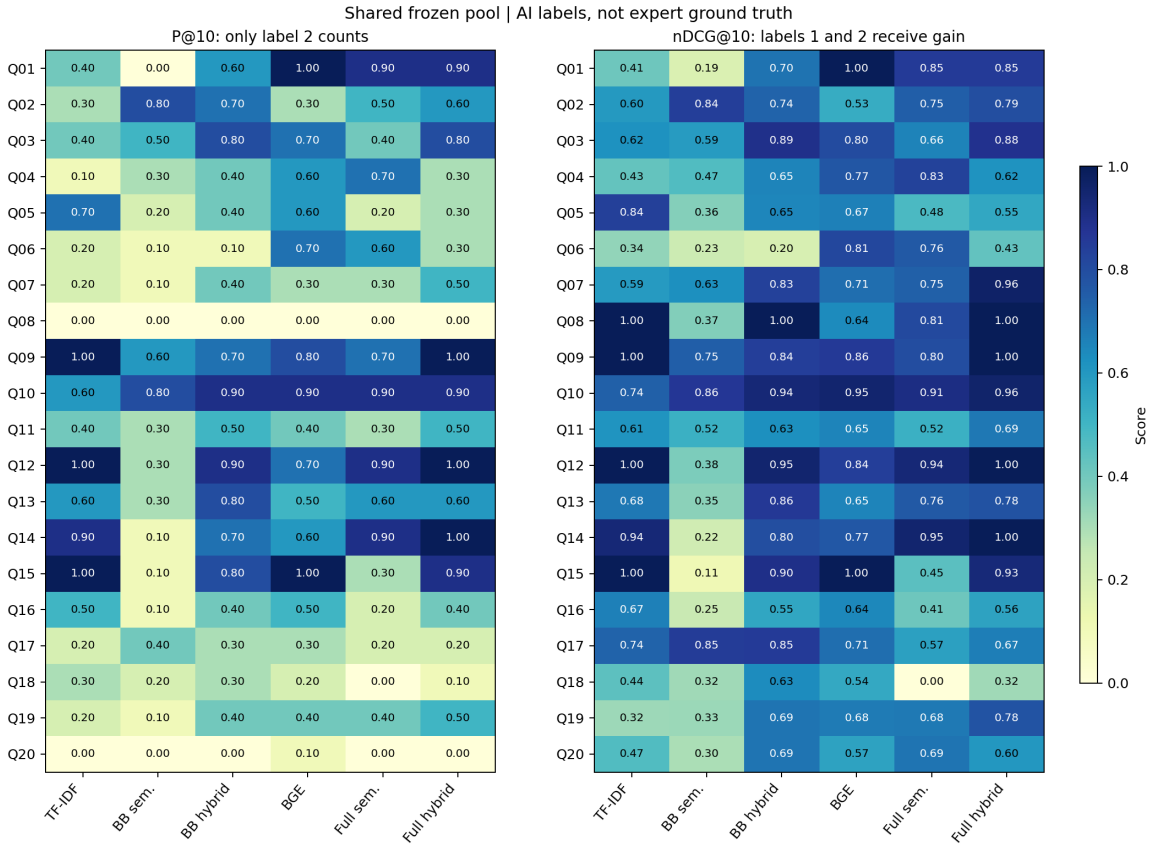
Phương pháp	P@10	nDCG@10	MRR@10
TF-IDF	0,4500	0,6719	0,6917
BatteryBERT semantic	0,2650	0,4457	0,5005
BatteryBERT hybrid	0,5050	0,7499	0,7238
BGE semantic	0,5300	0,7399	0,7383
Full-document semantic	0,4500	0,6786	0,7250
Full-document hybrid	0,5400	0,7693	0,7767

nghĩa là trung bình 5,4 kết quả grade 2 trong 10 bài, không phải accuracy 54% trên toàn hệ thống. Lợi thế P@10 so với BGE chỉ 0,01 và cần đọc cùng CI.



Hình 6: So sánh sáu phương pháp trên 703 nhãn AI Silver và cùng 20 queries; đây là đánh giá relevance, khác proxy chọn checkpoint.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/method_comparison.png.



Hình 7: Điểm theo từng query. Các điều kiện khó ở Q08, Q16–Q18 và Q20 cần phân tích cùng rubric và pool.

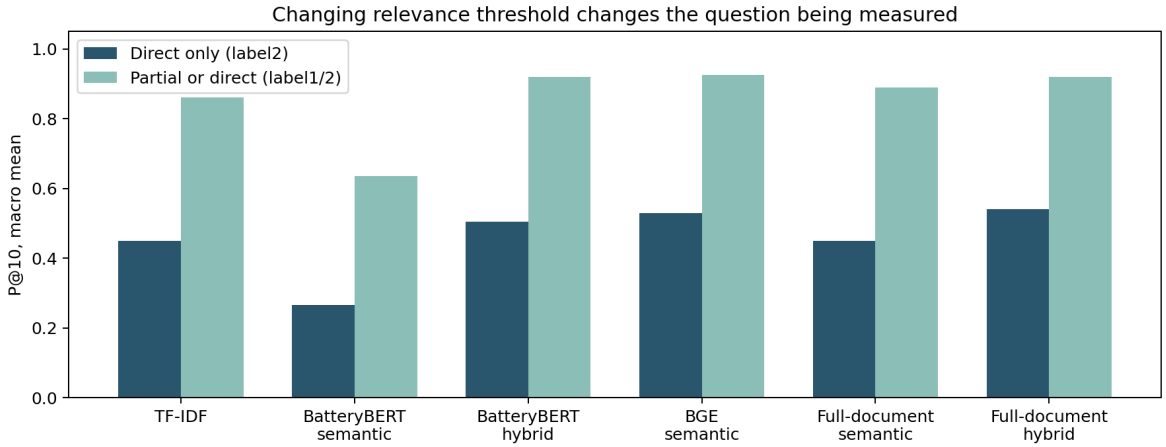
Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/query_heatmaps.png.

Bảng 6: Độ trễ warm requests đã lưu, đơn vị giây; khác phiên chạy.

Phương pháp	n	Median	Max
BatteryBERT hybrid	19	0,226	0,307
BatteryBERT semantic	19	0,210	0,385
BGE semantic	19	0,454	1,046
TF-IDF	19	0,018	0,028
Full-document hybrid	19	0,537	0,620
Full-document semantic	19	0,575	1,072

Nguồn: outputs/research_completion_v1/latency.csv;outputs/batterybert_full_document_20261024_v1/benchmark_latency.csv.

Đây là 19 warm requests/method ở các phiên chạy đã lưu, chưa phải thí nghiệm tải đồng thời hoặc cam kết p95. Median full-document hybrid khoảng 0,537 giây. Cần tách request đầu tiên, cache, độ dài query và thời gian encode/retrieval/fusion khi đo tiếp. Ma trận 13.702 × 768 float32 tốn khoảng 42,09MB thập phân, chưa gồm weights, sparse matrix, payload và index.



Hình 8: Độ nhạy khi thay ngưỡng relevance. Tính cả grade 1 trả lời câu hỏi khác với chỉ tính grade 2.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/figures_v2/threshold_sensitivity.png.

Thay đồng thời 70 nhãn review thành 0/2 cho P@10 hybrid full-document 0,525/0,600. Đây là kịch bản nhạy cảm, không phải nhãn mới hay khoảng tin cậy. Các 45 so sánh thăm dò chưa hiệu chỉnh đa kiểm định.

7. Ví dụ thực tế từ papers và patents

7.1. Q01: papers về hard carbon từ biomass

Query: *Hard carbon anodes derived from biomass for sodium-ion batteries.* Tín hiệu cần đồng thời là biomass, hard carbon, anode và sodium-ion. Paper hạng 1 được chấm 1 vì Abstract nói carbon rộng, chưa xác nhận hard carbon cụ thể. Paper hạng 2 được chấm 2 vì có bằng chứng hard carbon từ biomass làm anode SIB. Tiêu đề đầy đủ được giữ trong bảng và hình kết quả.

Bảng 7: Ba kết quả đầu Q01 của full-document hybrid.

Rank	Tiêu đề	Grade
1	Biomass-derived carbon anodes for sodium-ion batteries	1
2	Biomass hard carbon of high initial coulombic efficiency for sodium-ion batteries: Preparation and application	2
3	Biochars from various biomass types as precursors for hard carbon anodes in sodium-ion batteries	2

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

Grades theo thứ hạng là $[1, 2, 2, 2, 2, 2, 2, 2, 2, 2]$. Vì vậy P@10=0,9; RR@10=0,5. Từ pool chung, DCG=11,630678, IDCG=13,630678 và nDCG=0,853272. Các grades được ghép sau retrieval; ranking không bị sửa theo nhãn.

Q01 · Full-document hybrid · frozen Top 10
Reconstructed from saved output · AI Silver labels

Rank	Title	RRF	Silver
1	Biomass-derived carbon anodes for sodium-ion batteries	0.03028	1
2	Biomass hard carbon of high initial coulombic efficiency for sodium-ion batteries: Preparation and application	0.02878	2
3	Biochars from various biomass types as precursors for hard carbon anodes in sodium-ion batteries	0.02731	2
4	Revealing the sodium storage behavior of biomass-derived hard carbon by using pure lignin and cellulose as model precursors	0.02650	2
5	A Stable Biomass-Derived Hard Carbon Anode for High-Performance Sodium-Ion Full Battery	0.02513	2
6	High Capacity and High Efficiency Maple Tree-Biomass-Derived Hard Carbon as an Anode Material for Sodium-Ion Batteries	0.02492	2
7	Hard carbon derived for lignin with robust and low-potential sodium ion storage	0.02432	2
8	Biomass derived hard carbon used as a high performance anode material for sodium ion batteries	0.02312	2
9	Pectin, Hemicellulose, or Lignin? Impact of the Biowaste Source on the Performance of Hard Carbons for SodiumIon Batteries	0.02256	2
10	A porous biomass-derived anode for high-performance sodium-ion batteries	0.02158	2

Hình 9: Top 10 Q01 của full-document hybrid, dựng từ rankings đã khóa và nhãn Silver. Hình là bản trình bày output, không phải ảnh chụp phiên giao diện mới.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

7.2. Q16: patents về coating và roll pressing

Query: *Roll pressing and electrode coating equipment for sodium-ion batteries.* Bài toán yêu cầu đúng công đoạn và thiết bị, không chỉ có từ rolling hoặc coating. Hạng1 nói rolling để hỗ trợ thấm electrolyte trong pouch cell; hạng 2 nói electrode sheet/coating nhưng thiếu bằng chứng equipment/roll press. Hạng3 mô tả hot-press rollers cho slurry/foil được chấm 2 trong lượt Silver.

Bảng 8: Ba kết quả đầu Q16 của full-document hybrid.

Rank	Tiêu đề	Grade
1	Method for infiltrating electrolyte of soft-packed sodium-ion battery, involves injecting electrolyte into a battery soft bag, vacuumizing and sealing soft battery pack after vibration is completed, and placing soft battery pack for second time to obtain semi-finished product	1
2	Electrode sheet for battery such as energy storage sodium-ion batteries, has slurry coating including thermal insulation material coating and aqueous slurry coating that is coated on current collector and covers thermal insulation coating	1
3	Preparation method of cathode material of sodium ion battery, involves sending hot air pre-dried slurry and foil to hot pressing roller of hot pressing forming device for heating and drying, and hot pressing and forming by forming device	2

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

Q16 · Full-document hybrid · frozen Top 3
Reconstructed from saved output · AI Silver labels

Rank	Title	RRF	Silver
1	Method for infiltrating electrolyte of soft-packed sodium-ion battery, involves injecting electrolyte into a battery soft bag, vacuumizing and sealing soft battery pack after vibration is completed, and placing soft battery pack for second time to obtain semi-finished product	0.02964	1
2	Electrode sheet for battery such as energy storage sodium-ion batteries, has slurry coating including thermal insulation material coating and aqueous slurry coating that is coated on current collector and covers thermal insulation coating	0.02720	1
3	Preparation method of cathode material of sodium ion battery, involves sending hot air pre-dried slurry and foil to hot pressing roller of hot pressing forming device for heating and drying, and hot pressing and forming by forming device	0.02420	2

Hình 10: Ba patent đầu Q16 của full-document hybrid, dựng từ kết quả đã lưu. Nhãn phản ánh rubric thiết bị/công đoạn theo Title–Abstract.

Nguồn: outputs/ai_silver_labels_703_20261026_v1/evaluation/rankings_with_silver_labels.csv.

Ví dụ minh họa đúng token nhưng sai quan hệ kỹ thuật. Không suy nội dung claims chưa có trong corpus. Các ID trong ví dụ là identifier nội bộ đã lưu; có thể truy ngược nguồn bằng doc_id.

7.3. Q20: nhiều điều kiện trong cùng một full cell

Query: *Hard carbon full cells with layered oxide cathodes and electrolyte additives.* Các điều kiện là hard-carbon anode, layered-oxide cathode, full-cell configuration và electrolyte additive. Có các token ở những đoạn khác nhau chưa đủ chứng minh chúng cùng thuộc một hệ thí nghiệm.

Full-document hybrid không trả bài grade 2 trong Top 10, dù pool có một bài grade 2. BGE semantic lấy bài đó ở hạng 10: “The effects of the functional electrolyte additive on the cathode material Na0.76Ni0.3Fe0.4Mn0.3O2 for sodium-ion batteries”, ID pu blication:WOS:000439134600040. Paper hybrid hạng 1 về HC/layered oxide nhưng chưa xác nhận additive chỉ được chấm 1. Các diễn giải này là Silver reasoning, chưa có xác minh chuyên gia.

Case này cho thấy điểm trung bình tốt chưa có nghĩa tốt nhất mọi query. Cần tách lỗi candidate generation, xếp hạng và thiếu bằng chứng metadata; không mặc định đổ mọi lỗi cho encoder hoặc tăng trọng số từ khóa theo query_id đã xem.

8. Các phần còn thiếu và kế hoạch hoàn thiện

8.1. Đánh giá riêng Patent-only và Paper-only

Bảng703 nhãn phản ánh protocol hỗn hợp hiện có. Để kết luận riêng từng nguồn, phải chạy retrieval với filter Patent hoặc Publication trước lấy ứng viên, tạo pool hợp lệ và chấm theo intent tương ứng. Không lấy Top 10 chung rồi xóa một nguồn để gọi phần còn lại là benchmark của nguồn kia.

Cần giữ20 queries đã xem như benchmark chẩn đoán lịch sử, tạo query-family phát triển và giữ riêng mới. Quy tắc áp dụng query cho từng nguồn phải khóa trước khi xem điểm. Patent family hoặc DOI chỉ dùng nhóm trùng khi metadata đủ tin cậy; không giả định đã có family ground truth. Nếu thêm method làm pool lớn hơn, tạo version mới và tính lại mọi method trên cùng protocol.

8.2. Các hạng mục cần bổ sung

Bảng 9: Các việc tiếp theo và đầu ra cần có.

Hạng mục	Công việc và tiêu chí hoàn thành
Nhãn và query mới	Review nhãn bất định; khóa query-family phát triển và giữ riêng; chấm độc lập.
Patents / papers	Chạy filter trước retrieval; tạo pool và IDCG riêng cho từng chế độ nguồn.
Ablation	Giữ một yếu tố thay đổi: checkpoint/pooling, fusion, candidate budget hoặc reranker.
Intent và điều kiện	Kiểm vai trò, công đoạn, cấu hình; tách lỗi ứng viên, xếp hạng và metadata.
Vận hành	Đo latency, bộ nhớ, concurrency; kiểm phiên bản, filter và rollback.
Bàn giao	PDF và nguồn LaTeX đủ hình, bảng, công thức và sơ đồ; số liệu có nguồn.

Nguồn: docs/KE_HOACH_HOAN_THIEN_SEARCH_ENGINE_PATENTS_PAPERS.md.

Nên ưu tiên nhãn con người độc lập, review 70 trường hợp bất định và kiểm tra role labels mâu thuẫn. Sau đó mới thử passage/multi-vector retrieval hoặc fine-tuning mới theo giả thuyết rõ. Topic coherence không thay relevance; proxy Title–document không thay query người dùng.

Vận hành cần bổ sung latency p50/p95, concurrency, bộ nhớ, build/update time và rollback. Model/index mới phải qua kiểm tra hash, ID, finite values, L2 và filter parity. Chưa có số đo thì ghi “chưa đo”.

Tiêu chí nghiệm thu. Phần báo cáo cần cho phép truy query đến Top10, giải thích score và protocol. Bảng/hình có nguồn và phiên bản; công thức, sơ đồ và artifacts đủ để tái lập. Lựa chọn cấu hình xét chất lượng, uncertainty và chi phí vận hành.

9. Kết luận

Hệ thống hiện hành hợp nhất TF-IDF và BatteryBERT full-document bằng RRF 60 trên patents/papers. Hybrid cao nhất về trung bình trong lần chấm 703 nhãn AI; reranker không qua gate. Kết luận còn giới hạn bởi dữ liệu Title–Abstract và nhãn chưa xác minh. Ưu tiên tiếp theo là đánh giá nguồn riêng và nhãn con người độc lập.

Tài liệu

[1] Qdrant, “Vectors: Documentation,” nguồn tham khảo từ snapshot 19-10-2026; lịch sử local-mode đối chiếu inference contract. [Online]. Available: https://qdrant.tech/documentation/manage-data/vectors/

[2] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge University Press, 2008. [Online]. Available: https://nlp.stanford.edu/IR-book/

[3] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, pp. 333–389, 2009.

[4] BAAI, “bge-base-en-v1.5: Model card,” Hugging Face, nguồn tham khảo từ snapshot 19-10-2026; cấu hình thực nghiệm lấy từ checkpoint cục bộ. [Online]. Available: https://huggingface.co/BAAI/bge-base-en-v1.5

[5] BatteryData, “Batterybert-cased: Model card,” Đối chiếu ngày 26-10-2026; thông số thực nghiệm theo checkpoint cục bộ. [Online]. Available: https://huggingface.co/batterydata/batterybert-cased

[6] L. Gao, Y. Zhang, J. Han, and J. Callan, “Scaling deep contrastive learning batch size under memory limited setup,” in *Proceedings of RepL4NLP*, 2021. [Online]. Available: https://arxiv.org/abs/2101.06983

[7] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal rank fusion outperforms condorcet and individual rank learning methods,” in *Proceedings of SIGIR*, 2009, pp. 758–759.

[8] Sentence Transformers, “cross-encoder/ms-marco-minilm-l6-v2: Model card,” nguồn tham khảo từ snapshot 19-10-2026; pretrained cross-encoder chạy cục bộ. [Online]. Available: https://huggingface.co/cross-encoder/ms-marco-MiniLM-L6-v2