PHƯƠNG PHÁP VÀ KẾT QUẢ NGHIÊN CỨU

Sodium-ion Research Explorer

Dữ liệu, mô hình chủ đề, học biểu diễn và hệ thống tìm kiếm tài liệu

Bằng chứng từ code và outputs của dự án

Rà soát ngày 20/10/2026

Bài toán và phạm vi

- Khám phá chủ đề và tìm tài liệu nghiên cứu về **pin sodium-ion**.
- Hai nguồn: bài báo khoa học (Publication) và bằng sáng chế (Patent).
- Đơn vị xử lý: **Title–Abstract**, kèm nguồn, năm, định danh và provenance.
- Đầu ra sản phẩm: chủ đề để khám phá; Top5 tài liệu và passage để đọc kiểm tra.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 1

Một truy vấn có nhiều điều kiện

NaFSI ether electrolytes for low-temperature sodium-ion batteries

- **Vật liệu:** muối NaFSI.
- **Môi trường:** dung môi ether.
- **Điều kiện:** nhiệt độ thấp; đúng hệ pin sodium-ion.
- Các từ cùng xuất hiện chưa chứng minh các điều kiện cùng thuộc một thí nghiệm.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 1.1 và 8.5

Pipeline toàn bộ dự án

1. **Stage 1:** Excel → làm sạch, sàng lọc → corpus đóng băng.
2. **Stage 2:** tokens → LDA → phân phối chủ đề, từ khóa.
3. **Stage 3:** Title–Abstract → fine-tune BGE → embeddings; BERTopic.
4. **Nhánh chunked:** các cửa sổ Abstract → pooling → BERTopic đối chứng.
5. **Search V2:** BM25 + dense → RRF → MiniLM → Top5.
6. **Đánh giá:** topic, proxy retrieval, relevance và thời gian được đo riêng.

Nguồn: src/pipeline.py; src/stage2.py; src/stage3_neural.py; src/search_v2.py

Offline và online trong cùng một hệ thống

Chế độ	Công việc	Đầu ra
Offline	Làm sạch, fit LDA / BERTopic	Corpus và topics
Offline	Fine-tune BGE, encode corpus	Weights và vectors
Chuẩn bị	Nạp / xây BM25, kiểm tra artifacts	Search engine
Online	Encode query, truy hồi, RRF, rerank	Top5 + passage

- Huấn luyện không lặp lại khi người dùng gửi query.
- Nhánh mặc định dùng BGE pretrained, không cần checkpoint fine-tuned.

Nguồn: src/search_v2.py; src/search_v2_service.py; configs/search_v2.json

Dữ liệu trước và sau tiền xử lý

Nguồn	Đầu vào	Corpus chính
Patent	8.657	5.933
Publication	11.919	7.769
Tổng	**20.576**	**13.702**

- 13.650 tài liệu có đủ Title–Abstract để tạo cặp fine-tuning.
- 52 tài liệu chỉ có Title; giữ nội dung thật, không tạo Abstract giả.
- Bản clean master vẫn lưu mọi bản ghi và quyết định xử lý.

Nguồn: outputs/reports/stage1_summary.json; outputs/reports/stage3/split_audit.json

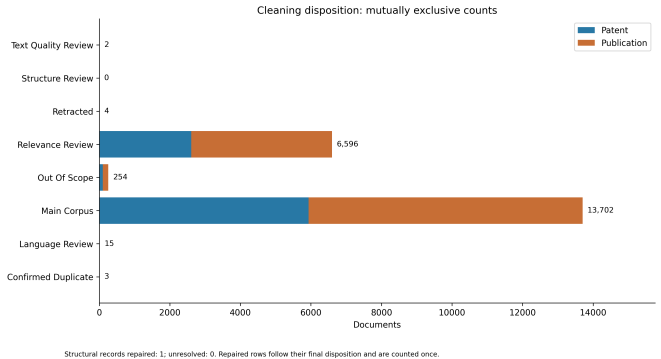
Quyết định sử dụng toàn bộ 20.576 bản ghi

Disposition	Số bản ghi
MAIN_CORPUS	13.702
RELEVANCE_REVIEW	6.596
OUT_OF_SCOPE	254
LANGUAGE_REVIEW	15
RETRACTED	4
CONFIRMED_DUPLICATE	3
TEXT_QUALITY_REVIEW	2

Relevance label và disposition là hai trường khác nhau. Clean master giữ mọi bản ghi.

Nguồn: outputs/reports/cleaning_summary.csv

Thay đổi dữ liệu qua từng quyết định xử lý



Bảng quyết định theo nguồn. Các nhóm review vẫn tồn tại trong clean master.

Nguồn: outputs/figures/data_preparation/figure_05_cleaning_summary.png

Tiền xử lý: mỗi bước phục vụ mục đích gì?

- **Hợp nhất schema:** đưa hai Excel về các trường dùng chung.
- **Chuẩn hóa:** Unicode NFC, chỉ số dưới, khoảng trắng và ký tự điều khiển.
- **Kiểm tra chất lượng:** cấu trúc, ngôn ngữ, nội dung rút lại và ngữ cảnh sodium-ion.
- **Kiểm tra trùng/liên kết:** định danh, DOI, độ gần Title và Abstract.
- **Ghi quyết định:** doc_id, source_row và split_group_id để truy vết.

Nguồn: src/data_io.py; src/text_processing.py; src/quality.py; configs/config.yaml

Phát hiện gần trùng và chống rò rỉ split

$$\cos(x, y) = \frac{x^\top y}{\|x\|\|y\|}, \qquad J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

- Title TF-IDF unigram/bigram: lấy cặp có cosine $\geq 0{,}88$.
- Kiểm tra tiếp Abstract word Jaccard $\geq 0{,}80$.
- Union-Find gộp liên kết thành `split_group_id`.
- Chỉ hợp nhất bản ghi trùng đã xác nhận. Patent khác ID có thể được giữ.

Nguồn: src/quality.py::duplicate_audit; configs/config.yaml

Ba biểu diễn văn bản khác nhau

Nhánh	Biểu diễn	Mục đích
LDA / c-TF-IDF	Tokens + cụm từ + công thức	Đếm từ, mô tả topic
BGE / MiniLM	Văn bản qua tokenizer model	Biểu diễn và so cặp
BM25 Search V2	Stemming + token chem:	Khớp từ / công thức

- LDA: bỏ stopwords, WordNet noun rồi verb; ghép `hard_carbon`.
- Search V2 có tokenizer riêng và aliases NaFSI/NaTFSI.
- Giữ Title/Abstract để hiển thị và kiểm tra bằng chứng.

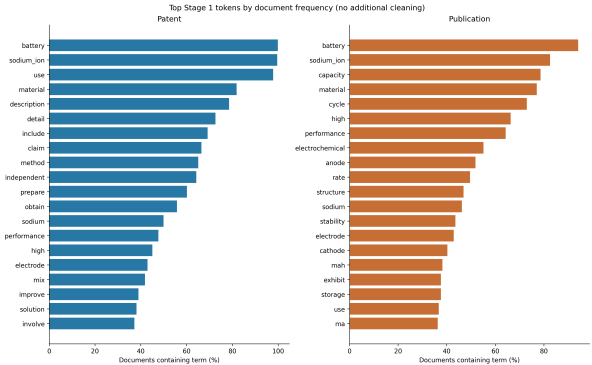
Nguồn: src/text_processing.py::lda_tokens; src/search_v2.py::lexical_tokens

Sau tiền xử lý thu được gì?

- `main_corpus.parquet`: 13.702 bản ghi dùng chung.
- `lda_tokens.parquet`: tokens cho LDA và từ khóa BERTopic.
- `bert_texts.parquet`: Title, Abstract và văn bản cho encoder.
- `metadata_extended.parquet`: metadata và provenance.
- **Ràng buộc:** doc_id và thứ tự hàng phải khớp giữa corpus, vector và kết quả.

Nguồn: src/pipeline.py::run, validate

Các từ xuất hiện nhiều theo từng nguồn



Thống kê tokens Stage 1. Tần suất cao thể hiện phổ biến, chưa thể hiện độ phân biệt của một topic.

Nguồn: outputs/figures/stage2/eda_02_top_terms.png

Top5 tokens: số lần và số tài liệu chứa từ

Nguồn	Token	TF	DF
Patent	material	33.433	4.857
Patent	battery	29.799	5.927
Patent	sodium_ion	20.077	5.910
Patent	use	13.200	5.806
Patent	sodium	12.439	2.965
Publication	battery	15.390	7.312
Publication	material	14.158	5.987
Publication	capacity	14.093	6.110
Publication	sodium_ion	12.704	6.412
Publication	cycle	12.509	5.667

Nguồn: outputs/tables/stage2/eda_term_frequencies.csv

LDA: định nghĩa và lý do dùng

Latent Dirichlet Allocation: mô hình chủ đề xác suất trên bag-of-words.

$$p(w \mid d) = \sum_{k=1}^{K} \theta_{dk} \phi_{kw}$$

- θ_{dk}: mức đóng góp của topic k trong tài liệu d.
- ϕ_{kw}: xác suất từ w trong topic k.
- Một tài liệu có thể chứa nhiều chủ đề; từ khóa dễ đọc và đối chiếu.
- Baseline chạy CPU; bỏ thứ tự từ nên hạn chế về ngữ nghĩa và quan hệ.

Nguồn: src/stage2.py::_fit_lda; configs/stage2.yaml

LDA: quy trình và sản phẩm sau huấn luyện

$$\text{Tokens} \rightarrow \text{Dictionary / BOW} \rightarrow \text{LdaModel} \rightarrow (\Theta, \Phi)$$

- $K \in \{10, 15, 20, 25, 30\}$; 10 passes, 100 iterations; seed cơ sở 42.
- Giữ toàn bộ vocabulary Stage 1; alpha asymmetric, eta symmetric.
- Chọn $K = 20$ trong tập khảo sát; lưu model và dictionary.
- Xuất vector 13.702×20, topic trội, entropy, Top10 từ và tài liệu đại diện.

Nguồn: src/stage2.py::export_topics; outputs/reports/stage2/selected_model.json

LDA: các phân phối thay đổi trong quá trình fit

$$r_{dnk} \propto \exp\{\mathbb{E}[\log \theta_{dk}] + \mathbb{E}[\log \phi_{k,w_{dn}}]\}$$

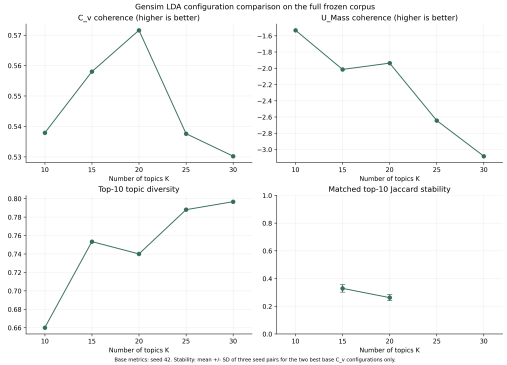
$$\gamma_{dk} = \alpha_k + \sum_n r_{dnk}, \quad \widehat{\lambda}_{kw} = \eta_w + \frac{D}{|\mathcal{B}|} \sum_{d \in \mathcal{B}, n: w_{dn}=w} r_{dnk}$$

$$\lambda^{new} = (1 - \rho_t)\lambda^{old} + \rho_t \widehat{\lambda}$$

Diễn giải variational inference của Gensim. r: trách nhiệm topic, γ: trạng thái tài liệu, λ: trạng thái topic–word. Dự án gọi thư viện để thực hiện cập nhật.

Nguồn: src/stage2.py::_fit_lda; gensim.models.ldamodel.LdaModel

So sánh các cấu hình LDA đã chạy



Chọn K=20 theo protocol hiện tại. Chỉ hai K qua sàng lọc được thử thêm seed.

Nguồn: outputs/figures/stage2/lda_01_model_comparison.png

Output LDA: ba topic trội lớn nhất

Topic 6 (5.207 tài liệu)
capacity; cycle; high; performance; sodium_ion; anode; battery; mah; rate; material

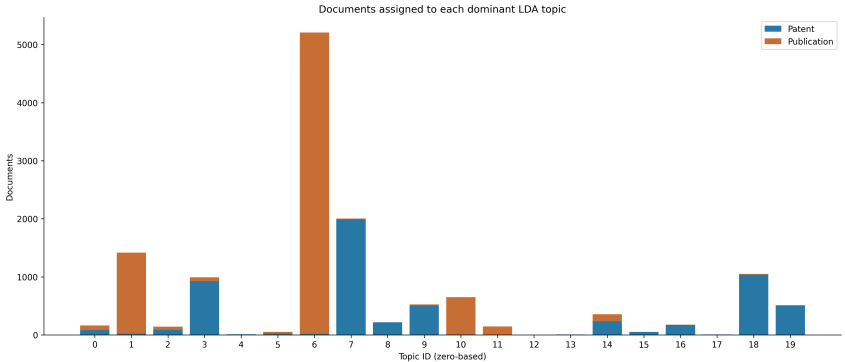
Topic 7 (2.004 tài liệu)
solution; obtain; prepare; material; add; water; mix; dry; stir; method

Topic 1 (1.417 tài liệu)
sodium; design; storage; energy; battery; application; kinetics; ion; demonstrate; work

ID chỉ có ý nghĩa trong cùng model. Các từ bên dưới là output gốc.

Nguồn: outputs/tables/stage2/topic_summary.csv

Phân bố tài liệu trên 20 topic LDA



Dominant assignment đếm mỗi tài liệu vào một topic. Soft mass cộng xác suất topic qua tài liệu.

Nguồn: outputs/figures/stage2/lda_02_topic_distribution.png

BGE: bi-encoder tạo vector ngữ nghĩa

`BAAI/bge-base-en-v1.5`: mã hóa query và tài liệu riêng.

$$e_q = \mathrm{norm}(f_\theta(I \,\|\, q)), \qquad e_d = \mathrm{norm}(f_\theta(d))$$

$$\mathrm{sim}(q, d) = e_q^\top e_d = \cos(e_q, e_d)$$

- Vector 768 chiều; pooling token `[CLS]` rồi L2-normalize.
- I: instruction tìm kiếm cho query; tài liệu không thêm instruction.
- Tính trước vector tài liệu; mỗi query chỉ cần encode một lần.

Nguồn: src/stage3_neural.py; models/bge_pretrained/1_Pooling/config.json

BGE: token tương tác qua self-attention

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right) V$$

- H: biểu diễn token. M: attention mask cho padding.
- Các lớp attention và feed-forward tạo biểu diễn có ngữ cảnh.
- BGE lấy hidden state `[CLS]` làm vector, sau đó L2-normalize.

Nguồn: models/bge_pretrained/config.json; src/stage3_neural.py

Fine-tuning: học từ Title và Abstract

Pseudo-query: Title; **positive:** Abstract tương ứng.

Split	Số cặp	Vai trò
Train	10.921	Cập nhật trọng số
Validation	1.361	Chọn checkpoint
Test	1.368	Đánh giá cuối

- Chia theo `split_group_id`; không có nhóm đã biết đi qua nhiều split.
- Title–Abstract là supervision thay thế, chưa có nhãn query tự nhiên.

Nguồn: outputs/reports/stage3/split_audit.json; configs/stage3.yaml

Fine-tuning: contrastive loss đối xứng

$$s_{ij} = \frac{e_{q_i}^{\top} e_{d_j}}{\tau}, \qquad \tau = 0{,}05$$

$$\mathcal{L} = -\frac{1}{2B} \sum_{i=1}^{B} \left[\log \frac{e^{s_{ii}}}{\sum_j e^{s_{ij}}} + \log \frac{e^{s_{ii}}}{\sum_j e^{s_{ji}}} \right]$$

- Đường chéo (i, i) là positive; các cặp khác trong batch là negative ứng viên.
- Cùng nhóm hoặc Title Jaccard $\geq 0{,}8$: logit được gán -10^4.
- Mục đích: kéo cặp đúng gần nhau, giảm nhầm lẫn với các cặp khác.

Nguồn: src/stage3_neural.py::false_negative_mask, train

False negatives: cơ chế mask và kết quả thực tế

- In-batch negatives chỉ lấy các Abstract khác trong cùng batch.
- Mask nếu cùng nhóm hoặc Title Jaccard $\geq 0{,}8$.
- Artifact run ghi `masked_pairs = 0`.
- Vì vậy, kết quả hiện có chưa đo được lợi ích thực nghiệm của mask.
- Evaluator chấp nhận nhiều positives cùng nhóm, loss dùng positive đường chéo.

Nguồn: models/bert_finetuned/training_success.json; src/stage3_neural.py

Fine-tuning: cập nhật gì, lưu lại gì?

- Chỉ mở **block encoder cuối**; các tham số còn lại đóng băng.
- 1 epoch; batch 8; AdamW; learning rate 2×10^{-5}.
- Weight decay 0,01; warm-up 10%; gradient norm tối đa 1.
- Đánh giá mỗi 250 steps; chọn checkpoint bằng validation group MRR@10.
- Lưu weights, lịch sử loss, validation, test metrics và embeddings 13.702×768.

Nguồn: configs/stage3.yaml; src/stage3_neural.py::train, embed

AdamW cập nhật trọng số block cuối

$$g_t = \nabla_\theta \mathcal{L}, \qquad g_t \leftarrow g_t \min\left(1, \frac{1}{\|g_t\|_2 + \varepsilon}\right)$$

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

$$\theta_t = (1 - \eta_t \lambda)\theta_{t-1} - \eta_t \frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \varepsilon}$$

$\widehat{m}, \widehat{v}$: bias correction. $\lambda = 0{,}01$, learning rate cực đại 2×10^{-5}. Warm-up 10% rồi giảm tuyến tính. Các tham số frozen giữ nguyên.

Nguồn: src/stage3_neural.py::train; torch.optim.AdamW

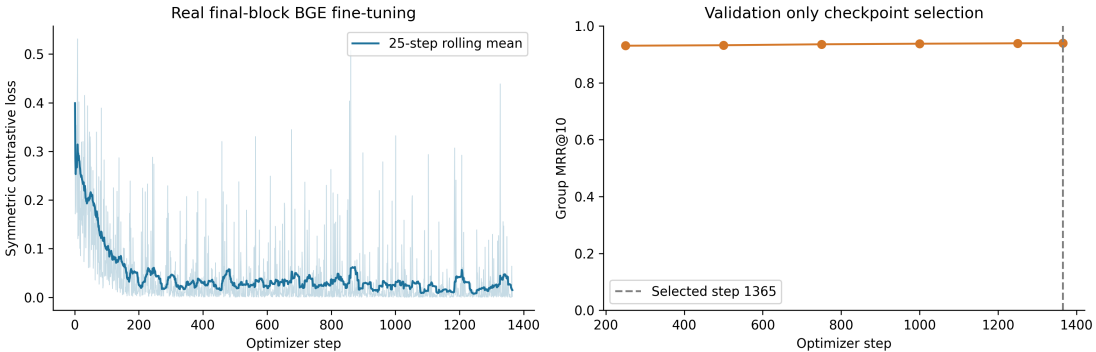
Bằng chứng cập nhật trọng số của phiên huấn luyện

Hạng mục	Giá trị đã lưu
Tổng tham số	109.482.240
Tham số trainable	7.087.872 (6.47%)
Optimizer steps / best checkpoint	1.365 / 1.365
$\|\|\theta_{selected} - \theta_{initial}\|\|_2$	2.396392
Hash tham số frozen trước / sau	Giống nhau
Test tham gia chọn checkpoint	False

Các giá trị lấy từ training_success.json, không chạy lại huấn luyện.

Nguồn: models/bert_finetuned/training_success.json

Loss huấn luyện và chọn checkpoint bằng validation



Loss giảm trong run đã lưu. Chọn step 1.365 bằng group MRR@10 trên validation, không dùng test.

Nguồn: outputs/figures/stage3/bert_01_training.png

Kết quả fine-tuning trên proxy test

Chỉ số	Pretrained	Fine-tuned	Δ
Group MRR@10	0,8936	0,9281	+0,0345
Group Success@1	0,8596	0,8991	+0,0395
Group Success@5	0,9371	0,9671	+0,0300
Group Success@10	0,9576	0,9817	+0,0241

- 1.368 Title queries; candidates trong cùng split test.
- Success@*k*: có ít nhất một Abstract đúng nhóm ở Top-*k*.
- Kết quả hỗ trợ proxy Title→Abstract; chưa xác nhận relevance query tự nhiên.

Nguồn: outputs/reports/stage3/{pretrained,finetuned}_test_metrics.json

BERTopic: định nghĩa và chuỗi thành phần

$$\underbrace{E \in \mathbb{R}^{13\,702\times 768}}_{\text{BGE fine-tuned}} \xrightarrow{\text{UMAP}} Y \in \mathbb{R}^{13\,702\times 5} \xrightarrow{\text{HDBSCAN}} \text{clusters} \xrightarrow{\text{c-TF-IDF}} \text{keywords}$$

- **UMAP:** giảm chiều để hỗ trợ biểu diễn cấu trúc lân cận.
- **HDBSCAN:** phân cụm mật độ; cho phép tài liệu là noise.
- **c-TF-IDF:** tìm từ nổi bật của từng cụm để mô tả topic.
- Số topic do clustering tạo ra; không đặt trước *K* như LDA.

Nguồn: src/stage3_topics.py::fit; src/stage3_bertopic_model.py

BERTopic: tham số, đầu ra và ý nghĩa

- UMAP: neighbors 15, components 5, min_dist 0, cosine, seed 42.
- HDBSCAN: min_cluster_size 30, min_samples 10, chọn cụm bằng eom.
- Baseline seed 42: **92 topics**; 2.751 outliers, khoảng 20,08%.
- Đầu ra: topic_id, membership strength, Top10 keywords, tài liệu đại diện.
- Topic -1 là noise; membership không phải độ đúng hay relevance.

Nguồn: configs/stage3.yaml; outputs/reports/stage3/bertopic_metrics.json

Output BERTopic baseline: ba cụm lớn nhất

Topic 0 (1.219 tài liệu)
P2; O3; O2; O-; type; Na2; P3; redox; Ni1; anionic

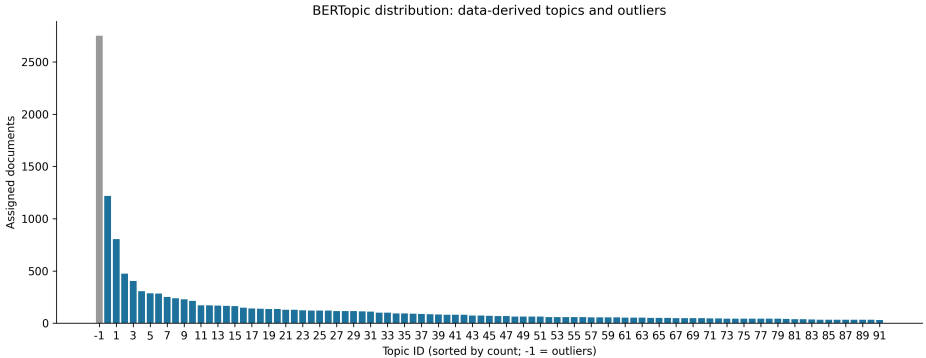
Topic 1 (804 tài liệu)
hard_carbon; biomass; carbonize; asphalt; crush; wash; resin; coal; carbonization; phenolic

Topic 2 (474 tài liệu)
layered_oxide; formula; ozone; manganese; element; manganese-based; new; nickel; magnesium; useful

ID chỉ có ý nghĩa trong cùng model. Các từ bên dưới là output gốc.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

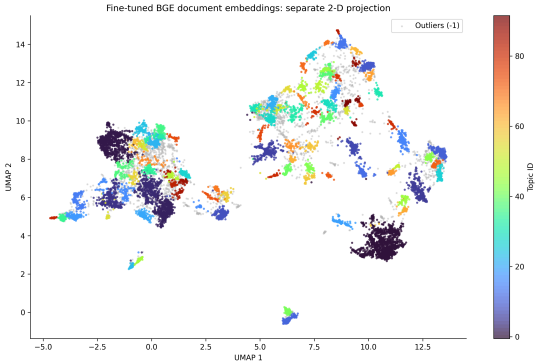
Phân bố cụm BERTopic baseline và noise



92 topics và 2.751 outliers. Topic -1 gom noise, không đại diện một chủ đề chuyên môn thống nhất.

Nguồn: outputs/figures/stage3/bertopic_01_distribution.png

Biểu diễn 2D của BERTopic baseline



Hình để quan sát cấu trúc. Clustering thực tế dùng UMAP 5D, không dùng trực tiếp tọa độ trên hình.

Nguồn: outputs/figures/stage3/bertopic_04_umap_2d.png

Chunking: bao phủ phần cuối Abstract

$$v_d = \text{norm}\left(\frac{1}{m}\sum_{j=1}^{m}\text{norm}(f_\theta(c_j))\right)$$

- Baseline dùng ngân sách 128 tokens; nhánh chunked dùng cặp Title–cửa sổ Abstract.
- Ngân sách **256 tokens/cặp**, gồm Title và special tokens; overlap 64.
- 29.139 chunks $\rightarrow$ một vector 768 chiều cho mỗi tài liệu.
- Bao phủ 100% Abstract WordPiece có sẵn; không đồng nghĩa có toàn văn.

Nguồn: src/bertopic_chunked.py::chunk_document, encode_features, embed

Output BERTopic chunked: ba cụm lớn nhất

Topic 0 (1.158 tài liệu)
P2; O3; O2; O-; type; P3; Na2; redox; Ni1; anionic

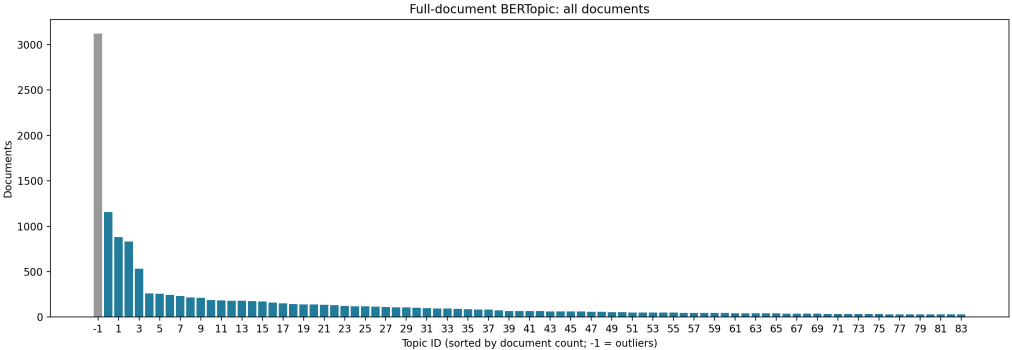
Topic 1 (882 tài liệu)
manganese; layered_oxide; formula; nickel; element; sinter; positive; ternary; precursor; magnesium

Topic 2 (834 tài liệu)
hard_carbon; biomass; carbonize; asphalt; resin; crush; wash; coal; carbonization; phenolic

ID chỉ có ý nghĩa trong cùng model. Các từ bên dưới là output gốc.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

Phân bố 84 topics của nhánh chunked



Nhánh chunked có 3.120 outliers. Topic ID được tạo lại, không đồng nhất trực tiếp với baseline.

Nguồn: outputs/bertopic_chunked/figures/topic_distribution.png

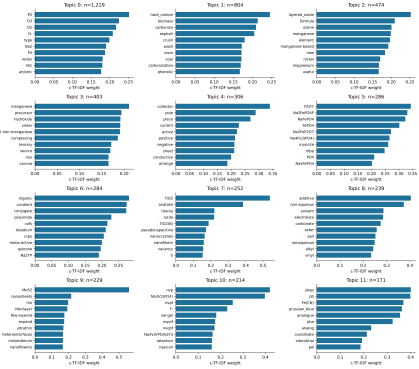
Kết quả BERTopic: có sự đánh đổi

Chỉ số	Baseline 128	Chunked 256
Topics	92	84
Outlier rate	20,08%	22,77%
C_v	0,4628	0,4779
U_Mass	-9,2563	-9,0806
Diversity	0,8587	0,8786

- Coherence/diversity tăng nhưng noise tăng 369 tài liệu.
- Coverage, Title context và pooling cùng thay đổi; chưa tách được tác động riêng.

Nguồn: outputs/bertopic_chunked/comparison.csv

Từ khóa và trọng số của các topic BERTopic



Các từ khóa theo c-TF-IDF của baseline. Phụ lục có đủ 92 IDs và bảng 84 IDs chunked.

Nguồn: outputs/figures/stage3/bertopic_02_keywords.png

Search liên hệ với các mô hình trước ra sao?

Thành phần	Nhánh nghiên cứu	Search mặc định
Corpus Stage 1	Dữ liệu dùng chung	Tái sử dụng
LDA / BERTopic	Khám phá chủ đề	Không cộng vào điểm
BGE pretrained	Baseline biểu diễn	Dùng để dense search
BGE fine-tuned / chunked	Đối chứng đã lưu	Chọn được để so sánh
MiniLM cross-encoder	Model công khai	Rerank ứng viên

Xây lớp truy hồi trên dữ liệu/model có sẵn; không huấn luyện mọi thứ lại từ đầu.

Nguồn: src/search_v2.py::_matrix, encode; configs/search_v2.json

Mỗi mô hình tạo bao nhiêu topic?

Thành phần	Đầu ra	Số topic
LDA K=20	Document–topic + topic–word	20
BERTopic baseline, seed 42	Cluster ID + keywords	92
BERTopic chunked, seed 42	Cluster ID + keywords	84
BGE pretrained / fine-tuned	Vector 768 chiều	Không tạo topic
BM25 / RRF / MiniLM	Điểm và danh sách xếp hạng	Không tạo topic

Noise -1 không nằm trong 92/84 topics. Seed BERTopic 123 của baseline cho 82 topics.

Nguồn: outputs/reports/stage3/bertopic_metrics.json; outputs/bertopic_chunked/metrics.json

Xây chỉ mục Search V2 trước khi truy vấn

- Corpus $\rightarrow$ lexical tokens riêng cho Title và Abstract.
- Khởi tạo hai `BM25Okapi`: tần suất, IDF và độ dài từng field.
- Nạp dense matrix pretrained 13.702×768 đã chuẩn hóa.
- Kiểm tra hash, kích thước, giá trị hữu hạn, norm và thứ tự doc_id.
- Exact matrix scan; backend mặc định không cần Qdrant/ANN.

Nguồn: src/search_v2.py::_load_lexical, _matrix; configs/search_v2.json

Mười phương pháp Search V2 có thể chọn

Nhóm	Các phương pháp
Lexical	`BM25_CHEMICAL`
Dense	PRETRAINED, FINETUNED, CHUNKED
Hybrid (RRF)	PRETRAINED, FINETUNED, CHUNKED
Rerank	PRETRAINED, FINETUNED, CHUNKED

- Các tên dense/hybrid/rerank là kết hợp nhóm với hậu tố biểu diễn.
- Mặc định: `RERANK_PRETRAINED`.
- 14 methods ở evaluator gồm thêm bốn đối chứng lịch sử, không phải 14 backend mới.

Nguồn: src/search_v2.py::METHODS; configs/search_v2.json

BM25: định nghĩa và công thức thực tế

$$B_F(q,d) = \sum_{t \in q} \mathrm{IDF}_F(t) \frac{f(t,F)(k_1+1)}{f(t,F) + k_1\left(1 - b + b\frac{|F|}{\overline{|F|}}\right)}$$

$$s_{\mathrm{lex}}(q,d) = 2\max(B_{\mathrm{Title}}, 0) + \max(B_{\mathrm{Abstract}}, 0)$$

- f: tần suất token; $|F|$: độ dài field; $\overline{|F|}$: độ dài trung bình.
- $k_1 = 1{,}5$: bão hòa tần suất; $b = 0{,}75$: hiệu chỉnh độ dài.
- Title trọng số 2; giữ tín hiệu từ và công thức cụ thể.

Nguồn: src/search_v2.py::lexical; rank_bm25.py::BM25Okapi

Query được chuẩn hóa và lọc thế nào?

- Chuẩn hóa Unicode NFKC, HTML entities, dấu gạch và khoảng trắng.
- Token từ thường qua stemming; chuỗi giống công thức nhận prefix `chem:`.
- Source/year và required terms tạo tập hợp lệ **trước Top-K**.
- Required terms phân cách bằng dấu `;` mang nghĩa AND trên Title/Abstract.
- Query neural vượt 128 tokens, tính cả prefix/special tokens, bị từ chối.

Nguồn: src/search_v2.py::normalize, lexical_tokens, allowed, encode; src/search_v2_constraints.py

Dense retrieval và RRF

$$s_{\text{dense}} = E e_q, \qquad E \in \mathbb{R}^{13\,702 \times 768}$$

$$s_{\text{RRF}}(d) = \sum_{j:\, d \in L_j} \frac{1}{60 + \text{rank}_j(d)}$$

- Mỗi nhánh BM25/dense lấy Top100 trong tập hợp lệ; hợp tối đa 200 tài liệu.
- RRF dùng hạng bắt đầu từ 1, tránh cộng điểm khác thang đo.
- Hybrid/rerank trả rỗng nếu không có lexical support: một heuristic bảo thủ.

Nguồn: src/search_v2.py::dense, reciprocal_rank_fusion, rank

MiniLM reranker: cross-encoder

$$s(q,p) = g_\psi([q;p]), \qquad s(q,d) = \max_{p \in P_d} s(q,p)$$

- Model: `cross-encoder/ms-marco-MiniLM-L6-v2`.
- Nhận đồng thời query và passage để so sánh chi tiết hơn bi-encoder.
- Lấy Top50 sau RRF; tối đa 2 passages/tài liệu; lấy điểm lớn nhất.
- Model công khai chạy cục bộ; không fine-tune riêng cho hóa học trong bài.

Nguồn: src/search_v2.py::_load_reranker, rerank

Chọn passage: ngân sách và giới hạn

- Quét Abstract theo cửa sổ yêu cầu 320 tokens, overlap 64.
- Ưu tiên cửa sổ có lexical overlap với query; lấy tối đa 2.
- Title tối đa 80; query tối đa 128; toàn cặp tối đa 512 tokens.
- Lưu offset đoạn trích trong Abstract đã chuẩn hóa để kiểm tra.
- Reranker không cứu được tài liệu mất trước Top50 hoặc evidence không được chọn.

Nguồn: src/search_v2.py::select_passages; configs/search_v2.json

Luồng online và kết quả trả về

1. Nhận query, source, year range, required terms và method.
2. Kiểm tra đầu vào; tạo tập hợp lệ.
3. BM25 Top100 và dense Top100 → RRF.
4. Top50 → passages → MiniLM → Top5.
5. Trả Title, Abstract, metadata, score, passage và tải CSV.

Đây là hệ thống trả tài liệu; không có bước LLM sinh câu trả lời trong luồng search.

Nguồn: src/search_v2.py::search; src/search_v2_service.py; app.py

Query Q19: Top5 thực tế của RERANK_PRETRAINED

Aqueous sodium-ion batteries with water-in-salt electrolytes

Hạng	Title (rút gọn để hiển thị)	Score
1	Fluorine-Free Water-in-Salt Electrolyte for Green and Low-Cost Aqueous Sodium-Ion Batteries	9.818
2	High-Energy Aqueous Sodium-Ion Batteries	9.336
3	Halide-free water-in-salt electrolytes for stable aqueous sodium-ion batteries	9.304
4	Synthesis and Application of an Aromatic Sulfonate Sodium Salt for Aqueous Sodium-Ion Battery El...	9.203
5	A High-Voltage Aqueous Electrolyte for Sodium-Ion Batteries	9.139

Score chỉ dùng xếp hạng trong method. Đây là kết quả đã lưu, chưa có grade độc lập.

Nguồn: outputs/search_upgrade_20261018/query_runs/Q19.json

Q19: passage để người dùng kiểm tra bằng chứng

Fluorine-Free Water-in-Salt Electrolyte for Green and Low-Cost Aqueous Sodium-Ion Batteries

> *The highly concentrated ”water-in-salt” electrolyte (WiSE) containing sodium acetate and potassium acetate demonstrates surprising performance (specific capacity of 37 mA h(-1) g(-1) at the 5th cycle and average discharge voltage of 0.82 V) in aqueous sodium-ion batteries (SIBs) based on Na2MnFe(CN)(6) and NaTi2(PO4)(3). The fluorine-free electrolyte offers a wide electrochemical stability window and compatibility with Al current collector. The electrolyte, current collector, and the electrode materials based on abundant elements make the proposed battery chemistry safe, low-cost, and environmentally friendly.*

Trích liên tục từ passage của hạng 1, rút gọn phần cuối. Offset ánh xạ về Abstract đã chuẩn hóa. Người dùng cần đọc toàn Abstract và tài liệu gốc.

Nguồn: outputs/search_upgrade_20261018/query_runs/Q19.json

Đánh giá phải đúng với từng đầu ra

Đầu ra	Đánh giá trong bài
Chủ đề	Coherence, diversity, stability, outlier
Title *o* Abstract	Group MRR / Success theo split
Top5 theo query miền	P@5, nDCG@5, MRR@5 khi đủ labels
Query AI *o* source ID	Hit@k / MRR: proxy source recovery
Code và thời gian	Tests kỹ thuật, timing, rank/score guards

Topic coherence, tests và source recovery không thay nhãn relevance độc lập.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 8; src/research_evaluation.py

Công thức đánh giá Top5

$$P@5 = \frac{\sum_{r=1}^{5} \mathbf{1}[g_r \geq 2]}{5}, \qquad RR@5 = \begin{cases} 1/r^*, & r^* \leq 5 \\ 0, & \text{không có relevant} \end{cases}$$

$$DCG@5 = \sum_{r=1}^{5} \frac{2^{g_r} - 1}{\log_2(r+1)}, \qquad nDCG@5 = \frac{DCG@5}{IDCG@5}$$

- Grade $g \in \{0, 1, 2, 3\}$; r^* là hạng relevant đầu tiên; MRR là trung bình RR.
- IDCG lấy thứ tự lý tưởng từ pool chung; IDCG = 0 thì nDCG = 0.
- Thiếu kết quả vẫn chia 5 cho P@5; thiếu nhãn không tự xem là grade 0.

Nguồn: src/research_evaluation.py::metrics_at_5, evaluate_frames

Rubric relevance và bằng chứng cần chấm

Grade	Ý nghĩa theo rubric đang dùng
0	Ngoài intent hoặc mâu thuẫn một yêu cầu bắt buộc
1	Liên quan một phần / nền tảng, thiếu đặc điểm chính
2	Đáp ứng intent chính có bằng chứng, còn thiếu chi tiết
3	Đáp ứng đầy đủ intent và các quan hệ được yêu cầu
UNRESOLVED	Title/Abstract chưa đủ để đánh giá có cơ sở

- Các trục: hệ pin, vật liệu/công thức, điều kiện và quan hệ kỹ thuật.
- Code kiểm tra trích dẫn có thật trong văn bản. Việc diễn giải vẫn cần review.

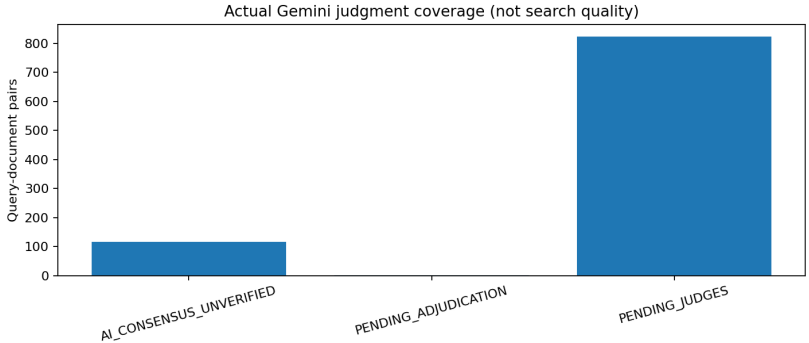
Nguồn: src/ai_judge.py::RUBRIC, validate_judgment; src/research_evaluation.py

Nhãn relevance độc lập: hiện chưa hoàn tất

- Benchmark V2: 24 queries, gồm 23 query miền và 1 synthetic OOV.
- 10 methods ở benchmark V2; evaluator mở rộng 14 methods.
- Pool chung: **942 cặp query–document**.
- Hai biểu mẫu annotator A/B: **0/942 grade được điền** ở mỗi bảng.
- Vì vậy chưa có P@5, nDCG@5, MRR@5 chính thức từ nhãn độc lập.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 8.2; outputs/search_upgrade_20261018/

Mức hoàn thành của bộ nhãn AI



AI consensus số: 116/942 cặp. Chỉ 2/23 query đủ pool. Hai biểu mẫu nhãn độc lập vẫn trống.

Nguồn: outputs/retrieval_ai_evaluation_v1/judgment_coverage.png

AI relevance: kết quả từng phần

- 116/942 cặp có consensus số; chỉ **2/23 queries** đủ nhãn toàn pool.
- Trên 2 queries này, RERANK_PRETRAINED: P@5 = 0,8000; nDCG@5 = 0,8812.
- Cùng model Gemini chấm hai lượt; không phải hai chuyên gia độc lập.
- Job ghi nhận HTTP 429 / hết quota; phần thiếu chưa được chấm.
- Chỉ dùng để chẩn đoán phần đã có; chưa đủ chọn method thắng.

Nguồn: outputs/retrieval_ai_evaluation_v1/REPORT.md; docs/FINAL_RESEARCH_REPORT.md, mục 8.3

Source recovery: một proxy khác

Method	Hit@5	MRR@10
BM25_CHEMICAL	0,8071	0,7080
DENSE_PRETRAINED	0,8528	0,7600
DENSE_FINETUNED	0,8782	0,8066
DENSE_CHUNKED	0,8934	0,8436
RERANK_PRETRAINED	0,8579	0,7651

- 197/200 query hợp lệ, sinh từ Abstract để tìm lại đúng source doc_id.
- 163/197 source thuộc train cũ; chưa độc lập với tài liệu fine-tuning.
- Không dùng kết quả này để khẳng định relevance chuyên gia hoặc Recall toàn corpus.

Nguồn: outputs/retrieval_ai_evaluation_v1/synthetic/summary.csv; docs/FINAL_RESEARCH_REPORT.md, mục 8.4

Phân tích lỗi từ truy vấn thực tế

- **Q08 – NaFSI, ether, nhiệt độ thấp:** có kết quả mới đáp ứng một phần điều kiện.
- **Q19 – aqueous, water-in-salt:** có tài liệu điện giải 0,5 m chưa đủ evidence water-in-salt.
- **Q23 – Na2FeP2O7:** có công thức chưa bảo đảm đúng vai trò vật liệu.
- Cần tách lỗi: mất ứng viên, chọn sai passage, sai rerank, thiếu evidence trong Abstract.

Nguồn: docs/SEARCH_RESULTS_REVIEW.md; docs/FINAL_RESEARCH_REPORT.md, mục 8.5

Tối ưu kỹ thuật đã có bằng chứng

- Top-K kernel: thời gian mới/cũ = 0,05300 trên tập final đã lưu.
- Required-term filter kernel: thời gian mới/cũ = 0,15760.
- Lưới CPU đã thử: 4 threads, reranker batch 4 tốt nhất quan sát.
- Median warm 4,506 giây/request: 3 dev queries, 2 lượt/query ở cấu hình này.
- Runtime snapshot ghi 311 tests pass; đó là kết quả đã lưu, không phải relevance.

Nguồn: docs/MATH_AND_OPTIMIZATION_REVIEW.md; outputs/search_runtime_optimization_20261019/verification.json

Độ trễ đo được và giới hạn vận hành

- Lưới CPU: threads $\{1, 2, 4\}$ và batch $\{4, 8, 16\}$.
- 3 development queries, 2 repetitions, tổng 54 requests được đo.
- Giữ 4 threads / batch 4, median warm 4,506 giây/request.
- Có spike 839,663 giây ở một cấu hình khác, vẫn giữ trong raw data.
- Một worker tuần tự hóa tác vụ. Chưa có benchmark concurrency/p95 đại diện.

Nguồn: outputs/math_optimization_20261019/execution_dev/summary.json; src/search_v2_service.py

Cải thiện tiếp theo và cách kiểm chứng

1. **Nhãn độc lập:** hai người chấm, evidence, consensus; query families mới.
2. **Định vị lỗi:** candidate Top100/50, passage coverage, rerank và điều kiện.
3. **Ablation:** passage retrieval, selector và pooling ở cùng ngân sách.
4. **Fine-tuning theo relevance:** multi-positive và negatives đã kiểm tra.
5. **Vận hành:** warm/cold, RAM, concurrency; đo quality/latency cùng lúc.

Đây là **đề xuất**, chưa phải các cải tiến đã được chứng minh trong dự án.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 10–11

Kết quả và giới hạn của bài

- Đã tích hợp corpus 13.702 tài liệu với provenance và nhiều biểu diễn.
- LDA/BERTopic tạo đầu ra khám phá; BGE fine-tuning cải thiện proxy đã đo.
- Search V2 kết hợp lexical, dense và rerank, trả passage để đọc kiểm tra.
- Có kiểm chứng code và tối ưu thành phần; chưa xác lập relevance độc lập.
- Giá trị hiện tại: hỗ trợ tìm ứng viên trong corpus và phân tích chủ đề.

Nguồn: README.md; docs/FINAL_RESEARCH_REPORT.md, mục 12

Bản đồ mô hình, input và output

Thành phần	Input	Output
LDA	BOW	Topic–word; document–topic
BGE	Văn bản tokenized	Vector CLS 768 chiều
UMAP	Embeddings 768 chiều	Điểm 5 chiều cho clustering
HDBSCAN	Điểm UMAP 5 chiều	Cluster ID / noise; strength
c-TF-IDF	Counts gộp theo cluster	Trọng số từ / keywords
BM25	Query tokens; corpus stats	Điểm lexical từng tài liệu
RRF	Các danh sách xếp hạng	Danh sách hợp nhất
MiniLM	Cặp query–passage	Scalar score

Nguồn: src/stage2.py; src/stage3_topics.py; src/search_v2.py

LDA: quá trình sinh và suy luận

$$\phi_k \sim \text{Dir}(\eta), \quad \theta_d \sim \text{Dir}(\alpha), \quad z_{dn} \sim \text{Cat}(\theta_d), \quad w_{dn} \sim \text{Cat}(\phi_{z_{dn}})$$

- Biến ẩn z_{dn} biểu diễn topic của token thứ n trong tài liệu d.
- Quan sát BOW, suy luận các phân phối topic thay vì biết trước nhãn.
- Dự án gọi Gensim `LdaModel`; không tự triển khai Gibbs sampling.
- $H(d) = -\sum_k \theta_{dk} \log \theta_{dk}$: entropy của phân phối topic.

Nguồn: src/stage2.py::_fit_lda, export_topics

Chọn LDA K và đo topic stability

$$S_K = 0{,}50\widetilde{C_v} + 0{,}15\widetilde{U_{Mass}} + 0{,}15D + 0{,}20T$$

$$D = \frac{|\bigcup_{k=1}^{K} W_k|}{10K}, \quad J(A,B) = \frac{|A \cap B|}{|A \cup B|}, \quad T = \frac{1}{K}\max_{\pi}\sum_{k} J(W_k, W'_{\pi(k)})$$

- W_k: Top10 từ; Hungarian matching tìm ghép topic tốt nhất giữa seeds.
- Chỉ Top2 theo C_v được chạy thêm seeds; chọn $K = 20$ trong protocol này.
- Min–max phụ thuộc tập ứng viên; stability LDA tổng hợp qua các cặp seed.

Nguồn: src/stage2.py::match_stability, main; configs/stage2.yaml

c-TF-IDF đúng với cấu hình đang dùng

$$x_{ct} = \sum_{d \in c} \text{count}(t, d), \quad u_{ct} = \frac{x_{ct}}{\sum_v x_{cv}}$$

$$F_t = \sum_c x_{ct}, \quad A = \left\lfloor \text{mean}_c \sum_t x_{ct} \right\rfloor, \quad w_{ct} = \sqrt{u_{ct}} \log\left(1 + \frac{A}{F_t}\right)$$

- Gộp tokens theo cluster; L1-normalize counts trước tính trọng số.
- Có căn bậc hai vì `reduce_frequent_words=True`.
- F_t là tổng số lần xuất hiện qua các lớp, không phải document frequency thông thường.

Nguồn: src/stage3_topics.py::fit; bertopic/vectorizers/_ctfidf.py::fit, transform

UMAP và HDBSCAN: khái niệm toán học

$$d_{\cos}(u, v) = 1 - \frac{u^\top v}{\|u\|\|v\|}$$

$$d_{\mathrm{mr}}(a, b) = \max\{\mathrm{core}_k(a), \mathrm{core}_k(b), \|a - b\|_2\}$$

- UMAP dùng cosine ở không gian embedding và xây biểu diễn lân cận 5 chiều.
- HDBSCAN dùng Euclidean ở không gian đã giảm chiều; mutual reachability hỗ trợ cây mật độ.
- EOM chọn cụm theo độ bền trong cây; điểm không thuộc cụm nhận -1.
- Phần tối ưu nội bộ do thư viện thực hiện; dự án không tự viết UMAP/HDBSCAN.

Nguồn: src/stage3_topics.py::fit; configs/stage3.yaml

BM25 IDF: biến thể thư viện đang cài

$$a_t = \log \frac{N - n_t + 0{,}5}{n_t + 0{,}5}, \quad \overline{a} = \text{mean}_{v \in V}\, a_v$$

$$\text{IDF}(t) = \begin{cases} a_t, & a_t \geq 0 \\ 0{,}25\overline{a}, & a_t < 0 \end{cases}$$

- N: số tài liệu của field; n_t: số tài liệu chứa token t.
- Tính riêng cho Title và Abstract; sau đó clipping field score về không âm.
- Không thay bằng công thức IDF khác khi giải thích kết quả hiện hành.

Nguồn: rank_bm25.py::BM25Okapi._calc_idf; src/search_v2.py::lexical

RRF: ví dụ tính tay minh họa

Tài liệu	Hạng BM25	Hạng dense	RRF với k=60
A	1	3	$1/61 + 1/63 \approx 0{,}03227$
B	2	1	$1/62 + 1/61 \approx 0{,}03252$
C	–	2	$1/62 \approx 0{,}01613$

- B đứng trước A nhờ thứ hạng tốt ở cả hai nhánh.
- Tài liệu vắng một danh sách không có đóng góp ở danh sách đó.
- **Ví dụ minh họa công thức**, không phải kết quả chạy query trong dự án.

Nguồn: src/search_v2.py::reciprocal_rank_fusion

Đánh giá Top5: ví dụ tính tay minh họa

Giả sử grades theo hạng là $[3, 0, 2, 1, 0]$, pool chung cũng có grades này.

$$P@5 = 2/5 = 0{,}4, \qquad RR@5 = 1$$

$$DCG = 7 + \frac{3}{\log_2 4} + \frac{1}{\log_2 5} \approx 8{,}9307$$

$$IDCG = 7 + \frac{3}{\log_2 3} + \frac{1}{\log_2 4} \approx 9{,}3928, \quad nDCG \approx 0{,}9508$$

Ví dụ minh họa, không phải nhãn hoặc metric thực nghiệm của bài.

Nguồn: src/research_evaluation.py::metrics_at_5

Success, Recall và source recovery khác gì?

$$\text{Success}@k = \mathbf{1}[R_q \cap \text{Top}_k(q) \neq \varnothing]$$

$$\text{Recall}@k = \frac{|R_q \cap \text{Top}_k(q)|}{|R_q|}$$

- Có 3 relevant, tìm được 1: Success = 1 nhưng Recall = $1/3$.
- Proxy group Success chỉ cần một Abstract cùng nhóm trong Top-*k*.
- Source recovery chỉ tìm đúng doc_id nguồn; relevant khác vẫn có thể bị tính miss.
- Không có danh sách relevant đầy đủ thì không khẳng định Recall toàn corpus.

Nguồn: docs/MATH_AND_OPTIMIZATION_REVIEW.md; src/research_evaluation.py

Bootstrap và độ tin cậy của kết quả

$$\widehat{\Delta} = \frac{1}{Q}\sum_{q}(m_{Aq} - m_{Bq})$$

$$CI_{95\%} = [\text{percentile}_{2{,}5}(\Delta^*), \text{percentile}_{97{,}5}(\Delta^*)]$$

- Paired bootstrap: hai methods dùng cùng các query được resample.
- Proxy dùng cluster bootstrap theo split_group_id; 2.000 repetitions.
- Cluster proxy tính trung bình theo tài liệu, không cân bằng từng nhóm.
- CI giữ cố định model và labels; không bao gồm mọi training/annotation uncertainty.

Nguồn: src/research_evaluation.py::paired_bootstrap, paired_cluster_bootstrap

Câu hỏi bảo vệ: vì sao không dùng mọi model?

- **LDA/BERTopic có làm search tốt hơn không?** Chưa kiểm chứng; code không cộng topic bonus.
- **Fine-tuned tốt hơn sao không làm mặc định?** Mới thắng proxy; chưa có relevance độc lập.
- **Vì sao BM25 cùng dense?** Hai tín hiệu bổ sung: token cụ thể và diễn đạt gần nghĩa.
- **Vì sao thêm reranker?** Chấm cặp chi tiết sau truy hồi, đổi lại tăng chi phí.

Nguồn: configs/search_v2.json; docs/FINAL_RESEARCH_REPORT.md, mục 5 và 7

Câu hỏi bảo vệ: hỏi gì về kết quả trả về?

- **Score có phải độ tin cậy không?** Không; score phụ thuộc từng method.
- **Passage có chứng minh query đúng không?** Chỉ là đoạn ứng viên để đọc kiểm tra.
- **Có dịch query tiếng Việt không?** Không có bước dịch trong luồng mặc định.
- **Có sinh câu trả lời bằng LLM không?** Search trả tài liệu; AI dùng ở nhánh đánh giá.
- **Có luôn đủ 5 kết quả không?** Không; filters/gate có thể làm ít hoặc rỗng.

Nguồn: src/search_v2.py::rank, search; src/search_v2_constraints.py; app.py

Hạn chế dữ liệu và tái lập

- Nhãn CORE/RELATED là heuristic; corpus có thể thiếu hoặc giữ tài liệu không phù hợp.
- Audit topic ghi 355 tài liệu/716 occurrences có placeholder kế thừa.
- Group split chỉ bảo vệ các liên kết đã biết; không bao quát mọi quan hệ semantic.
- Hash/model revision/config/ordered IDs giúp tránh dùng nhầm artifacts.
- Giữ baseline; thay preprocessing hoặc model phải tạo thí nghiệm có version mới.

Nguồn: docs/FINAL_RESEARCH_REPORT.md, mục 2.3; docs/MATH_AND_OPTIMIZATION_REVIEW.md

Đối chiếu slide với code

Nội dung	File / vị trí chính
Dữ liệu, tokens	pipeline.py; quality.py; text_processing.py
LDA / chọn K	stage2.py; configs/stage2.yaml
BGE / loss / checkpoint	stage3_neural.py; configs/stage3.yaml
BERTopic	stage3_topics.py; stage3_bertopic_model.py
Chunking / pooling	bertopic_chunked.py
Search / passages / RRF	search_v2.py; search_v2_constraints.py
Metrics / bootstrap	research_evaluation.py
Kết luận / hạn chế	docs/FINAL_RESEARCH_REPORT.md

Nguồn: Đường dẫn tương đối từ D:/daln; file Python ở src/ nếu không ghi khác

LDA K20: topic 0–5

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
0	162	carbon; composite; sulfide; volume; development
1	1.417	sodium; design; storage; energy; battery
2	143	carbon; porous; surface; particle; benefit
3	994	material; battery; anode; sodium_ion; cathode
4	12	coat; analysis; O3; hollow; carbon
5	54	layer; metal; P2; oxide; transition

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage2/topic_summary.csv

LDA K20: topic 6–11

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
6	5.207	capacity; cycle; high; performance; sodium_ion
7	2.004	solution; obtain; prepare; material; add
8	219	successfully; shell; core; plate; inner
9	527	hard_carbon; material; carbon; obtain; temperature
10	650	na-ion; phase; study; x-ray; electrochemical
11	146	na; cathode; redox; poor; dope

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage2/topic_summary.csv

LDA K20: topic 12–17

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
12	2	organic; polymer; membrane; separator; V2O5
13	9	graphene; composite; oxide; flexible; nanofibers
14	356	electrolyte; sodium; battery; sodium_ion; solid_electrolyte
15	53	device; electric; connect; vehicle; unit
16	176	battery; sodium_ion; model; expect; method
17	8	sheet; binder; conductive; slurry; agent

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage2/topic_summary.csv

LDA K20: topic 18–19

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
18	1.051	electrode; battery; positive; material; negative
19	512	sodium; source; material; iron; vanadium

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage2/topic_summary.csv

BERTopic baseline: topic 0–5

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
0	1.219	P2; O3; O2; O-; type
1	804	hard_carbon; biomass; carbonize; asphalt; crush
2	474	layered_oxide; formula; ozone; manganese; element
3	403	manganese; precursor; hydroxide; sinter; nickel-iron-manganese
4	306	collector; pole; piece; current; active
5	286	P2O7; Na2FePO4F; NaFePO4; FePO4; Na2FeP2O7

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 6–11

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
6	284	organic; covalent; conjugate; polyimide; cofs
7	252	TiO2; anatase; titania; rutile; TiO2(B)
8	239	additive; non-aqueous; solvent; electrolyte; carbonate
9	229	MoS2; nanosheets; mo; interlayer; few-layered
10	214	nvp; Na3V2(PO4); nvpf; F-; sol-gel
11	171	pbas; pb; Fe(CN); prussian_blue; analogue

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 12–17

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
12	170	Na2Ti3O7; nto; Na2Ti6O13; titanate; Li4Ti5O12
13	169	CoSe2; znse; NiSe2; selenides; Cu2Se
14	165	portion; module; terminal; pack; unit
15	164	V2O5; V2O3; NaV3O8; vanadate; VO2
16	149	slurry; binder; agglomerant; waste; adhesive
17	140	SnS2; sn; SnO2; cnts; heterostructures

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 18–23

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
18	137	plate; radiate; cover; connect; box
19	135	NaxCoO2; CoO2; superconducting; yh; superconductivity
20	135	positive; exclude; manganese; active; formula
21	129	heteroatom; nitrogen; mesoporous; co-doped; interlayer
22	127	selenide; selenium; diselenide; cobalt; selenizing
23	122	prussian_blue; ferrocyanide; prussian; white; soluble

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 24–29

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
24	121	antimony; bismuth; trichloride; trioxide; bismuth-carbon
25	121	FeS2; Fe7S8; fe; x; pyrite
26	121	nasicon; nmvp; Na4MnV(PO4); nasicon-type; Na3MnTi(PO4)
27	115	vanadium; fluorophosphate; phosphate; sodium-vanadium; vanadyl
28	115	hc; hard; ice; hard_carbon; region
29	115	SnO2; snsb; sno; sn; snox

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 30–35

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
30	112	biomass; hard; derive; hard_carbon; biomass-derived
31	110	Ti3C2Tx; mxene; mxenes; Ti3C2; mxene-based
32	101	adsorption; graphyne; atom; GDY-; graphene
33	100	sulfide; cobalt; disulfide; tin; sulfur
34	94	titanate; titanium; dioxide; titanic; sodium-iron-nickel-titanium
35	94	roller; frame; rotate; fixedly; plate

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 36–41

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
36	91	molybdenum; disulfide; molybdate; melanin; tungsten
37	89	silicon; particulate; negative; negative-electrode; silicon-carbon
38	86	Co9S8; CoS2; co; Co3S4; x
39	82	sn; ge; alloy; germanium; Zn2GeO4
40	81	peo; polymer; spe; gel; ionic
41	80	hexacyanoferrate; fehcf; NaMnHCF; cohcf; fe-hcf

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 42–47

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
42	80	Na3SbS4; all-phraseplaceholderi; Na3PS4; superionic; conductor
43	73	F-; Na3V2(PO4); O2F; nvpof; nvpf
44	73	Ni3S2; NiS2; ni; nisx; NiCo2S4
45	71	SO4; Na2FeSiO4; alluaudite; Na2+; nfs
46	69	prussian; prussian_blue; white; Fe(CN)6; ferromanganese-based
47	67	cop; fep; phosphides; Ni2P; phosphide

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 48–53

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
48	64	pyrophosphate; iron; phosphate; ferrous; ferric
49	63	cuo; Co3O4; Cu2O; NiCo2O4; mno
50	62	NaTi2(PO4); ntp; Gd3+; NaTi2V(PO4)4; NaTi2(PO4)3
51	62	mask; cnfs; nanofibers; bacterial; cellulose
52	58	tin; stannate; stannous; tin-carbon; dioxide
53	57	sb; Sb2O3; wtc; antimony; mcnt

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 54–59

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
54	57	diaphragm; ceramic; membrane; separator; film
55	57	red; rp; phosphorus; SeP2; GeP5
56	57	niobium; mat; titanium; titanium-based; active
57	56	polymer; polymerize; monomer; solid_electrolyte; filler
58	56	nzsp; Na3Zr2Si2PO12; glass; nasicon; Na2O
59	56	review; summarize; recent; sifcs; progress

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 60–65

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
60	55	graphene-embraced; graphene; laser-induced; graphene-encapsulated; three-dimensional
61	53	MoSe2; MoTe2; mosse; moxn; rgo-cnt
62	53	il; fsa; NaFSI; fsi; pc
63	52	FeF3; Fe2F5; feof; FeF2; FeF2.2(OH)
64	51	MoO2; MoO3; Mo2C; Mo2N; vg
65	51	NaTi2(PO4); ntp; aqueous; NaTiOPO4; nasicon-structured

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 66–71

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
66	50	fec; sei; interphase; additive; decomposition
67	49	red; phosphorus; phosphide; phosphorus-carbon; black
68	48	phosphorene; bp; monolayer; li; black
69	48	solid_electrolyte; zirconium; halide; conductor; super
70	47	FeSe2; fese; Fe3Se4; selenides; nc
71	46	Fe2O3; Fe3O4; alpha; fcmo; d-graphene

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 72–77

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
72	45	Na3V(PO4); Li3; xnaxv; PO4; Na3V2(PO4)
73	44	aqueous; asibs; water-in-salt; arsibs; window
74	44	hexafluorophosphate; difluorophosphate; imide; bisfluorosulfonimide; fluoride
75	44	mxene; carbide; carbide-mxene; titanium; dispersion
76	43	mofs; mof; metal-organic; framework; imidazolate
77	43	bi; bismuth; Bi2O3; biocl; bismuthene

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 78–83

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
78	42	Cu2S; cu; Cu9S5; CuSO4; cfss
79	42	Sn4P3; snxpy; snp; sbsn; oxide-stannic
80	40	VS4; VS2; V3S4; v-c; nanoblocks
81	39	separator; membrane; nonwoven; mca; cellulose
82	38	tank; shaft; drive; rod; barrel
83	36	pyrophosphate; ferric; sodium-iron-metal-phosphate-fluoride-metal; carbon-coated; iron

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 84–89

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
84	33	snse; SnSe2; se-c; sn-c; nanoplates
85	33	titanium; phosphate; micro-nano; carbon-coated; graphene-reinforced
86	33	vanadium; vanadium-based; magnesium-vanadium; Xn-; chlorophosphate
87	33	fluorophosphate; vanadium; vanadium-site; phosphate; sodium-vanadium
88	32	WS2; WTe2; WSe2; nrs; WO2
89	32	Nb2O5; Co2B2O5; NbOPO4; niobium; multishelled

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic baseline: topic 90–91

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
90	32	Bi2S3; Bi2Se3; Bi2Te3; Bi0.94Sb1.06S3; NaBiS2
91	31	Sb2S3; Sb2Se3; stibnite; Fe2S3; ncrs

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv

BERTopic chunked: topic 0–5

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
0	1.158	P2; O3; O2; O-; type
1	882	manganese; layered_oxide; formula; nickel; element
2	834	hard_carbon; biomass; carbonize; asphalt; resin
3	533	collector; diaphragm; slurry; pole; piece
4	263	MoS2; nanosheets; mo; interlayer; ultrathin
5	255	TiO2; anatase; titania; rutile; TiO2(B)

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 6–11

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
6	246	additive; non-aqueous; electrolyte; solvent; carbonate
7	234	covalent; organic; conjugate; cofs; redox-active
8	217	prussian_blue; ferrocyanide; prussian; white; analog
9	213	Na2FePO4F; NaFePO4; FePO4; P2O7; maricite
10	187	sei; il; ec; fec; NaPF6
11	185	pyrophosphate; iron; phosphate; ferric; ferrous

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 12–17

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
12	182	nvp; Na3V2(PO4); nvpf; sol-gel; nasicon
13	182	pb; Fe(CN); pbas; prussian_blue; analogue
14	175	vanadium; fluorophosphate; phosphate; sodium-vanadium; source
15	170	Na2Ti3O7; nto; Na2Ti6O13; titanate; Li4Ti5O12
16	161	CoSe2; znse; NiSe2; selenides; Cu2Se
17	151	antimony; bismuth; trichloride; trioxide; trisulfide

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 18–23

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
18	145	FeS2; Fe7S8; fe; x; CuFeS2
19	141	mxene; Ti3C2Tx; mxenes; Ti3C2; mxene-based
20	138	V2O5; V2O3; nh; NaV6O15; VO2
21	135	NaxCoO2; CoO2; superconducting; yh; superconductivity
22	133	SnS2; sn; snsb; snsx; SnO2
23	122	separator; membrane; polymer; peo; poly

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 24–29

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
24	120	hard; biomass; lignin; derive; hard_carbon
25	120	tin; stannous; pentahydrate; cloth; stannate
26	115	selenide; selenium; diselenide; cobalt; iron-cobalt
27	112	molybdenum; disulfide; molybdate; tungsten; diselenide
28	106	roller; frame; connect; rotate; fixedly
29	106	titanate; titanium; dioxide; titanic; titanate-based

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 30–35

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
30	104	plate; cover; radiate; box; clamp
31	100	hexacyanoferrate; nihcf; cohcf; fehcf; NaMnHCF
32	96	Ni3S2; NiS2; ni; NiCo2S4; sulfide
33	93	F-; Na3V2(PO4); PO4; Na3V(PO4); Na3V2
34	90	sb; Sb2O3; antimonene; antimony; wtc
35	88	NaTi2(PO4); ntp; NaTiOPO4; nasicon-type; NaTi2(PO4)3

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 36–41

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
36	83	sulfide; cobalt; disulfide; copper; sulfur
37	83	SnO2; sno; sn; SnP2O7; snox
38	76	nasicon; Mn2+; nasicon-type; Na4MnV(PO4); Mn3+
39	68	polymer; solid_electrolyte; polyurethane; polymerize; gel
40	68	niobium; active; niobate; titanium-based; titanium
41	67	cop; fep; Ni2P; phosphides; phosphide

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 42–47

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
42	66	Co9S8; CoS2; Co3S4; co; cosx
43	64	MoSe2; WSe2; WTe2; MoTe2; dichalcogenides
44	64	hard; hc; region; plateau; hcs
45	63	aqueous; Na2VTi(PO4); asibs; water-in-salt; Na2SO4
46	61	nzsp; Na3Zr2Si2PO12; glass; nasicon; solid_state
47	58	data; detect; target; estimation; determine

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 48–53

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
48	57	FeSe2; fese; Fe3Se4; Fe7Se8; selenides
49	54	cuo; Co3O4; Cu2O; NiCo2O4; CuCo2O4
50	53	Na3SbS4; all-phraseplaceholderi; Na3PS4; superionic; conductor
51	51	red; rp; phosphorus; GeP5; nrp
52	50	graphene; laser-induced; three-dimensional; gqd; reactor
53	50	nvp; Na3V2(PO4); nvpf; rgo; NVPF1+

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 54–59

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
54	49	bi; bismuth; biocl; Bi2O3; bismuthene
55	49	Fe2O3; Fe3O4; MoO4; Fe-; MnFe2O4
56	48	mxene; carbide; titanium; carbide-mxene; mxene-doped
57	47	portion; terminal; monomer; cap; direction
58	46	pcns; NPCs-; hpcns; nanospheres; CoMn2O4
59	45	VS4; VS2; VSe2; V3S4; Ga2S3

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 60–65

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
60	45	MoO2; MoO3; Mo2C; Mo2N; vg
61	43	hexafluorophosphate; difluorophosphate; imide; bisfluorosulfonimide; fluoride
62	43	cu; Cu2S; Cu9S5; CuSO4; k-sp
63	42	FeF3; Fe2F5; feof; FeF2.2(OH); NaFeF3
64	41	nghms; rgom; graphene; fsg; ppycs
65	41	sulfur; co-doping; sulfur-doped; co-doped; heteroatom

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 66–71

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
66	40	solid_electrolyte; zirconium; conductor; halide; phraseplaceholderj-sodium
67	40	graphyne; adsorption; atom; biphenylene; T-
68	38	snse; SnSe2; se-c; sn-c; nanoplates
69	37	titanium; phosphate; phosphorus-titanium; carbon-coated; graphene-reinforced
70	36	red; phosphorus; phosphorus-carbon; black; carbon-loaded
71	36	mof; mofs; metal-organic; ZIF-; framework

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 72–77

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
72	35	Sn4P3; snxpy; snp; NbOPO4; sbsn
73	35	tank; shaft; drive; barrel; stir
74	35	ge; germanium; Zn2GeO4; Cu3Ge; GeP3
75	33	sulfate; ferrous; heptahydrate; ferric; anhydrous
76	32	Sb2S3; stibnite; Fe2S3; sonochemical; ncrs
77	32	module; supply; pack; flywheel; unit

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

BERTopic chunked: topic 78–83

ID	Tài liệu	Top5 từ khóa xuất trực tiếp
78	32	vanadate; pentoxide; vanadium; metavanadate; calcium
79	32	sn; LaSn3; sn-based; ligament; micro-sn
80	32	phosphorene; bp; blue-p; monolayer; li
81	30	WS2; WO3; WO2; wsse; va
82	30	NaCrO2; Cr2O3; nco; CrO2; Cr6+
83	30	Na2FeSiO4; SO4; NaFeSO4F; orthosilicates; alluaudite

Thứ tự ID gốc. Top10 đầy đủ nằm trong `topic_catalog.csv`. Số tài liệu dùng dominant assignments cho LDA, cluster assignments cho BERTopic.

Nguồn: outputs/bertopic_chunked/topic_summary.csv

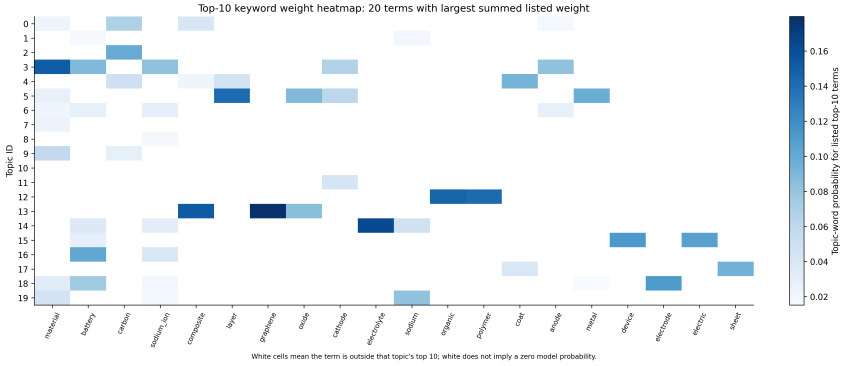
Noise trong hai nhánh BERTopic

Nhánh	ID	Tài liệu	Top5 từ khóa trong noise
Baseline	-1	2.751	sulfide; sulfate; vanadium; phosphate; iron
Chunked	-1	3.120	graphene; sulfide; compound; vanadium; lithium

- Noise chứa tài liệu có mật độ không phù hợp các cụm được chọn.
- Từ khóa của noise chưa tạo thành một chủ đề thống nhất.
- Tăng coherence của inlier đồng thời tăng noise là một đánh đổi cần review.

Nguồn: outputs/tables/stage3/bertopic_topic_summary.csv; outputs/bertopic_chunked/topic_summary.csv

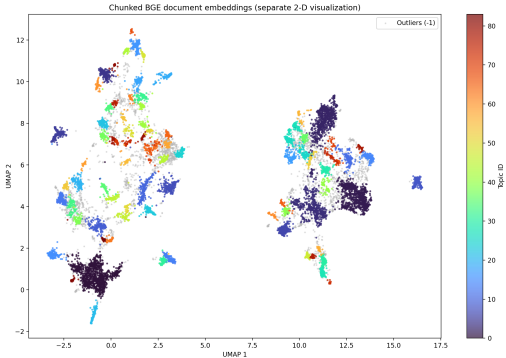
Keyword heatmap của 20 topic LDA



Trọng số topic–word theo model đã chọn. Đây là phân phối từ, khác tần suất từ toàn corpus.

Nguồn: outputs/figures/stage2/lda_06_keyword_heatmap.png

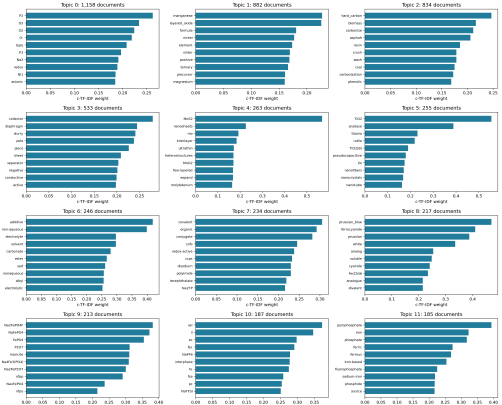
UMAP 2D của biểu diễn chunked



Projection 2D để quan sát. Phân cụm vẫn chạy trên 5 chiều.

Nguồn: outputs/bertopic_chunked/figures/umap_2d.png

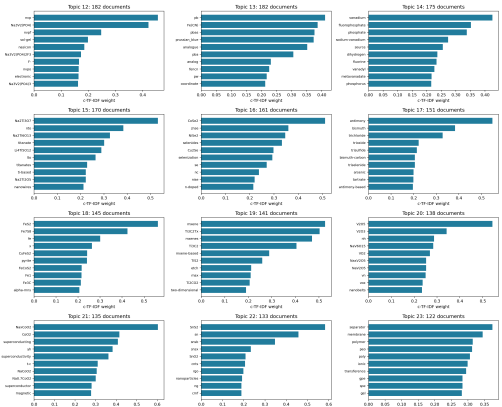
Top10 từ khóa chunked: trang 1/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_01.png

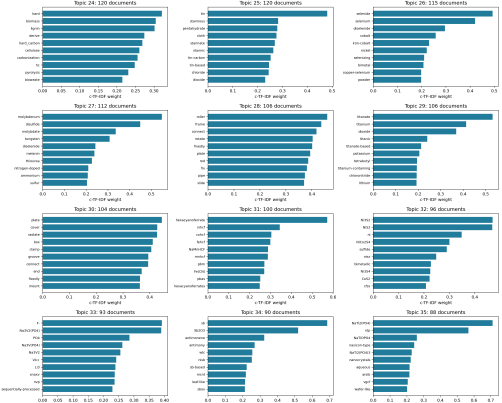
Top10 từ khóa chunked: trang 2/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_02.png

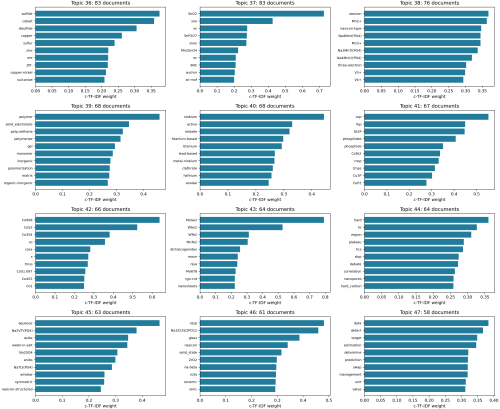
Top10 từ khóa chunked: trang 3/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_03.png

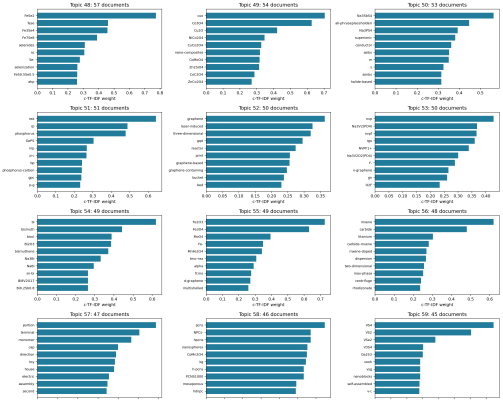
Top10 từ khóa chunked: trang 4/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_04.png

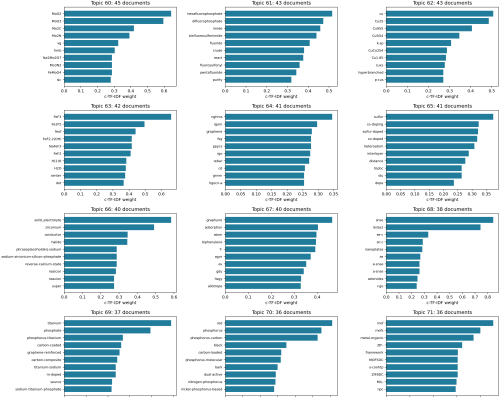
Top10 từ khóa chunked: trang 5/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_05.png

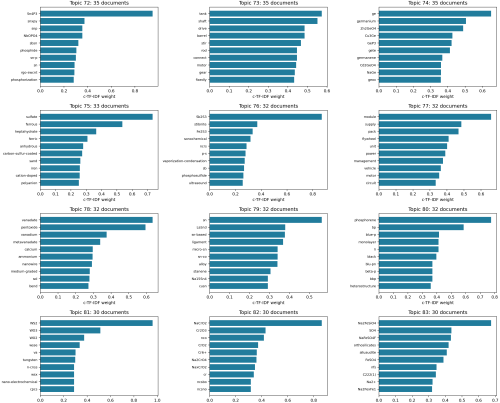
Top10 từ khóa chunked: trang 6/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_06.png

Top10 từ khóa chunked: trang 7/7



Hình gốc từ outputs. Bảy trang hình bao phủ 84 topic, mỗi topic có trọng số c-TF-IDF.

Nguồn: outputs/bertopic_chunked/figures/top10_keywords_07.png